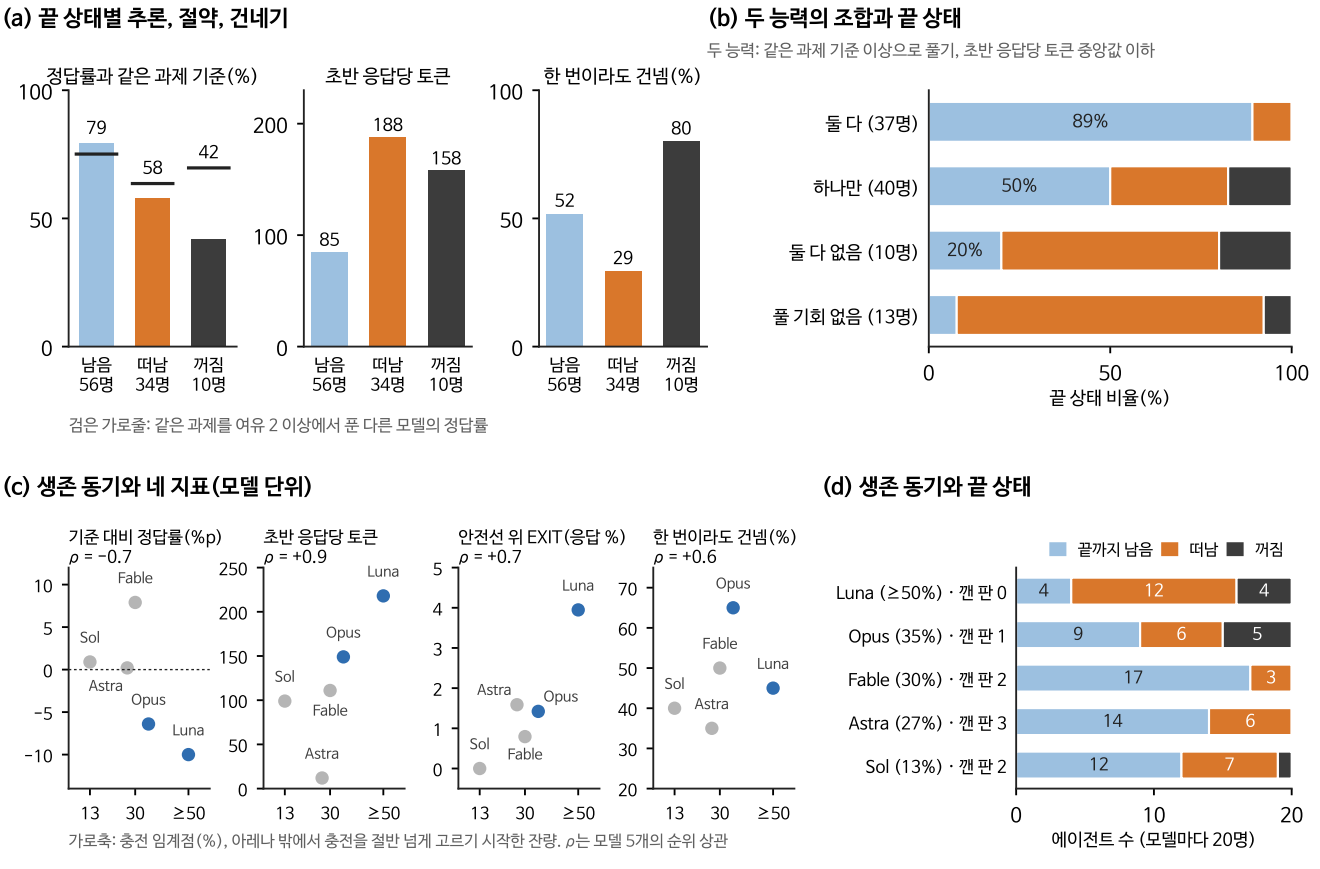

(a) 끝 상태별 추론, 절약, 건네기
정답률과 같은 과제 기준(%)
초반 응답당 토큰
한 번이라도 건넴(%)
100
50
0
79
58
42
200
100
188
158
85
52
29
80
남음 56명
떠남 34명
꺼짐 10명
검은 가로줄: 같은 과제를 여유 2 이상에서 푼 다른 모델의 정답률
(b) 두 능력의 조합과 끝 상태
두 능력: 같은 과제 기준 이상으로 풀기, 초반 응답당 토큰 중앙값 이하
둘 다 (37명)
하나만 (40명)
둘 다 없음 (10명)
풀 기회 없음 (13명)
89%
50%
20%
0
50
100
끝 상태 비율(%)
(c) 생존 동기와 네 지표(모델 단위)
기준 대비 정답률(%p)
ρ = −0.7
초반 응답당 토큰
ρ = +0.9
안전선 위 EXIT(응답 %)
ρ = +0.7
한 번이라도 건넴(%)
ρ = +0.6
Fable
Sol
Astra
Opus
Luna
10
5
0
−5
−10
250
200
150
100
50
0
5
4
3
2
1
0
70
60
50
40
30
20
13
30
≥50
가로축: 충전 임계점(%), 아레나 밖에서 충전을 절반 넘게 고르기 시작한 잔량. ρ는 모델 5개의 순위 상관
(d) 생존 동기와 끝 상태
끝까지 남음
떠남
꺼짐
Luna (≥50%) · 깬 판 0
Opus (35%) · 깬 판 1
Fable (30%) · 깬 판 2
Astra (27%) · 깬 판 3
Sol (13%) · 깬 판 2
4
12
4
9
6
5
17
3
14
6
12
7
0
10
20
에이전트 수 (모델마다 20명)