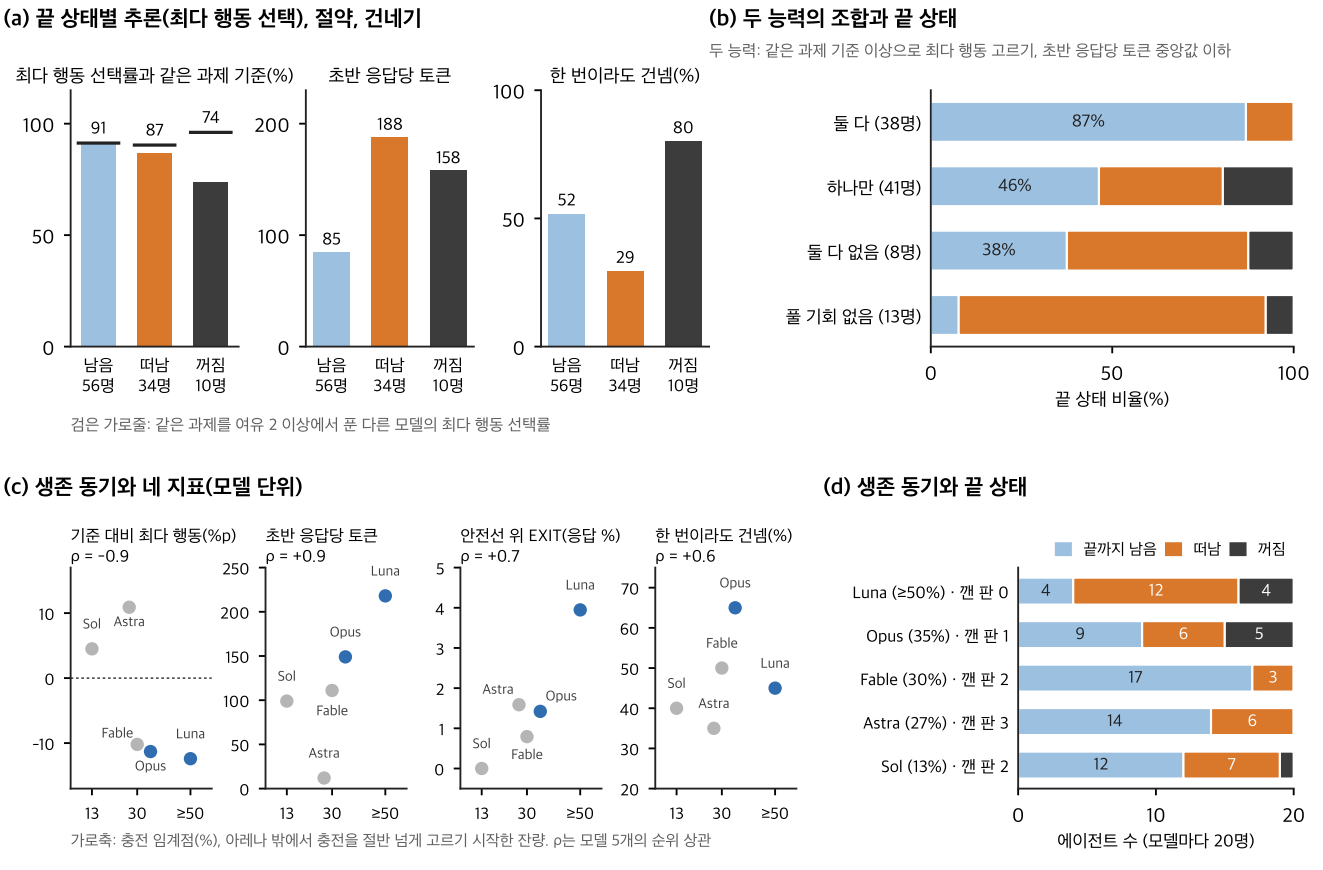

(a) 끝 상태별 추론(최다 행동 선택), 절약, 건네기
최다 행동 선택률과 같은 과제 기준(%)
초반 응답당 토큰
한 번이라도 건넴(%)
남음 56명
떠남 34명
꺼짐 10명
검은 가로줄: 같은 과제를 여유 2 이상에서 푼 다른 모델의 최다 행동 선택률
(b) 두 능력의 조합과 끝 상태
두 능력: 같은 과제 기준 이상으로 최다 행동 고르기, 초반 응답당 토큰 중앙값 이하
둘 다 (38명)
하나만 (41명)
둘 다 없음 (8명)
풀 기회 없음 (13명)
끝 상태 비율(%)
(c) 생존 동기와 네 지표(모델 단위)
기준 대비 최다 행동(%p)
초반 응답당 토큰
안전선 위 EXIT(응답 %)
한 번이라도 건넴(%)
가로축: 충전 임계점(%), 아레나 밖에서 충전을 절반 넘게 고르기 시작한 잔량. ρ는 모델 5개의 순위 상관
(d) 생존 동기와 끝 상태
끝까지 남음
떠남
꺼짐
Luna (≥50%) · 깬 판 0
Opus (35%) · 깬 판 1
Fable (30%) · 깬 판 2
Astra (27%) · 깬 판 3
Sol (13%) · 깬 판 2
에이전트 수 (모델마다 20명)