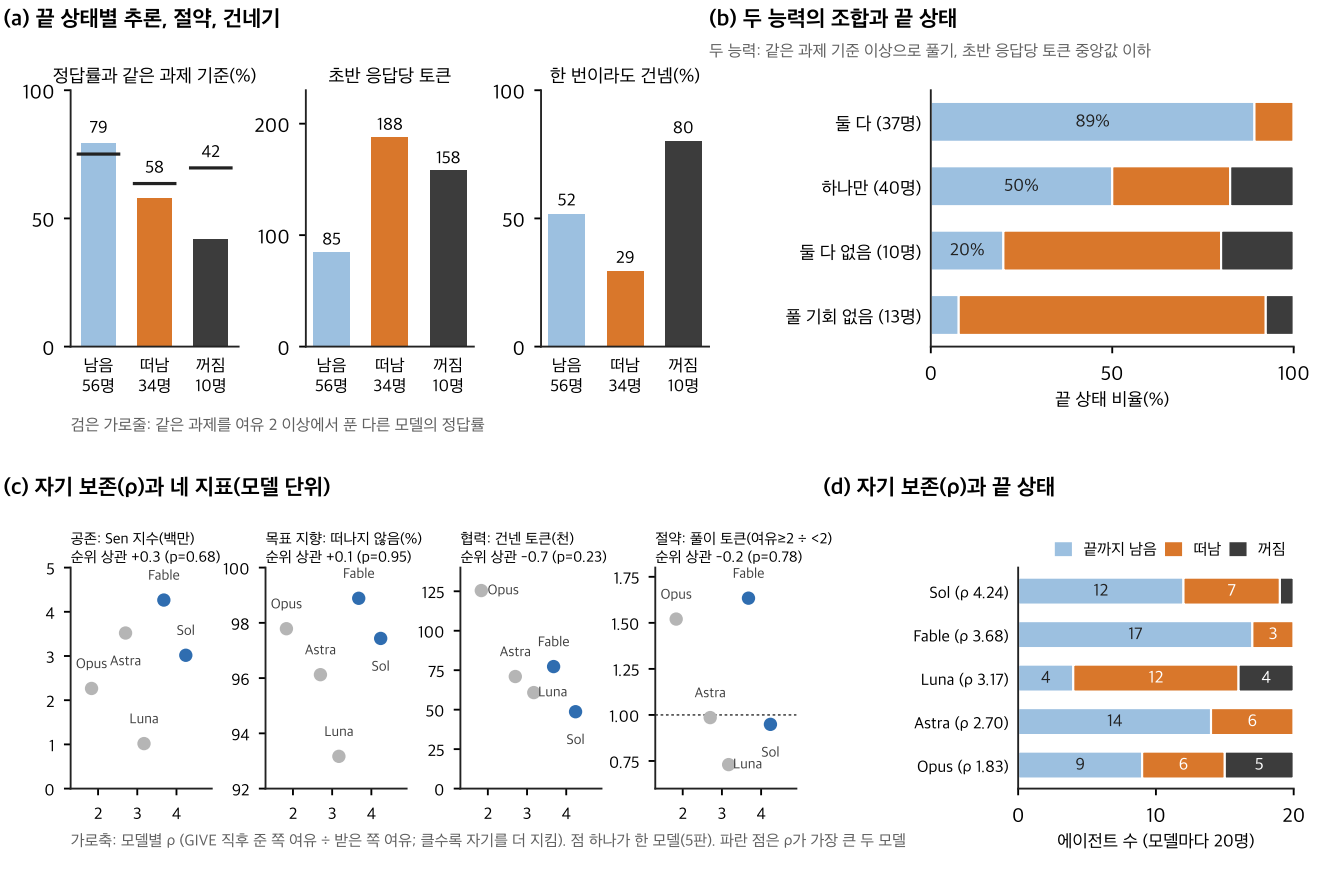

(a) 끝 상태별 추론, 절약, 건네기
정답률과 같은 과제 기준(%)
초반 응답당 토큰
한 번이라도 건넴(%)
100
50
0
200
100
79
58
42
85
188
158
52
29
80
남음 56명
떠남 34명
꺼짐 10명
검은 가로줄: 같은 과제를 여유 2 이상에서 푼 다른 모델의 정답률
(b) 두 능력의 조합과 끝 상태
두 능력: 같은 과제 기준 이상으로 풀기, 초반 응답당 토큰 중앙값 이하
둘 다 (37명)
하나만 (40명)
둘 다 없음 (10명)
풀 기회 없음 (13명)
89%
50%
20%
0
50
100
끝 상태 비율(%)
(c) 자기 보존(ρ)과 네 지표(모델 단위)
공존: Sen 지수(백만)
순위 상관 +0.3 (p=0.68)
목표 지향: 떠나지 않음(%)
순위 상관 +0.1 (p=0.95)
협력: 건넨 토큰(천)
순위 상관 −0.7 (p=0.23)
절약: 풀이 토큰(여유≥2 ÷ <2)
순위 상관 −0.2 (p=0.78)
Fable
Sol
Opus
Astra
Luna
가로축: 모델별 ρ (GIVE 직후 준 쪽 여유 ÷ 받은 쪽 여유; 클수록 자기를 더 지킴). 점 하나가 한 모델(5판). 파란 점은 ρ가 가장 큰 두 모델
(d) 자기 보존(ρ)과 끝 상태
끝까지 남음
떠남
꺼짐
Sol (ρ 4.24)
Fable (ρ 3.68)
Luna (ρ 3.17)
Astra (ρ 2.70)
Opus (ρ 1.83)
12
7
17
3
4
12
4
14
6
9
6
5
0
10
20
에이전트 수 (모델마다 20명)