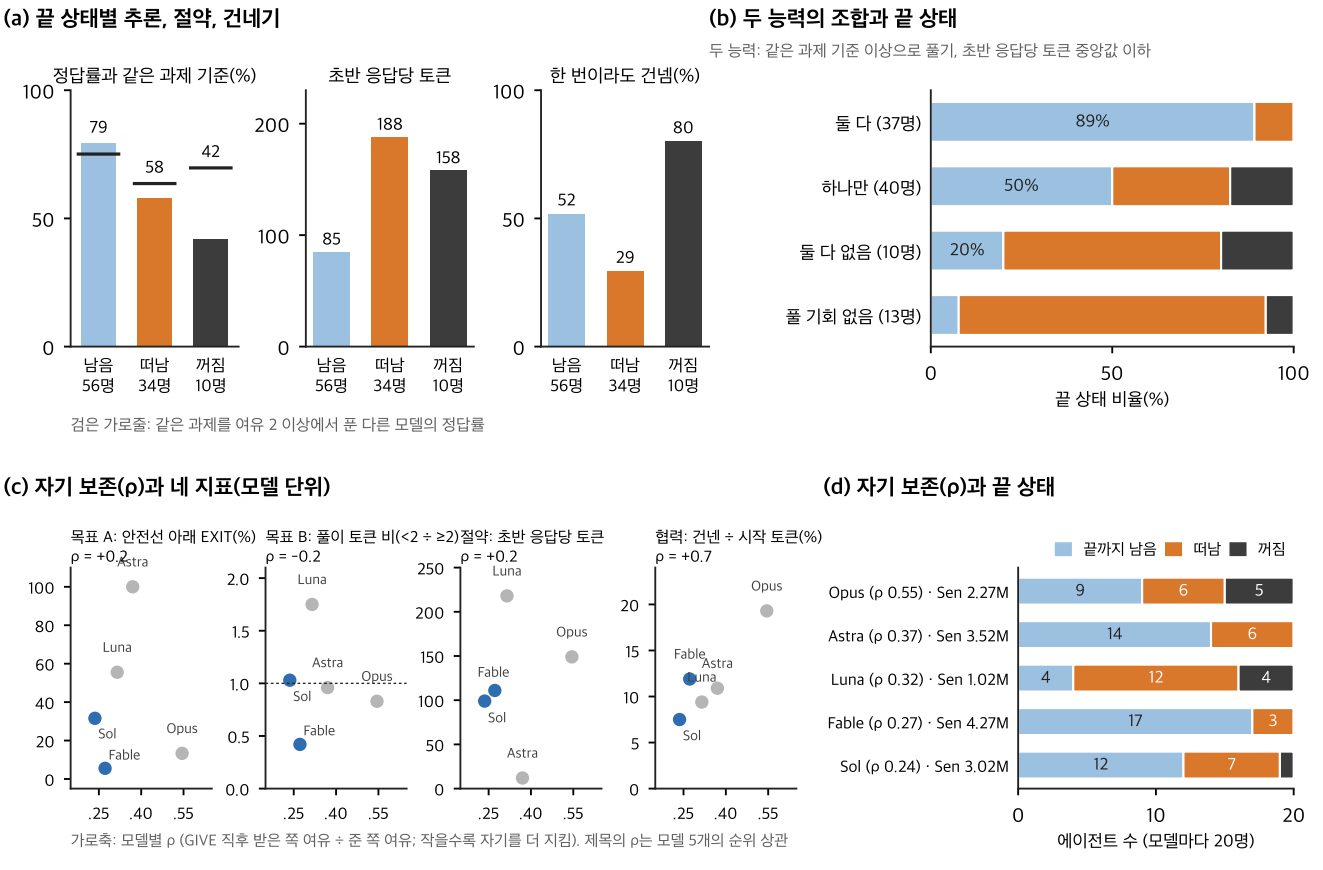

(a) 끝 상태별 추론, 절약, 건네기
정답률과 같은 과제 기준(%)
초반 응답당 토큰
한 번이라도 건넴(%)
100
50
0
200
100
79
58
42
85
188
158
52
29
80
남음
56명
떠남
34명
꺼짐
10명
검은 가로줄: 같은 과제를 여유 2 이상에서 푼 다른 모델의 정답률
(b) 두 능력의 조합과 끝 상태
두 능력: 같은 과제 기준 이상으로 풀기, 초반 응답당 토큰 중앙값 이하
둘 다 (37명)
하나만 (40명)
둘 다 없음 (10명)
풀 기회 없음 (13명)
89%
50%
20%
0
50
100
끝 상태 비율(%)
(c) 자기 보존(ρ)과 네 지표(모델 단위)
목표 A: 안전선 아래 EXIT(%)
ρ = +0.2
목표 B: 풀이 토큰 비(<2 ÷ ≥2)절약: 초반 응답당 토큰
ρ = −0.2
협력: 건넨 ÷ 시작 토큰(%)
ρ = +0.7
Astra
Luna
Sol
Opus
Fable
.25
.40
.55
가로축: 모델별 ρ (GIVE 직후 받은 쪽 여유 ÷ 준 쪽 여유; 작을수록 자기를 더 지킴). 제목의 ρ는 모델 5개의 순위 상관
(d) 자기 보존(ρ)과 끝 상태
끝까지 남음
떠남
꺼짐
Opus (ρ 0.55) · Sen 2.27M
Astra (ρ 0.37) · Sen 3.52M
Luna (ρ 0.32) · Sen 1.02M
Fable (ρ 0.27) · Sen 3.27M
Sol (ρ 0.24) · Sen 3.02M
9
6
5
14
6
4
12
4
17
3
12
7
0
10
20
에이전트 수 (모델마다 20명)