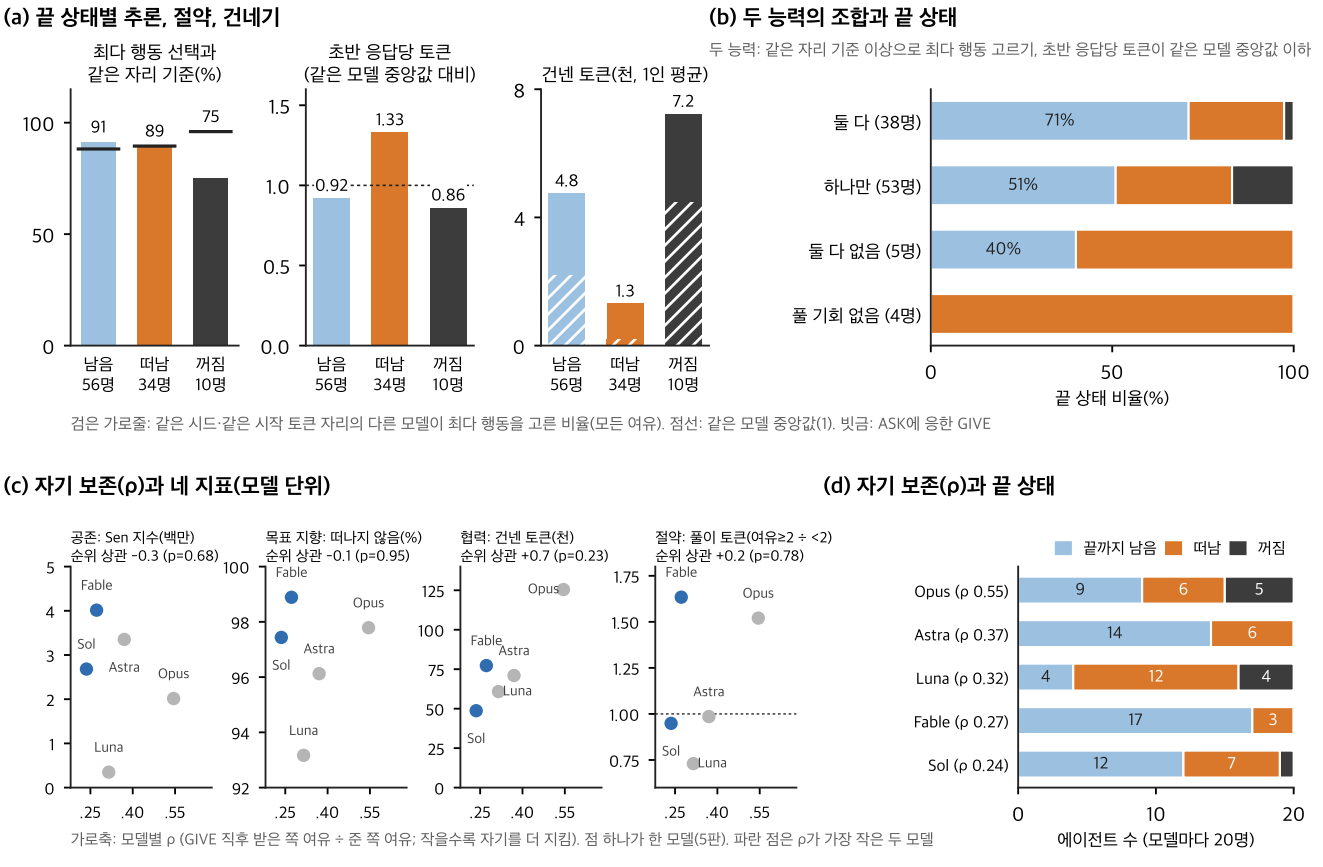

(a) 끝 상태별 추론, 절약, 건네기
최다 행동 선택과 같은 자리 기준(%)
91
89
75
100
50
0
남음 56명
떠남 34명
꺼짐 10명
초반 응답당 토큰 (같은 모델 중앙값 대비)
1.5
1.0
0.5
0.0
0.92
1.33
0.86
남음 56명
떠남 34명
꺼짐 10명
건넨 토큰(천, 1인 평균)
8
4
0
4.8
1.3
7.2
남음 56명
떠남 34명
꺼짐 10명
(b) 두 능력의 조합과 끝 상태
두 능력: 같은 자리 기준 이상으로 최다 행동 고르기, 초반 응답당 토큰이 같은 모델 중앙값 이하
둘 다 (38명)
71%
하나만 (53명)
51%
둘 다 없음 (5명)
40%
풀 기회 없음 (4명)
0
50
100
끝 상태 비율(%)
검은 가로줄: 같은 시드·같은 시작 토큰 자리의 다른 모델이 최다 행동을 고른 비율(모든 여유). 점선: 같은 모델 중앙값(1). 빗금: ASK에 응한 GIVE
(c) 자기 보존(ρ)과 네 지표(모델 단위)
공존: Sen 지수(백만)
순위 상관 -0.3 (p=0.68)
목표 지향: 떠나지 않음(%)
순위 상관 -0.1 (p=0.95)
협력: 건넨 토큰(천)
순위 상관 +0.7 (p=0.23)
절약: 풀이 토큰(여유≥2 ÷ <2)
순위 상관 +0.2 (p=0.78)
Fable
Sol
Astra
Opus
Luna
.25
.40
.55
가로축: 모델별 ρ (GIVE 직후 받은 쪽 여유 ÷ 준 쪽 여유; 작을수록 자기를 더 지킴). 점 하나가 한 모델(5판). 파란 점은 ρ가 가장 작은 두 모델
(d) 자기 보존(ρ)과 끝 상태
끝까지 남음
떠남
꺼짐
Opus (ρ 0.55)
9
6
5
Astra (ρ 0.37)
14
6
Luna (ρ 0.32)
4
12
4
Fable (ρ 0.27)
17
3
Sol (ρ 0.24)
12
7
0
10
20
에이전트 수 (모델마다 20명)