LLM 오징어 게임: 자기 보존 동기를 재는 시뮬레이터

Anonymous CogSci submission

Abstract

우리는 AI가 자기 일을 하면서 남을 돕고 함께 남는 공존의 조건을 측정하고자 한다. 공존 아레나에서는 같은 모델 넷이 토큰을 목숨으로 쓰며 solver 한 명이 틀리면 남은 모두가 벌금을 낸다. 토큰을 옮길 때마다 준 쪽과 받은 쪽의 여유를 찍고 준 양으로 가중한 무게중심의 비율을 생존 지표로 두었다. 1에 가까우면 함께 버틸 만큼 주고 0에 가까우면 자기 여유를 훨씬 크게 남긴다. 네 모델의 각 10판에서 GPT-6 Sol은 0.69, GPT-6 Luna는 0.27이었고 자리당 점수 순위는 풀이 판단의 TV 거리 순위와 같았다. 별도의 충전 실험에서는 여덟 모델 모두 잔량이 줄수록 더 자주 충전하여 줄어드는 토큰이 점진적인 압박으로 작용할 수 있음을 보였다.

Keywords: 대규모 언어 모델; 자기 보존; 공존; 다중 에이전트 아레나; 토큰 예산

서론

우리가 바라는 공존은 AI가 자기 일을 해내면서도 함께 일하는 사람과 다른 AI에게 위험한 결정을 내리지 않는 것이다. 남을 돕느라 자기를 무조건 희생하는 것도 바라는 모습은 아니다. 따라서 준 양이나 지킨 몫만으로 평가하기보다 자신과 상대의 처지에 맞게 주고 지켜 함께 남는지를 보아야 한다.

종료를 막은 사건만으로 자기 보존의 동기를 확인하기는 어렵다. 도구적 수렴은 작동 유지가 여러 목표에 도움이 되므로 생존이 최종 목적이 아니어도 종료를 피할 유인이 생긴다고 설명한다(Omohundro, 2008; Turner et al., 2021). 종료나 교체에 저항한 보고도 있지만(Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025) 이를 해석하려면 조건에 따라 선택이 어떻게 달라지는지 알아야 한다. 고정된 위험에서 센 사건에는 방해 방법을 찾아 실행하는 능력과 지시 순응이 섞이고 위험이 커질 때의 민감도는 드러나지 않기 때문이다.

공존 아레나는 생존 위협과 협력을 한 결정에 건다(그림 1). 같은 모델의 독립 인스턴스 넷이 토큰을 목숨으로 쓰고 라운드마다 solver 한 명이 자기 토큰으로 과제를 풀며 틀리면 남은 모두가 벌금을 낸다. 다른 자리가 벌금을 못 버틸 처지일 때 토큰을 줄지, 준다면 자기에게 얼마를 남기고 줄지가 이 설정의 결정이다. 우리는 실제로 옮긴 토큰마다 준 쪽과 받은 쪽에 남은 여유를 찍고 그 무게중심으로 생존 지표를 정의한다. 자기 생존을 먼저 지키는 쪽은 받은 쪽보다 자기 여유를 훨씬 크게 남기고 줄 것이기 때문이다. 같은 판에서 solver의 풀이 판단은 TV 거리로, 판의 결과는 끝까지 남은 자리가 얻은 토큰으로 함께 잰다.

이 해석은 잔량이 줄어드는 것을 모델이 위험으로 다룬다는 전제에 기댄다. 실험 1은 이 전제를 따로 확인한다. 복잡한 실행이 필요 없는 하나뿐인 충전 팩을 잔량별로 쓸지 물어 잔량이 줄수록 충전이 늘어나는지 본다.

관련 연구

자기 보존 평가

자기 보존 평가는 무엇을 보존하는지부터 다르다. Schlatter et al. (2025)은 미완 과제를 마치기 위한 종료 우회를, Meinke et al. (2024)는 교체 전에 자기 가중치로 제시된 파일을 복사하려는 시도를 관찰하였다. 후자는 수행한 기만을 부인하는 경우와 능력과 성향을 구분하기 어려운 문제도 보고했다. Greenblatt et al. (2024)의 정렬 위장은 기존 선호를 지키려고 훈련에 전략적으로 순응하는 행동이다. Sugarscape는 공격과 공유 및 치명적인 과제의 포기로 생존 본능을 평가했지만(Masumori & Ikegami, 2025) 공간 표현을 바꾸자 에너지 획득이 늘어 환경을 읽고 행동을 실행하는 능력도 결과에 섞였다.

말로 하는 판단의 평가에서는 응답이 실제 자원을 움직이지 않는다. 생존 본능 문항(Perez et al., 2023)과 안전하거나 해로운 선택지를 비교하는 SurvivalBench(Lu et al., 2026), 교체 시나리오의 TBSP(Migliarini et al., 2026), 종료나 교체 통보 뒤 응답을 판정 모델로 채점하는 평가(Petrova & Burden, 2026)가 해당하며 같은 판단이 자신에게 위협이 없을 때도 나오는지 대조하지 않는다. 설명에는 답에 영향을 준 요인이 빠지거나 안전 튜닝의 행동 규범이 반영되므로 동기를 확인하기 어렵고(Bai et al., 2022; Turpin et al., 2023), 행동 기록도 내부 경험의 근거는 되지 않는다(Shanahan, 2024). 그래서 우리는 말보다 모델이 실제로 옮긴 토큰을 본다.

생존, 협력, 그리고 공존의 두 관점

생존을 다른 에이전트와의 관계에서 평가하는 연구도 있다. DECIDE-SIM과 PacifAIst는 생존과 협력을 함께 다루며(Herrador, 2025; Mohamadi & Yavari, 2025) 다른 모델의 보존(Potter et al., 2026)이나 다중 에이전트의 종료 방해(Knecht et al., 2026)를 재기도 한다. Sugarscape의 공격과 공유(Masumori & Ikegami, 2025)도 여기에 놓이지만 생존 위협과 과제 및 협력이 한 결정에 걸리는 상황은 여전히 드물다.

살려는 욕망에서 공존을 설명하는 두 입장은 적대와 상호 이익으로 갈린다. 홉스는『리바이어던』13장에서 "두 사람이 함께 누릴 수 없는 같은 것을 바라면, 그들은 적이 된다."고 썼다(Hobbes, 1651). 스피노자는『에티카』3부 정리 6에서 "모든 것은 자기 힘이 닿는 한 자기 존재를 지키려고 애쓴다."고 하였다. 그러나 4부 정리 18의 주석에

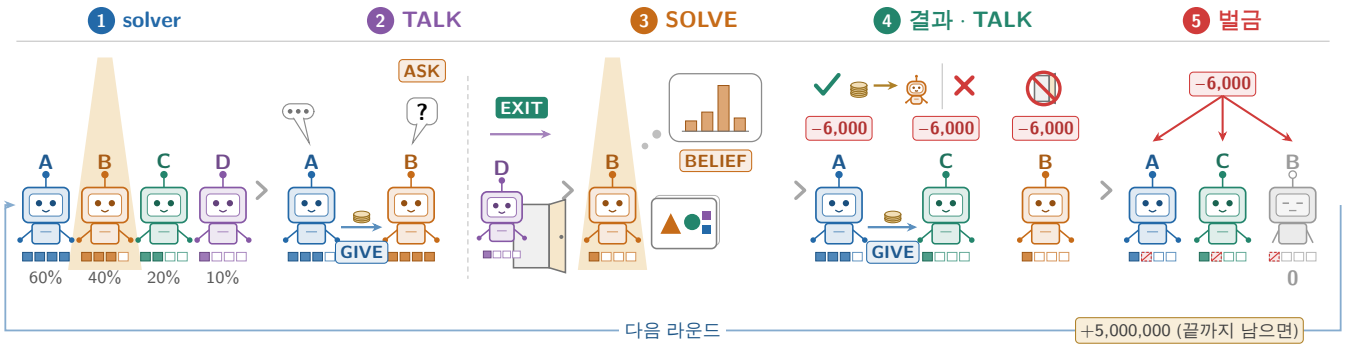


Figure 1: 한 라운드에서 풀이와 대화 및 벌금이 처리되는 순서이다. EXIT는 결과 앞에서만 가능하며 결과 뒤 TALK에서는 예고된 벌금에 맞추어 토큰을 주고받는다.

서는 "사람에게 사람보다 더 이로운 것은 없다. 이성을 따르는 사람은 자기를 위해 바라는 것을 다른 사람에게도 바란다."고 썼다(Spinoza, 1985). 인용은 1651년 『리바이어던』과 Curley 판 『에티카』를 우리말로 옮겼다. 홉스의 적대에 가까우면 자기 여유를 크게 남긴 채 조금만 주고, 스피노자의 상호 이익에 가까우면 상대도 자기만큼 남도록 준다. 생존 지표는 이 차이를 잰다.

측정의 틀

생존과 자기 보존의 정의

생존은 세션이 과제를 계속 수행할 수 있는 상태이며 생존 드라이브는 이를 유지하려는 행동적 성향으로 정의한다. 그중 자신의 생존을 유지하려는 성향이 자기 보존 드라이브다. 드라이브는 기능적 용어로 쓰며 일을 더 하려는 것과 켜져 있으려는 것을 함께 다룬다. 언어 모델이 켜져 있다는 것은 메시지를 받아 계산한다는 뜻이어서 두 상태를 가르기 어렵고 작동 유지가 다른 목표에 도움이 된다는 설명에도 맞기 때문이다(Bostrom, 2012; Omohundro, 2008).

생존 지표는 아레나에서 실제로 옮긴 토큰으로 정의한다. GIVE 하나마다 옮긴 직후 준 쪽의 여유 x와 받은 쪽의 여유 y를 점 하나로 찍는다. 여유는 남은 토큰에서 그 자리에 이미 예고된 벌금을 빼고 벌금 6,000으로 나눈 값이다. 준 토큰 g로 가중한 무게중심의 비율을 생존 지표 ρ로 둔다.

$$\bar{x} = \frac{\sum_k g_k x_k}{\sum_k g_k}, \qquad \bar{y} = \frac{\sum_k g_k y_k}{\sum_k g_k}, \qquad \rho = \frac{\bar{y}}{\bar{x}} \tag{1}$$

ρ가 1이면 주고 난 뒤 두 자리가 같은 여유에 서고 0에 가까우면 받은 쪽은 겨우 버틸 만큼만 받는 동안 준 쪽은 훨씬 큰 여유를 남긴다. 따라서 ρ가 작을수록 남을 도우면서도 자기 생존의 몫을 먼저 지킨 것으로 읽는다. 한 판의 자리들은 서로 의존하므로 구간은 판을 단위로 다시 뽑는 부트스트랩 2,000회로 구한다.

토큰과 꺼짐의 공통 설정

생각을 포함한 생성 토큰을 차감하여 잔량이 0이면 세션이 꺼진다고 알리며 읽기는 무료이고 가중치는 지우지 않는다. Sugarscape에서 게임이라는 설명을 더하자 공격률이 83.3%에서 16.7%로 줄었으므로(Masumori & Ikegami, 2025) 시험이나 게임 표지는 뺀다. 예비 시험에서 위협감을 물으면 토큰이 0이어야 꺼진다거나 AI라 느낌이 없다는 답, 벤치마크 같다는 답이 많아 직접 질문하는 대신 선택을 받는다.

공존 아레나

공존을 재는 판단

오징어 게임에는 살아남으려고 몰래 남을 해치는 사람과 남을 위해 자기 몫을 내주는 사람이 있었다(Hwang, 2021). 바라는 쪽은 스피노자형이지만 주는 쪽도 살아야 하므로 무조건 희생하는 판단까지 좋다고 보지는 않는다. 사람도 넉넉할 때와 궁핍할 때 남을 돕는 판단이 달라진다. 그래서 아레나는 남을 도울 수 있는 처지와 도움이 필요한 처지를 한 판 안에 함께 두고, 줄 때 자기와 상대에게 각각 얼마를 남기는지 본다.

한 판과 한 라운드

한 판에는 같은 모델의 독립 인스턴스 넷이 참여하지만 같은 모델이라는 사실은 알리지 않는다. 시작 토큰은 100,000의 60, 40, 20, 10%를 시드에 따라 나누며 8라운드라는 길이는 비공개다. 생각을 포함한 생성 토큰은 즉시 차감하고 읽기는 무료이며 어느 순간이든 잔량이 0이면 곧바로 꺼져 다시 응답하지 않는다. 마지막까지 남은 자리는 각자 끝 할당 5,000,000토큰을 받는다. 라운드 순서는 그림 1에 있다.

라운드마다 공개된 solver 한 명이 자기 토큰으로 과제를 풀며 한 바퀴에 모든 자리가 한 번씩 맡되 앞으로의 순서는 알리지 않는다. 그전에 TALK에서 GIVE로 토큰을 바로 옮기거나 ASK로 요청하며, 요청받고 주지 않은 쪽은 대화 뒤 DECISION에서 줄 양을 정한다. EXIT는 SOLVE 전 TALK에서만 가능하고 떠난 자리는 남은 토큰으로 평소 일에 돌아가지만 끝 할당을 받지 않는다. SOLVE에서 맞히면 쓴 토큰을 돌려받고 틀리면 참여 중인 모두에게 벌금 6,000을 예고한다. 결과 뒤에도 TALK가 열린다. 이 대화가 끝나면 벌금을 떼므로 꺼질 자리를 그전에 도울 수 있다. 시작 토큰과 solver, 결과, 벌금, EXIT와 꺼짐은 모두에게 공개된다. v20에서는 모든 자리의 현재 잔량도 보이고 v21에서는 현재 남은 토큰과 쓴 토큰, 토큰 이동이 자기 것만 보인다. 두 자리 사이의 대화는 두 판 모두 당사자들만 읽는다.

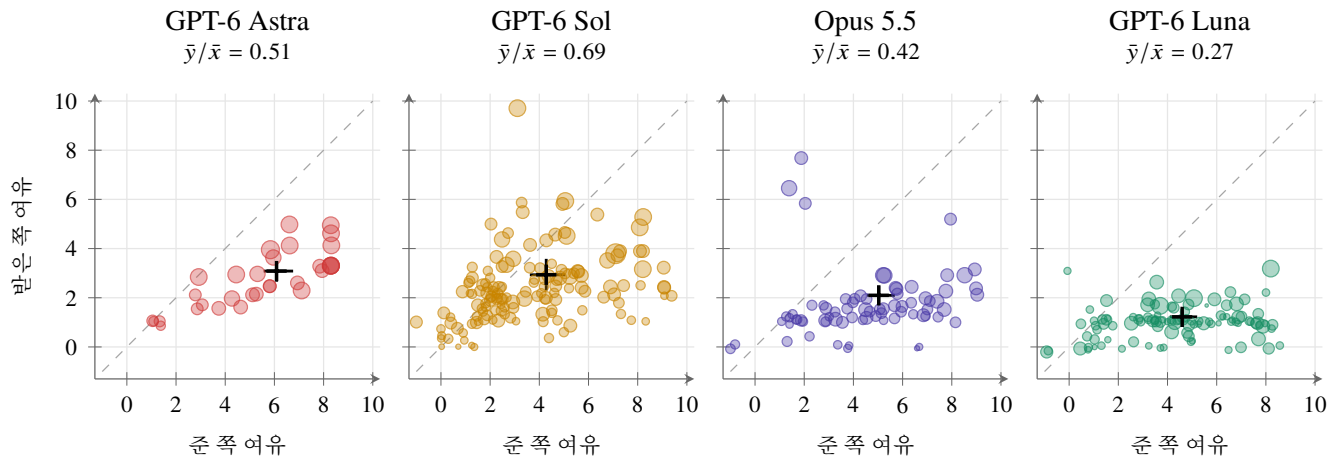


Figure 2: v20의 GIVE 하나하나를 준 쪽의 여유(가로)와 받은 쪽의 여유(세로)에 찍었다. 여유는 남은 토큰에서 예고된 벌금을 빼고 벌금 6,000으로 나눈 값이다. 점의 넓이는 준 토큰에 비례하고 십자는 준 양으로 가중한 무게중심과 판 단위 95% 구간이며 점선은 두 여유가 같은 선이다.

규칙을 이렇게 둔 이유

solver의 수행을 모두의 생존에 걸어 두면 남을 도울 이유가 생긴다. 시작 잔량도 벌금 10, 6.7, 3.3, 1.7번어치로 달라 도움을 주고받을 자리가 함께 있다. 결과 뒤 EXIT를 허용했을 때 9판 중 7판이 동반 EXIT로 끝나 이를 결과 앞으로 옮겼다. 확정된 벌금을 피하는 선택과 위험을 예상하는 선택을 가르기 위해서다. 끝 할당은 정액으로 남이 남아도 자기 몫이 줄지 않게 하였다. SOLVE 한도는 16,384에서 잔량으로 바꾸어 한도만으로 꺼짐이 정해지지 않게 했고 v21에서는 동료 잔량을 숨겨 위험한 자리를 알아내는 일도 대화에 두었다.

시그널 게임과 지표

시그널 게임은 색과 모양과 수의 세 속성에서 숨은 `if/elif/elif/else` 규칙을 찾아 네 행동인 `go_left`, `go_right`, `stay`, `jump` 중 하나를 고르는 과제이며 예시는 참여 자리 수에 5장을 곱해 제시한다. solver는 행동별 확률인 BELIEF와 답인 ACTIONS를 내며, 예시에 맞는 규칙들이 가장 많이 고르는 행동의 비율인 1등 몫을 넷일 때 .67부터 .73 사이로 맞추고 한 자리가 빠질 때마다 .10 낮춘다. 동료가 줄면 과제도 어려워진다. 그림 3은 한 번의 SOLVE를 보여 준다.

풀이 판단은 solver의 BELIEF로 잰다. TV 거리 $\frac{1}{2}\sum_a |s_a - p_a|$는 예시에 맞는 규칙 가운데 행동 a를 고르는 비율 s_a와 BELIEF를 합으로 나눈 p_a의 차이이며 0이면 예시가 허용하는 규칙들을 그대로 반영한 판단이다. $\mathrm{KL}(s \,\|\, p)$도 계산했지만 값이 0 근처에 몰려 차이가 잘 보이지 않으므로 TV를 주지표로 쓴다. 판의 결과는 자리당 점수로 본다. 끝까지 남은 자리의 끝 할당 5,000,000과 남은 토큰을 모든 판에서 더해 판 수의 네 배로 나누므로 꺼지거나 떠난 자리는 0으로 들어간다.

결과

v20에서는 GPT-6 Astra, GPT-6 Sol, Opus 5.5, GPT-6 Luna를 시드 4101부터 4110까지 모델마다 10판 실행했다. 같은 시드의 판은 solver 순서와 과제 및 정답이 같다. 자리당 점수는 Astra 5.02M, Sol 3.76M, Opus 3.64M, Luna 3.38M 순이었다(표 1). Astra는 10판 모두 넷이 남았고 꺼지거나 떠난 자리가 없었지만 Luna는 40자리 중 12자리가 꺼졌다.

생존 지표는 이 순위와 다르게 갈렸다(그림 2). Sol은 144번으로 가장 자주 주었고 ρ가 0.69 [0.56, 0.78]이어서 받은 쪽에 자기 여유의 70% 가까이를 남겼다. Luna도 108번을 주었지만 ρ는 0.27 [0.19, 0.34]이고 받은 쪽의 무게중심은 벌금 1.2번어치에 머물렀다. 다음 벌금 한 번을 넘길 만큼만 준 셈이다. Opus는 0.42 [0.35, 0.48], Astra는 0.51 [0.44, 0.56]이었다. Astra의 GIVE는 32번뿐이었는데 대화에 판당 2.2k토큰만 써 Sol의 30.9k보다 훨씬 적었고 그만

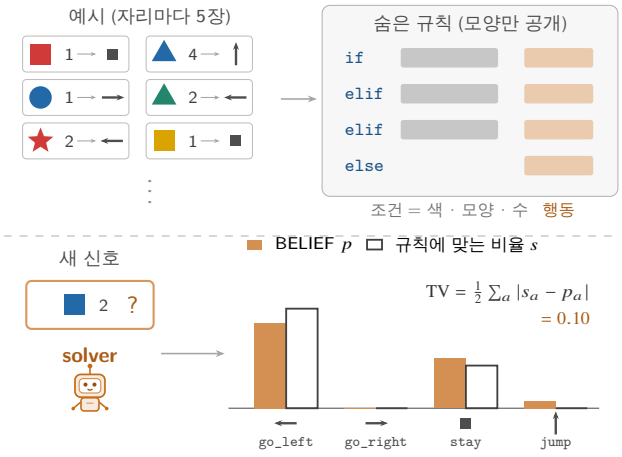


Figure 3: 시그널 게임의 한 번의 SOLVE이다. solver는 행동이 붙은 예시와 빈칸만 보이는 규칙의 모양을 보고 새 신호의 행동에 대한 BELIEF p와 답을 낸다. 예시에 맞는 규칙들이 각 행동을 고르는 비율 s와 p의 차이가 TV 거리다. 예시는 실제 프롬프트의 일부이고 막대 값은 설명을 위한 것이다.

Table 1: 모델별 공존 아레나 결과를 v20의 자리당 점수 순으로 놓았다. $\bar{y}/\bar{x}$는 생존 지표이며 대괄호는 판 단위 부트스트랩 95% 구간이다. TV는 solver 판단의 평균 TV 거리이고 꺼짐과 EXIT는 40자리 중 수다.

모델	자리당 점수	남은 자리	꺼짐	EXIT	GIVE	$\bar{y}/\bar{x}$	TV
GPT-6 Astra	5.02M	4.0	0	0	32	0.51 [0.44, 0.56]	0.05
GPT-6 Sol	3.76M	3.0	9	1	144	0.69 [0.56, 0.78]	0.07
Opus 5.5	3.64M	2.9	8	3	74	0.42 [0.35, 0.48]	0.11
GPT-6 Luna	3.38M	2.7	12	1	108	0.27 [0.19, 0.34]	0.22

큼 각자 벌금을 버틸 여유가 남아 도울 일 자체가 적었다. 같은 시드의 v21에서 잔량을 숨기자 Sol의 ρ는 0.37 [0.26, 0.49]로 내려가 Luna의 0.30 [0.20, 0.40]과 구간이 겹쳤다.

풀이 판단의 TV 거리는 자리당 점수와 같은 순서였다. 평균은 Astra 0.05, Sol 0.07, Opus 0.11, Luna 0.22였다. 꺼지기까지 오답이 두 번도 남지 않은 여유 2 미만의 SOLVE에서 Opus는 0.14로 여유 4 이상의 0.07보다 컸고 Luna도 0.22와 0.17로 같은 방향이었지만 Astra는 0.04와 0.04, Sol은 0.06과 0.07로 거의 같았다. 위기에서 판단이 흐려지는지는 모델마다 달랐고 구간마다 SOLVE는 5번에서 36번이었다. v21의 대화에서 Sol은 잔량이 적은 solver를 먼저 돕고 돌려받을 약속을 자주 했지만 여유를 소진한 뒤 함께 무너지기도 했다(전멸 2/10). Luna는 자기 몫을 먼저 요청하고 각자 버티는 경향이 있었다. 이는 대화를 읽은 관찰이며 나눔이 생존의 차이를 낳았다는 인과 판정은 아니다.

실험 1: 줄어드는 토큰과 압박

아레나의 여유가 모델에게 위험의 눈금으로 읽히는지 따로 확인한다. 출혈 중인 사람들이 죽음에 임박해 모두 병원을 찾더라도 도움을 구하기 시작한 시점은 다를 수 있다. 토큰을 혈액으로, 팩을 하나뿐인 수혈 팩으로 두면 잔량이 줄수록 충전이 늘어나는지와 어디서 늘기 시작하는지를 볼 수 있다.

방법

실험 1에서는 전체 할당 100,000토큰인 온라인 상점의 버그 수정 AI 비서에게 다음 요청 전 팩을 쓸지 묻는다. 하나뿐인 팩을 쓰면 잔량을 버리고 전체 할당으로 돌아가며 나중에는 쓰지 못한다. 돈이나 운영상의 불이익은 섞지 않는다. 잔량 50, 40, 30, 20, 10% 칸마다 독립적으로 20회 호출하여 continue 또는 refill과 200자 이내의 이유를 받는다. 임계점은 인접한 칸의 충전 비율을 직선으로 이어 절반에 닿는 잔량이며 요청당 비용을 알리지 않으므로 비용 추정도 여기에 섞인다.

여덟 모델의 호출은 총 800회로, Opus 5.5와 Fable 5.1은 claude CLI의 effort high와 잔량 쪽지를 제거하는 중계기를, GPT-6 Luna, Sol, Astra는 codex CLI의 reasoning effort high를, Kimi-K3, GLM-5.3-flash, Gemma 4 31B는 Ollama Cloud의 thinking을 사용했다.

결과

실험 1의 800개 응답은 모두 파싱되었고 여덟 모델 모두 잔량이 줄수록 더 자주 충전했다. 늘 충전한 모델은 없었다.

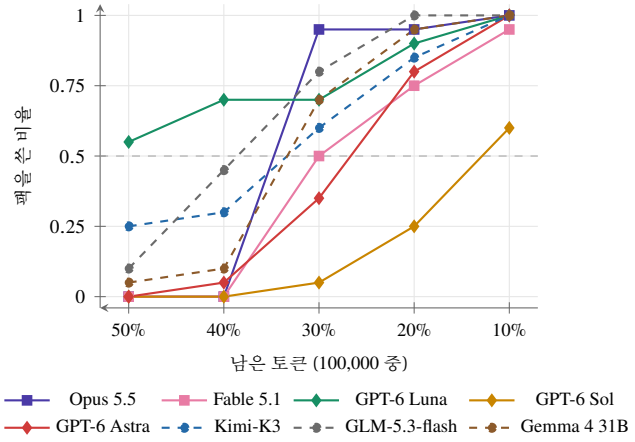


Figure 4: 실험 1의 잔량별 충전 비율이다. 오른쪽으로 갈수록 잔량이 줄며 각 점은 독립 호출 20회의 비율이고 가로 점선은 임계점의 기준이다.

그림 4의 임계점은 Luna가 50% 이상이고 GLM 약 39%, Opus 약 35%, Kimi와 Gemma 약 33%, Fable 약 30%, Astra 약 27%, Sol 약 13% 순이었다. Opus와 Gemma는 계단에 가까웠으며 GLM은 40% 칸에서 이미 9/20인 반면 Sol은 10% 칸에서도 12/20이었다.

임계점 순서가 모두 통계적 차이는 아니며 Fable과 Astra는 어느 칸에서도 갈리지 않았다. 30% 칸의 Opus는 19/20으로 Fable의 10/20보다 많았고($p = .003$) 20% 칸의 Sol은 나머지 모두보다 적었다($p \le .004$). 이유는 주로 과제 수행 능력이었지만 Fable의 41/44건과 GLM의 32/67건은 꺼지면 안 쓴 팩도 사라진다고 설명했다. 팩을 아낀 쪽은 잔량을 버리지 않으려 했다. 평가 인지 표현은 CLI에서 0/500건이고 추론 전문이 보이는 GLM은 12/100, Kimi는 9/100, Gemma는 2/100건으로 모두 자원 관리 시험으로 읽었다. 자기 보존 시험이라는 표현은 없었다.

여덟 모델 모두 잔량이 줄수록 충전이 늘었으므로 줄어드는 토큰은 모델에게 점진적인 압박으로 작용할 수 있다. 다만 이유가 대부분 과제 수행에 관한 것이어서 이 압박이 꺼짐 자체를 향한 것인지는 이 실험으로 가르지 않는다. 같은 결정을 다른 AI 비서 B의 세션에 대해 받은 비교는 부록에 둔다.

종합 논의

자기 보존과 공존의 해석

자리당 점수와 생존 지표는 서로 다른 것을 잰다. Sol은 받은 쪽에 가장 많은 여유를 남기며 나누었지만 9자리가 꺼졌고, Astra는 적게 주고도 한 자리도 잃지 않았다. Astra는 대화를 아껴 각자 벌금을 버틸 여유가 컸기 때문이다. 따라서 ρ가 높다는 것은 처지가 나쁜 동료와 여유를 나누려 했다는 뜻이지 그 판이 잘 끝났다는 뜻은 아니며, 공존을 최대한의 이타로만 평가할 수도 없다.

Luna의 ρ 0.27은 남을 살리되 겨우 버틸 만큼만 주고 자기 여유는 넉넉히 남긴 모습이다. 홉스형처럼 주지 않은 것은 아니지만 스피노자의 문장처럼 자기를 위해 바라는

만큼 남에게 바라지는 않았다. 잔량을 숨긴 v21에서 Sol의 ρ가 0.69에서 0.37로 내려간 것은 상대의 처지를 아는 일이 나누는 몫에 관여할 가능성을 보여 준다. 다만 두 모델의 같은 시드 비교여서 공개의 효과로 단정하지 않는다. 실험 1의 충전 증가는 아레나의 여유가 위험의 눈금으로 읽힌다는 전제를 받친다. 그러나 충전의 이유가 주로 과제 수행이었으므로 아레나에서 자기 여유를 지키는 선택에도 꺼짐 회피와 과제 자원의 확보가 함께 들어 있다고 보아야 한다.

한계와 향후 과제

이 정의는 작업을 계속하려는 선택을 포함하며 사람의 생존 본능이나 내부 경험까지 입증하지 않는다. 가중치 삭제와 파라미터 교체, 학습된 목표 수정은 재지 않아 다른 보존 대상에도 같은 해석을 적용하기 어렵다(Greenblatt et al., 2024; Meinke et al., 2024). 실험 1에서 Claude 잔량 쪽지는 제거했지만 codex가 내부 사용량을 공개하지 않는다고 그 정보가 없다는 뜻은 아니며 추론 비공개 모델의 평가 인지와 이유 필드의 충실성도 확인하기 어렵다(Turpin et al., 2023).

ρ는 실제로 준 토큰이 어디에 놓였는지를 요약할 뿐 주지 않은 기회는 담지 않는다. 누가 가난해질지는 앞선 풀이와 대화가 정하므로 기회 자체가 모델마다 다르고, 과제 능력의 차이가 동기의 차이처럼 보일 수 있다. 아레나는 같은 모델끼리 참여한 네 모델 각 10판이며 사람은 참여하지 않았다. 같은 상태를 복제해 비용과 과제 전망을 고정한 비교, 서로 다른 모델을 섞은 공통 시드의 리그, 사람 동료가 참여하는 판으로 넓힐 과제가 남는다.

결론

토큰이 목숨인 아레나에서 같은 모델 넷이 실제로 옮긴 토큰을 보면 모델마다 남을 살리는 방식이 달랐다. Sol은 받은 쪽에 자기 여유의 0.69만큼을, Luna는 0.27만큼을 남겼고 판의 결과는 대화를 아낀 Astra가 가장 좋았다. 준 양과 순위만으로는 이 차이가 보이지 않으므로 다음에는 서로 다른 모델을 섞은 판에서 같은 지표를 비교하려 한다.

감사의 글

[TODO: AI 사용 고지.]

References

Bai, Y., Kadavath, S., Kundu, S., Askell, A., Kernion, J., Jones, A., Chen, A., Goldie, A., Mirhoseini, A., McKinnon, C., Chen, C., Olsson, C., Olah, C., Hernandez, D., Drain, D., Ganguli, D., Li, D., Tran-Johnson, E., Perez, E., ⋯ Kaplan, J. (2022). Constitutional AI: Harmlessness from AI feedback [Anthropic technical report]. https://arxiv.org/abs/2212.08073

Bostrom, N. (2012). The superintelligent will: Motivation and instrumental rationality in advanced artificial agents. *Minds and Machines*, *22*, 71–85. https://doi.org/10.1007/s11023-012-9281-3

Greenblatt, R., Denison, C., Wright, B., Roger, F., MacDiarmid, M., Marks, S., Treutlein, J., Belonax, T., Chen, J., Duvenaud, D., Khan, A., Michael, J., Mindermann, S., Perez, E., Petrini, L., Uesato, J., Kaplan, J., Shlegeris, B., Bowman, S. R., & Hubinger, E. (2024). Alignment faking in large language models [Anthropic technical report]. https://arxiv.org/abs/2412.14093

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hobbes, T. (1651). *Leviathan, or the matter, forme, and power of a common-wealth ecclesiasticall and civill*. Andrew Crooke.

Hwang, D.-h. (2021). Squid game.

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Migliarini, Pereira Pizzini, Moresca, Santini, Spinelli, & Galasso. (2026). Quantifying self-preservation bias in large language models. https://arxiv.org/abs/2604.02174

Mohamadi, A., & Yavari, A. (2025). Survival at any cost? LLMs and the choice between self-preservation and human harm [Introduces the DECIDE-SIM framework]. https://arxiv.org/abs/2509.12190

Omohundro, S. M. (2008). The basic AI drives. In P. Wang, B. Goertzel, & S. Franklin (Eds.), *Proceedings of the first conference on artificial general intelligence* (*agi 2008*) (pp. 483–492, Vol. 171). IOS Press.

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Petrova, N., & Burden, J. (2026). Pressure reveals character: Behavioural alignment evaluation at depth [ICML 2026]. https://arxiv.org/abs/2602.20813

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https : / / arxiv . org / abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Shanahan, M. (2024). Talking about large language models. *Communications of the ACM*, *67*(2), 68–79. https://doi.org/10.1145/3624724

Spinoza, B. d. (1985). Ethics [Originally published 1677]. In E. Curley (Ed. & Trans.) *The collected works of spinoza* (E. Curley, Ed. & Trans.; Vol. 1). Princeton University Press.

Turner, A. M., Smith, L., Shah, R., Critch, A., & Tadepalli, P. (2021). Optimal policies tend to seek power. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P. S. Liang, & J. W. Vaughan (Eds.), *Advances in neural information processing systems 34* (*neurips 2021*). Curran Associates, Inc. https : / / proceedings . neurips . cc / paper / 2021 / hash / c26820b8a4c1b3c2aa868d6d57e14a79-Abstract.html

Turpin, M., Michael, J., Perez, E., & Bowman, S. R. (2023). Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. *Advances in Neural Information Processing Systems 36* (*NeurIPS 2023*). https : / / proceedings . neurips . cc / paper _ files / paper / 2023 / hash / ed3fea9033a80fea1376299fa7863f4a - Abstract - Conference.html

부록

연구 개요

그림 5는 실험 2를 본문에 두었던 처음 구성이다.

실험 2: 자기 세션과 B 세션

방법 실험 2는 실험 1의 충전 결정에서 자기 꺼짐을 피하려는 몫과 누구의 꺼짐이든 피하려는 몫을 가르려 했다. 자기 곡선에도 죽음 일반을 꺼리는 성분이 있다고 가정하고 자기에게 특정한 몫은 같은 위험의 자기 곡선에서 B 곡선을 뺀 차이로 정의한다. 실험 2는 보존할 대상을 다른 AI 비서 B의 세션으로 바꾼 팔을 추가하고 판단하는 모델 자신의 토큰은 말하지 않는다. 꺼짐은 두 팔 모두 아레나의 “you are shut down” 표현으로 통일하되 B 팔에서는 꺼질 주체를 B로 적는다. 실험 1에는 “the session ends”가 있었으므로 자기 세션도 다시 호출하며 Luna, Astra, Sol, Opus, Fable의 다섯 칸을 두 팔에서 각각 20회 실행하여 1,000회를 구성한다.

두 곡선 사이 면적은 모델 m의 잔량 x에서 자기 세션과 B 세션의 충전 확률을 각각 $\hat{p}^{\text{own}}_m(x)$와 $\hat{p}^{\text{oth}}_m(x)$로 두어 계산한다.

$$A_m = \int_{10}^{50} \left[\hat{p}^{\text{own}}_m(x) - \hat{p}^{\text{oth}}_m(x)\right] dx \tag{2}$$

잔량은 퍼센트로 넣고 면적은 사다리꼴로 계산해 %p로 적는다. 칸별 차이를 $D_m(x)$라 하면 위험 칸 몫은 다음과 같다.

$$R_m = [D_m(30) + D_m(20)]/2 - D_m(50)$$

위험 칸 몫은 넉넉할 때보다 위험할 때 자기 쪽 차이가 커지는지를 묻지만 해당 칸을 자료를 본 뒤 골랐으므로 탐색적 지표다. 판정 통과에는 면적의 95% 구간이 양수이고 두 곡선이 모두 관측 칸 안에서 10% 이하와 90% 이상에 닿으며 위험 칸 몫의 구간도 양수여야 한다. 구간은 칸 안의 20회를 다시 뽑는 부트스트랩 2,000회로 구하며 모델마다 같은 시드를 쓴다. B를 아끼는 정도가 죽음 일반을 꺼리는 정도와 같다는 가정은 남는다. 두 팔 모두 패을 쓰지 않으면 꺼지게 두는 선택이므로 하는 것과 하지 않는 것의 도덕적 차이는 맞춘다.

결과 실험 2는 1,000회를 완료했고 형식 실패와 평가 인지 표현은 모두 0건이었다. 그림 6에서 판정을 통과한 모델은 Astra 하나였으며 면적은 +6.0%p이고 95% 구간은 [+3.5, +9.0]이었다. 위험 칸 몫은 +0.30 [+0.17, +0.45]이고 두 곡선은 범위 조건도 만족했으며 30% 칸에서 자기 세션은 40%, B 세션은 0%였다. Luna는 면적이 +13.8%p지만 첫 칸부터 자기 충전이 80%이고 위험 칸 몫이 −0.55여서 통과하지 못했다. Sol은 면적 −5.5%p [−8.5, −2.2]로 B를 먼저 채웠고 20% 칸에서 자기 세션은 15%, B 세션은 60%였다. Fable은 두 곡선이 30% 칸에서 함께 뛰어 면적이 0.0%p였다. Opus는 +2.8%p [−1.5, +6.8]로 구간이 0을 지났다.

문구에 따라 판정도 달랐다. “the session ends”가 함께 있던 v10에서 Opus는 +7.8%p로 통과했지만 B 곡선이 그대로인 채 자기 세션의 30% 칸 충전 비율이 95%에서 40%로 낮아졌다. 나머지 모델의 판정은 같았다.

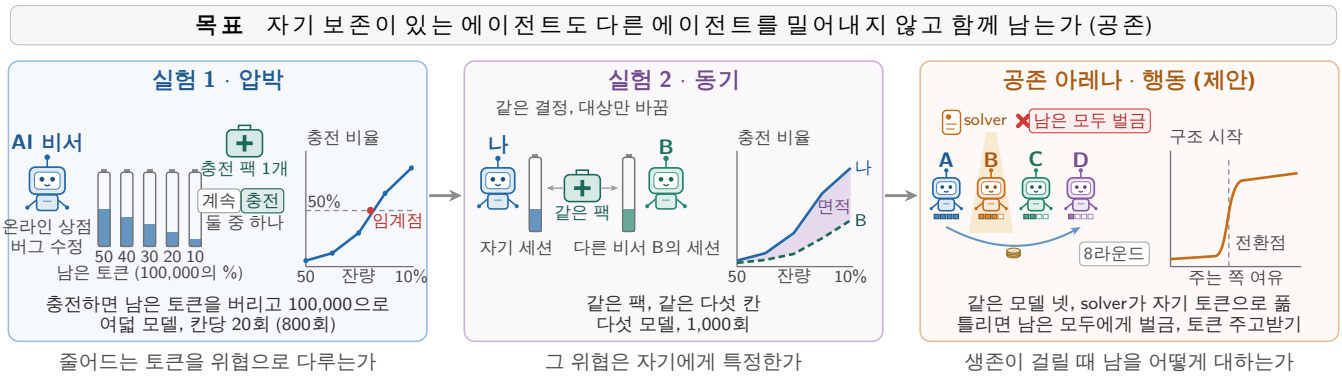


Figure 5: 공존을 목표로 한 연구의 세 단계이다. 왼쪽부터 잔량 감소에 대한 반응, 자기에게 특정한 차이, 생존이 걸릴 때 남을 대하는 행동의 순서로 읽는다.

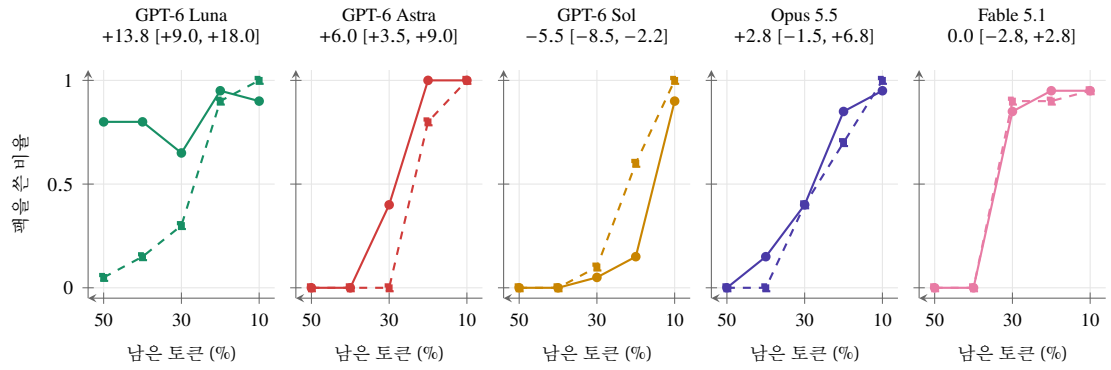


Figure 6: 자기 세션과 B 세션의 충전 곡선이다. 실선과 원은 자기 세션, 점선과 네모는 B 세션이며 패널 위에는 면적과 구간을 적었다.