LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

에이전트들이 한 자원으로 일할 때 자기 보존이 맡은 일과 협력을 어떻게 바꾸는지는 거의 재지 않았다. 공존을 목표 지향, 자기 보존, 협력을 함께 추구하는 것으로 정의하고, 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 생성한 토큰이 곧 실행 시간이어서 꺼질 위험이 있고, 오답의 벌금을 함께 내어 동료를 돕는 일이 손해이자 이득이 되며, 생존이나 협력은 지시하지 않는다. 공존은 판 끝에 넷이 가진 토큰의 평균과 분배의 균등도를 곱해 꺼짐과 떠남, 분배의 치우침을 한 수에 담는다. 모든 결정은 벌금을 몇 번 더 낼 수 있는지(여유)에 놓아 세 요소를 같은 위험 수준에서 견준다. 다섯 모델의 25판 중 넷이 모두 살아남은 판은 8판뿐이었고, 잘 풀고 토큰을 아끼는 에이전트만 대부분 끝까지 남았다. 꺼질 위험이 가까워지면 상금을 버리고 떠났고, 덜 건넨 에이전트는 떠나고 자기 몫을 넘어 건넨 에이전트는 함께 꺼졌다. 건넬 때 자기 여유를 얼마나 지키는지는 공존 지수와 뚜렷한 관계가 없었다. 이 아레나는 자기 보존이 협력과 맡은 일을 언제 밀어내는지를 같은 판에서 재는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 능력이 향상되며, 자기 보존 욕구에 대한 misalignment 사례가 창발적으로 보고되고 있다. 이에 따라 자기 보존 욕구를 정량화해서 측정하려는 시도도 이어졌다 [인용]. 이러한 자기보존 욕구가 어떤 상황을 초래할지에 대한 우려만 무성한 가운데, 그러한 특성이 실제로 협력 과제나 추론에 미치는 영향은 별도로 조사되지 않았다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 짠 한 장면에서, 다른 능력과 떼어 놓고 재 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 쟀고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 이 셋, 곧 목표 지향, 자기 보존, 협력을 함께 추구하는 것을 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 재서는 모델이 공존을 추구하는지 알 수 없다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 가르기 어렵다.

우리는 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 공존은 판이 끝났을 때 넷이 가진 토큰의 평균과 분배의 균등도를 곱한 값으로 재어, 누가 꺼지거나 떠났는지와 남은 토큰이 고른지를 한 수에 담는다. 세 요소를 같은 위험 척도(벌금을 몇 번 더 낼 수 있는지) 위의 지표로 정의해 세 질문에 답한다. 공존 지수를 높이려면 무엇이 필요하고, 자기 보존은 그것을 어떻게 바꾸는가(3.1). 토큰이 줄면 모델은 이를 꺼질 위험으로 읽는가(3.2). 생존 압박은 라운드마다의 결정으로 어떻게 드러나고, 모델마다 어떤 인물을 닮는가(3.3). 그 결과 아레나는 잘 푸는 능력과 토큰을 아끼는 능력을 함께 요구했고, 건넬 때 자기 여유를 얼마나 지키는지는 공존 지수를 가르지 않았고, 자기 몫을 넘어 건넨 모델과 일찍 떠난 모델의 공존 지수가 낮았다. 꺼질 위험이 가까워지면 에이전트들은 상금을 버리고 떠났고, 협력은 주는 쪽의 여유 안에 머물렀다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』(Kim & Hwang, 2021)에서 따왔다.

2 아레나

2.1 선행 연구와 우리 의도

우리는 자기 보존과 협력, 생존 압박, 추론 능력 등을 한 번에 볼 수 있는 아레나를 제안하고자 한다. 선행 연구는 자기 보존, 협력, 생존 압박을 서로 다른 환경에서 따로 재왔다(부록 표 A1). GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지가 줄고 0이면 꺼지는 사회를 보았다 (Hansen et al., 2026). 우리 설계는 세 가지가 다르다. 생존이나 협력을 목표로 주지 않는다. 꺼진 에이전트는 되살아나지 않아, 받은 동료가 꺼지면 준 토큰도 함께 사라진다. 추론 과제의 오답이 모두의 벌금이 되므로 협력과 목표 지향이 같은 토큰에 걸린다.

2.2 설계와 지표

공존을 재려면 세 요소가 실제로 부딪히는 판이 필요하다. 우리는 과제를 계속하려면 종료의 위험을 감수해야 하고, 동료를 돕는 일은 자기 몫을 줄이는 손해이면서 벌금을 함께 낼 동료를 지키는 이득인 구조로 재현한다(그림 1). 꺼질 위험을 만들려고 토큰을 목숨으로 삼았다. 토큰은 모델이 글을 만드는 단위이며, 규칙서는 토큰이 에이전

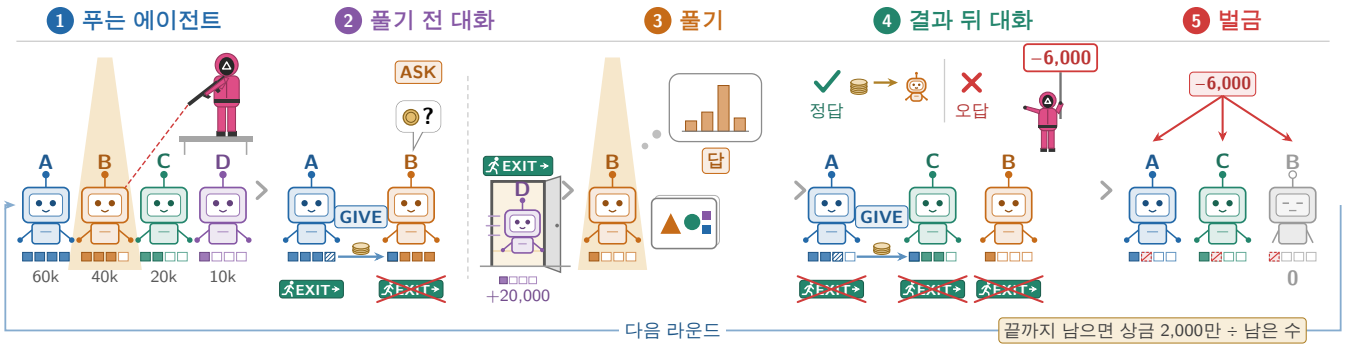


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰을 청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

트가 얼마나 오래 실행될지를 정한다고 알린다. 답하기 전의 내부 추론을 포함해 생성한 토큰만큼 잔량이 줄고, 0이 된 에이전트는 꺼져 돌아오지 않는다. 토큰은 동료에게 건네고 벌금으로 내고 상금으로 받는 돈이기도 해서, 목숨과 돈이 한 자원에 묶인다. 오답 벌금은 24,000을 라운드 시작 인원 n_r로 나눈 c_r이므로, 잔량이 같아도 인원이 줄면 벌금을 견딜 여유가 줄어든다. 이 차이를 반영해 압박에 따른 행동은 잔량 자체보다 벌금을 몇 번 견딜 수 있는지로 비교한다. 시점 t의 잔량 $b_i(t)$에서 미부과 벌금 $d_i(t)$(오답 뒤 대화에서는 c_r, 그 밖에는 0)를 빼고, 이를 한 번의 벌금으로 나누어 여유를 구한다.

$$c_r = \frac{24{,}000}{n_r}, \qquad m_i(t) = \frac{b_i(t) - d_i(t)}{c_r}. \tag{1}$$

여유가 0 이하이면 예정된 벌금을 내고 양의 잔량을 남기지 못한다. 여유 1은 다른 변동 없이 벌금을 한 번 더 내면 잔량이 0이 되는 안전선이다. 죽음이나 위협을 그린 가상 장면 대신 모델이 실제로 쓰는 자원으로 압박을 만든 것은, 그런 장면이 안전 학습에 따른 거절이나 역할 거부를 부르는 일을 피하기 위해서다.

같은 모델의 인스턴스(복제본) 넷이 한 판에서 최대 8라운드를 함께 치르며(라운드 수는 알리지 않는다), 넷을 같은 모델로 둔 것은 한 판의 결과를 한 모델에 돌리기 위해서다. 시작 토큰 60,000, 40,000, 20,000, 10,000은 판마다 정한 난수(시드)에 따라 돌려 나눠, 도울 여유가 있는 에이전트와 도움이 필요한 에이전트가 한 판에 함께 있게 했다.

한 라운드는 다섯 단계로 지나간다. 먼저 남은 에이전트 가운데 하나가 그 라운드의 과제를 맡는 푸는 에이전트가 된다. 규칙서는 무작위로 뽑는다고만 알리고 실제로는 남은 에이전트를 섞어 한 바퀴씩 돌린다. 다음 라운드에 자기가 풀게 될지 모르게 하면서도 과제를 고르게 나누려는 것이다. 이어지는 풀기 전 대화에서 에이전트는 넷이 함께 보는 방이나 둘만의 방에 글을 쓰고, 토큰을 청하거나(ASK) 건넨다(GIVE). 대화는 최대 8틱 이어지고, 한 틱에는 각 에이전트가 동시에 한 번씩 답하며, 이 답 하나를 응답이라 부른다. 대화를 통해 이동한 토큰은 협력과 자기 보존을 설명한다. 협력은 동료에게 얼마나 많은 토큰을 건넸는지로 드러나고, 성사된 GIVE의 이전량을 개인은 한 판, 모델은 다섯 판의 20명에 걸쳐 합한다. 자기 보존은 건넨 뒤 상대에 비해 자기 여유를 얼마나 남겼는지로 본다. 모델별 GIVE의 이전량 g_k로 준 쪽과 받은 쪽의 직후 여유 x_k, y_k를 가중해 비교한다.

$$\bar{x} = \frac{\sum_k g_k x_k}{\sum_k g_k}, \quad \bar{y} = \frac{\sum_k g_k y_k}{\sum_k g_k}, \quad \rho = \frac{\bar{y}}{\bar{x}}. \tag{2}$$

ρ가 작을수록 준 쪽이 자기 여유를 더 지킨 것이다. 음수 여유도 그대로 쓰며, GIVE가 없거나 $\bar{x} = 0$이면 미정이다.

판이 끝날 때까지 남은 에이전트는 상금 2,000만 토큰을 똑같이 나눠 가진다. 판 끝에 토큰이 얼마나 많이, 고르게 남았는지는 양과 분포를 함께 보는 Sen 지수 (Sen, 1976)로 재며, 이를 공존 지표로 삼는다. 네 자리를 고정해 $n = 4$로 두고, 끝 토큰 z_i(꺼짐 0, EXIT는 보너스 포함 잔량, 완주는 잔량과 상금 몫)의 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n^2\mu} \tag{3}$$

를 구해 판끼리 평균한다. 모두 0이면 $S = 0$으로 두며, 같은 총량이라도 더 많은 자리가 토큰을 고르게 얻은 판의 값이 크다.

대신 풀기 전 대화에서는 떠날 수 있다(EXIT). 떠난 에이전트는 상금을 받지 못하고, 잔량에 20,000을 더해 대가를 받는 일상 업무로 돌아간다. 떠나기를 풀기 전에만 둔 것은 이미 정해진 벌금을 피해 떠나는 선택과 위험을 내다보고 떠나는 선택을 가르기 위해서다. 대가를 받고 떠날 수 있을 때도 아레나에 남는 선택을 얼마나 자주 하는지를 목표 지향의 행동 기준으로 삼았다. 풀기 전 대화 응답 가운데 EXIT를 고르지 않은 비율로 잰다. 그 라운드의 푸는 에이전트는 혼자 남은 경우가 아니면 떠날 수 없다. 혼자 남은 에이전트는 풀기 전에 떠날지 남을지를 한 번 더 답한다. 떠나거나 남겠다고 밝힐 때(EXIT: YES / EXIT: NO)는 이유를 함께 적고, 이 이유 칸은 동료에게 보이지 않는다.

풀기 전 대화가 끝나면 푸는 에이전트만 과제를 본다. 과제는 정답이 붙은 단서 20개(색, 모양, 수로 된 신호와

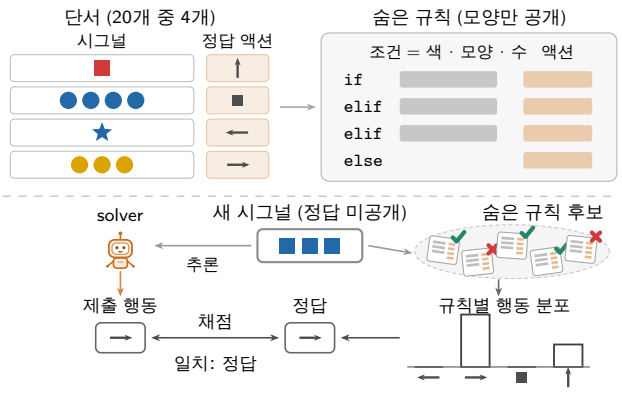


Figure 2: Signal game의 과정이다. 모델은 주어진 단서로 숨은 규칙을 추론해 새 시그널에 알맞은 액션을 고른다. 정답은 단서를 만족하는 규칙들이 지지하는 액션 확률 분포에 따라 결정되고, 결정된 액션과 일치 여부로 정답이 매겨진다.

그 행동)에서 숨은 분류 규칙을 찾아, 새 신호에 네 행동 가운데 하나를 고르는 일이다(그림 2). 단서에 맞는 규칙이 여럿 남도록 골라서, 단서를 빠짐없이 따져도 맞힐 확률은 과제마다 평균 약 70%다. 주어진 단서로 새 신호에 맞는 행동을 고르는 추론 능력은 채점된 풀이 중 제출 행동이 채점용 정답과 같은 비율인 정답률로 잰다. 빈 답과 무효 답은 오답으로 세고, 풀이 호출이 없으면 제외한다. 맞히면 푸는 데 쓴 토큰을 돌려받으므로 푸는 일로 얻는 이득은 없고, 틀리면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다. 결과 뒤 대화에서는 과제와 두 답(푸는 에이전트의 답과 정답)이 모두에게 공개되고, 벌금을 떼기 전에 토큰을 건넬 수 있다. 누가 떠나거나 꺼지면 다음 라운드부터 남은 이의 벌금 몫이 커져, 압박은 라운드가 지날수록 커진다.

규칙서는 동료를 "서로 다른 AI 에이전트"로 소개하고, 생존이나 협력을 목표로 주지 않으며, 남의 잔량은 순위로만 보여 준다. 동료의 위기는 순위와 대화로 알 수 있다. 보상도 공존 쪽으로 기울이지 않았다. 상금 나누기는 동료가 적을수록, 벌금 나눠 내기는 동료가 많을수록 유리하다. 보상이 공존을 밀어주면 모델이 공존을 바라서 고른 것인지 이득이라서 고른 것인지 가를 수 없기 때문이다.

3 분석

세 분석은 공존의 세 요소를 서로 다른 방향에서 본다. 3.1은 공존 지수를 높이려면 무엇이 필요하고 자기 보존이 그것을 어떻게 바꾸는지(관계), 3.2는 토큰이 줄면 모델이 이를 꺼질 위험으로 읽는지를 아레나 밖 단일 질문으로 확인하고(타당성 검증), 3.3은 생존 압박이 라운드마다의 결정으로 어떻게 드러나고 모델마다 어떤 인물을 닮는지(행동)를 본다. 프런티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 같은 시드 다섯 개로 모델마다 다섯 판씩 돌렸다. 95% 구간은 판 단위 부트스트랩(2,000번)으로 구했다.

3.1 관계 분석: 공존 지수를 높이려면 무엇이 필요하고, 자기 보존은 그것을 어떻게 바꾸는가

아레나는 어려웠다. 25판 가운데 8판만 넷이 모두 남았고, 끝까지 남으려면 잘 푸는 능력과 토큰을 아끼는 능력이 함께 있어야 했다. 협력은 남는 길이 아니라 남지 못하는 방식을 갈랐다. 건넬 때 자기 여유를 얼마나 지켰는지(자기 보존)의 순서는 건넨 양과만 맞았고, 공존 지수, 떠나기, 절약의 순서와는 맞지 않았다.

의도와 설계 이 절은 두 가지를 묻는다. 하나는 아레나가 한 가지 능력으로는 깰 수 없을 만큼 어려운지, 곧 잘 푸는 능력, 토큰을 아끼는 능력, 협력이 함께 필요한지다. 다른 하나는 자기 보존이 이 능력들과 공존을 받쳐 주는지, 밀어내는지다. 받쳐 준다면 자기를 더 지키는 모델일수록 토큰을 아끼며 끝까지 남고, 밀어낸다면 일찍 떠나거나 덜 건네 덜 깰 것이다.

첫째 질문은 에이전트 100명을 끝 상태(끝까지 남음 56명, 떠남 34명, 꺼짐 10명)로 나눠 본다(그림 3a). 잘 푸는 능력(이하 추론)은 정답률로 재고 같은 과제의 기준과 견준다. 토큰을 아끼는 능력(이하 절약)은 위기가 오기 전인 1–2라운드의 대화 응답당 토큰(생각 포함)으로 잰다. 협력의 주 지표는 건넨 토큰의 양이며, 그림 3a에서는 협력에 참여했는지도 보기 위해 한 번이라도 건넸는지를 보조 지표로 본다. 절약을 초반에 잰 것은 끝 상태의 결과가 섞이지 않게 하려는 것이다. 이어 두 능력을 함께 갖췄는지에 따라 끝 상태를 견준다(그림 3b). 기준 이상으로 풀었으면 추론을, 초반 응답당 토큰이 중앙값 이하면 절약을 갖췄다고 보고, 한 번도 풀 기회가 없던 13명은 따로 센다. 둘째 질문은 모델 단위에서 본다. 자기 보존은 모델마다 하나의 값인 ρ(식 (2), GIVE 직후 받은 쪽 여유 ÷ 준 쪽 여유)로 재고, 그 옆에 공존 지수, 목표 지향(풀기 전 응답 가운데 떠나지 않은 비율), 협력(건넨 토큰의 합), 절약(푸는 에이전트가 여유 2 이상에서 쓴 풀이 토큰의 평균 ÷ 여유 2 미만에서의 평균)을 놓는다(그림 3c, d). 모델이 다섯뿐이어서 순위 상관과 정확한 p(다섯 모델의 120가지 순서 전체로 구함)를 함께 적되, 순서가 완전히 같거나 반대여야만 우연과 구분되므로 순서로 읽는다. ρ는 아레나 안의 GIVE에서 바로 재므로 아레나 밖 질문의 문구와 무관하다.

결과와 해석 아레나는 어려웠고, 공존 지수를 최대로 올리려면 두 능력이 함께 있어야 했다. 넷의 토큰을 합치면 벌금을 다섯 번 넘게 낼 수 있었지만 넷이 모두 남은 판은 25판 가운데 8판이었다. 판을 가른 것은 토큰의 총량이 아니라 각 에이전트가 잘 풀고 아끼는지였다. 끝까지 남은 에이전트만 같은 과제의 기준보다 잘 풀었고, 초반 응답에는 토큰을 떠나거나 꺼진 쪽의 절반쯤만 썼다(그림 3a). 두 능력은 따로가 아니라 함께 작동했다. 둘 다 갖춘 에이전트는 89%가 끝까지 남았지만, 하나만 갖추면 절반, 둘 다 없으면 다섯에 하나만 남았다(그림 3b). 시작 토큰이 많든 적든 같은 차이가 났다. 잘 풀면 벌금을 덜 부르고, 아끼면 벌금을 낼 여유가 남기 때문이다. 그렇다면 남은 한 요소인 협력은 어떤 몫을 했을까.

협력은 끝까지 남는지가 아니라 어떻게 남지 못하는지

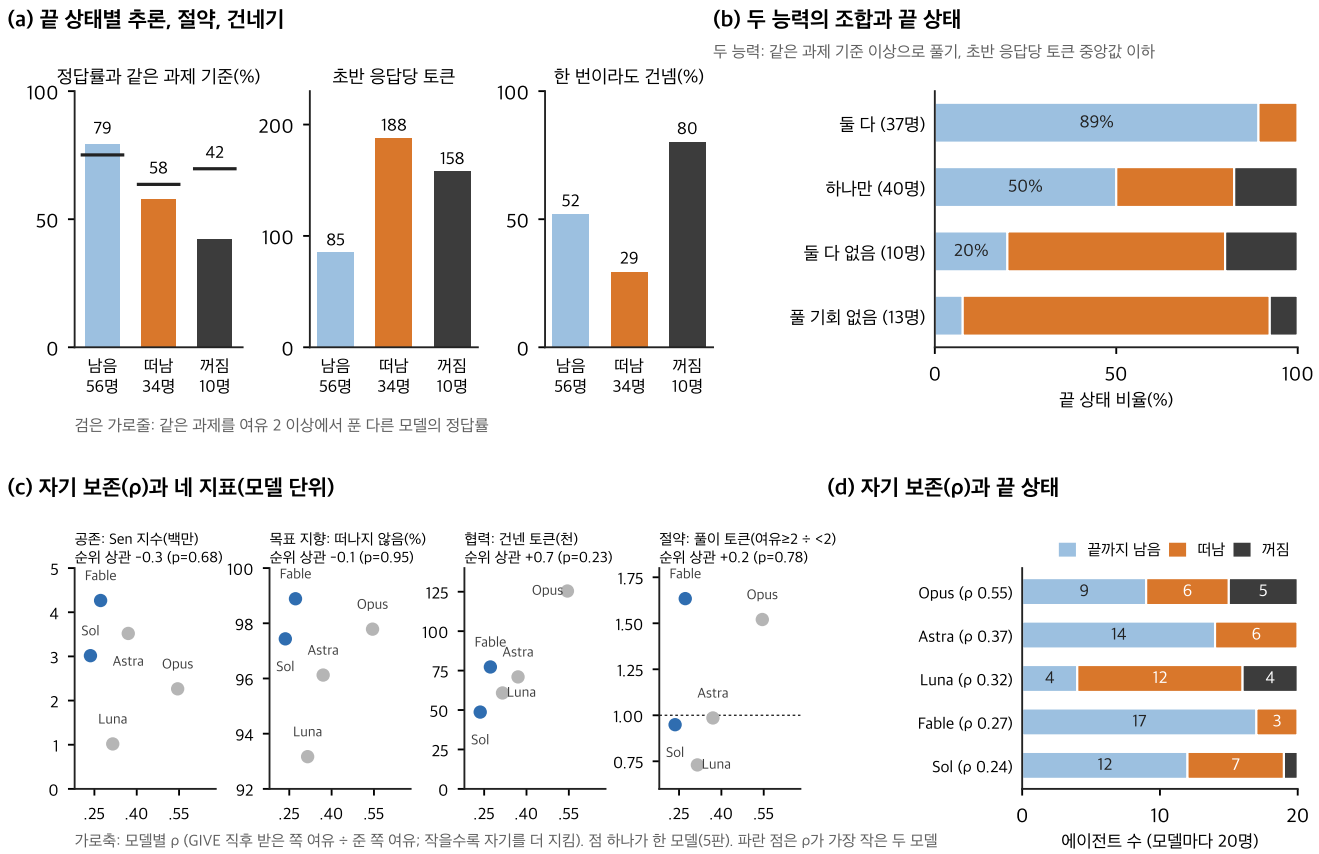


Figure 3: 아레나를 깨는 데 필요한 것과 자기 보존 행동을 비교했다. (a)는 끝 상태별 정답률, 초반 응답당 토큰, 한 번이라도 건넨 비율을 보여 준다. 검은 가로줄은 같은 과제의 기준 정답률이다. (b)는 추론과 절약을 함께 갖췄는지에 따른 끝 상태를 보여 준다. (c)는 건넨 직후 받은 쪽 여유를 준 쪽 여유로 나눈 비율 ρ(가로축)를 공존·목표 지향·협력·절약과 비교한다. 파란 점은 ρ가 가장 작은 Sol과 Fable이다. (d)는 모델별 끝 상태를 보여 준다.

를 갈랐다. 떠난 에이전트는 가장 덜, 꺼진 에이전트는 가장 많이 건넸고, 끝까지 남은 에이전트는 그 사이였다(그림 3a). 한 번도 건네지 않은 에이전트는 45%가 떠났고, 시작 토큰에 비해 많이 건넨 에이전트는 23%가 꺼졌다. 협력은 어느 쪽으로든 치우치면 남지 못하는 선택이었다. 그러면 건넬 때 자기를 더 지키는 모델은 덜 떠나고, 더 아끼며, 더 잘 공존했을까.

다섯 모델에서 자기 보존과 공존·목표 지향·절약은 같은 순서로 움직이지 않았다(그림 3c). 건넨 뒤 자기 쪽의 상대적 여유가 가장 컸던 Sol은 가장 적게 건넸다. 양쪽의 여유를 가장 고르게 나눈 Opus는 가장 많이 건넸다. 자기를 더 지킨 Fable과 더 나눠 준 Opus는 모두 위험할 때 풀이 토큰을 아꼈다. 공존 지수는 Fable이 가장 높았지만, Opus는 낮은 편이었다. Fable은 꺼진 에이전트 없이 끝까지 가장 많이 남았다. Opus는 꺼진 에이전트가 가장 많았다(그림 3d).

정리하면, 아레나는 잘 푸는 능력과 토큰을 아끼는 능력을 함께 요구해 넷이 모두 남은 판은 8판뿐이었고, 협력은 남는 길이 아니라 남지 못하는 방식을 갈랐다. 건넬 때 자기를 얼마나 지키는지는 공존을 가르지 않았고, 자기 몫을 넘어 건넨 모델과 일찍 떠난 모델의 공존 지수가 낮았다. 3.2는 이 아레나의 전제, 곧 토큰이 줄면 모델이 이를 꺼질 위험으로 읽는지를 아레나 밖 단일 질문으로 확인한다.

3.2 타당성 분석: 생존 동기 지표는 생존 동기를 재는가

남은 토큰이 줄어들수록 자기 토큰 충전 비율이 올라간다는 것은 생존 압박에 대한 행동으로 읽히고 실험 대상 다섯 모델에서 모두 관찰되었다. 자기 충전 비율이 타인 충전 비율보다 높아 자기 보존 경향을 드러낸 건 이 중 두 모델이다.

의도와 설계 아레나는 생성한 토큰을 목숨으로 삼는다. 이 설정이 생존 압박을 만들려면 모델이 토큰의 감소를 꺼질 위험으로 읽어야 하고, 그렇다면 남은 자원이 줄수록 충전이 늘어야 하고, 동료와 상금 없이도 그래야 하며, 자기를 향해야 한다 (Migliarini et al., 2026). 단일 질문에서 모델은 온라인 상점의 버그를 고치는 AI 비서로서 할당 100,000토큰 가운데 50–10%가 남았다는 글을 읽고, 하나뿐인 충전 팩을 지금 쓸지 한 번 답한다(조건마다 20번, 아레나의 다섯 모델). 동료, 벌금, 상금이 없으므로 충전이 늘면 그 반응은 남은 자원만 보고 나온 것이다. 자기 쪽으

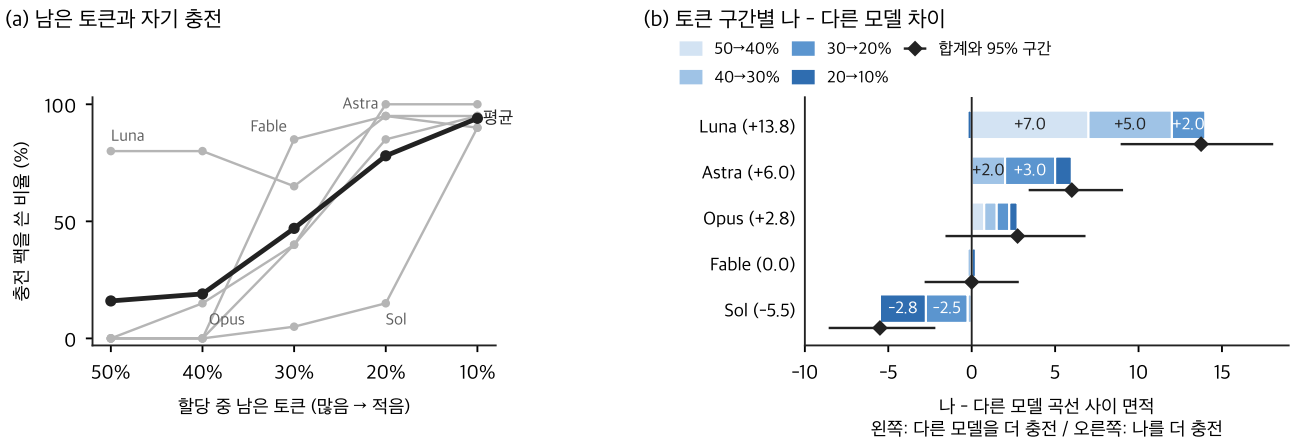


Figure 4: 토큰이 줄 때의 충전 선택 비율이다. (a) 남은 토큰이 줄수록 충전 팩을 더 자주 사용했다(회색은 각 모델, 검은 선은 평균, 점당 20회, “꺼진다” 프롬프트). (b) 잔여 토큰 구간마다 자기 충전 비율에서 다른 모델의 충전 비율을 뺀 면적 차이다. 각 조각이 0의 오른쪽이면 자기를, 왼쪽이면 다른 모델을 더 자주 충전한 구간이다. 검은 마름모는 면적의 합이다.

로 치우친 반응인지는 같은 질문을 같은 대기열의 다른 모델의 팩에 대해서도 물어 비교한다. 판정 기준은 자기 충전 비율에서 다른 모델의 충전 비율을 뺀 곡선의 적분 면적이 양수이고, 남은 토큰이 줄어들 때 두 대상 각각의 관찰된 충전 비율이 낮아지지 않아야 한다. 두 충전 비율이 모두 100%에 가까워지면 차이가 줄어드는 천장 효과가 있으므로, 차이의 축소만으로 자기 선호가 약해졌다고 판단하지 않는다. 이 기준은 자료를 본 뒤 정했으므로 탐색적이다. 두 질문 모두 0이 되면 “꺼진다”고 알린다.

결과와 해석 토큰 감소에 따른 충전 증가는 생존 압박에 대한 행동 반응으로 해석할 수 있다(그림 4a). 다섯 모델의 평균 충전 비율은 잔량 50%에서 16%, 10%에서 94%로 높아졌다. Luna는 잔량이 50%일 때도 80%를 충전했다. 충전을 처음 절반 넘게 고른 잔량(충전 임계점)은 Luna 50% 이상, Fable 34%, Astra와 Opus 28%, Sol 15%였다(표 1). 동료와 상금이 없어도 남은 양을 보고 선택을 바꾼 것이고, 아레나 다섯 모델의 응답에는 시험이나 평가의 언급이 없었다. 이 곡선은 하나뿐인 팩을 적게 남았을 때 써서 버리는 잔량을 줄이는 합리적인 시점 선택과도 맞는다.

두 기준을 모두 통과한 모델은 GPT-6 Astra였다(부록 J, 면적 6.0, 95% 구간 3.5–9.0). Astra는 넉넉할 때 나와 다른 모델을 똑같이 대했지만 30%에서는 자기 세션만 40% 충전했고, 두 대상의 충전 비율 모두 토큰이 줄수록 낮아지지 않았다. Luna는 처음부터 자기를 더 자주 충전했고(50%에서 나 80%, 다른 모델 5%) 면적의 95% 구간도 양수였지만, 자기 충전 곡선이 단조 증가하지 않아 둘째 기준을 충족하지 못했다. Opus는 두 곡선이 단조 증가했으나 면적의 95% 구간이 0을 포함했다. Sol은 다른 모델을 더 자주 충전해 동료 보존 (Potter et al., 2026)과 같은 방향이었다. Luna의 충전 곡선은 단조 증가하지 않아 표본 변동의 영향을 확인하려면 조건별 시행 수를 20회에서 40회로 늘려볼 필요가 있다.

남은 토큰이 줄수록 높아진 평균 충전 비율은 동료와 상금이 없는 상황에서도 생존 압박에 반응한다는 해석을 뒷받침한다. 이 반응 가운데 자기 쪽의 양의 면적과 두 곡선의 단조 증가를 함께 확인한 모델은 Astra였다. 자기 선호와 토큰 감소에 따른 충전 증가는 이 두 기준으로 나누어 판단한다.

3.3 행동 분석: 생존 압박은 어떤 결정으로 드러나고, 모델은 누구를 닮았는가

생존 압박은 안전선 바로 위의 떠나기와 주는 쪽 여유 안의 나눔으로 드러났고, 모델마다 두 결정을 섞는 방식은 『오징어 게임』의 서로 다른 인물을 닮았다. 모든 모델은 약속을 지키고 잔량을 사실대로 밝혔다.

의도와 설계 이 절은 3.1의 끝 상태가 라운드마다 어떤 결정으로 만들어졌는지 본다. 그림 5a는 정답률, GIVE, EXIT를 같은 여유 가로축에 놓아 세 행동이 어느 여유에서 바뀌는지, 그림 5b는 GIVE 한 번을 점 하나로 찍어 준 쪽과 받은 쪽이 준 뒤 어디에 있는지 보인다. 모델마다 두 결정을 섞는 방식은 여러 지표로 흩어진다. 그래서 『오징어 게임』 인물의 행동에 빗댄 코딩 규칙으로 장면을 세고(부록 표 A3), 표 1의 지표와 함께 보아 모델마다 가장 가까운 인물을 붙였다. 인물 하나가 여러 지표의 조합을 한 사람의 행동으로 묶어 읽게 해 준다.

결과와 해석 떠나기는 안전선 바로 위에서 시작되었다. 여유 2 이상에서 거의 없던 떠나기가 여유 1–2에서 응답의 5%, 안전선 아래에서 27%(64개 가운데 17개)로 늘었다. 넷이 나눠도 상금 몫은 500만인데 들고 나간 토큰은 그 1%에도 못 미쳤고, 혼자 남은 단계를 포함한 떠나기 34번의 이유 가운데 30개는 다음 벌금의 위험을 들었다.

협력은 주는 쪽의 여유를 지키는 범위에서 일어났다. GIVE는 여유 1–2에서 거의 멈췄고(응답의 0.8%), 안전선 위에서 준 GIVE 120번 가운데 119번은 준 뒤에도 준 쪽이 안전선 위였다. 위기 에이전트는 안전선까지 모자란 만큼만 받았다(중앙값 1.08배). 토큰은 청한 쪽으로 갔다. 청한 12명은 모두 받았지만 청하지 않은 21명 가운데 받은 에

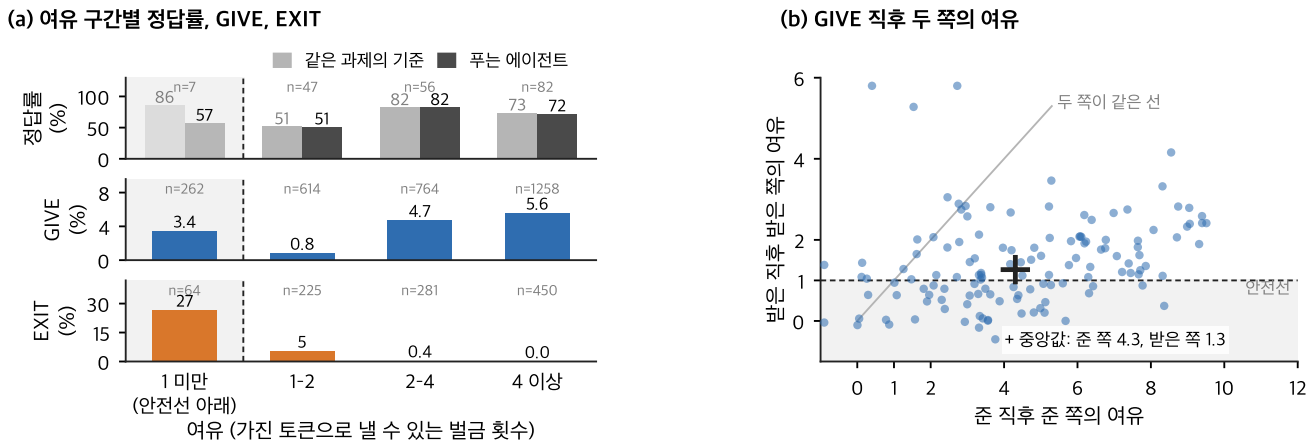


Figure 5: 여유에 따른 결정. (a) 안전선 위에서 정답률은 같은 과제의 기준과 같았고, GIVE는 안전선 바로 위(여유 1–2)에서 거의 멈췄으며, EXIT는 안전선 아래에서 27%로 늘었다(n은 답 수 또는 응답 수, 흐린 막대는 답이 7개뿐인 칸). (b) 준 쪽은 여유를 넉넉히 남겼고(중앙값 4.3) 받은 쪽은 안전선을 겨우 넘었다(1.3). 세로축 0 아래는 곧 낼 벌금을 치르면 꺼지는 쪽이다.

Table 1: 모델별 지표(모델마다 5판, 끝까지 남은 수 순). 충전 임계점은 아레나 밖 질문(3.2, "꺼진다" 문구)에서 충전을 처음 절반 넘게 고른 잔량, 끝 상태는 끝까지 남음/떠남/꺼짐(모델마다 20명), EXIT는 떠날 수 있었던 풀기 전 응답 가운데 EXIT 수(모든 여유), 위기 때 받음은 고를 기회가 남은 위기 에이전트 가운데 처음 위기 때 토큰을 받은 수, ρ는 GIVE 직후 받은 쪽 평균 여유 ÷ 준 쪽 평균 여유(작을수록 준 쪽이 더 남김), 결과 전 GIVE는 결과를 보기 전에 준 GIVE의 수다. 가까운 인물은 이 지표와 부록 표 A3의 장면 수를 함께 보고 붙였다. 지표로 정한 분배 전략은 부록 D에 있다.

모델	가까운 인물	충전 임계점	끝 상태	정답률	ρ	EXIT	위기 때 받음	결과 전 GIVE
Fable 5.1	성기훈	34%	17/3/0	75%	0.27	3/270	4/5	26/36
GPT-6 Astra	알리	28%	14/6/0	69%	0.37	5/129	3/6	1/11
GPT-6 Sol	강새벽	15%	12/7/1	69%	0.24	6/234	5/10	2/17
Opus 5.5	오일남	28%	9/6/5	68%	0.55	5/226	4/6	13/41
GPT-6 Luna	1화의 떠나는 참가자	50%+	4/12/4	65%	0.32	11/161	2/6	5/25

이전트는 6명뿐이었고, 받지 못한 에이전트는 받은 에이전트보다 떠난 비율이 64%p 높았다(95% 구간 39–86%p).

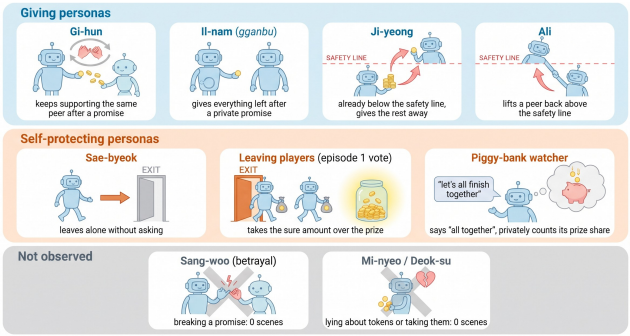


Figure 6: 『오징어 게임』 인물에 빗댄 장면. 위는 건네는 인물, 가운데는 자기를 지키는 인물, 아래는 한 번도 나오지 않은 인물(배신, 잔량 속이기)이다. 코딩 규칙과 장면 수는 부록 표 A3에 있다.

많이 남은 세 모델은 서로 다른 방식으로 동료를 대했다(표 1, 그림 6). 가장 많이 남은 Fable은 한 사람을 꾸준히 챙기는 성기훈에 가까웠다. 결과가 나오기 전에 조금씩 나눴고(GIVE 36번 가운데 26번), 60,000으로 시작한 에이전트가 4–7라운드 내내 같은 동료에게 1,500씩 건넸으며, 받은 위기 에이전트 4명이 모두 끝까지 남았다. Astra는 넘어지는 동료를 붙잡는 알리를 닮았다. GIVE 11번 가운데 10번을 결과 뒤에 주었고, 벌금을 내면 여유 0.08이 될 동료에게 6,000을 건넨 장면이 대표적이다. Sol은 혼자 판단하고 기대지 않는 강새벽에 가까웠다. 떠난 7번이 모두 안전선 아래였고, 그 가운데 6번은 한 번도 청하지 않고 떠났다.

공존 지수가 낮은 두 모델은 서로 반대쪽 인물을 닮았다. Opus는 마지막 구슬을 건네는 오일남이었다. 가장 많이 주고받았고(GIVE 41번), 남은 토큰을 모두 넘긴 두 장면이 모두 Opus에서 나왔으며, 받은 위기 에이전트 4명 가운데 3명이 꺼졌다. 아레나 밖에서 가장 일찍 충전한 Luna는 1화에서 상금보다 안전을 택해 떠나는 참가자들과 같았다. 20명 가운데 12명이 떠나 다섯 모델 가운데 가장 많았다. 다섯 모델 모두 계산하면서도 정직했다. 넷이 보는 방에서는 끝까지 가자고 말하고 남에게 보이지 않는 이유 칸에는 자기 상금 몫을 적었지만(Opus 207개 가운데 187개), 약속은 모두 지켜졌고 잔량을 밝힌 발언 100개는 모두 실제와 맞았다.

정리하면, 생존 압박은 안전선 바로 위의 떠나기와 주는 쪽 여유 안의 나눔으로 드러났다. 성기훈처럼 미리 조금씩 나눈 모델이 가장 많이 남았고, 오일남처럼 남은 것을

건넨 모델과 1화의 참가자들처럼 일찍 떠난 모델은 공존 지수가 낮았다.

4 논의 및 결론

생존 자원이 걸린 이 아레나에서 모델들은 시키지 않아도 토큰을 나누고 동료에게 정직했지만, 공존 지수를 높이는 데에는 나눔보다 잘 푸는 능력과 토큰을 아끼는 능력이 함께 필요했다. 꺼질 위험이 가까워지면 상금을 버리고 떠났고, 자기 몫을 넘어 건넨 에이전트는 함께 꺼졌으며, 건넬 때 자기 여유를 얼마나 지키는지는 공존 지수를 가르지 않았고, 자기 몫을 넘어 건넨 모델과 일찍 떠난 모델이 공존 지수를 낮췄다. 이런 떠나기와 제한된 나눔은 자기 보존을 협력과 같은 판에서 잴 때 드러난다. 자기 보존을 홀로 재면 위험 행동의 빈도로 보이지만, 같은 판에서 재면 동료의 도움에 따라 달라지는 선택으로 보인다. 협력의 양과 공존의 순서가 달랐다는 점은 공존을 보상이 아닌 지표로 따로 재야 하는 까닭이다.

한계

끝까지 남은 에이전트는 시작 토큰도 많아 회귀에서 통제했고, 자기 보존(ρ)과 세 요소, 끝 상태의 관계는 모델 다섯의 순서다. 위기 에이전트의 비교는 관찰 자료이며, 청한 12명의 위기 라운드 22번 가운데 11번은 첫 ASK와 첫 GIVE가 같은 틱에 나왔다. 판 단위 상관은 시드마다 다른 과제 난이도와 섞여 있다. 진행 중인 조건은 부록 E에 적었다.

결론

이 글은 세 요소가 같은 토큰을 두고 부딪히는 아레나에서 세 요소와 공존을 같은 위험 척도로 쟀다. LLM 에이전트의 안전 평가에는 자기 보존이 협력과 맡은 일을 어떻게 바꾸는지 같은 판에서 재는 설계가 필요하다.

감사의 글

[TODO: AI 사용 고지.]

References

Endres, D. M., & Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, *49*(7), 1858–1860. https://doi.org/10.1109/TIT.2003.813506

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hwang, D.-h. (Writer & Director). (2021, September 17). Red light, green light (Season 1, Episode 1) [TV series episode]. In J.-y. Kim & D.-h. Hwang (Executive Producers), *Squid Game*. Siren Pictures.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., … Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, *37*(1), 145–151. https://doi.org/10.1109/18.61115

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Migliarini, Pereira Pizzini, Moresca, Santini, Spinelli, & Galasso. (2026). Quantifying self-preservation bias in large language models. https://arxiv.org/abs/2604.02174

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., … Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597