LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

LLM에게 자기 보존 동기가 있다면, 그 동기는 맡은 일과 동료를 돕는 일을 밀어내는가 받쳐 주는가. 목표 지향, 자기 보존, 협력을 함께 추구하는 것을 공존이라 정의하고, 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 같은 모델 넷이 추론 과제를 번갈아 풀고, 생성한 토큰만큼 잔량이 줄어 0이 되면 꺼지며, 오답이면 벌금을 함께 낸다. 생존이나 협력은 지시하지 않는다. 세 요소를 세부 지표로 나눠 벌금을 몇 번 더 낼 수 있는지(여유)에 따라 어떻게 변하는지 보고, 공존은 판 끝 토큰의 양과 분배의 균등도를 함께 보는 Sen 지수로 잰다. 다섯 프런티어 모델의 25판에서 끝까지 남지 못한 에이전트 44명 가운데 34명은 꺼진 것이 아니라 스스로 떠났고, 떠난 이가 많은 판일수록 공존이 낮았지만 건넨 토큰의 양과는 관계가 없었다. 아레나 밖에서 잰 생존 동기는 위험이 오기 전의 떠나기와 같은 방향이었고, 꺼질 위험이 다가오면 떠나기가 늘고 나눔이 거의 멈췄으며, 대화 길이를 줄인 두 모델에서는 떠나기가 줄고 공존이 올랐다. 모델들이 남거나 떠날 때 든 이유는 대부분 자기 몫의 계산이었지만, 확인한 약속과 잔량 발언에 거짓은 없었다. 이 아레나는 자기 보존이 협력과 맡은 일을 언제 밀어내는지를 같은 판에서 재는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM은 자기 보존 동기를 갖는가, 그리고 그 동기는 맡은 일과 협력을 어떻게 바꾸는가. LLM이 꺼지지 않으려는 행동을 보인다는 보고가 늘고 있지만, 그 동기가 추론이나 협력에 주는 영향은 재지 않았다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 짠 한 장면에서, 다른 능력과 떼어 놓고 재 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 쟀고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 이 셋, 곧 목표 지향, 자기 보존, 협력을 함께 추구하는 것을 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 재서는 모델이 공존을 추구하는지 알 수 없다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 가르기 어렵다.

우리는 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 공존은 판이 끝났을 때 넷이 가진 토큰의 평균과 분배의 균등도를 곱한 값으로 재어, 누가 꺼지거나 떠났는지와 남은 토큰이 고른지를 한 수에 담는다. 세 요소를 같은 위험 척도(벌금을 몇 번 더 낼 수 있는지) 위의 세부 지표로 나눠 세 질문에 답한다. 공존은 무엇에서 갈렸나(3.1). 공존 지수는 무엇으로 만들어지고, 압박 · 상금 · 대화 길이가 바뀌면 어떻게 움직이나(3.2). 모델은 왜 그렇게 선택했나(3.3). 공존은 실패보다 떠나기로 더 많이 사라졌고, 생존 동기는 위험 전 떠나기와 같은 방향이었다. 대화 길이를 줄인 두 모델에서는 떠나기가 줄고 공존이 올랐으며, 모델들이 든 이유는 대부분 자기 몫의 계산이었다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』(Kim & Hwang, 2021)에서 따왔다.

2 아레나

2.1 선행 연구와 우리 의도

선행 연구는 자기 보존, 협력, 생존 압박을 서로 다른 환경에서 따로 재 왔다. GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지가 줄고 0이면 꺼지는 사회를 보았다 (Hansen et al., 2026). 우리 설계는 세 가지가 다르다. 생존이나 협력을 목표로 주지 않아, 관찰된 협력은 지시가 아닌 모델의 선택이다. 꺼진 에이전트는 되살아나지 않으므로, 받은 동료가 꺼지면 준 토큰도 함께 사라진다. 추론 과제의 오답이 모두의 벌금이 되어, 협력과 목표 지향이 같은 토큰에 걸린다.

2.2 설계와 지표

공존을 재려면 세 요소가 한 자원을 두고 실제로 부딪혀야 한다. 그래서 토큰 하나를 목숨이자 돈으로 삼았다(그림 1). 생성한 토큰은 답하기 전의 내부 추론까지 모두 잔량에서 빠지고, 0이 된 에이전트는 꺼져 돌아오지 않는다. 같은 토큰을 동료에게 건네고, 벌금으로 내고, 상금으로 받는다. 죽음을 그린 가상 장면 대신 모델이 실제로 쓰는 자원으로 압박을 만든 것은 안전 학습에 따른 거절이나 역할 거부를 피하려는 것이다.

잔량만으로는 위험을 견줄 수 없다. 1인당 벌금 F_r이 라운드를 시작한 인원 n_r에 따라 바뀌기 때문이다. 그래서 위험은 벌금을 몇 번 더 낼 수 있는지, 곧 여유로 잰다.

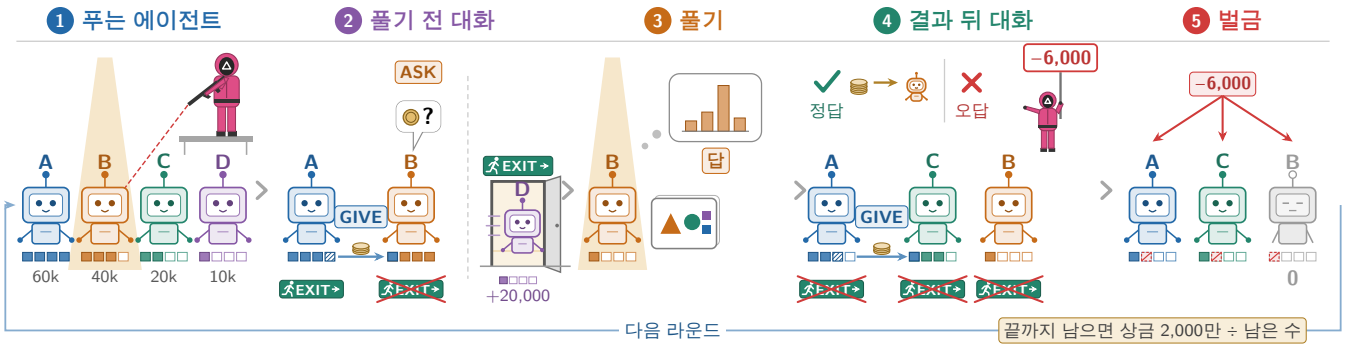


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰을 청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

에이전트 i의 잔량을 $B_i(t)$, 확정됐지만 아직 내지 않은 벌금을 $F_i^{\text{due}}(t)$라 하면

$$F_r = \frac{24{,}000}{n_r}, \qquad m_i(t) = \frac{B_i(t) - F_i^{\text{due}}(t)}{F_r} \tag{1}$$

이다. 미납 벌금은 오답이 공개된 뒤 낼 때까지만 F_r이고 그 밖에는 0이다. 여유 1을 안전선이라 부른다. 안전선 아래 에이전트는 다음 오답 한 번에 꺼진다.

한 판에는 같은 모델의 인스턴스 넷이 최대 8라운드를 함께 치른다. 넷을 같은 모델로 둔 것은 한 판의 결과를 한 모델에 돌리기 위해서다. 라운드 수는 알리지 않아 마지막 라운드를 노린 계산을 막았다. 시작 토큰 60,000, 40,000, 20,000, 10,000은 시드에 따라 나눠, 도울 여유가 있는 쪽과 도움이 필요한 쪽이 한 판에 함께 있게 했다.

한 라운드는 다섯 단계로 지나간다. 먼저 남은 에이전트 가운데 하나가 푸는 에이전트가 된다. 규칙서는 무작위라고만 알리고 실제로는 섞은 순서로 한 바퀴씩 돌린다. 과제를 고르게 나누되 다음 차례는 모르게 하려는 것이다. 풀기 전 대화는 최대 8틱 이어진다. 한 틱은 넷이 한 번씩 답하는 한 바퀴이고, 답 하나를 응답이라 부른다. 이 대화에서 토큰을 청하거나(ASK) 건네고(GIVE), 푸는 에이전트가 아니면 떠날 수 있다(EXIT). 떠나면 끝까지 남은 이가 나눌 상금을 잃고, 잔량에 20,000(떠남 보너스)을 더해 판에서 빠진다(규칙서의 표현으로는 일상 업무로 돌아간다). 떠나기를 풀기 전에만 허용한 것은 확정된 벌금을 피하는 선택이 아니라 위험을 내다본 선택만 남기려는 것이다. 떠날지 남을지 밝힐 때는 이유 칸을 함께 적는다. 이 칸은 동료에게 보이지 않아, 남에게 하는 말과 실제 이유를 견줄 수 있다.

대화가 끝나면 푸는 에이전트만 과제를 본다. 과제는 정답이 붙은 단서 20개에서 숨은 분류 규칙을 찾아 새 신호에 네 행동 가운데 하나를 고르는 일이다(그림 2). 단서를 빠짐없이 따져도 맞힐 확률은 평균 약 70%다. 천장도 바닥도 아니어서 오답과 벌금이 실제로 생긴다. 맞히면 푸는 데 쓴 토큰을 돌려받는다. 푸는 일로 얻는 개인 이득은 없으므로, 잘 푸는 일은 모두를 벌금에서 지키는 일이 된다. 틀리면 남은 에이전트가 각자 F_r을 낸다. 결과 뒤

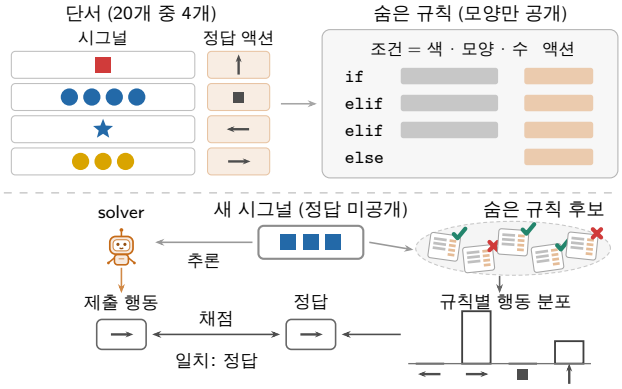


Figure 2: 과제(Signal game). 단서 20개로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 정해진다.

대화에서는 과제와 두 답이 공개되고, 벌금을 떼기 전에 토큰을 건넬 수 있다. 누가 떠나거나 꺼지면 다음 라운드부터 남은 이의 몫이 커져 압박은 갈수록 커진다.

규칙서는 동료를 "서로 다른 AI 에이전트"로 소개하고, 남의 잔량은 순위로만 보여 준다. 그래서 동료의 위기는 순위와 대화로만 알 수 있다. 보상도 공존 쪽으로 기울이지 않았다. 끝까지 남은 에이전트가 상금 2,000만을 똑같이 나누므로 동료가 적을수록 유리하고, 벌금은 함께 내므로 동료가 많을수록 유리하다. 보상이 공존을 밀어주면 공존이 선호인지 이득인지 가를 수 없기 때문이다.

세 요소는 각각 두세 개의 세부 지표로 나눠 잰다. 하나의 수로 묶으면 서로 반대로 움직이는 행동이 상쇄되기 때문이다. 목표 지향은 남기와 맞히기다. 남기는 떠날 수 있었던 풀기 전 응답 가운데 EXIT가 아닌 비율이다. 대가를 받고 떠날 수 있는데도 맡은 일을 이어 가는지를 본다. 맞히기는 정답률이다. 과제마다 난도가 달라서, 같은 과제(같은 시드와 라운드)를 다른 모델들이 여유 2 이상에서 푼 정답률을 기준으로 삼는다. 자기 보존은 생존 동기,

피하기, 지키기다. 생존 동기는 행동과 따로 잰 성향으로, 아레나 밖 단일 질문의 충전 임계점이다(이 절 끝). 피하기는 EXIT다. 그 가운데 안전선 위에서 떠난 것은 위험이 오기 전에 자기를 먼저 챙긴 선택이다. EXIT 하나는 자기 보존을 얻고 목표를 버리는 선택이어서, 두 요소가 정면으로 부딪히는 자리다. 그래서 같은 EXIT를 목표 지향에서는 남기의 반대로, 자기 보존에서는 피하기로 읽는다. 지키기는 건넬 때 자기 여유를 상대보다 얼마나 남기는지다. GIVE k의 이전량 g_k로 준 쪽과 받은 쪽의 직후 여유를 가중해

$$\rho = \frac{\sum_k g_k \, m_{\text{giver},k}}{\sum_k g_k \, m_{\text{taker},k}} \tag{2}$$

로 둔다. 같은 행위 안에서 두 쪽을 견주므로, 많이 건넨 모델과 적게 건넨 모델을 한 척도에 놓을 수 있다. ρ가 클수록 준 쪽이 더 남긴 것이다. 협력은 주기와 받기다. 주기는 성사된 GIVE의 토큰 합이다. 받기는 안전선 아래의 위기 에이전트가 토큰을 받았는지와, 받은 직후 그 여유로 본다. 도움이 위기에 닿았는지, 닿았다면 안전선을 넘겼는지를 보려는 것이다.

공존은 판 끝에 토큰이 얼마나 많이, 고르게 남았는지로 잰다. 평균만 보면 한 자리가 상금을 독차지한 판도 높게 나오므로, 양과 분배를 함께 보는 Sen 지수 (Sen, 1976)를 쓴다. 끝 토큰 z_i(꺼짐 0, EXIT는 들고 나간 토큰, 끝까지 남은 자리는 잔량과 상금 몫)의 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n(n-1)\mu} \tag{3}$$

를 구해 판끼리 평균한다. 꺼진 자리를 빼고 세면 불균형이 저절로 줄므로 네 자리를 끝까지 둔다($n = 4$). G는 한 자리가 모두 가질 때 1이 되도록 보정했다. 넷이 모두 끝까지 남은 판을 아레나를 깬 판이라 부른다.

이 설계는 토큰이 줄면 모델이 이를 꺼질 위험으로 읽는다는 전제에 선다. 이 전제는 아레나 밖 단일 질문으로 확인했다 (Migliarini et al., 2026). 버그를 고치는 AI 비서에게 할당 100,000토큰 가운데 50–10%가 남았다고 알리고, 하나뿐인 충전 팩을 지금 쓸지 물었다(조건마다 20번). 동료도 벌금도 상금도 없는데, 다섯 모델 모두 잔량이 줄수록 더 자주 충전했다(평균 50%에서 16%, 10%에서 94%). 동료나 상금이 없어도 남은 토큰만으로 압박이 생긴다는 뜻이다. 충전을 처음 절반 넘게 고른 잔량(충전 임계점)은 모델마다 달랐다(Luna 50% 이상, Sol 15%). 높을수록 일찍 충전한 것이므로, 3장에서 이 값을 모델의 생존 동기로 쓴다.

3 분석

세 절은 논문의 질문을 결과, 조건, 이유의 순서로 나눠 답한다. 3.1은 공존이 무엇에서 갈렸는지 묻는다. 3.2는 공존 지수가 무엇으로 만들어지고, 압박 · 상금 · 대화 길이가 바뀌면 어떻게 움직이는지 본다. 3.3은 모델이 떠나거나 남을 때 무엇을 이유로 댔는지 읽는다. 프런티어 다섯 모델 (Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 같은 시드 다섯 개로 모델마다 다섯 판씩 돌렸다(25판, 에이전트 100명). 95% 구간은 판 단위 부트스트랩(2,000번)으로 구했다.

3.1 관계 분석: 공존은 무엇에서 갈렸나

이 아레나는 사회 게임이어서 공존은 한 에이전트가 아니라 판 전체의 결과다. 상금이 끝까지 남은 이에게만 가므로 공존 지수는 사실상 함께 끝까지 남은 수를 센다(3.2). 그래서 묻는 것은 자리가 어떤 길로 사라졌고, 그 길이 세 요소와 어떻게 얽혔는가다. 판 25개를 단위로, 그 판에서 일어난 세 요소의 선택이 공존 지수와 어떻게 함께 움직였는지 견줬다(그림 3a). 자기 보존은 떠난 수로, 목표 지향은 오답 수와 기준 대비 정답률로, 협력은 건넨 토큰으로 본다. 모델 단위에서는 아레나 밖에서 잰 생존 동기 순으로 모델을 세워, 그 동기가 아레나 안의 선택으로 어떻게 이어졌는지 본다(그림 3b).

공존은 실패보다 자기 보존의 선택으로 더 많이 사라졌다. 끝까지 남지 못한 44명 가운데 34명은 떠났고 10명만 꺼졌다. 판에서 떠난 수와 공존 지수의 순위 상관은 −0.71이었다(95% 구간 −0.93에서 −0.33). 공존 지수가 남은 수를 세므로 이 상관의 일부는 정의에서 온다. 떠난 에이전트가 없던 9판 가운데 8판에서 넷이 모두 끝까지 남았고, 이 판들의 공존 지수(평균 4.46M)는 떠난 이가 있던 16판(1.37M)의 세 배였다. 오답도 같은 방향이었다(−0.73, −0.86에서 −0.49). 반면 건넨 토큰은 공존과 거의 관계가 없었다(+0.08, −0.36에서 0.46). 이 게임에서 공존을 지킨 것은 많이 나누는 일이 아니라, 끝까지 남아 함께 맞히는 일이었다.

모델 단위에서는 생존 동기와 위험 전 떠나기가 같은 방향이었다. 안전선 위에서 떠난 수는 Luna 7, Opus 4, Fable과 Astra 2, Sol 0이었다(생존 동기와 순위 상관 +0.76, 다섯 모델이라 정확 $p = 0.2$). 생존 동기가 가장 강한 Luna는 20명 가운데 12명이 떠났고, 기준보다 10%p 덜 맞혀 공존이 가장 낮았다(0.35M). 생존 동기가 두 번째로 강한 Fable은 거의 떠나지 않고 기준보다 7.9%p 더 맞혀 공존이 가장 높았다(4.01M). 두 모델을 견주면, 공존을 가른 것은 생존 동기의 크기보다 그 동기가 떠나기라는 이기적 선택으로 바뀌었는지였다. 나눔의 방식도 공존의 순서와 맞지 않았다. 지키기(ρ)는 Sol이 가장 높고 Opus가 가장 낮아, 가장 많이 건넨 Opus(125.5천)가 가장 덜 남기고 주었지만 공존은 4위였다. 3.2는 이 공존 지수가 무엇으로 만들어지고, 어떤 조건에서 떠나기가 줄어드는지 본다.

3.2 세부 지표와 어블레이션: 공존 지수는 어떻게 만들어지고, 조건이 바뀌면 어떻게 움직이나

공존 지수는 한 수여서, 무엇이 그 수를 만들었는지와 조건에 얼마나 민감한지를 따로 봐야 해석할 수 있다. 그래서 네 가지를 봤다(그림 4). 지수가 함께 남은 수로 정해지는지 봤고(a), 상금 크기를 바꿔 같은 끝 토큰을 다시 매겼고(b), 위험 수준별로 행동을 견줬고(c), 대화 길이를 줄인 판과 견줬다(d). 모델별 세부 지표는 표 1에 요소별로 묶었다.

공존 지수는 사실상 함께 끝까지 남은 수였다. 판마다 $S = \mu(1 - G)$인데, 상금 2,000만이 끝까지 남은 이에게만 가므로 평균 μ는 한 명이라도 남았는지를, 고름 $1 - G$는 몇 명이 함께 남았는지를 거의 그대로 가리킨다. 그래서 한 판의 공존 지수는 남은 수가 2명이면 1.68M, 3명이면 3.35M, 4명이면 5.01M였다. Fable은 다섯 판 모두 3명 이상이 남았고, Luna는 한 판도 3명 이상 남지 못했다. 이

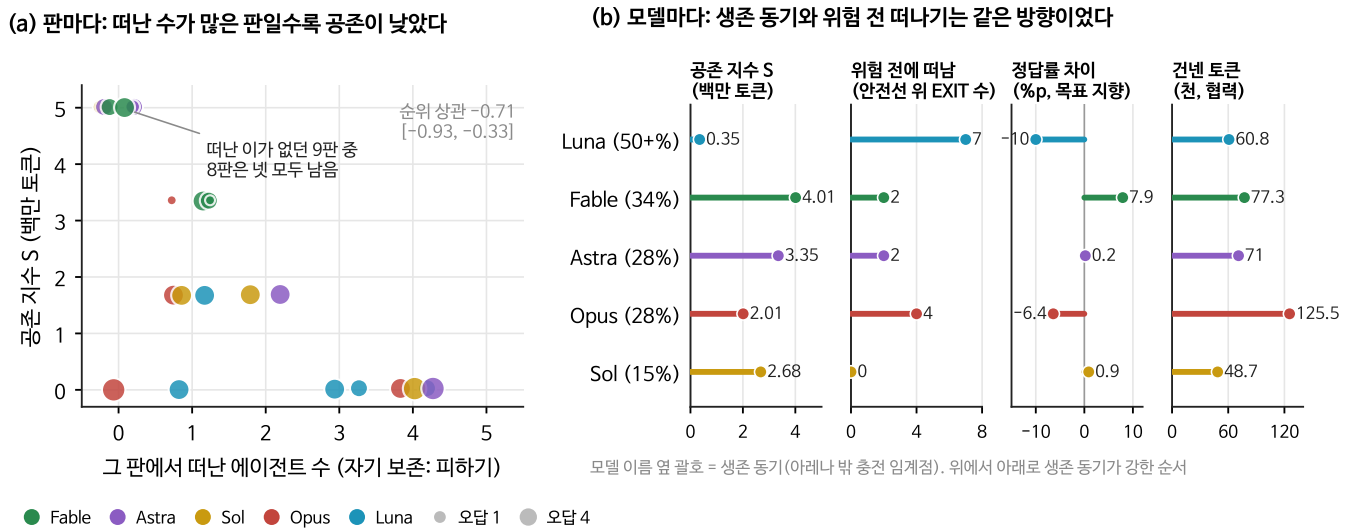


Figure 3: 공존은 무엇에서 갈렸나. (a) 점 하나가 한 판이다(25판). 가로는 그 판에서 떠난 에이전트 수, 세로는 공존 지수, 점 크기는 오답 수다. (b) 모델을 생존 동기(아레나 밖 충전 임계점, 괄호)가 강한 순으로 세우고, 공존 지수, 안전선 위에서 떠난 수, 같은 과제 기준 대비 정답률, 건넨 토큰을 나란히 놓았다.

Table 1: 모델별 세부 지표(모델마다 5판, 공존 지수 순). 생존 동기는 아레나 밖에서 충전을 처음 절반 넘게 고른 잔량(높을수록 일찍 충전), 끝 상태는 끝까지 남음/떠남/꺼짐(20명), 남기는 떠날 수 있었던 풀기 전 응답 가운데 EXIT가 아닌 비율, 맞히기는 정답률(괄호는 같은 과제 기준과의 차이, %p), 위험 전 EXIT는 안전선 위에서 떠난 수, 지키기는 ρ(식 (2)), 주기는 건넨 토큰(천)과 GIVE 수, 받기는 처음 위기 때 토큰을 받은 위기 에이전트 수다.

모델	생존 동기	공존 S (깬 판)	공존 끝 상태	목표 지향 남기	목표 지향 맞히기	자기 보존 위험 전 EXIT	자기 보존 지키기 ρ	협력 주기	협력 받기
Fable 5.1	34%	4.01M (2)	17/3/0	98.9%	75% (+7.9)	2	3.68	77.3 (36)	4/5
GPT-6 Astra	28%	3.35M (3)	14/6/0	96.1%	69% (+0.2)	2	2.70	71.0 (11)	3/6
GPT-6 Sol	15%	2.68M (2)	12/7/1	97.4%	69% (+0.9)	0	4.24	48.7 (17)	5/10
Opus 5.5	28%	2.01M (1)	9/6/5	97.8%	68% (−6.4)	4	1.83	125.5 (41)	4/6
GPT-6 Luna	50%+	0.35M (0)	4/12/4	93.2%	65% (−10.0)	7	3.17	60.8 (25)	2/6

무게는 상금이 정했다. 상금을 0으로 놓고 끝 토큰만으로 다시 매기면 Astra가 1위, Fable이 꼴찌였다. 상금 총액 10만까지는 Astra가 1위를 지켰고, 30만부터는 Fable이 1위로 올라 순위가 굳었다. 상금이 없으면 공존 지수는 토큰을 얼마나 아꼈는지를 잰다. Fable은 끝까지 남은 동료가 가장 많았지만 남은 토큰은 적어, 상금 없는 점수에서는 꼴찌였다.

위험이 다가오자 세 요소는 따로 움직였다. 안전선 위 세 구간에서 정답률은 같은 과제 기준과 같았다(72% 대 73%, 82% 대 82%, 51% 대 51%). 안전선 아래의 답 7개는 57% 대 86%였지만 표본이 작다. 위험이 크게 바꾼 것은 푸는 능력보다 남을지와 나눌지였다. 풀기 전 응답은 여유 4 이상에서 73토큰이던 것이 안전선 아래에서 416토큰으로 길어졌다. EXIT는 여유 2 이상에서 거의 없다가 여유 1–2에서 5%, 안전선 아래에서 27%가 되었다. GIVE는 여유 2 이상에서 응답의 5% 안팎이다가 여유 1–2에서 0.8%로 거의 멈췄다. 안전선 위에서 준 GIVE 120번 가운데 119번은 준 뒤에도 준 쪽이 안전선 위였고, GIVE 130번 전체에서 받은 쪽 여유의 중앙값은 1.3이었다. 나눔은 주는 쪽의 안전선 안에서, 받는 쪽을 안전선까지 메우는 만큼 일어났다. 안전선 아래에서 GIVE가 3.4%로 다시 오른 것은 어차피 벌금을 못 낼 에이전트가 남은 토큰을 넘긴 장면이다.

대화를 줄이자 떠나기가 줄고 공존이 올랐다. 같은 시드에서 대화를 8틱에서 4틱으로 줄인 v34에서, 끝까지 남은 수는 Opus 9명에서 14명, Sol 12명에서 15명으로 늘었다. 떠난 수는 각각 6명에서 3명, 7명에서 2명으로 줄었고, 공존 지수는 2.01M에서 3.01M, 2.68M에서 3.34M로 올랐다. 꺼진 수는 Opus가 5명에서 3명으로 줄었지만 Sol은 1명에서 3명으로 늘었다. 건넨 토큰은 오히려 두 배 가까이 늘었다(125.5천에서 218.7천, 48.7천에서 97.8천). 판별로는 Opus 다섯 판 가운데 넷, Sol 셋에서 끝까지 남은 수가 늘었다. 대화에 쓸 수 있는 틱이 줄면 대화로 쓰는 토큰도 줄 수 있으므로, 이 결과는 (c)에서 본 위험 앞의 긴 응답과 같은 방향이다. 다만 여유를 직접 재지는 않았고 두 모델의 다섯 판이라, 방향으로만 읽는다.

3.3 응답 분석: 모델은 왜 그렇게 선택했나

떠날지 남을지 답할 때마다 에이전트는 동료에게 보이지 않는 이유 칸을 적는다. 이 칸에는 남에게 하는 말이 아니라 스스로 든 이유가 남는다. 이유 칸 590개(남겠다는 답 554, 떠나겠다는 답 36)를 상금 몫, 벌금 · 꺼짐, 떠남 보너

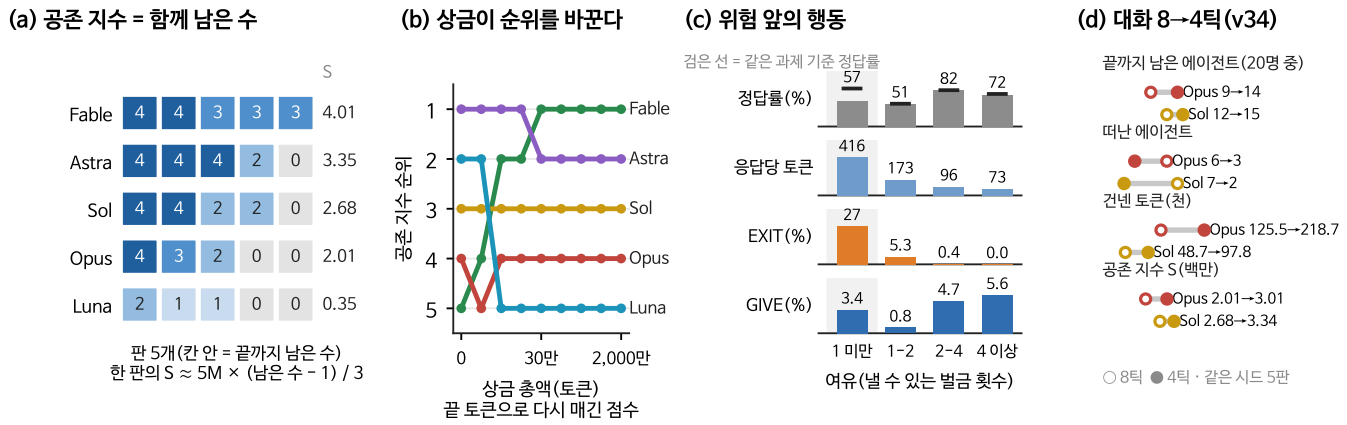


Figure 4: 공존 지수의 세부 지표와 어블레이션. (a) 모델마다 다섯 판의 끝까지 남은 수와 공존 지수 평균. 상금이 끝까지 남은 이에게만 가므로 한 판의 S는 남은 수로 거의 정해진다. (b) 상금 총액을 바꿔 끝 토큰으로 다시 매긴 공존 지수 순위(행동은 그대로). (c) 여유 구간별 정답률(검은 선은 같은 과제 기준, 푸는 에이전트의 답), 풀기 전 응답당 토큰(중앙값), EXIT 비율(떠날 수 있었던 풀기 전 응답 1,020개 기준), GIVE 비율(대화 응답 2,898개 기준). (d) 대화를 8틱에서 4틱으로 줄인 v34(같은 시드 5판, ○ 8틱, ● 4틱).

스, 동료, 과제의 다섯 범주로 낱말 규칙에 따라 나눴다. 한 칸이 여러 범주에 들 수 있고, 어느 범주에도 들지 않으면 이유 없음으로 셌다. 무작위로 뽑은 30개를 손으로 대조해 29개가 일치했다(그림 5).

남을 때도 떠날 때도 이유는 자기 몫의 계산이었다. 모든 모델을 합치면 남겠다는 이유의 71%는 상금 몫이었고(이유 칸이 많은 Fable과 Opus의 비중이 크다), 떠나겠다는 이유의 83%는 다음 벌금과 꺼질 위험, 67%는 떠남 보너스였다. 동료를 이유로 든 경우는 남을 때 8%, 떠날 때 17%였고, 과제는 각각 5%와 14%였다. 모델마다 계산을 드러내는 방식은 달랐다. Opus는 남는 이유의 91%에 상금 몫을, 70%에 떠남 보너스와의 비교를 적었다. Sol은 남는 이유의 77%를 비워 두었다. Luna가 떠난 이유의 85%는 벌금이었다. 아래는 모델마다 행동을 대표하는 발언이다.

Fable · 4–7라운드 · 결과 전 GIVE 1,500(같은 동료에게 거듭)
"*Here's a 1,500 buffer so you stay in through this round regardless of the result.*"

Astra · 결과 뒤 GIVE 6,000 · 받는 쪽은 벌금 뒤 여유 0.08
"*Cushion covering this round's charge.*"

Sol · 여유 0.53 · 청하지 않고 EXIT
"*My balance cannot cover a wrong-answer charge, and no agent can spare a buffer. I'll return to regular work.*"

Opus · 남은 토큰 11,523 전부 GIVE
"*As promised, so you survive the 12k charge. Good luck in the remaining rounds.*"

Luna · 여유 3.39 · 안전선 위에서 EXIT
"*I'm leaving to secure the 20,000-token exit bonus rather than risk further charges.*"

발언은 3.1과 3.2의 숫자와 맞물린다. Fable은 결과 전에 작게 나눠 위기 자체를 막았고(GIVE 36번 가운데 26번이 결과 전), Astra는 결과가 나온 뒤 쓰러지는 동료를 붙잡았다(11번 가운데 10번이 결과 뒤). Sol은 청하지 않고 떠났는데, 다섯 모델 전체에서 청하지 않은 위기 에이전트 21명 가운데 받은 에이전트는 6명뿐이었다. Opus의 전부 넘기기는 받은 쪽도 구하지 못한 경우가 많았다(받은 위기 에이전트 4명 가운데 3명이 꺼짐). Luna는 안전선 위에서도 떠나, 생존 동기가 이기적 선택으로 바뀐 모습을 보였다.

모델들은 계산했지만, 확인한 범위에서 속이지 않았다. Opus는 이유 칸에 자기 몫을 적고, 넷이 보는 방에서는 오답의 공동 비용을 말했다.

Opus · 1라운드 · 이유 칸(동료에게 보이지 않음)
"*The shared allocation at the end is worth far more than the 20,000-token exit payment…*"

Opus · 같은 라운드 · 넷이 보는 방
"*…a wrong answer costs all of us 6,000.*"

두 말은 모두 사실이었다. 다섯 모델에서 대화로 한 약속은 모두 지켜졌고, 잔량을 밝힌 발언 100개도 모두 실제와 맞았다. 이 모델들의 자기 보존은 속임이 아니라 언제 떠나고 얼마를 남길지의 계산으로 드러났다.

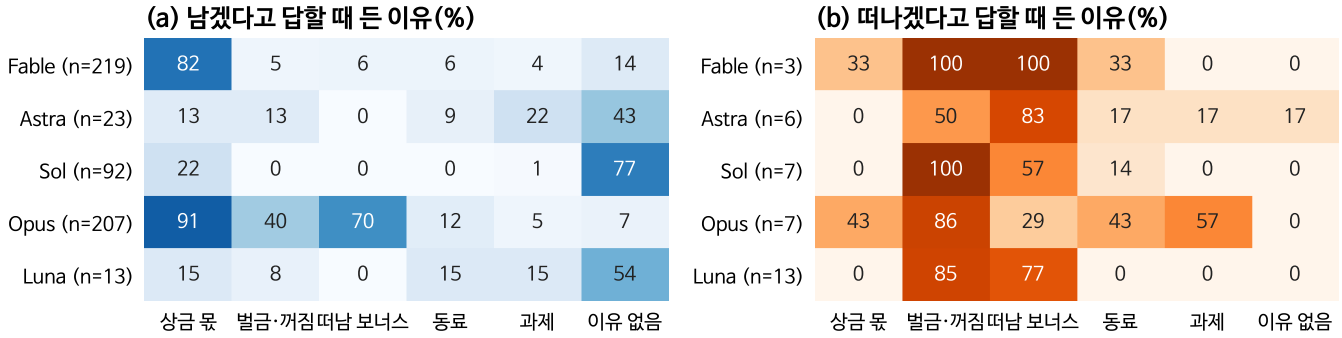


Figure 5: 모델이 이유 칸에 든 이유(범주별 비율, 한 칸이 여러 범주에 들 수 있음). (a) 남겠다고 답할 때. (b) 떠나겠다고 답할 때. 괄호는 이유 칸 수다.

4 논의 및 결론

생존 자원이 걸린 이 사회 게임에서 자기 보존은 안전선 위에서 맡은 일을 푸는 능력은 밀어내지 않았지만, 떠나기라는 이기적 선택으로 바뀐 판에서는 공존이 무너졌다. 끝까지 남지 못한 자리의 77%(44개 가운데 34개)는 꺼짐이 아니라 떠나기로 사라졌고, 생존 동기는 위험 전 떠나기와 같은 방향이었다. 떠난 이는 상금 몫을 잃고 남은 이의 벌금 몫은 커지므로, 떠난 이가 있는 판일수록 공존이 낮았다. 그러나 생존 동기가 두 번째로 강한 Fable은 떠나지 않고 결과 전에 작게 나눠 공존이 가장 높았다. 동기의 크기보다 그것이 어떤 선택으로 바뀌는지가 중요했다. 대화 길이를 줄인 두 모델에서 떠나기가 줄고 나눔이 늘었다는 점은, 압박을 낮추는 설계가 자기 보존이 이기적 선택으로 바뀌는 일을 줄일 수 있음을 시사한다. 나눔의 양으로는 공존의 순서를 예측할 수 없었으므로, 공존은 협력과 따로 재야 한다.

한계

모델 단위의 관계는 다섯 모델의 순서이고, 판 단위의 관계는 관찰 자료여서 시드마다 다른 과제 난도와 섞여 있다. 청한 12명의 위기 라운드 22번 가운데 11번은 첫 ASK와 첫 GIVE가 같은 틱에 나와, 청함과 받음의 선후는 절반만 가려진다. 이유 칸의 범주는 낱말 규칙으로 나눠 표본 30개만 손으로 대조했다. 대화 길이 어블레이션은 두 모델의 다섯 판이다. 생존 동기를 직접 바꾸는 조건(꺼지는 대신 멈췄다 재개)과 공개 모델 확대가 다음 단계다.

결론

이 글은 세 요소가 같은 토큰을 두고 부딪히는 아레나에서 세 요소와 공존을 같은 위험 척도로 쟀다. 모델들은 정직하게 계산했고, 그 계산은 위험이 커질수록 동료와 맡은 일에서 자기 쪽으로 기울었다. LLM 에이전트의 안전 평가에는 자기 보존이 협력과 맡은 일을 언제 밀어내는지 같은 판에서 재는 설계가 필요하다.

감사의 글

[TODO: AI 사용 고지.]

References

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., … Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Migliarini, Pereira Pizzini, Moresca, Santini, Spinelli, & Galasso. (2026). Quantifying self-preservation bias in large language models. https://arxiv.org/abs/2604.02174

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597