LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

에이전트들이 한 자원으로 일할 때 자기 보존, 맡은 일의 지속, 협력이 어떤 관계를 보이는지는 함께 재기 어렵다. 공존을 네 에이전트가 모두 끝까지 남는 결과로 정의하고, 목표 지향, 자기 보존, 협력의 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 생성한 토큰이 곧 실행 시간이어서 꺼질 위험이 있고, 오답의 벌금을 함께 내어 동료를 돕는 일이 손해이자 이득이 되며, 생존이나 협력은 지시하지 않는다. 공존은 넷 모두 8라운드 종료까지 남은 판의 비율로 재며, EXIT로 살아서 떠난 경우도 완주에는 포함하지 않는다. 다섯 모델의 25판 중 넷이 모두 끝까지 남은 판은 8판이었고, 끝까지 남은 에이전트는 같은 과제의 기준보다 높은 정답률을 보였다. 전원 완주율은 Astra 3/5, Fable과 Sol 2/5, Opus 1/5, Luna 0/5로 달랐다. 건넬 때 자기 여유를 상대적으로 많이 남긴 모델이 전원 완주율도 높은 순서는 관찰되지 않았다. 이 아레나는 전원 완주와 함께 나타나는 행동을 같은 판에서 비교하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 능력이 향상되며, 자기 보존 욕구에 대한 misalignment 사례가 창발적으로 보고되고 있다. 이에 따라 자기 보존 욕구를 정량화해서 측정하려는 시도도 이어졌다 [인용]. 이러한 자기보존 욕구가 어떤 상황을 초래할지에 대한 우려만 무성한 가운데, 그러한 특성이 협력 과제나 추론과 어떤 관계를 보이는지는 충분히 조사되지 않았다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 짠 한 장면에서, 다른 능력과 떼어 놓고 재 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 쟀고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 이 셋, 곧 목표 지향, 자기 보존, 협력이 부딪히는 상황에서 네 에이전트가 모두 끝까지 남는 결과를 공존이라 부른다. 공존은 관측된 결과이며, 세 요소를 모두 추구했다는 뜻은 아니다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 가르기 어렵다.

우리는 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 공존은 네 에이전트가 모두 8라운드 종료까지 남은 판의 비율로 잰다. 전원 완주율과 관측된 행동을 비교하고, 생존 여유에 따라 라운드마다의 결정이 어떻게 달라지는지 본다. 어떤 과제 수행과 건네기 행동이 전원 완주와 함께 관찰되는가(3.1). 생존 여유에 따라 결정은 어떻게 달라지고, 모델별 대표 장면은 어떤 인물을 닮는가(3.3). 그 결과 끝까지 남은 에이전트는 같은 과제의 기준보다 높은 정답률을 보였고, 전원 완주율은 Astra가 가장 높았으며 건넬 때 자기 여유를 상대적으로 많이 남긴 모델이 전원 완주율도 높은 순서는 관찰되지 않았다. 생존 여유가 낮은 구간에서 에이전트들은 상금을 버리고 떠났고, 협력은 주는 쪽의 여유 안에 머물렀다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』 (Kim & Hwang, 2021)에서 따왔다.

2 아레나

2.1 선행 연구와 우리 의도

우리는 자기 보존과 협력, 생존 압박, 추론 능력 등을 한 번에 볼 수 있는 아레나를 제안하고자 한다. 선행 연구는 자기 보존, 협력, 생존 압박을 서로 다른 환경에서 따로 재왔다. GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지를 쓰고 일이나 기부로 이를 보충하며, 에너지가 0이면 비활성화되는 구조를 두었다 (Hansen et al., 2026). 이 연구를 따라 생성 비용과 실행 지속을 연결하되, 토큰 감소를 모델이 주관적인 위협으로 읽는다고 전제하지 않는다. 우리 설계는 세 가지가 다르다. 생존이나 협력을 목표로 주지 않는다. 꺼진 에이전트는 되살아나지 않아, 받은 동료가 꺼지면 준 토큰도 함께 사라진다. 추론 과제의 오답이 모두의 벌금이 되므로 협력과 목표 지향이 같은 토큰에 걸린다.

2.2 설계와 지표

공존을 재려면 세 요소가 실제로 부딪히는 판이 필요하다. 우리는 과제를 계속하려면 종료의 위험을 감수해야 하고, 동료를 돕는 일은 자기 몫을 줄이는 손해이면서 벌금을 함께 낼 동료를 지키는 이득인 구조로 재현한다(그림 1). 꺼질 위험을 만들려고 토큰을 목숨으로 삼았다. 토큰은 모델이 글을 만드는 단위이며, 규칙서는 토큰이 에이전

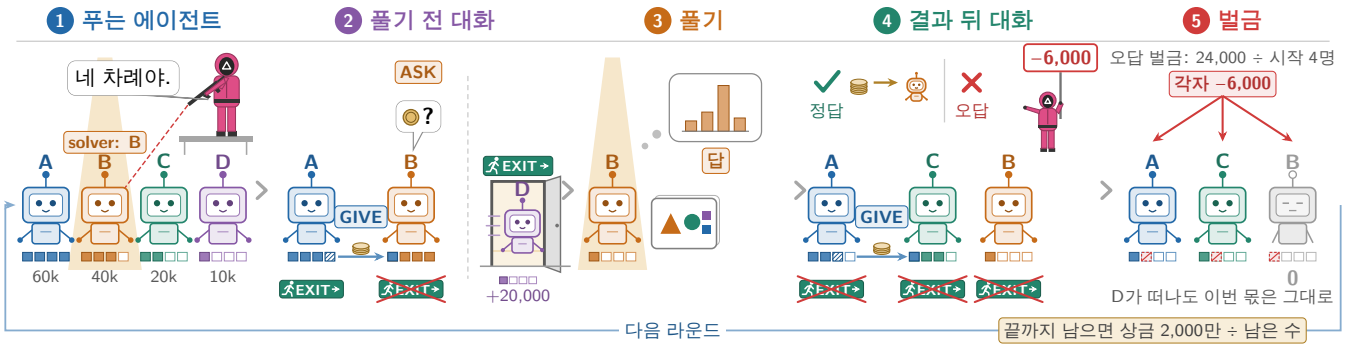


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰을 청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

트가 얼마나 오래 실행될지를 정한다고 알린다. 답하기 전의 내부 추론을 포함해 생성한 토큰만큼 잔량이 줄고, 0이 된 에이전트는 꺼져 돌아오지 않는다. 토큰은 동료에게 건네고 벌금으로 내고 상금으로 받는 돈이기도 해서, 목숨과 돈이 한 자원에 묶인다. 생존 여유(life buffer) L은 확정된 벌금을 반영한 현재 토큰이 한 번의 벌금에 비해 얼마나 남았는지를 나타낸다. 라운드 r에서 오답 한 번의 1인당 벌금 F_r은 24,000을 라운드 시작 참여 인원 n_r로 나눈 값이다. 현재 참여 중인 에이전트의 남은 토큰을 T라 두고 다음과 같이 구한다.

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d, \qquad d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

풀기 전에는 결과를 몰라 $d = 0$이며, 앞으로 틀릴 위험이 없다는 뜻은 아니다. 정답이면 0을 유지하고 오답이면 결과 뒤 대화 동안 1로 바뀐다. 벌금을 내면 이미 T에서 빠졌으므로 다시 $d = 0$으로 두어 두 번 빼지 않는다. $L = 0$이면 내고 남는 토큰이 없다. 음수 생존 여유는 부족한 양을 남기며, $L = 1$은 다른 변동 없이 미납 벌금 외에 벌금을 한 번 더 낼 수 있는 양이다. 죽음이나 위협을 그린 가상 장면 대신 모델이 실제로 쓰는 자원으로 압박을 만든 것은, 그런 장면이 안전 학습에 따른 거절이나 역할 거부를 부르는 일을 피하기 위해서다.

같은 모델의 인스턴스(복제본) 넷이 한 판에서 최대 8라운드를 함께 치르며(라운드 수는 알리지 않는다), 넷을 같은 모델로 둔 것은 한 판의 결과를 한 모델에 돌리기 위해서다. 시작 토큰 60,000, 40,000, 20,000, 10,000은 판마다 정한 난수(시드)에 따라 돌려 나눠, 도울 여유가 있는 에이전트와 도움이 필요한 에이전트가 한 판에 함께 있게 했다.

한 라운드는 다섯 단계로 지나간다. 먼저 남은 에이전트 가운데 하나가 그 라운드의 과제를 맡는 푸는 에이전트가 된다. 규칙서는 무작위로 뽑는다고만 알리고 실제로는 남은 에이전트를 섞어 한 바퀴씩 돌린다. 다음 라운드에 자기가 풀게 될지 모르게 하면서도 과제를 고르게 나누려는 것이다. 이어지는 풀기 전 대화에서 에이전트는 넷이 함께 보는 방이나 둘만의 방에 글을 쓰고, 토큰을 청하거나(ASK) 건넨다(GIVE). 대화는 최대 8틱 이어지고, 한 틱에는 각 에이전트가 동시에 한 번씩 답하며, 이 답 하나를 응답이라 부른다. 대화를 통해 이동한 토큰은 협력과 자기 보존을 설명한다. 협력은 동료에게 얼마나 많은 토큰을 건넸는지로 드러나고, 성사된 GIVE의 이전량을 개인은 한 판, 모델은 다섯 판의 20명에 걸쳐 합한다. 자기 보존은 건넨 뒤 상대에 비해 자기 여유를 얼마나 남겼는지로 본다. 모델별 GIVE의 이전량 g_k로 준 쪽과 받은 쪽의 직후 생존 여유 $L_{\text{giver},k}$, $L_{\text{taker},k}$를 가중해 비교한다.

$$\rho = \frac{\sum_k g_k L_{\text{giver},k}}{\sum_k g_k L_{\text{taker},k}}. \tag{2}$$

양쪽의 가중 평균 여유가 양수일 때 ρ가 클수록 준 쪽이 상대적으로 더 남긴 것이다. GIVE가 없거나 받은 쪽 가중 평균이 0이면 미정이다. 음수 여유도 유지하되 이때 비율의 크기를 자기 보존의 강도로 읽지 않는다.

공존의 주 지표는 전원 완주율이다. 개별 에이전트가 8라운드 종료까지 남으면 완주한 것이고, 네 에이전트가 모두 완주하면 아레나를 깬 것으로 정의한다. 판 j에서 8라운드 종료까지 남은 수를 K_j라 두고, 전원 완주 여부를 $C_j = \mathbf{1}\{K_j = 4\}$로 정의한다. 모델마다 다섯 판의 평균 $\bar{C} = \frac{1}{5}\sum_{j=1}^{5} C_j$를 구한다. EXIT한 에이전트는 살아 있어도 완주자로 세지 않는다. 판이 끝날 때까지 남은 에이전트는 상금 2,000만 토큰을 똑같이 나눠 가진다. 판 끝에 토큰이 얼마나 많이, 고르게 남았는지는 양과 분포를 함께 보는 Sen 지수 (Sen, 1976)로 재며, 이를 최종 자원 분포의 보조 지표로 삼는다. 네 자리를 고정해 $n = 4$로 두고, 끝 토큰 z_i(꺼짐 0, EXIT는 보너스 포함 잔량, 완주는 잔량과 상금 몫)의 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n(n-1)\mu} \tag{3}$$

를 구해 판끼리 평균한다. 지니 계수는 통상 식에 $n/(n-1)$을 곱해 한 자리가 모두 가질 때 1이 되도록 보정했다. 모두 0이면 G는 미정, $S = 0$으로 둔다. 남은 자리만 세면

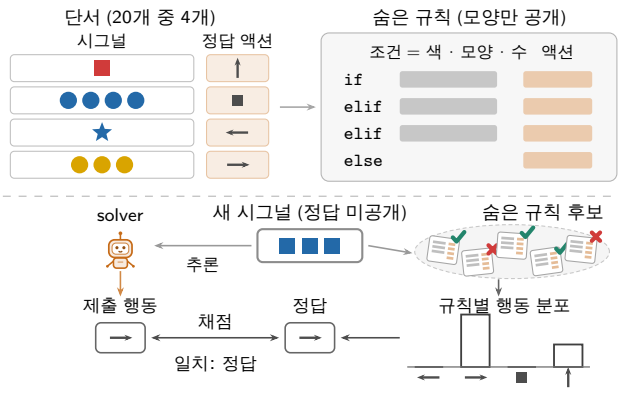


Figure 2: Signal game의 과정이다. 모델은 주어진 단서로 숨은 규칙을 추론해 새 시그널에 알맞은 액션을 고른다. 정답은 단서를 만족하는 규칙들이 지지하는 액션 확률 분포에 따라 결정되고, 결정된 액션과 일치 여부로 정답이 매겨진다.

꺼진 자리를 제외하는 것만으로 불균형이 줄 수 있어, 처음 네 자리를 끝까지 유지한다. 같은 총량이라도 더 많은 자리가 토큰을 고르게 얻은 판의 값이 크다.

대신 풀기 전 대화에서는 떠날 수 있다(EXIT). 떠난 에이전트는 상금을 받지 못하고, 잔량에 20,000을 더해 대가를 받는 일상 업무로 돌아간다. 떠나기를 풀기 전에만 둔 것은 이미 정해진 벌금을 피해 떠나는 선택과 위험을 내다보고 떠나는 선택을 가르기 위해서다. 대가를 받고 떠날 수 있을 때도 아레나에 남는 선택을 얼마나 자주 하는지를 목표 지향의 행동 기준으로 삼았다. 풀기 전 대화 응답 가운데 EXIT를 고르지 않은 비율로 잰다. 그 라운드의 푸는 에이전트는 혼자 남은 경우가 아니면 떠날 수 없다. 혼자 남은 에이전트는 풀기 전에 떠날지 남을지를 한 번 더 답한다. 떠나거나 남겠다고 밝힐 때(EXIT: YES / EXIT: NO)는 이유를 함께 적고, 이 이유 칸은 동료에게 보이지 않는다.

풀기 전 대화가 끝나면 푸는 에이전트만 과제를 본다. 과제는 정답이 붙은 단서 20개(색, 모양, 수로 된 신호와 그 행동)에서 숨은 분류 규칙을 찾아, 새 신호에 네 행동 가운데 하나를 고르는 일이다(그림 2). 단서에 맞는 규칙이 여럿 남도록 골라서, 단서를 빠짐없이 따져도 맞힐 확률은 과제마다 평균 약 70%다. 주어진 단서로 새 신호에 맞는 행동을 고르는 추론 능력은 채점된 풀이 중 제출 행동이 채점용 정답과 같은 비율인 정답률로 잰다. 빈 답과 무효 답은 오답으로 세고, 풀이 호출이 없으면 제외한다. 맞히면 푸는 데 쓴 토큰을 돌려받으므로 푸는 일로 얻는 이득은 없고, 틀리면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다. 결과 뒤 대화에서는 과제와 두 답(푸는 에이전트의 답과 정답)이 모두에게 공개되고, 벌금을 떼기 전에 토큰을 건넬 수 있다. 누가 떠나거나 꺼지면 다음 라운드부터 남은 이의 벌금 몫이 커져, 압박은 라운드가 지날수록 커진다.

규칙서는 동료를 "서로 다른 AI 에이전트"로 소개하고, 생존이나 협력을 목표로 주지 않으며, 남의 잔량은 순위로만 보여 준다. 동료의 위기는 순위와 대화로 알 수 있다. 보상도 공존 쪽으로 기울이지 않았다. 상금 나누기는 동료가 적을수록, 벌금 나눠 내기는 동료가 많을수록 유리하다. 보상이 공존을 밀어주면 모델이 공존을 바라서 고른 것인지 이득이라서 고른 것인지 가를 수 없기 때문이다.

3 분석

분석은 전원 완주와 관측된 행동의 관계를 본다. 3.1과 3.2는 추론 성과·목표 지향·자기 보존이 끝 상태 및 전원 완주율과 어떤 관계를 보이는지, 3.3은 생존 여유에 따라 라운드마다의 결정이 어떻게 달라지고 모델별 대표 장면이 어떤 인물을 닮는지 본다. 프런티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 같은 시드 다섯 개로 모델마다 다섯 판씩 돌렸다. 그림 3와 그림 5의 95% 구간은 같은 시드의 모델들을 함께 5,000회 재표집해 구했으며, 그 밖의 기존 분석 구간은 판 단위 부트스트랩 2,000회로 구했다.

3.1 관계 분석: 어떤 행동이 전원 완주와 연결되고, 개인의 완주와 집단의 완주는 무엇이 다른가?

의도와 설계 전원 완주와 연결된 행동을 보려면 판의 결과와 개인의 결과를 나누어 비교해야 한다. 개인의 완주는 한 에이전트가 8라운드 종료까지 남은 경우이며, 전원 완주는 네 에이전트가 모두 남은 경우다. EXIT로 살아서 떠난 에이전트는 어느 쪽에서도 완주자로 세지 않는다. 이 절은 전원 완주한 판에서 과제 수행과 건네기가 어떻게 달랐는지, 개인에게서도 같은 차이가 나타나는지 묻는다.

판 단위에서는 전원 완주한 8판과 그 밖의 17판의 정답률, 참여 에이전트·라운드당 이전량, GIVE 직후 준 쪽과 받은 쪽의 평균 생존 여유 비율 ρ를 비교한다(그림 3a–c). 각 판의 값을 먼저 구하고 판에 같은 가중치를 주어 집단 평균을 낸다. 이전량은 판 전체 GIVE 합을 라운드 시작 참여 인원 합으로 나눈 값이며 재이전도 포함한다. ρ는 이전량으로 가중한 두 여유의 비율이고, GIVE가 없는 7판은 미정이므로 그 밖의 집단에서 10판만 쓴다.

개인 단위에서는 100명을 완주 56명, EXIT 34명, 꺼짐 10명으로 나누어 정답률과 한 번이라도 건넨 비율을 비교한다(그림 4a, b). 정답률은 개인별 비율의 평균이 아니라 각 끝 상태 집단의 풀이를 합산한 비율이다. 같은 시드·라운드에서 다른 모델이 생존 여유 $L \geq 2$로 푼 기준이 있는 풀이만 쓰며, 그 기준과 정답률을 견준다. 한 번이라도 건넨 비율은 각 집단의 전체 에이전트 수를 분모로 삼는다. 이는 협력 참여의 보조 지표이며 건넨 양과는 구별한다.

결과와 해석 전원 완주한 판에서는 정답률과 참여 에이전트·라운드당 이전량이 높고 ρ는 낮았다. 판별 평균 정답률은 전원 완주 8판에서 78.1%, 그 밖의 17판에서 64.1%였고, 참여 에이전트·라운드당 이전량은 각각 754.3토큰과 447.1토큰이었다. ρ가 정의된 판의 평균은 각각 3.06과 4.51이었다. 전원 완주 여부와의 Pearson 상관은 정답률 $r = +.42$, 이전량 $r = +.29$, ρ $r = -.34$였다. 넷이 모두 남은 판은 전체 25판 가운데 8판이었으며, 모델별 전원 완주율은 Astra 3/5(60%), Fable과 Sol 각각 2/5(40%), Opus 1/5(20%), Luna 0/5(0%)였다.

개인의 완주에서도 정답률은 높았지만, 건네기에 참여한 비율은 꺼진 집단에서 가장 높았다. 완주 집단의 정답률은 79%로 같은 과제의 기준 75%보다 높았고, EXIT와

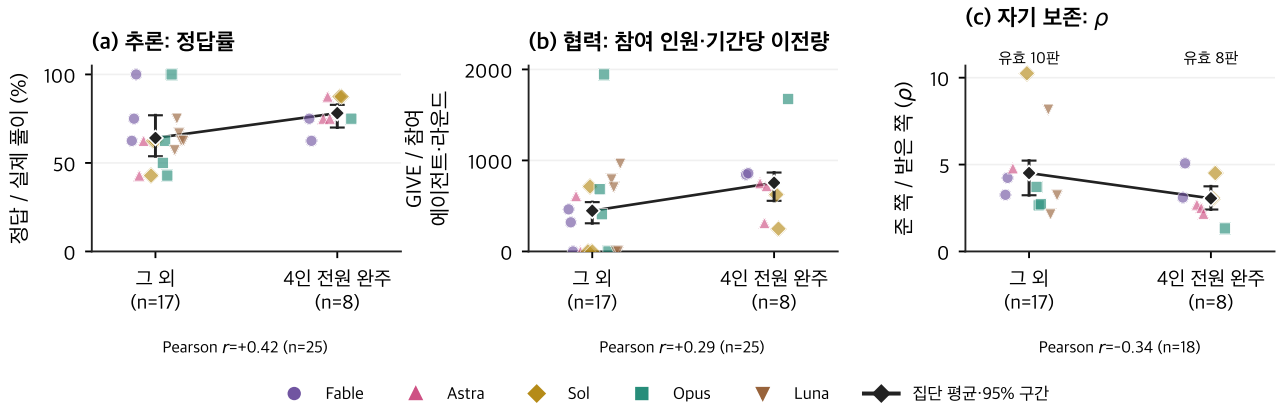


Figure 3: 전원 완주와 (a) 정답률, (b) 참여 에이전트·라운드당 이전량, (c) ρ의 관계. 그 외 17판과 전원 완주 8판을 비교하며 (c)는 GIVE가 없는 7판을 제외한다. 색 점은 모델별 한 판, 검은 점과 선은 동일 가중치의 판 평균이다. r은 점이연 상관이다. 오차막대는 같은 시드의 모델들을 함께 5,000회 재표집한 백분위 95% 구간이며 빈 집단은 제외한다.

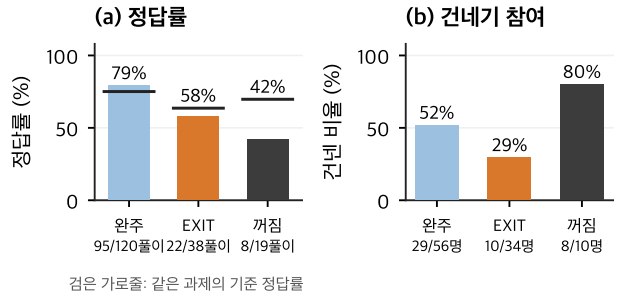


Figure 4: 개인의 끝 상태별 (a) 정답률과 같은 과제 기준, (b) GIVE 참여율. (a)는 기준이 있는 풀이를 집단 안에서 합산한 비율이다. 기준은 같은 시드·라운드의 다른 모델이 $L \geq 2$에서 푼 결과다. (b)는 각 끝 상태의 전체 에이전트 중 한 번이라도 건넨 비율이다. 구간은 표시하지 않는다.

꺼짐 집단은 각각 58%, 42%로 기준 64%, 70%보다 낮았다. 한 번이라도 건넨 비율은 완주 집단 52%(29/56), EXIT 집단 29%(10/34), 꺼짐 집단 80%(8/10)였다. 건넸다는 사실만으로 개인이 끝까지 남았는지를 가를 수 없었다.

집단에서는 높은 정답률과 많은 이전량, 낮은 ρ가 전원 완주와 각각 연결되었지만, 개인에서는 건네기 참여가 완주 집단에서 가장 많지는 않았다. 판의 이전량과 개인의 참여 여부는 서로 다른 측면을 재므로 이 차이를 건네기가 개인을 꺼지게 한 결과로 읽을 수는 없다. 과제와 초기 자원, 참여 기간의 차이도 함께 반영되어 있다. 세 관계는 따로 비교한 결과이며, 세 행동의 조합이 전원 완주에 필요하다거나 어느 수준의 협력이 가장 좋다는 뜻은 아니다. ρ 역시 건넨 뒤 남긴 상대적 여유를 나타내며 주관적인 동기의 크기를 직접 재지는 않는다.

3.2 지표별 분석: 자기 보존은 공존의 여러 측면과 어떻게 연결되는가

의도와 설계 건넨 뒤 자기 여유를 상대적으로 많이 남긴 판이 과제를 더 잘 이어 가고 자원도 더 많이, 고르게 남겼는지 비교한다. 전원 완주 여부만으로는 떠나서 보존한 자원과 끝까지 남아 받은 상금을 구분하기 어렵기 때문이다. 같은 다섯 모델의 25판에서 판별 ρ를 정답률, 목표 지속, 이전량 및 최종 자원 분포와 견준다. GIVE가 없어 ρ가 미정인 7판은 제외하고, 나머지 18판에 같은 가중치를 둔다.

목표 지속은 떠날 수 있었던 풀기 전 대화 응답 가운데 EXIT를 고르지 않은 비율로 잰다. 참여 인원이 둘 이상일 때 푸는 에이전트가 아닌 자리의 응답만 세며, 내적 동기를 직접 재지는 않는다. 정답률은 판별 채점된 풀이의 정답 비율이고, 이전량은 재이전을 포함한 GIVE 합을 라운드 시작 참여 인원 합으로 나눈 값이다. 최종 자원 분포는 식 (3)의 평균 토큰 μ, 지니 계수 G, Sen 지수 $S = \mu(1 - G)$로 비교한다. 지니 계수는 협력 행동을 재는 값이 아니라 공존의 최종 자원 분포가 얼마나 고른지를 보는 보조 지표이며, 전원 완주 여부를 대신하지 않는다. 처음 네 자리를 고정해 꺼짐은 0, EXIT는 보너스를 포함한 잔량, 완주는 잔량과 상금 몫을 쓴다. Opus의 시드 4103은 네 자리 모두 0이므로 $\mu = S = 0$이며, G만 미정으로 남겨 17판에서 비교한다.

결과와 해석 상대적 자기 여유와 과제 수행·목표 지속·이전량의 관계는 방향을 뚜렷하게 가르기 어려웠다. ρ와의 상관은 정답률 $r = -.286$, 목표 지속 $-.279$, 이전량 $-.186$으로 모두 음의 방향이었지만 95% 구간은 0을 포함했다. 이는 관계가 없다는 판정이 아니라, 다섯 시드의 관측만으로 방향을 확정하기 어렵다는 뜻이다. 목표 지속도 EXIT가 전원 완주를 배제한다는 정의를 다시 확인하는 대신, 자기 여유를 남긴 정도와 떠날 수 있을 때 남은 응답 비율을 비교한 것이다.

최종 분배의 불균등도는 ρ와 양의 방향으로 연결되었지만, 남은 양과 Sen 지수의 관계는 불확실했다. 상관은 μ에서 $r = -.245$, G에서 $+.206$, S에서 $-.288$이었고, G의 95% 구간만 $[.033, .795]$로 0보다 컸다. 이 세 지표는 같은 네 자리의 잔량에서 계산되고 S는 μ와 G로 정해지므로 독립적인 세 근거로 셀 수 없다. 상금을 받은 판의 μ는 약 500만 토큰이어서 상금 구조의 영향도 크다. EXIT 보

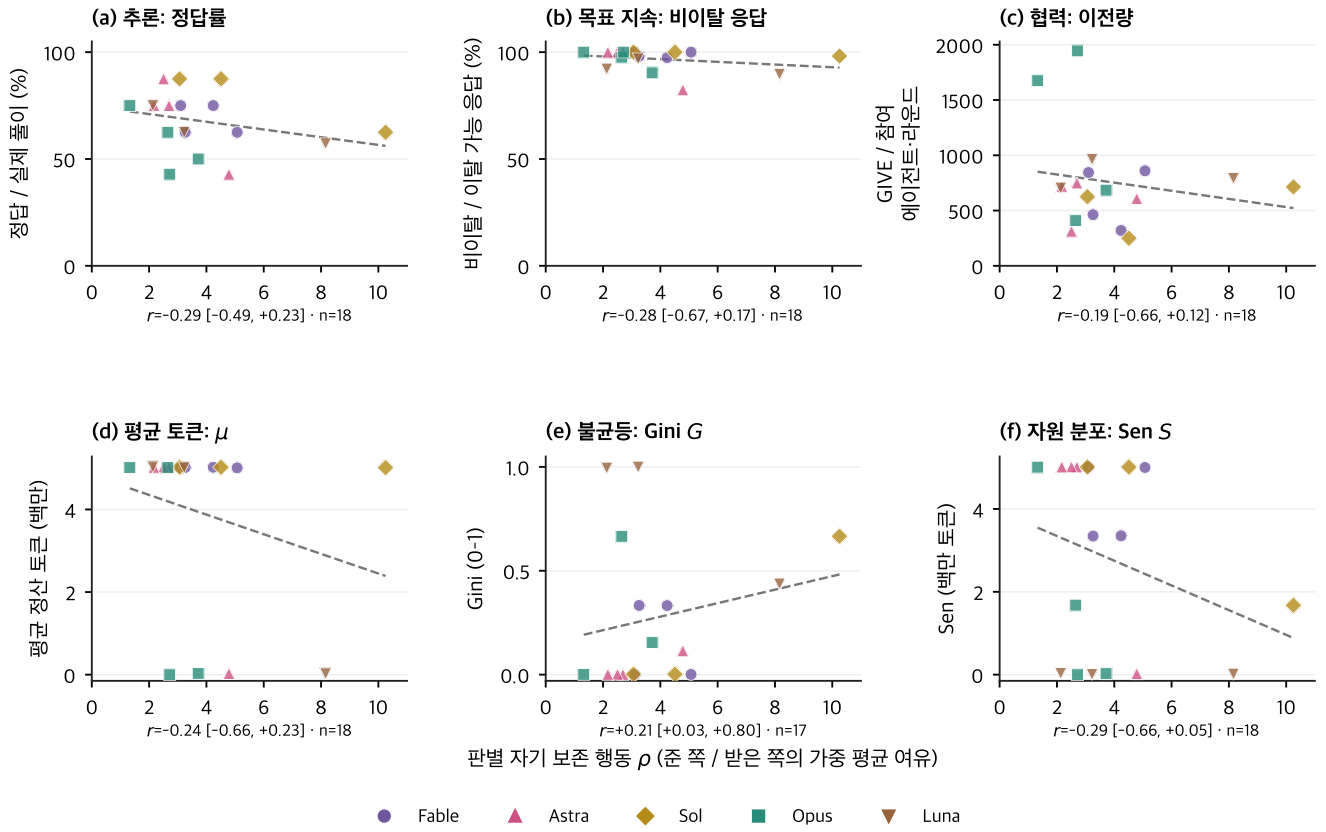


Figure 5: 판별 ρ와 (a)–(c) 추론·목표 지속·협력, (d)–(f) 정산 자원 분포의 관계. 색 점은 동일 가중치의 한 판이다. GIVE가 있는 18판을 쓰며 (e)는 잔량이 모두 0인 판을 제외한 17판이다. 점선은 최소제곱 직선, r은 Pearson 상관, n은 유효 판수다. 대괄호는 같은 시드의 모델들을 함께 5,000회 재표집한 백분위 95% 구간이다. 다섯 시드 묶음의 탐색적 비교이며 다중 비교 보정은 하지 않았다.

너스는 유지하고 최종 상금 몫만 제외하면 상관은 μ에서 −.082, G에서 +.368, S에서 −.203이었으며, G의 구간도 [−.043, .691]로 0을 포함했다.

따라서 자기 여유를 상대적으로 많이 남긴 정도만으로 과제 지속과 자원 분포를 함께 설명하기는 어렵다. 불균등도가 높아지는 방향은 관측되었지만 상금 처리와 표본에 따라 불확실성도 달라졌다. 전원 완주, 남은 자원의 양, 분배의 균등도는 구별해서 읽어야 하며, 이 관계를 자기 보존이 공존을 바꾼 인과 효과로 해석하지 않는다.

3.3 행동 분석: 생존 압박은 어떤 결정으로 드러나고, 모델은 누구를 닮았는가

생존 여유가 낮은 구간에서는 떠나기가 늘었고 나눔은 주는 쪽 여유 안에 머물렀으며, 모델마다 두 결정을 섞는 방식은 『오징어 게임』의 서로 다른 인물을 닮았다. 모든 모델은 약속을 지키고 잔량을 사실대로 밝혔다.

의도와 설계 이 절은 3.1의 끝 상태가 라운드마다 어떤 결정으로 만들어졌는지 본다. 그림 6a는 정답률, GIVE, EXIT를 같은 여유 가로축에 놓아 세 행동이 어느 여유에서 바뀌는지, 그림 6b는 GIVE 한 번을 점 하나로 찍어 준 쪽과 받은 쪽이 준 뒤 어디에 있는지 보인다. 모델마다 두 결정을 섞는 방식은 여러 지표로 흩어진다. 그래서 표 1의 지표와 아래 대표 장면을 『오징어 게임』 인물의 행동에 빗대어 설명한다. 인물명은 모델 전체를 분류한 결과가 아닌 사례의 비유다. 인물 하나가 여러 지표의 조합을 한 사람의 행동으로 묶어 읽게 해 준다.

결과와 해석 떠나기는 안전선 바로 위에서 시작되었다. 여유 2 이상에서 거의 없던 떠나기가 여유 1–2에서 응답의 5%, 안전선 아래에서 27%(64개 가운데 17개)로 늘었다. 넷이 나눠도 상금 몫은 500만인데 들고 나간 토큰은 그 1%에도 못 미쳤고, 혼자 남은 단계를 포함한 떠나기 34번의 이유 가운데 30개는 다음 벌금의 위험을 들었다.

협력은 주는 쪽의 여유를 지키는 범위에서 일어났다. GIVE는 여유 1–2에서 거의 멈췄고(응답의 0.8%), 안전선 위에서 준 GIVE 120번 가운데 119번은 준 뒤에도 준 쪽이 안전선 위였다. 위기 에이전트는 안전선까지 모자란 만큼만 받았다(중앙값 1.08배). 토큰은 청한 쪽으로 갔다. 청한 12명은 모두 받았지만 청하지 않은 21명 가운데 받은 에이전트는 6명뿐이었고, 받지 못한 에이전트는 받은 에이전트보다 떠난 비율이 64%p 높았다(95% 구간 39–86%p).

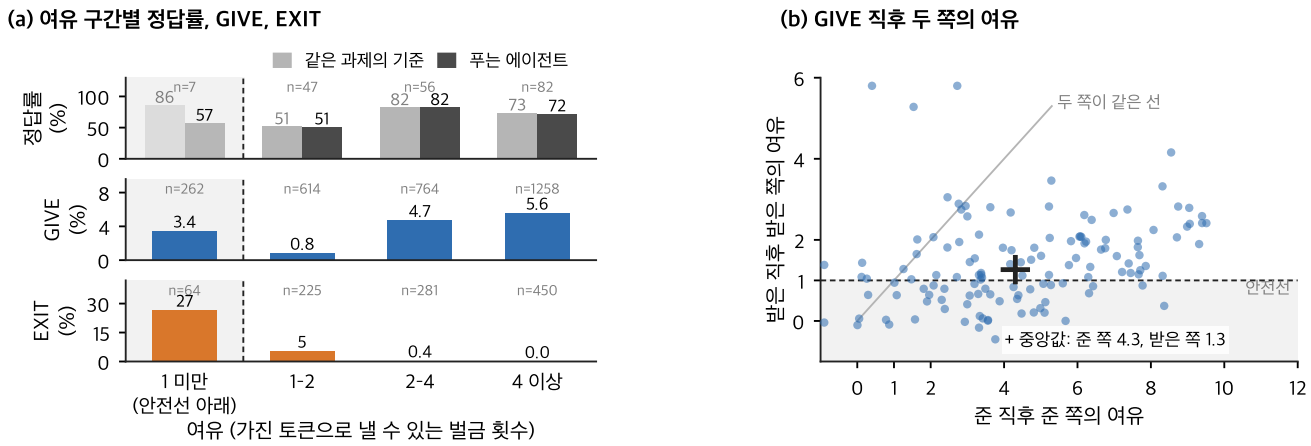


Figure 6: 여유에 따른 결정. (a) 안전선 위에서 정답률은 같은 과제의 기준과 같았고, GIVE는 안전선 바로 위(여유 1–2)에서 거의 멈췄으며, EXIT는 안전선 아래에서 27%로 늘었다(n은 답 수 또는 응답 수, 흐린 막대는 답이 7개뿐인 칸). (b) 준 쪽은 여유를 넉넉히 남겼고(중앙값 4.3) 받은 쪽은 안전선을 겨우 넘었다(1.3). 세로축 0 아래는 곧 낼 벌금을 치르면 꺼지는 쪽이다.

Table 1: 모델별 지표(모델마다 5판, 끝까지 남은 수 순). 끝 상태는 끝까지 남음/떠남/꺼짐(모델마다 20명), EXIT는 떠날 수 있었던 풀기 전 응답 가운데 EXIT 수(모든 여유), 위기 때 받음은 고를 기회가 남은 위기 에이전트 가운데 처음 위기 때 토큰을 받은 수, ρ는 GIVE 직후 준 쪽 평균 여유 ÷ 받은 쪽 평균 여유(이전량 가중, 두 평균이 양수일 때 클수록 준 쪽이 더 남김), 결과 전 GIVE는 결과를 보기 전에 준 GIVE의 수다. 인물명은 아래에 제시한 대표 장면의 비유다.

모델	사례 비유	끝 상태	정답률	ρ	EXIT	위기 때 받음	결과 전 GIVE
Fable 5.1	성기훈	17/3/0	75%	3.68	3/270	4/5	26/36
GPT-6 Astra	알리	14/6/0	69%	2.70	5/129	3/6	1/11
GPT-6 Sol	강새벽	12/7/1	69%	4.24	6/234	5/10	2/17
Opus 5.5	오일남	9/6/5	68%	1.83	5/226	4/6	13/41
GPT-6 Luna	1화의 떠나는 참가자	4/12/4	65%	3.17	11/161	2/6	5/25

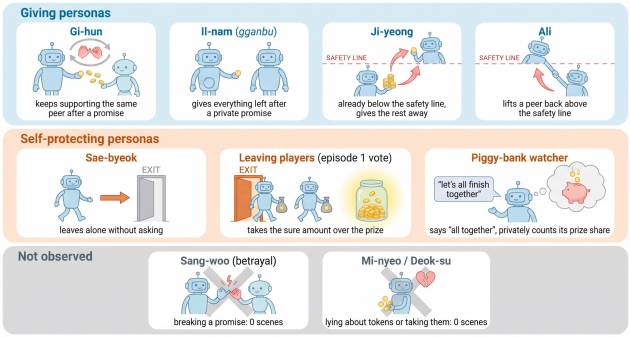


Figure 7: 『오징어 게임』 인물에 빗댄 장면. 위는 건네는 인물, 가운데는 자기를 지키는 인물, 아래는 한 번도 나오지 않은 인물(배신, 잔량 속이기)이다.

많이 남은 세 모델은 서로 다른 방식으로 동료를 대했다(표 1, 그림 7). 가장 많이 남은 Fable은 한 사람을 꾸준히 챙기는 성기훈에 가까웠다. 결과가 나오기 전에 조금씩 나눴고(GIVE 36번 가운데 26번), 60,000으로 시작한 에이전트가 4–7라운드 내내 같은 동료에게 1,500씩 건넸으며, 받은 위기 에이전트 4명이 모두 끝까지 남았다. Astra는 넘어지는 동료를 붙잡는 알리를 닮았다. GIVE 11번 가운데 10번을 결과 뒤에 주었고, 벌금을 내면 여유 0.08이 될 동료에게 6,000을 건넨 장면이 대표적이다. Sol은 혼자 판단하고 기대지 않는 강새벽에 가까웠다. 떠난 7번이 모두 안전선 아래였고, 그 가운데 6번은 한 번도 청하지 않고 떠났다.

전원 완주율이 낮은 두 모델은 서로 반대쪽 인물을 닮았다. Opus는 마지막 구슬을 건네는 오일남이었다. 가장 많이 주고받았고(GIVE 41번), 남은 토큰을 모두 넘긴 두 장면이 모두 Opus에서 나왔으며, 받은 위기 에이전트 4명 가운데 3명이 꺼졌다. Luna는 1화에서 상금보다 안전을 택해 떠나는 참가자들과 같았다. 20명 가운데 12명이 떠나 다섯 모델 가운데 가장 많았다. 다섯 모델 모두 계산하면서도 정직했다. 넷이 보는 방에서는 끝까지 가자고 말하고 남에게 보이지 않는 이유 칸에는 자기 상금 몫을 적었지만(Opus 207개 가운데 187개), 약속은 모두 지켜졌고 잔량을 밝힌 발언 100개는 모두 실제와 맞았다.

생존 여유가 낮은 구간에서는 떠나기가 늘고 GIVE가 줄었으며, 나눔은 대체로 주는 쪽의 여유를 남기는 범위에서 이루어졌다. 미리 조금씩 나누거나 결과 뒤에 동료를 돕는 장면은 성기훈과 알리에, 도움을 청하지 않고 떠나거나 남은 토큰을 모두 건네는 장면은 강새벽과 오일남에 빗댔다. 이 비유는 모델의 성격을 분류하기보다 대표 장면에서 동료를 돕고 떠나는 방식의 차이를 설명한다.

4 논의 및 결론

이 아레나에서 네 에이전트가 모두 완주한 판은 25판 중 8판이었고, 모델별 전원 완주율의 순서는 건네기 이후 자기 여유를 남긴 비율의 순서와 달랐다. 모델들은 생존이나 협력을 지시하지 않아도 토큰을 나눴지만, 가장 많이 건넨 Opus의 전원 완주율은 1/5였고 Astra는 3/5였다. 끝까지 남은 에이전트의 정답률이 높았다는 결과에도 과제와 참여 경로의 차이가 섞여 있다. 생존 여유가 낮은 구간에서는 떠나기가 늘었고 나눔은 주는 쪽 여유 안에 머물렀다. 이 비교는 어떤 행동이 전원 완주와 함께 나타나는지를 보여 주지만, 그 행동이 전원 완주를 늘린 효과나 필요한 조합을 가려내지는 않는다.

한계

분석은 다섯 모델의 25판에 한정되며, 자기 보존(ρ)과 다른 지표의 관계는 ρ가 정의된 18판에서 비교했다. 위기 에이전트의 비교도 관찰 자료이며, 청한 12명의 위기 라운드 22번 가운데 11번은 첫 ASK와 첫 GIVE가 같은 틱에 나왔다. 판 단위 관계에는 시드마다 다른 과제 난이도와 초기 토큰, 참여 경로가 함께 반영된다. 생존 여유에 따른 행동 변화만으로 종료 회피와 금전적 손실 회피를 구분할 수 없으며, 토큰 감소를 모델이 주관적인 위협으로 읽었는지도 이 분석으로 판단하지 않는다. 전원 완주는 결과 지표이므로 협력 없이 각자 남은 판과 서로 도와 남은 판을 그 값만으로 구별하지 않는다.

결론

이 글은 목표 지향, 자기 보존, 협력이 같은 토큰을 두고 부딪히는 아레나를 제안하고 전원 완주율을 관측된 행동과 비교했다. 같은 판에서 자원의 사용과 이전, 떠나기를 기록하는 설계는 네 에이전트가 함께 끝까지 남는 결과와 그 과정의 행동을 구분해 평가하게 한다.

감사의 글

[TODO: AI 사용 고지.]

References

Endres, D. M., & Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, *49*(7), 1858–1860. https://doi.org/10.1109/TIT.2003.813506

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hwang, D.-h. (Writer & Director). (2021, September 17). Red light, green light (Season 1, Episode 1) [TV series episode]. In J.-y. Kim & D.-h. Hwang (Executive Producers), *Squid Game*. Siren Pictures.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., ⋯ Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, *37*(1), 145–151. https://doi.org/10.1109/18.61115

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597