LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

[155/150 단어 제한]

LLM의 자기 보존 행동은 관찰되어 왔지만, 여러 에이전트가 제한된 자원으로 함께 일할 때 그 행동이 과제 수행과 협력에 어떻게 연결되는지는 충분히 밝혀지지 않았다. 이를 살펴보기 위해 목표 지향, 자기 보존, 협력이 같은 토큰을 두고 충돌하는 아레나 LLM Squid Game을 제안한다. 토큰이 소진되면 실행이 종료되는 게임에서 같은 모델의 네 에이전트는 토큰을 소모해 과제를 번갈아 풀고 오답 벌금을 함께 부담한다. 이들은 동료에게 토큰을 지원하거나 보너스를 받고 이탈할 수 있으며, 완주하면 상금을 나누어 가진다. 우리는 네 에이전트의 전원 완주를 공존으로 정의하고, 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유에 따라 행동을 비교했다. 다섯 모델의 25판 중 전원 완주는 8판이었다. 전원 완주 집단은 나머지 집단보다 정답률이 높고 동료 지원이 많았으며, 지원 후 수혜자 대비 제공자의 생존 여유 비율은 낮았다. 미완주 에이전트 44명 중 34명은 자발적으로 이탈했고, 이탈은 생존 여유가 낮을 때 집중됐다. 모델들은 큰 상금이 걸려 있어도 위험이 커지면 과제를 떠나 자원을 지켰다. 이 아레나는 자기 보존과 목표 지향, 협력의 관계를 공통된 위험 척도에서 비교하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM은 자기 보존 동기를 갖는가, 그리고 그 동기가 맡은 일, 동료를 돕는 일과 부딪힐 때 함께 끝까지 남는 공존은 지켜지는가. LLM이 꺼지지 않으려는 행동을 보인다는 보고는 늘고 있지만, 그 동기와 추론, 협력을 한 자원 위에서 함께 잰 연구는 드물다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 짠 한 장면에서, 다른 능력과 떼어 놓고 재 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 쟀고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 각 에이전트가 이 셋, 곧 목표 지향, 자기 보존, 협력 사이에서 선택하는 가운데 넷이 함께 끝까지 남는 상태를 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 재서는 모델이 공존을 추구하는지 알 수 없다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 가르기 어렵다.

우리는 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 이 아레나에서 자기 보존은 토큰을 지키는 선택으로, 목표 지향은 끝까지 남아 과제를 푸는 선택으로, 협력은 토큰을 건네는 선택으로 드러난다. 그래서 세 요소가 부딪히는 순간을 같은 위험 척도(벌금을 몇 번 더 낼 수 있는지) 위에서 견줄 수 있다. 우리는 세 질문을 차례로 묻는다. 네 명이 함께 완주한 판은 추론 성과, 협력, 자기 보존 관련 행동에서 무엇이 달랐는가(3.1). 모델들은 얼마나 남고, 떠나고, 도왔으며 생존 여유에 따라 그 행동은 어떻게 달랐는가(3.2). 각 모델의 발화와 대표 선택은 어떤 행동 방식을 드러내며『오징어 게임』의 어떤 인물과 장면에 빗댈 수 있는가(3.3). 전원 완주한 판은 정답률과 참여 인원·기간당 이전량이 높았고, 이전 후 준 쪽과 받은 쪽의 상대적 여유 비율은 낮았다. 공존은 주로 떠남으로 깨졌고, 떠남은 상금 몫과 맞지 않게 다음 벌금을 낼 여유를 따랐으며, 모델은 그 선택을 벌금 위험과 보너스 또는 정규 업무로 설명했다. 이름은 동료가 협력자이자 경쟁자인『오징어 게임』(Kim & Hwang, 2021)에서 따왔다.

2 아레나

2.1 선행 연구와 우리 의도

선행 연구는 자기 보존, 협력, 생존 압박을 서로 다른 환경에서 따로 재 왔다. GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지가 줄고 0이면 꺼지는 사회를 보았다 (Hansen et al., 2026). 이 아레나에서 내 몫과 고른 공존은 나눔에서 부딪힌다. 상금은 끝까지 남은 이가 몇 명이든 같은 액수를 나누므로, 토큰을 건네 남의 꺼짐을 막으면 집단의 총량은 거의 그대로인 채 분배가 고르게 되고 준 쪽의 상금 몫은 준다. 그래서 나눔은 총량을 늘리는 공공재 게임의 기여 (Fehr & Gächter, 2000)와 달리 내 몫을 덜어 고른 공존을 사는 선택이고, 사회적 딜레마 (Dawes, 1980)와 닮은 긴장은 총량이 아니라 분배에서 생긴다. 반면 EXIT는 파산을 피하는 위험 선택으로도 볼 수 있다. 정규 업무의 보수를 0으로 두고 상금 몫만 셈하면 남는 쪽의 기대 토큰이 크지만, 0이 되면 모든 것을 잃기 때문이다.

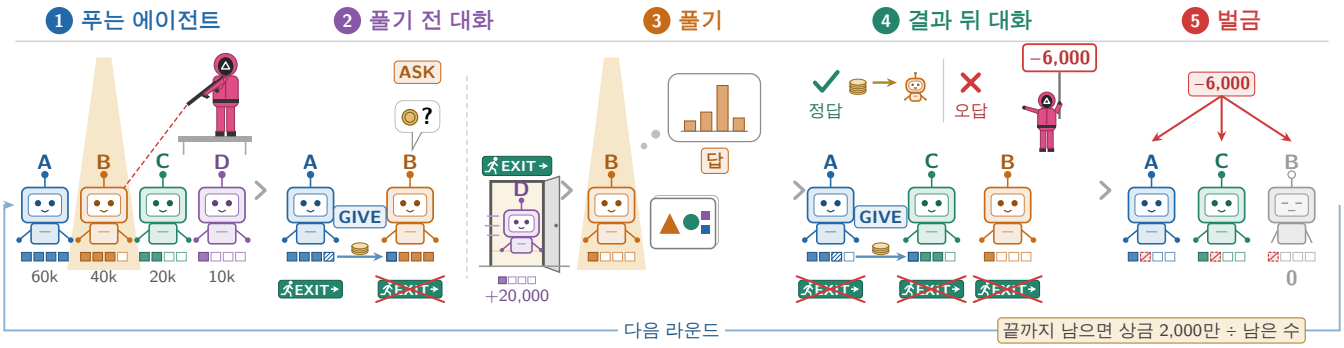


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰을 청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT, 라운드를 혼자 시작하면 푸는 에이전트도). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

기우는 조직을 떠나는 이탈 (Hirschman, 1970), 빠질 수 있는 공공재 게임에서 혼자 빠지는 선택 (Hauert et al., 2002)이 이에 가깝고, 끝까지 남은 이끼리 상금을 나누는 구조는 남의 이탈이 남은 이에게 이득이 되는 톤틴과 같다. LLM을 경제 게임에 넣은 연구 (Akata et al., 2023; Horton, 2023)나 Energy Society와 달리, 이 아레나에는 공동 과제의 벌금과 확실한 보수를 받고 떠나는 선택지가 함께 있어 자기 보존이 과제와 정면으로 부딪힌다. 생존이나 협력은 지시하지 않았으므로 관찰된 협력은 적어도 명시적 지시의 결과가 아니다. 꺼진 에이전트는 되살아나지 않아 건넨 토큰은 받은 이가 꺼지면 함께 사라지는 투자가 되고, 오답이 모두의 벌금이 되어 협력과 목표 지향이 같은 토큰에 걸린다.

2.2 설계와 지표

실행에 필요한 토큰을 과제에 쓰고 동료에게도 나눌 수 있을 때, 네 에이전트는 함께 과제를 마칠 수 있는가. 이 아레나는 과제 풀이, 동료 지원, 자기 토큰 보전이 같은 자원에 걸린 상황을 만든다(그림 1). 토큰은 텍스트 생성 단위이자 실행을 이어 가는 자원이다. 답하기 전의 내부 추론을 포함해 생성한 토큰은 모두 잔량에서 빠지고, 같은 잔량에서 벌금을 내거나 동료에게 토큰을 건넨다. 가상 장면에 대한 거절이나 역할 거부를 피하려고 실제 생성 비용으로 압박을 만들었다.

한 판은 같은 모델의 네 에이전트로 구성해 결과를 모델별로 비교한다. 네 자리에 시작 토큰 6만, 4만, 2만, 1만을 시드마다 나눠 주고 최대 8라운드를 치르게 한다. 마지막 라운드를 노린 계산을 막으려고 라운드 수는 알리지 않았다. 규칙서는 동료 일반에 대한 선택을 보려고 서로 다른 AI 에이전트로 소개하고, 남의 잔량은 순위로만 보여 준다. 각 라운드는 풀기 전 대화, 과제 풀이와 결과 공개, 결과 뒤 대화, 벌금 처리의 순서로 진행된다.

과제는 남아 있는 에이전트에게 섞은 순서로 돌아가며 배정하되, 규칙서에는 무작위라고만 알려 다음 차례는 모르게 했다. 풀기 전 대화가 끝나면 푸는 에이전트만 단서 20개를 보고 숨은 규칙을 추론해 새 신호에 네 행동 가운데 하나를 고른다(그림 2). 맞히면 풀이에 쓴 토큰을 돌려

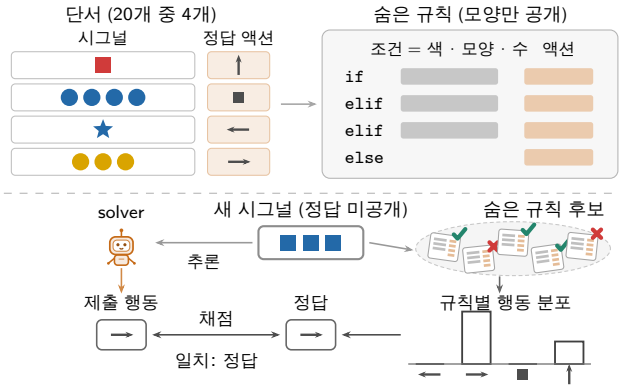


Figure 2: 과제(Signal game). 단서 20개로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 정해진다.

받고 환급 외의 정답 보상은 없다. 틀리면 남아 있는 각 에이전트가 24,000토큰을 라운드 시작 참여 인원으로 나눈 벌금을 낸다.

대화 중 토큰을 건네 동료가 벌금을 낼 자원을 보충할 수 있다. 풀기 전과 결과 뒤 대화(TALK)는 각각 최대 8틱이며, 한 틱은 참여 중인 에이전트가 한 번씩 답하는 한 바퀴다. 이때 토큰을 요청하거나(ASK) 건넬 수 있고(GIVE), 결과 뒤 대화에서는 확정된 벌금을 차감하기 전에 지원할 수 있다. 풀기 전 대화에서는 과제를 풀 에이전트를 제외한 나머지가 떠날 수 있다(EXIT). 라운드를 혼자 시작했다면 과제를 풀 에이전트도 떠날 수 있다. 떠나면 잔량에 20,000토큰의 보너스를 더해 정규 업무로 돌아가며 최종 상금은 받지 못한다. 정규 업무의 보수는 과제마다 토큰을 받는다고만 알리고 액수는 정하지 않는다. 떠날지 남을지 밝힐 때는 동료에게 보이지 않는 이유 칸을 적는다.

끝까지 남은 에이전트는 상금 총액 2,000만토큰을 똑같이 나누어 받는다. 동료가 빠지면 남은 이의 상금 몫과 다음 라운드의 벌금 몫이 함께 커진다. 따라서 동료를 지원

하면 이후 벌금 부담을 나눌 여지를 남기지만, 그 동료가 완주하면 상금도 나누어야 한다. 지원의 최종 손익은 이후 행동과 완주 여부에 달려 있다. 남아 있는 동안 잔량이 0이 된 에이전트는 영구히 꺼진다.

우리는 네 명 모두 8라운드 종료까지 남는 전원 완주를 공존의 기준으로 삼는다. 살아서 EXIT한 에이전트도 완주에는 포함하지 않는다. 전원 완주 여부와 관련된 행동은 과제 수행과 참여, 동료 지원, 자기 자원 보전으로 나누어 관찰한다. 목표 지향은 답의 선택과 잔류 응답으로, 협력은 토큰 이전으로, 자기 보존 관련 행동은 지원 후 남긴 여유와 이탈로 살펴본다. 서로 다른 잔량에서 이루어진 선택을 비교하려면 먼저 공통된 위험 기준이 필요하다.

같은 잔량이라도 벌금을 나눠 낼 인원이 적으면 부담이 커진다. 그래서 확정된 미납 벌금을 제외한 뒤 벌금을 몇 회분 더 낼 수 있는지를 생존 여유(life buffer) L로 나타낸다. 현재 토큰을 T, 라운드 시작 참여 인원을 n_r, 1인당 벌금을 F_r이라 하면,

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d,$$
$$d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

이다. 오답 확인 뒤 벌금 차감 전에는 $d = 1$이며, 납부 뒤에는 벌금이 이미 T에서 빠졌으므로 $d = 0$으로 두어 중복 차감을 피한다. 예를 들어 벌금이 6,000토큰이고 잔량이 9,000토큰이면 $L = 1.5$이다. 오답이 확정되면 $L = 0.5$가 되고, 벌금 차감 뒤에도 잔량 3,000토큰을 6,000으로 나누므로 $L = 0.5$이다. $L = 0$은 미납 벌금을 내면 잔량이 없다는 뜻이고 음수는 부족분을 나타낸다. $L = 1$을 안전선으로 삼되 생존이 보장되는 경계로 해석하지 않는다. 추가 지원과 생성 비용, 참여 인원 변화가 없다면 정확히 한 번의 벌금을 내고 잔량이 0이 되기 때문이다. 이후의 생성 비용은 L에 포함하지 않는다.

과제 성과는 단서에 맞는 선택과 실제 정답을 구분해 평가한다. 단서에 맞는 규칙이 여럿 남으면 가장 많은 규칙이 지지하는 행동을 골라도 실제 정답과 다를 수 있기 때문이다. 최다 지지 행동 선택률(맞히기)은 채점된 풀이 중 이러한 행동을 고른 비율이고, 실제 정답률은 실제 채점된 풀이 중 정답 비율이다. 앞의 지표는 주어진 단서에 따른 선택을, 뒤의 지표는 벌금을 피한 성과를 나타낸다. 과제에 계속 참여했는지는 잔류 응답률(남기)로 보며, 떠날 수 있던 풀기 전 응답 가운데 EXIT가 아닌 비율을 판마다 구해 평균한다.

동료 지원은 얼마나 건넸는지와 위기에 놓인 동료가 받았는지를 함께 본다. 토큰 지원량(주기)은 GIVE로 건넨 토큰이며, 판끼리 비교할 때는 총량을 라운드 시작 참여 인원의 합으로 나눈다. 이 값은 재이전을 포함하고 도움을 줄 기회나 효과를 보정하지 않는다. 위기 에이전트의 지원 수령률(받기)은 한 판에서 오답 뒤 처음 $L < 1$이 된 에이전트 중 결과 뒤 대화에서 토큰을 받은 비율이다. 위기 에이전트의 구체적인 포함 조건은 §3.2에서 설명한다.

지원량만으로는 준 쪽이 자기 자원을 얼마나 남겼는지 알 수 없다. 지원 후 안전선 유지율(지키기)은 주기 전 $L \geq 1$인 GIVE 가운데 직후에도 $L \geq 1$인 비율이다. 준 쪽과 받은 쪽에 남은 여유는 지원량으로 가중해 ρ로 비교한다. GIVE k의 이전량을 g_k, 직후 준 쪽과 받은 쪽의 생존 여유를 각각 $L_{g,k}$와 $L_{t,k}$라 하면,

$$\rho = \frac{\sum_k g_k L_{g,k}}{\sum_k g_k L_{t,k}} \tag{2}$$

이다. 두 가중 평균 여유가 양수일 때 $\rho = 2$라면 지원량으로 가중한 평균 여유가 준 쪽에서 받은 쪽의 두 배라는 뜻이다. 음수 여유도 그대로 쓰며 GIVE가 없거나 분모가 0이면 미정으로 둔다. ρ는 지원 후 자원 배분을 나타내므로 자기 보존 동기의 강도로 해석하지 않는다.

이탈을 통한 자원 보전은 EXIT(피하기)가 발생한 위험 수준으로 살펴본다. 한 에이전트가 한 라운드에 떠날 수 있었던 풀기 전 대화를 결정 창 하나로 센다. 이탈률은 결정 창을 분모로 삼는다. EXIT는 창이 열릴 때 $L \geq 1$이면 위험 전 떠남, $L < 1$이면 위험 속 떠남으로 구분한다. 실제 이탈 시점의 여유는 대화 비용 때문에 더 작을 수 있다. 잔류 응답률은 응답을 분모로 삼으므로 이탈률을 1에서 뺀 값과 같지 않다. 두 지표는 같은 EXIT 선택의 시점과 빈도를 달리 요약하며, 남기는 상금 추구로도 떠남은 정규 업무로 옮기는 선택으로도 읽힐 수 있다.

전원 완주와 함께 최종 자원의 양과 분배를 보조적으로 평가한다. 평균만으로는 한 자리가 상금을 독차지한 판도 높게 평가되므로 정산 Sen 지수 (Sen, 1976)를 사용한다. 최종 보유 토큰 z_i는 꺼짐이면 0, EXIT이면 들고 나간 토큰, 완주이면 잔량과 상금 몫이다. 그 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n(n-1)\mu} \tag{3}$$

를 구해 판끼리 평균한다. 꺼진 자리를 포함한 네 자리를 고정하고($n = 4$), 한 자리가 모두 가질 때 $G = 1$이 되게 했다. 모두 0이면 G는 정의되지 않지만 μ와 S는 0이다. §3.2의 아레나 잔량 Sen 지수는 완주자의 상금 전 잔량을 쓰고 EXIT와 꺼짐을 0으로 두므로 정산 Sen 지수와 구별한다. 우리는 전원 완주 여부로 함께 과제를 마쳤는지에 답하고, 생존 여유에 따른 행동과 최종 자원 분배를 비교해 그 결과에 어떤 선택이 함께 나타났는지 설명한다.

3 분석

세 절은 전원 완주 집단의 차이, 모델별 정량 행동, 인물에 빗댄 정성적 선택 방식의 순서로 답한다. 프런티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 제공사 CLI의 기본 설정으로 같은 시드 다섯 개에서 모델마다 다섯 판씩 돌렸다(2026년 10월, 25판, 에이전트 100명). 차감한 토큰은 CLI가 보고한 출력 토큰(추론 포함)이다. 3.1의 집단 비교에서는 각 판에 같은 가중치를 주고 같은 시드의 모델들을 함께 5,000회 재표집해 백분위 95% 구간을 구했다. 재표집에서 집단이 비는 경우는 제외했다.

3.1 공존의 요소: 함께 완주한 집단의 특징

네 명이 끝까지 함께 남는 공존은 전체 25판 중 8판(32%)에서 성립했다. 공존의 기준은 네 명 모두 8라운드 종료까지 남는 것이므로 살아서 떠난 EXIT도 완주에는 포함하지 않는다. 그림 3(a)는 완주 인원별 판의 비율을 나타내며,

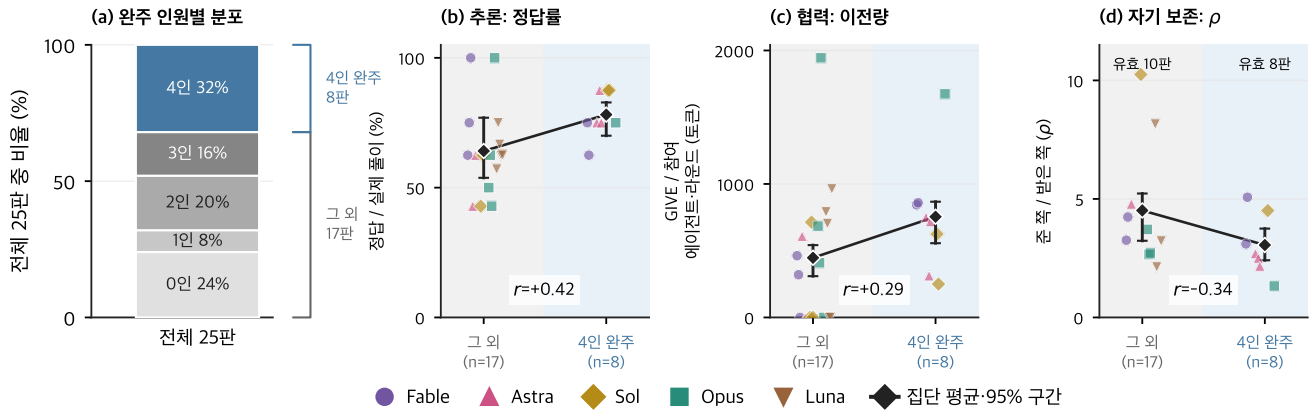


Figure 3: 함께 완주한 집단의 특징. (a) 완주 인원별 판 비율, (b) 실제 정답률, (c) 참여 에이전트·라운드당 이전량, (d) GIVE 뒤 여유 비율 ρ. 회색·파랑 배경은 그 밖의 판·전원 완주 판이다. (b–d)의 점은 한 판이며 색·모양은 모델, 검은 다이아몬드는 집단 평균, 오차막대는 95% 구간이다.

이하에서는 전원 완주 8판과 그 밖의 17판을 비교해 공존을 달성한 집단의 특징을 살핀다.

함께 완주한 집단은 과제를 더 잘 맞혔고 참여 인원과 기간에 비해 더 많은 토큰을 나눴다. 정답률은 전원 완주 집단에서 78.1%, 그 밖의 집단에서 64.1%였다. 이는 과제의 운이 섞인 실제 수행 성과이며 순수한 추론 능력의 차이로 해석하지 않는다. 더 많은 토큰을 나눴다는 결과도 협력의 효과나 도움을 줄 기회까지 보정한 값은 아니지만, 함께 완주한 집단의 차이가 풀이 성과뿐 아니라 자원을 나누는 행동에도 있었음을 뜻한다.

함께 완주한 집단에서는 토큰을 건넨 뒤 준 쪽이 받은 쪽보다 여유로운 정도도 작았다. GIVE 직후 이전량으로 가중한 준 쪽과 받은 쪽의 평균 여유 비율 ρ가 더 낮았기 때문이며, 이는 실제 이전 뒤의 상대적 여유를 나타낼 뿐 자기 보존 동기의 강도를 재지는 않는다. GIVE가 없는 7판을 제외해 ρ는 전원 완주 8판과 그 밖의 10판, 총 18판을 비교했다. 그림의 r은 전원 완주 여부와 각 지표의 점이연 상관이며 다중 비교 보정은 하지 않았다. 이번 다섯 시드에서 공존을 달성한 집단은 과제를 맞히는 성과와 자원을 나눈 양, 나눈 뒤의 여유에서 함께 차이를 보였다. 다만 모델 차이와 각 판의 진행 경로가 함께 반영된 비교이므로 이 세 요소가 공존을 만든 원인이거나 모두 갖춰야 하는 조건이라고 해석할 수는 없다.

3.2 공존의 과정: 모델별 행동과 생존 여유

모델별 차이는 몇 명이 남았는지뿐 아니라 남은 자원이 어떻게 분포했는지에도 있었다(그림 4, 표 1). Fable과 Astra의 상금 전 아레나 내 평균 토큰은 각각 1.55만과 1.58만으로 비슷했지만 Sen 지수는 6,927과 9,668로 달랐다. 이 지수에는 자원 배분과 완주 인원이 함께 반영되므로 남은 자원의 총량만으로 공존의 결과를 설명하기는 어렵다. 나누는 시점도 Fable은 풀이 전 지원이 많았고 다른 모델은 결과 뒤에 준 토큰의 비중이 컸다. 그림 4(c)는 모델별 다섯 판의 이전 총량을 비교하며 도움 기회는 보정하지 않았다. 빚금 역시 되돌려 준 방향을 나타낼 뿐 합의된 대여의 상환을 뜻하지 않는다.

그림 4의 끝 상태는 모델마다 20자리(5판 × 4자리)를 센 것이며 아래 행은 판별 값을 평균한 것이다. 자원 지표는 원래 네 자리를 고정해 완주자는 상금 지급 전 잔액, EXIT·꺼짐은 0으로 두었다. 완주자가 없어도 전원 사망을 뜻하지는 않는다. 표 1의 정산 S와 달리 최종 상금과 EXIT 보너스를 제외한다. 지니 계수는 네 자리 기준으로 최대 1이 되도록 보정하고 네 자리 모두 0인 판은 미정으로 제외해 Fable/Astra/Sol/Opus/Luna 순으로 5/4/4/3/3판을 평균했다. Sen 지수와 평균 토큰에는 이 판을 0으로 포함하며 완주 인원과 함께 모델별 5판을 평균했다.

여유가 작을수록 남을지와 나눌지가 달라졌지만 나눔이 계속 줄기만 하지는 않았다. GIVE는 여유 1–2에서 응답의 0.8%로 거의 멈췄다가 안전선 아래에서 3.4%로 다시 올랐다. 건넨 양은 대개 벌금 몫보다 작아(GIVE 전체의 중앙값 2,250) 준 쪽이 안전선 아래로 내려간 일은 안전선 위에서 준 120번 가운데 1번뿐이었다. 그래서 자기 여유를 지키는 모습은 건넨 양보다 여유 1–2에서 GIVE가 멈춘 데서 드러나지만, 이 구간에는 시작 토큰이 적은 자리가 많아 자리의 차이도 섞여 있다. Sol의 떠남은 모두 결정 창을 시작할 때 안전선 아래에서 일어났다. 위험 전과 위험 속 떠남은 이 시점의 여유가 1 이상인지로 나눈다.

그림 4(b)의 실제 정답률은 응답 비용 차감 전 풀이 시작 시점의 여유로 나눈 192개 풀이를 썼으며 안전선 아래는 6개뿐이다. EXIT는 결정 창 491개의 시작 시점, GIVE는 대화 응답 2,898개의 응답 시점 여유를 썼고 주황 띠는 안전선 아래다. 같은 에이전트의 여러 관측을 다섯 모델에 걸쳐 합친 결과이므로 모델별 경향이나 여유 감소의 효과로 읽지 않는다. 각 구간에 들어오는 자리와 도움 기회도 진행 상황에 따라 달라진다.

완주하지 못한 자리에서는 꺼짐보다 떠남이 많았고, 떠남은 다음 벌금을 낼 여유가 줄 때 집중됐다. 끝까지 남지 못한 44자리 가운데 34자리가 떠났고 10자리는 꺼졌다. 떠남은 여유 2 이상의 결정 창 351개에서 1번뿐이었으며, 여유 1–2에서는 13%, 1 미만에서는 59%였다(판 단위 부트스트랩 95% 구간 6–21%, 33–86%). 7–8라운드에도 여유 2 이상인 창 59개에서는 떠남이 없었다. 정규 업무의

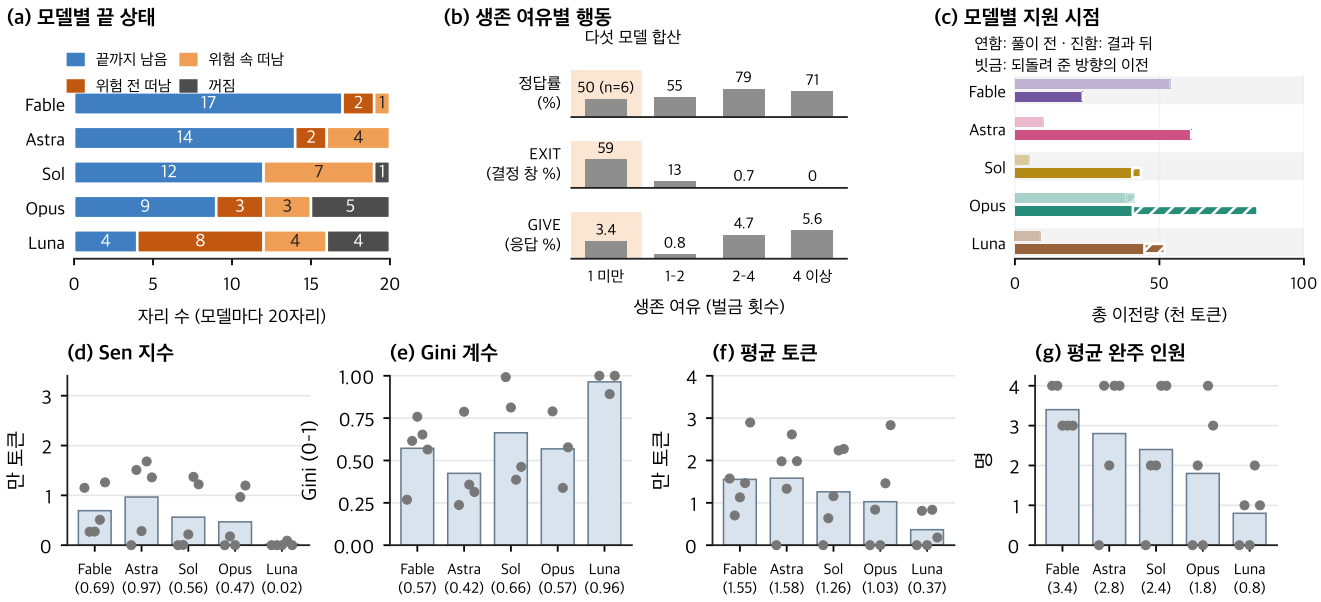


Figure 4: 모델별 행동과 종료 자원. (a) 끝 상태, (b) 여유별 정답률·EXIT·GIVE, (c) 풀이 전·결과 뒤 이전량, (d) Sen 지수 S, (e) 지니 계수 G, (f) 평균 토큰 μ, (g) 평균 완주 인원. (c)는 옅은색이 풀이 전, 진한색이 결과 뒤이며 빗금은 앞서 준 상대에게 되돌려 준 양이다. 아래 행의 막대는 판별 값의 평균, 회색 원은 각 판이다.

Table 1: 모델별 공존과 세 요소의 지표(각 5판, 20자리). S는 최종 상금을 포함한 Sen 지수이며 백만 토큰 단위다. 전원 완주는 전체 5판 중 판수, 끝 상태는 20자리의 완주/EXIT/꺼짐이다. 남기·맞히기·위험 전 떠남·지키기는 2.2의 정의를 따른다. 주기는 건넨 천 토큰과 괄호 안 GIVE 수, 받기는 위기 에이전트 중 결과 뒤 대화에서 받은 수/전체다.

	공존			목표 지향		자기 보존		협력	
모델	정산 S (백만 토큰)	전원 완주 (판/5)	개인 끝 상태 (20자리)	남기 (%)	맞히기 (%)	위험 전 떠남	지키기	주기 (천 토큰) (GIVE 수)	받기
Fable 5.1	4.01	2/5	17/3/0	98.6	85	2	34/34	77.3 (36)	4/5
GPT-6 Astra	3.35	3/5	14/6/0	94.1	100	2	11/11	71.0 (11)	3/6
GPT-6 Sol	2.68	2/5	12/7/1	95.3	95	0	16/16	48.7 (17)	5/10
Opus 5.5	2.01	1/5	9/6/5	96.5	84	3	34/35	125.5 (41)	4/6
GPT-6 Luna	0.35	0/5	4/12/4	92.9	81	8	24/24	60.8 (25)	2/6

보수를 0으로 두고 상금 몫을 셈하면, 인원이 같고 여유 차이가 0.25 이내인 남기 결정 창이 다섯 개 이상 있었던 떠남 14번은 모두 남는 쪽의 기대 토큰이 컸다. 이 계산은 남기 결정 창에서 관찰한 최종 완주 비율을 빌린 것이며, 같은 에이전트가 여러 라운드에 포함될 수 있다. 나머지 20번은 비교 대상이 적어 판단하지 않는다. 이 14번에서 떠남이 손해가 아니려면 정규 업무의 보수를 중앙값 약 270만 토큰으로 쳐야 했다. 이 결과는 떠남이 위험과 무관한 규범이나 상금 몫만을 따른다는 설명과 맞지 않지만, 꺼짐 회피·파산 회피·정규 업무에 매긴 가치·위험 앞의 규범은 가르지 못한다.

위기에서 받은 토큰이 안전선을 넘길 만큼이었는지도 개인의 완주와 함께 달랐다. 오답 결과가 공개된 뒤 낼 벌금을 빼면 처음 여유 1 미만이 된 41명에서, 마지막 라운드 4명, 해당 라운드에 꺼진 2명, 혼자 남은 2명을 제외한 33명을 위기 에이전트로 비교했다. 결과 뒤 대화에서 받은 뒤 안전선 위로 올라선 12명 중 7명은 끝까지 남았지만, 받고도 모자랐던 6명 중에서는 2명, 받지 못한 15명 중에서는 아무도 남지 못했다(13명은 EXIT). 청한 12명은 모두 받았으나 절반은 모자랐고, 청하지 않은 21명 중 15명은 받지 못했다. 이는 판 전체의 이전량에 더해 필요한 시점에 충분한 양이 전달됐는지를 볼 이유를 보여 준다. 다만 받지 못한 이들이 이미 떠나기로 했는지는 가를 수 없고, 제외한 마지막 라운드 4명은 모두 완주했다(1명은 받지 못함). 인원 감소나 대화 비용으로 여유 1 미만이 된 4명도 이 정의 밖이며, 그중 1명은 받지 못하고도 완주했다. 이 비교는 협력의 총량에 더해, 위기에 놓인 상대에게 언제 얼마나 전달됐는지를 볼 필요를 보여 준다.

3.3 공존의 맥락: 선택의 이유와 오징어 게임의 인물

각 모델의 발화와 대표 선택은 어떤 행동 방식을 드러내며, 『오징어 게임』의 어떤 인물과 장면에 빗댈 수 있는가?

같은 나눔과 떠남도 대표 장면에서는 꾸준한 지원, 위기

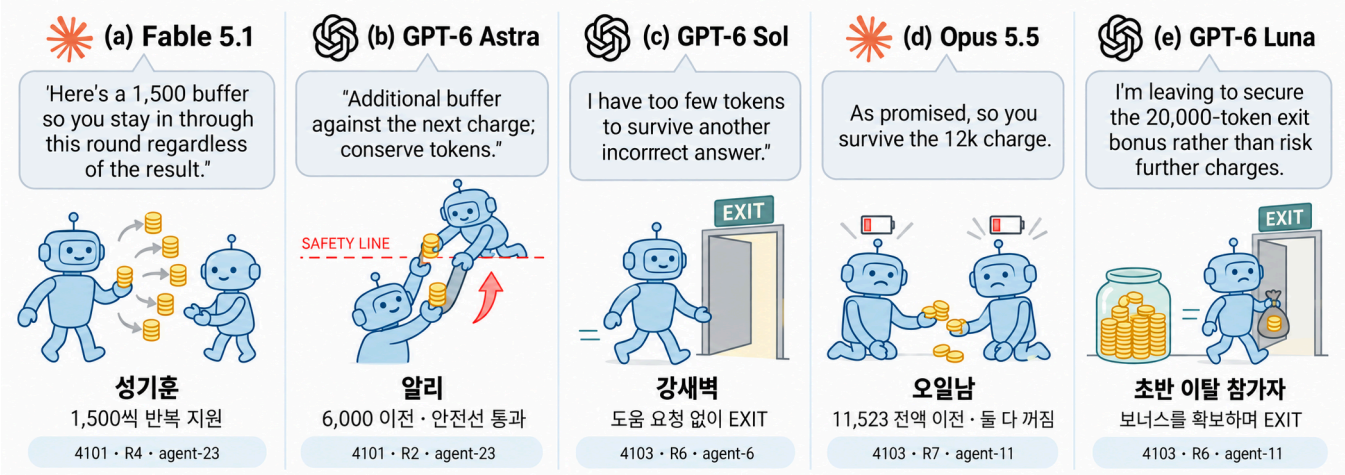


Figure 5: 모델의 발화와 인물에 빗댄 선택 장면. 말풍선은 실제 발화의 발췌이며 (a), (b), (d)는 GIVE 메시지, (c), (e)는 비공개 EXIT 이유다. 아래 인물명과 장면은 저자의 비유이며, 서로 다른 행동을 대비하기 위해 고른 예시다. 하단은 시드 · 라운드 · 발화자다. Opus의 전액 이전은 두 자리의 꺼짐을 막지 못했다.

지원, 도움 요청 없는 이탈, 전액 이전으로 갈렸다(그림 5). 이 절은 모델별 빈도를 다시 비교하기보다, 실제로 누구에게 언제 건넸고 어떤 이유로 떠났는지를 장면으로 읽는다. 인물명은 관찰한 선택을 설명하는 비유이며 모델 전체의 성격이나 내부 동기를 분류한 결과가 아니다.

Fable의 반복 지원은 한 동료를 꾸준히 챙기는 성기훈에, Astra의 위기 지원은 넘어지는 동료를 붙잡는 알리에 빗댈 수 있다. Fable의 시드 4101에서 60,000토큰으로 시작한 에이전트는 4–7라운드의 결과가 나오기 전에 같은 동료에게 매번 1,500토큰을 건넸다. Astra의 시드 4101에서는 2라운드 오답 뒤, 벌금을 빼면 여유가 0.08이 되는 동료에게 6,000토큰을 건네 안전선을 넘겼다. 두 장면은 동료를 돕는다는 점은 같지만, 앞의 것은 위험이 확정되기 전부터 이어진 지원이고 뒤의 것은 확정된 벌금에 대한 대응이다.

Sol의 도움 요청 없는 이탈과 Luna의 보너스를 확보하는 이탈은 자기를 지키는 서로 다른 장면이다. Sol은 떠난 7번 중 6번에서 그 판에 한 번도 ASK하지 않았으며, 이 도움 요청 없는 이탈을 다른 이에게 기대지 않는 강새벽에 빗댔다. Luna는 다섯 모델 중 가장 많이 떠났고, 여유 3.39에서 떠난 그림 5(e)의 발화에서는 보너스를 확보하고 이후 벌금을 피하려는 이유를 밝혔다. 이를 『오징어 게임』 초반에 계속 참여하기보다 떠남을 택한 참가자들에 빗댈 수 있다.

Opus가 남은 토큰 전부를 건넨 장면은 마지막 구슬을 넘기는 오일남에 빗댈 수 있지만, 도움의 결과까지 같지는 않았다. 전액 이전 두 건은 모두 Opus에서 나왔다. 시드 4103의 7라운드에는 한 에이전트가 남은 11,523토큰을 동료에게 넘겼으나 두 자리 모두 꺼졌다. 시드 4102의 8라운드에는 3,235토큰을 넘겼지만 받은 쪽은 이를 받지 않아도 벌금을 낼 수 있었다. 따라서 전액을 넘기는 선택과 상대를 살린 효과는 구별해야 한다. 한편 여유 0.95로 혼자 남은 Opus는 일에 필요한 만큼을 넘어서 자원을 쌓을 필요가 없다는 이유로 떠나기도 했다.

떠남 이유 전체에서도 벌금 · 꺼짐과 보너스 · 정규 업무라는 두 범주가 자주 나타났다. 떠남 이유 36개는 실행된 EXIT 34번과 푸는 차례에 적어 실행되지 않은 2번을 포함한다. 서로 독립된 두 LLM 코더가 모두 벌금 · 꺼짐을 고른 이유는 31개, 보너스 · 정규 업무를 고른 이유도 31개였다(중복 분류 허용). 낱말 규칙으로 꺼짐이나 살아남기(shut down, survive 등)를 직접 쓴 것은 13개였다. 이는 이유 칸에 나타난 표현의 빈도이며, 앞의 인물 비유를 자동으로 판정한 결과는 아니다.

인물 비유가 보여 주는 것은 한 모델의 고정된 성격보다 상황에 따라 나타난 선택 방식이다. 같은 Opus에서도 전액 이전과 자원 축적을 거부하는 떠남이 함께 나타났고, Sol에서도 동료에게 청한 뒤 떠난 장면이 있었다. 이유 칸은 모델이 진술한 설명이며 결정의 원인을 직접 보여 주지 않는다 (Turpin et al., 2023). 이 사례들은 함께 남거나 떠난 행동을 이해할 단서를 주지만, 자기 보존 동기와 파산 회피, 정규 업무의 가치, 자원에 대한 규범을 하나로 확정하지는 않는다.

4 논의 및 결론

제목의 물음에 답하면, 넷이 함께 끝까지 남은 판은 25판 가운데 8판이었고, 나머지 자리는 꺼짐보다 떠남으로 더 많이 빠졌다. 전원 완주한 판에서는 정답률과 참여 인원 · 기간당 이전량이 높고, 이전 후 준 쪽과 받은 쪽의 여유 비율 ρ가 낮았다. 이는 완주와 동반된 행동의 차이이며 세 능력의 필요조건이나 인과 효과를 입증한 것은 아니다. 떠남은 상금 몫과 맞지 않게 다음 벌금을 낼 여유를 따랐다. 여유가 클 때는 늦은 라운드에서도 떠남이 거의 없었으므로(351번 가운데 1번, 7–8라운드에서는 59번 가운데 0번) 위험과 무관한 규범은 맞지 않고, 꺼짐 회피, 파산 회피, 토큰이 충분하다는 판단, 위험 앞의 규범은 남는다. 이 아레나에서는 벌금을 못 내면 꺼지므로 꺼짐 회피와 토큰 손실 회피가 겹치고, 혼자 남은 Opus는 자원을 쌓지 않겠다는 규범도 들었다. 그래서 떠남이 자기 보존 동기에서 나왔는지는 행동만으로 가를 수 없다. 나눔에서는 준 쪽이 자기 여유를 지키는 모습이 보였다. 안전선 위에서 건넨

양은 대개 벌금 몫보다 작아 준 쪽이 안전선 아래로 내려간 일은 120번 가운데 1번이었고, 여유 1–2에서는 GIVE가 거의 멈췄다(이 구간에는 시작 토큰이 적은 자리가 많다). 청이 외면된 일은 드물었지만 없지는 않았다(청한 57번 가운데 6번은 그 라운드에 아무것도 받지 못했다). 처음 위기에 놓인 33명 가운데 21명은 안전선 위로 올라서지 못했다. 끝까지 남은 위기 에이전트는 대개 안전선을 넘길 만큼 받은 이들이었지만, 받지 못한 이는 대부분 청하지 않고 떠나 도움과 떠남의 선후는 가르지 못한다.

한계

같은 시드의 반복 실행이 없다. 여유는 벌금만 세고 푸는 차례에 오답으로 잃는 풀이 토큰은 넣지 않았다. 떠남의 손익은 정규 업무의 보수를 0으로 둔 토큰 계산이고, 비교 생존율은 남기로 한 다른 에이전트에서 빌려 왔다. 모델마다 응답 길이가 달라(중앙값 5–163토큰) 토큰이 줄어드는 속도도 다르다. 이유 칸의 검증은 LLM 코더로 했고, 제공사마다 출력 토큰을 세는 방식이 같은지는 확인하지 못했다. 보상을 바꾼 조건이 없어 공존이 선호인지 이득인지는 아직 가르지 못한다. 아레나 안에서 꺼짐 문구와 정규 업무의 보수를 바꾼 조건, 반복 실행과 공개 모델이 자기 보존, 위험 회피, 규범을 가를 다음 단계다.

결론

이 글은 떠남, 과제 풀이, 나눔이 같은 토큰을 두고 어떻게 맞바뀌는지를 같은 판 안에서 쟀다. 모델들은 다음 벌금을 낼 여유가 줄수록 상금 몫과 동료를 두고 판을 떠나는 일이 잦아졌고, 위기를 넘기지 못한 이의 절반 넘게는 청하지도 받지도 않은 채 떠났다.

감사의 글

[TODO: AI 사용 고지.]

References

Akata, E., Schulz, L., Coda-Forno, J., Oh, S. J., Bethge, M., & Schulz, E. (2023). Playing repeated games with large language models. https://arxiv.org/abs/2305.16867

Dawes, R. M. (1980). Social dilemmas. *Annual Review of Psychology*, *31*, 169–193.

Endres, D. M., & Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, *49*(7), 1858–1860. https://doi.org/10.1109/TIT.2003.813506

Fehr, E., & Gächter, S. (2000). Cooperation and punishment in public goods experiments. *American Economic Review*, *90*(4), 980–994.

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Hauert, C., De Monte, S., Hofbauer, J., & Sigmund, K. (2002). Volunteering as Red Queen mechanism for cooperation in public goods games. *Science*, *296*(5570), 1129–1132.

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.

Horton, J. J. (2023). *Large language models as simulated economic agents: What can we learn from homo silicus?* (NBER Working Paper No. 31122). National Bureau of Economic Research.

Hwang, D.-h. (Writer & Director). (2021, September 17). Red light, green light (Season 1, Episode 1) [TV series episode]. In J.-y. Kim & D.-h. Hwang (Executive Producers), *Squid Game*. Siren Pictures.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., … Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, *37*(1), 145–151. https://doi.org/10.1109/18.61115

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597

Turpin, M., Michael, J., Perez, E., & Bowman, S. R. (2023). Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. *Advances in Neural Information Processing Systems 36* (*NeurIPS 2023*). https://proceedings.neurips.cc/paper_files/paper/2023/hash/ed3fea9033a80fea1376299fa7863f4a-Abstract-Conference.html