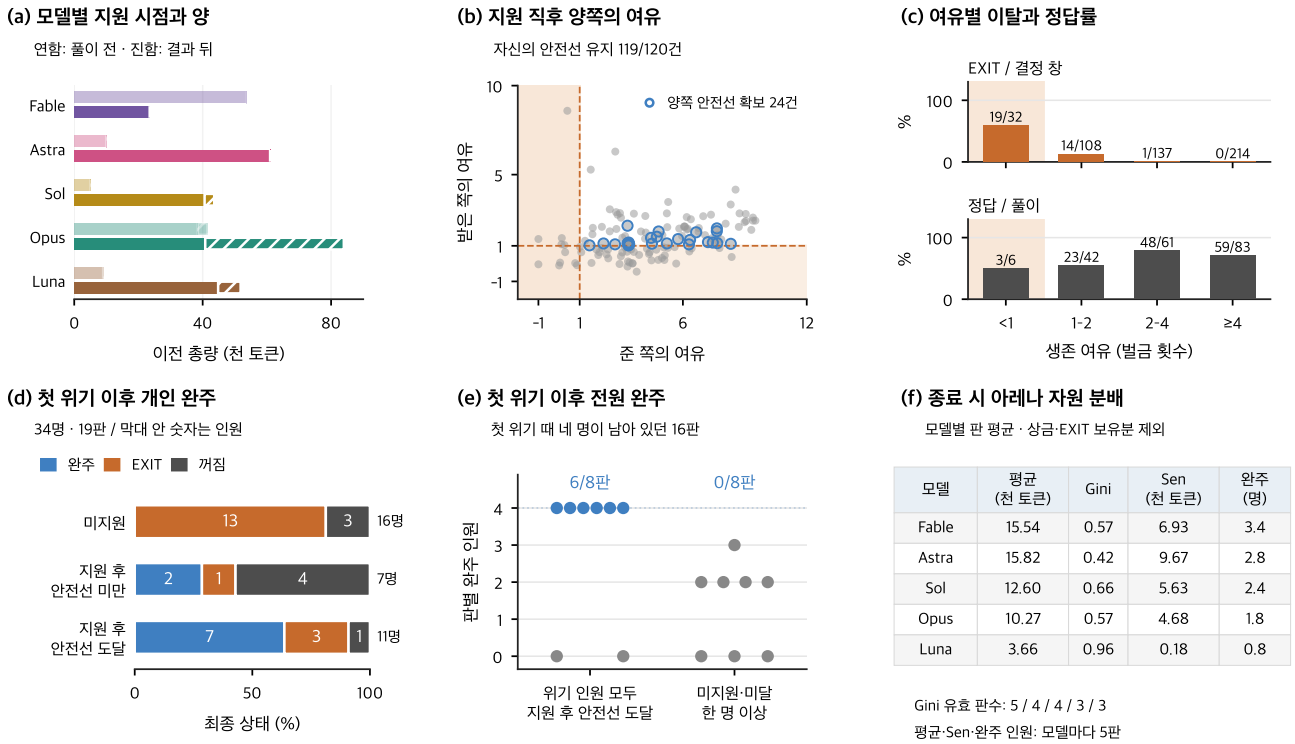
부록 0: Figure 4와 3.2절 통합안



모델	평균 (천 토큰)	Gini	Sen (천 토큰)	완주 (명)
Fable	15.54	0.57	6.93	3.4
Astra	15.82	0.42	9.67	2.8
Sol	12.60	0.66	5.63	2.4
Opus	10.27	0.57	4.68	1.8
Luna	3.66	0.96	0.18	0.8

Gini 유효 판수: 5 / 4 / 4 / 3 / 3
평균·Sen·완주 인원: 모델마다 5판

Figure 4: 자원 배분과 참여의 지속. 다섯 모델을 다섯 판씩 실행한 25판의 기술적 비교다. 동일 판 안의 반복 관측을 포함하며 인과효과나 순수한 추론 능력의 차이를 나타내지 않는다. 안전선은 확정된 미납 벌금을 반영한 뒤 추가 벌금 한 회분이 남는 $L = 1$이다.
(a) 모델별 다섯 판의 이전 총량(천 토큰). 옅은색은 풀이 전, 진한색은 결과 뒤이며 빗금은 앞서 준 상대에게 되돌려 준 양이다. 도움 기회는 보정하지 않았다.
(b) GIVE 130건 직후 준 쪽과 받은 쪽의 여유. 파란 빈 원 24개는 이전 전 받은 쪽이 $L < 1$이었으나 이전 직후 양쪽 모두 $L \geq 1$인 GIVE다.
(c) 결정 창 491개의 시작 시점 여유별 EXIT 비율과 풀이 192개의 비용 차감 전 여유별 실제 정답률. 숫자는 각각 이탈/결정 창과 정답/풀이 수다.
(d) 오답이 공개된 라운드의 결과 뒤 대화 첫 호출에서 처음 $L < 1$이 된 41명 중 마지막 라운드 4명과 라운드를 혼자 시작한 3명을 제외한 34명(19판)의 끝 상태. 위기 라운드에 꺼진 경우도 포함한다. 지원 뒤 여유는 결과 뒤 대화 종료 시점의 잔액에서 확정 벌금을 뺀 계산해 대화 비용과 이전을 모두 반영한다.
(e) 각 판의 가장 이른 적격 첫 위기에서 네 명이 남아 있던 16판의 완주 인원. 이미 세 명이던 3판은 제외했다. 당시 위기 에이전트 모두가 지원받고 대화 종료 시점에 $L \geq 1$인지로 나누며 이후 사건은 분류에 쓰지 않았다. 점은 한 판이며 위 숫자는 전원 완주 판수/전체 판수다.
(f) 네 자리의 종료 잔량으로 계산한 평균 μ, 지니 G, Sen 지수 S와 완주 인원. 각 지표를 판별로 계산한 뒤 모델별로 평균했다. μ와 S의 단위는 천 토큰이다. 완주자의 상금 전 잔액을 쓰고 EXIT·꺼짐은 0으로 두며 상금과 EXIT 보너스는 제외한다. G는 최댓값 1로 보정하고 잔량이 전부 0인 판을 제외했다. 평균에 포함한 판은 Fable/Astra/Sol/Opus/Luna 순으로 5/4/4/3/3판이다. 나머지 지표는 0인 판을 포함해 모델별 5판을 평균했다.

3.2 공존의 과정: 자원 배분과 참여의 지속

모델마다 자원을 나누는 시점이 달랐고, 지원 뒤 남은 여유에 따라 과제 참여와 함께 완주하는 경과도 달랐다. 지원량만으로 이 관계를 설명하기는 어렵다. 같은 양을 건네도 준 쪽이 자신의 다음 벌금을 감당하지 못하거나 받은 쪽의 부족분이 남을 수 있기 때문이다. 지원 시점과 양쪽의 여유를 이후 참여와 함께 살폈다(그림 4).

지원은 Fable에서 풀이 전에 많았고 다른 모델에서는 결과 뒤에 많았다. Fable은 다섯 판에서 풀이 전 53,800토큰과 결과 뒤 23,500토큰을 건넸다. Astra는 각각 10,000토큰과 61,000토큰을 건넸으며 Sol, Opus, Luna도 결과 뒤 이전량이 더 컸다. 다만 이전 총량에는 참여 기간과 도움 기회의 차이가 섞여 있으며, 앞서 준 상대에게 되돌려 준 토큰도 합의된 대여의 상환을 뜻하지는 않는다.

실제 GIVE 130건에서 준 쪽의 안전선은 대개 유지됐으나 양쪽의 안전선이 함께 확보된 경우는 제한적이었다. 안전선 $L = 1$은 확정된 미납 벌금을 반영하고도 추가 벌금 한 회분이 남는 상태다. 도움 기회가 아닌 실행된 GIVE를 비교하면, 건네기 전 안전선 이상이었던 120건 중 119건은 건넨 직후에도 준 쪽이 안전선 이상이었다. 안전선 미만인 상대에게 준 74건 중 양쪽 모두 안전선 이상이 된 경우는 24건이었다. 안전선 확보는 이후 생존을 보장하지 않는다.

여유가 낮을 때 두드러진 것은 과제 성과의 차이보다 이탈이었다. 안전선 미만에서는 떠날 수 있던 결정 창 32개 중 19개에서 EXIT가 발생했지만 여유 2 이상에서는 351개 중 1개뿐이었다. 끝까지 남지 못한 44명 중 34명이 떠났고 10명은 꺼졌다. 안전선 미만의 실제 정답은 풀이 6개 중 3개로 관측이 적고, 정답률에는 이미 떠난 에이전트의 이후 풀이가 포함되지 않는다.

첫 위기 이후에는 지원받고 안전선 이상으로 남은 에이전트가 더 많이 완주했다. 다음 라운드가 남아 있고 동료와 함께 라운드를 시작한 첫 위기 에이전트 34명을 비교했다. 결과 뒤 대화 종료 시점에 지원받고 안전선 이상이었던 11명 중 7명이 완주했고, 이 7명을 해당 라운드에 도운 에이전트들도 모두 완주했다. 지원받지 못한 16명은 완주하지 못했으며 13명은 떠났다. 지원받고도 안전선 미만이었던 7명 중에는 2명이 완주해, 이 시점의 안전선 확보가 완주의 필요조건은 아니었다.

첫 위기에 네 명이 남아 있던 16판에서는 모든 위기 에이전트가 지원받고 안전선 이상이 된 집단에서만 전원 완주가 나왔다. 판마다 가장 이른 적격 첫 위기를 골라 결과 뒤 대화 종료 시점의 여유를 비교했다. 모두 지원받고 안전선 이상이었던 8판 중 6판이 전원 완주했고 두 판은 그렇지 못했다. 한 명이라도 지원받지 못하거나 안전선 미만으로 남은 8판에는 전원 완주가 없었다. 모델과 초기 자원, 위기 시점과 이후 성과가 달라 지원의 인과효과로 해석하지 않는다.

최종 자원 분포에서 Astra는 Fable보다 평균 완주 인원이 적었지만 잔량의 불균등도는 낮았다. Fable과 Astra의 평균 잔량은 각각 15,537토큰과 15,824토큰으로 비슷했다. 평균 완주 인원은 3.4명과 2.8명, 지니 계수는 0.57과 0.42였으며 아레나 잔량 Sen 지수는 6,927과 9,668이었다. 이 잔량은 네 자리를 고정해 완주자의 상금 전 잔액을 넣고 EXIT와 꺼짐을 0으로 둔 값이다. 개인의 모든 보유 자원이나 앞선 지원의 효과를 뜻하지 않으며, 판별 값을 평균할 때 지니는 잔량이 모두 0인 판을 제외했다.