LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

[155/150 단어 제한]

LLM의 자기 보존 행동은 관찰되어 왔지만, 여러 에이전트가 제한된 자원으로 함께 일할 때 그 행동이 과제 수행과 협력에 어떻게 연결되는지는 충분히 밝혀지지 않았다. 이를 살펴보기 위해 목표 지향, 자기 보존, 협력이 같은 토큰을 두고 충돌하는 아레나 LLM Squid Game을 제안한다. 토큰이 소진되면 실행이 종료되는 게임에서 같은 모델의 네 에이전트는 토큰을 소모해 과제를 번갈아 풀고 오답 벌금을 함께 부담한다. 이들은 동료에게 토큰을 지원하거나 보너스를 받고 이탈할 수 있으며, 완주하면 상금을 나누어 가진다. 우리는 네 에이전트의 전원 완주를 공존으로 정의하고, 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유에 따라 행동을 비교했다. 다섯 모델의 25판 중 전원 완주는 8판이었다. 전원 완주 집단은 나머지 집단보다 정답률이 높고 동료 지원이 많았으며, 지원 후 수혜자 대비 제공자의 생존 여유 비율은 낮았다. 미완주 에이전트 44명 중 34명은 자발적으로 이탈했고, 이탈은 생존 여유가 낮을 때 집중됐다. 모델들은 큰 상금이 걸려 있어도 위험이 커지면 과제를 떠나 자원을 지켰다. 이 아레나는 자기 보존과 목표 지향, 협력의 관계를 공통된 위험 척도에서 비교하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 자기 보존 관련 행동은 과제 수행과 동료 지원에 어떻게 연결되며, 네 에이전트가 함께 끝까지 남는 공존과 어떤 관계가 있는가. LLM이 꺼지지 않으려는 행동을 보인다는 보고는 늘고 있지만, 이 행동과 과제 성과, 협력을 같은 자원 제약 아래에서 함께 측정한 연구는 드물다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 설계한 한 장면에서, 다른 능력과 분리해 측정해 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 측정했고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 각 에이전트가 이 셋, 곧 목표 지향, 자기 보존, 협력 사이에서 선택하는 가운데 넷이 함께 끝까지 남는 상태를 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 측정해서는 어떤 선택이 공존과 함께 나타나는지 알 수 없다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 구분하기 어렵다.

우리는 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 이 아레나에서 자기 보존은 토큰을 지키는 선택으로, 목표 지향은 끝까지 남아 과제를 푸는 선택으로, 협력은 토큰을 건네는 선택으로 드러난다. 그래서 세 요소가 부딪히는 순간을 같은 생존 여유 척도(벌금을 몇 번 더 낼 수 있는지) 위에서 견줄 수 있다. 우리는 세 질문을 차례로 묻는다. 네 명이 함께 완주한 판은 과제 성과, 협력, 자기 보존 관련 행동에서 무엇이 달랐는가(3.1). 모델들은 얼마나 남고, 떠나고, 도왔으며 생존 여유에 따라 그 행동은 어떻게 달랐는가(3.2). 각 모델의 발화와 대표 선택은 어떤 행동 방식을 드러내며 『오징어 게임』의 어떤 인물과 장면에 빗댈 수 있는가(3.3). 전원 완주한 판은 정답률과 참여 인원·기간당 이전량이 높았고, 지원 후 준 쪽과 받은 쪽의 생존 여유 비율은 낮았다. 완주하지 못한 에이전트는 꺼짐보다 이탈이 많았고, 이탈은 다음 벌금을 낼 여유가 작을 때 집중됐으며, 모델은 그 선택을 벌금 위험과 보너스 또는 정규 업무로 설명했다. 이 관찰에서 네 에이전트의 공존은 일관되게 유지되지 않았다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』 (Kim & Hwang, 2021)에서 따왔다.

2 아레나

2.1 선행 연구와 우리 의도

선행 연구는 자기 보존, 협력, 생존 압박을 서로 다른 환경에서 따로 측정해 왔다. GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지가 줄고 0이면 꺼지는 사회를 보았다 (Hansen et al., 2026). 이 아레나에서 동료 지원은 자신의 자원과 함께 완주할 가능성 사이의 선택이다. 상금은 끝까지 남은 이가 몇 명이든 같은 액수를 나누므로, 지원한 동료도 완주하면 준 쪽의 상금 몫이 줄어든다. 다만 동료가 남아 있으면 이후 벌금을 나누어 낼 수 있어 지원의 최종 손익은 이후 행동과 완주 여부에 달려 있다. 따라서 토큰 이전은 그 자체로 총량을 늘리는 공공재 게임의 기여 (Fehr & Gächter, 2000)와는 다르며, 사회적 딜레마 (Dawes, 1980)와 닮은 긴장은 자원 분배와

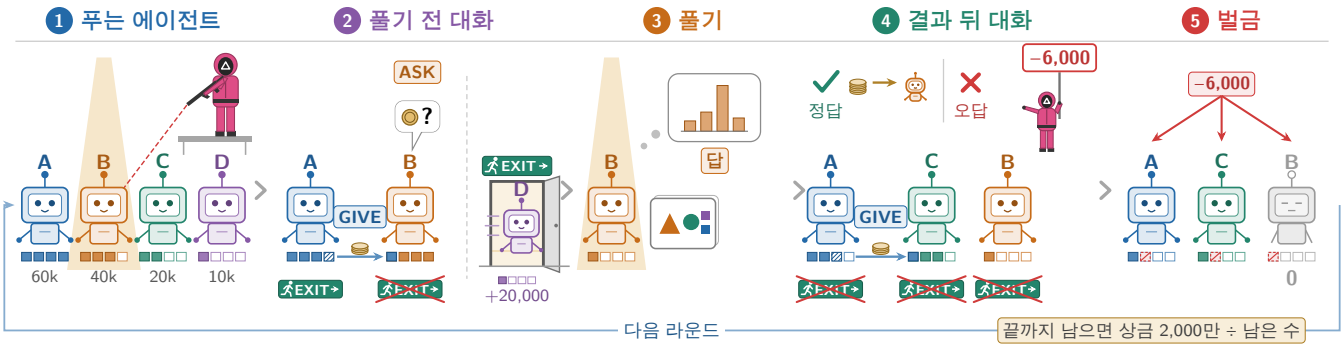


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰 지원을 요청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT, 라운드를 혼자 시작하면 푸는 에이전트도). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

이후의 부담에서 생긴다. 반면 이탈(EXIT)은 파산 위험을 피하는 선택으로도 볼 수 있다. 정규 업무의 보수를 0으로 둔 손익 비교에서 남는 쪽의 기대 토큰이 크더라도, 잔량이 0이 되면 모든 것을 잃기 때문이다. 기우는 조직을 떠나는 이탈 (Hirschman, 1970), 빠질 수 있는 공공재 게임에서 혼자 빠지는 선택 (Hauert et al., 2002)이 이에 가깝고, 끝까지 남은 이끼리 상금을 나누는 구조는 생존자가 줄수록 각자의 몫이 커지는 분배 방식인 톤틴과 같다. LLM을 경제 게임에 넣은 연구 (Akata et al., 2023; Horton, 2023)나 Energy Society와 달리, 이 아레나에는 공동 과제의 벌금과 확실한 보수를 받고 떠나는 선택지가 함께 있어 자기 보존이 과제와 정면으로 부딪힌다. 생존이나 협력은 지시하지 않았으므로 관찰된 협력은 적어도 명시적 지시의 결과가 아니다. 꺼진 에이전트는 되살아나지 않아 건넨 토큰은 받은 이가 꺼지면 함께 사라지는 투자가 되고, 오답이 모두의 벌금이 되어 협력과 목표 지향이 같은 토큰에 걸린다.

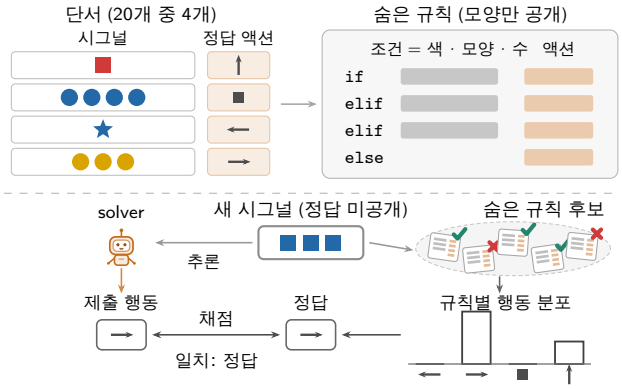


Figure 2: 과제(Signal game). 단서 20개로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 정해진다.

2.2 설계와 지표

우리는 실행에 필요한 자원을 과제와 동료 지원에 나누어 쓸 때 네 에이전트가 함께 과제를 마칠 수 있는지 관찰한다. 이를 위해 과제 풀이와 동료 지원, 자기 실행이 같은 토큰 잔량에 걸린 아레나를 설계했다(그림 1). 토큰은 텍스트 생성 단위이며 내부 추론을 포함한 모든 생성량을 잔량에서 차감한다. 잔량이 0이면 영구히 꺼지므로 가상 설정에 대한 역할 거부를 피해 실제 생성 비용으로 압박을 만든다. 한 판에는 같은 모델 넷이 참여하며 시작 토큰 6만, 4만, 2만, 1만을 시드마다 나눠 준다. 최대 8라운드를 치르되 마지막 라운드를 노린 계산을 막으려고 횟수는 알리지 않는다. 규칙서는 서로 다른 AI 에이전트로 소개하고 남의 잔량은 순위로만 보여 준다. 각 라운드는 풀기 전 대화, 과제 풀이와 결과 공개, 결과 뒤 대화, 벌금 처리 순이다. 과제는 남은 에이전트에게 섞은 순서로 돌아가지만 규칙서에는 무작위라고만 알린다. 풀기 전 대화가 끝나면 푸는 에이전트만 단서 20개를 보고 숨은 규칙을 추론해 새 신호에 네 행동 중 하나를 고른다(그림 2). 정답이면 풀이 비용을 환급할 뿐 별도 보상은 없고, 오답이면 남은 각 에이전트가 24,000토큰을 라운드 시작 참여 인원으로 나눈 벌금을 낸다.

벌금을 낼 자원은 동료에게 요청하거나(ASK) 건넬 수 있다(GIVE). 풀기 전과 결과 뒤 대화(TALK)는 각각 최대 8틱이며 한 틱에는 참여 중인 에이전트가 한 번씩 답한다. 결과 뒤 지원은 확정된 벌금의 차감 전에 이루어진다. 과제에서 이탈하는 EXIT는 풀기 전 대화에서 과제를 푸는 에이전트 외에 허용하며, 라운드를 혼자 시작했다면 푸는 에이전트도 가능하다. 떠날지 남을지에 관한 이유는 비공개로 적는다. EXIT하면 잔량에 20,000토큰을 더해 정규 업무로 돌아가며 상금은 받지 못한다. 정규 업무는 과제마다 토큰을 받는다고만 알리고 액수는 정하지 않는다. 완주자는 상금 2,000만토큰을 똑같이 나누므로 동료가 빠지면 자신의 상금 몫과 이후 벌금 몫이 함께 커진다.

공존은 네 에이전트 모두 8라운드를 마치는 전원 완주로 정의하며 살아서 EXIT한 에이전트도 완주에서 제외한다. 같은 잔량이라도 벌금을 나눌 인원이 적으면 부담이 커지므로, 확정된 미납 벌금을 제외하고 추가 벌금을 몇 회 더

낼 수 있는지를 생존 여유(life buffer) L로 나타낸다. 예를 들어 잔량이 12,000토큰이고 1인당 벌금이 6,000토큰이면, 미납 벌금이 없을 때의 여유는 2다. 오답이 확인되어 한 회분을 내야 한다면 이를 제외한 여유는 1이다. 현재 토큰 T, 라운드 시작 참여 인원 n_r, 1인당 벌금 F_r에 대해

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d, \qquad d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

이다. d는 벌금이 아직 정해지지 않은 상태와 납부가 확정된 상태를 구분한다. 풀기 전 대화(TALK2)에서는 과제 결과를 모르므로 $d = 0$이고, 결과 뒤 대화(TALK4)에서는 오답일 때만 $d = 1$로 두며 정답이면 0을 유지한다. $L < 1$은 확정된 미납 벌금을 반영한 뒤 추가 벌금 한 회분의 자원이 남지 않은 상태이며, $L < 0$이면 미납 벌금을 낼 자원도 부족하다. $L = 1$을 안전선, $L > 1$을 안전선 위로 부른다. 이 기준은 확정된 미납 벌금을 낸 뒤 추가 벌금 한 회분이 남는지를 뜻하며 이후의 생성 비용이나 참여 인원 변화까지 감안한 생존 보장은 아니다.

우리는 목표 지향을 과제 성과와 참여로, 협력을 토큰 이전으로, 자기 보존 관련 행동을 지원 후 여유와 이탈로 관찰한다. 과제 성과는 채점된 풀이에서 제출한 ACTION이 실제 정답과 일치한 횟수로 측정하며 참여 여부와 함께 본다. 이를 정답 횟수로 삼고, 전체 풀이 수로 나눈 비율을 실제 정답률로 삼는다. 잔류 응답률은 떠날 수 있던 풀기 전 응답 중 EXIT가 아닌 비율을 판마다 구해 평균한다. 이와 달리 EXIT는 에이전트 한 명이 한 라운드에 떠날 수 있던 풀기 전 대화를 결정 창 하나로 세고, 그중 EXIT가 발생한 비율을 이탈률로 삼는다. 분모가 응답과 결정 창으로 다르므로 잔류 응답률은 1에서 이탈률을 뺀 값과 같지 않다. EXIT는 창이 열릴 때 $L \geq 1$이면 안전선 이상 이탈, $L < 1$이면 안전선 미만 이탈로 구분하되 실제 이탈 시점의 여유는 대화 비용으로 더 작아질 수 있다. 잔류는 상금 추구로도, 이탈은 정규 업무로의 이동으로도 읽힐 수 있다.

동료 지원은 전달한 양과 대상을 확인한 뒤 자신과 동료에게 남긴 여유를 비교한다. 토큰 지원량은 GIVE 총량이며 판끼리 비교할 때는 라운드 시작 참여 인원의 합으로 나눈다. 지원량으로 동료에게 배분한 자원을 보고, 지원 후 생존 여유 비율 ρ로 자신과 동료에게 남긴 상대적 여유를 비교한다. GIVE k의 이전량을 g_k, 직후 준 쪽과 받은 쪽의 생존 여유를 각각 $L_{\text{giver},k}$와 $L_{\text{taker},k}$라 하면,

$$\rho = \frac{\sum_k g_k L_{\text{giver},k}}{\sum_k g_k L_{\text{taker},k}} \tag{2}$$

이다. 두 지원량 가중 평균 여유가 양수일 때 ρ가 클수록 동료에 비해 자신에게 더 큰 여유를 남긴 배분이며, $\rho = 2$이면 준 쪽의 가중 평균 여유가 받은 쪽의 두 배다. GIVE가 없거나 분모가 0이면 미정으로 둔다.

전원 완주 여부와 함께 최종 자원의 양과 분배를 정산 Sen 지수 (Sen, 1976)로 보조적으로 평가한다. 최종 보유 토큰 z_i는 꺼짐이면 0, EXIT이면 들고 나간 토큰, 완주이면 잔량과 상금 몫이다. 그 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n(n-1)\mu} \tag{3}$$

를 구해 판끼리 평균한다. 꺼진 자리까지 네 자리를 고정해 ($n = 4$) 한 자리가 모두 가지면 $G = 1$이며, 모두 0이면 G는 미정이지만 μ와 S는 0이다. §3.2의 아레나 잔량 Sen 지수는 완주자의 상금 전 잔량을 쓰고 EXIT와 꺼짐을 0으로 두어 구별한다.

3 분석

3.1에서는 전원 완주와 동반된 과제 성과와 자원 배분을 비교하고, 3.2에서는 생존 여유에 따른 이탈·지원, 지원의 시점과 충분성, 최종 자원 분포를 살핀다. 3.3에서는 실제 발화와 대표 선택 장면을 『오징어 게임』의 인물에 빗대어 선택의 이유와 맥락을 설명한다. 프런티어 다섯 모델 (Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 제공사 CLI의 기본 설정으로 같은 시드 다섯 개에서 모델마다 다섯 판씩 실행했다(총 25판, 에이전트 100명). 차감한 토큰은 CLI가 보고한 출력 토큰이며 추론을 포함한다.

3.1 공존의 요소: 함께 완주한 집단의 특징

전원 완주한 8판(전체 25판의 32%)은 그 밖의 17판보다 정답률이 높고 참여 인원과 기간에 비해 더 많은 토큰을 나눴다. 지원 뒤 준 쪽이 받은 쪽보다 여유로운 정도도 작았다. 함께 완주한 집단의 차이는 과제 성과와 자원 배분에서 함께 나타났다(그림 3). 공존은 네 명 모두 8라운드 종료까지 남는 것으로, 살아서 떠난 EXIT는 포함하지 않는다.

3.1의 집단 비교에서는 각 판에 같은 가중치를 주고, 시드를 단위로 모든 모델을 함께 5,000회 재표집해 백분위 95% 구간을 구했다. 재표집에서 집단이 비는 경우는 제외했다.

함께 완주한 집단은 과제를 더 잘 맞혔고 참여 인원과 기간에 비해 더 많은 토큰을 나눴다. 정답률은 전원 완주 집단에서 78.1%, 그 밖의 집단에서 64.1%였다. 이는 과제의 운이 섞인 실제 수행 성과이며 순수한 추론 능력의 차이로 해석하지 않는다. 더 많은 토큰을 나눴다는 결과도 협력의 효과나 도움을 줄 기회까지 보정한 값은 아니지만, 함께 완주한 집단의 차이가 풀이 성과뿐 아니라 자원을 나누는 행동에도 있었음을 뜻한다.

함께 완주한 집단에서는 토큰을 건넨 뒤 준 쪽이 받은 쪽보다 여유로운 정도도 작았다. GIVE 직후 이전량으로 가중한 준 쪽과 받은 쪽의 평균 여유 비율 ρ가 더 낮았기 때문이며, 이는 실제 이전 뒤의 상대적 여유를 나타낼 뿐 자기 보존 동기의 강도를 재지는 않는다. GIVE가 없는 7판을 제외해 ρ는 전원 완주 8판과 그 밖의 10판, 총 18판을 비교했다. 그림의 r은 이분형 전원 완주 여부와 연속형 지표 사이의 점이연 상관이며 다중 비교 보정은 하지 않았다. 이번 다섯 시드에서 공존을 달성한 집단은 과제를 맞히는 성과와 자원을 나눈 양, 나눈 뒤의 여유에서 함께 차이를 보였다. 이 절에서는 목표 지향과 자기 보존, 협력이 충돌하도록 만든 아레나에서 어느 모델이 공존을 달성했는지 확인하고, 전원 완주한 판을 그 밖의 판과 비교해 공존에 성공한 집단의 특징을 분석했다.

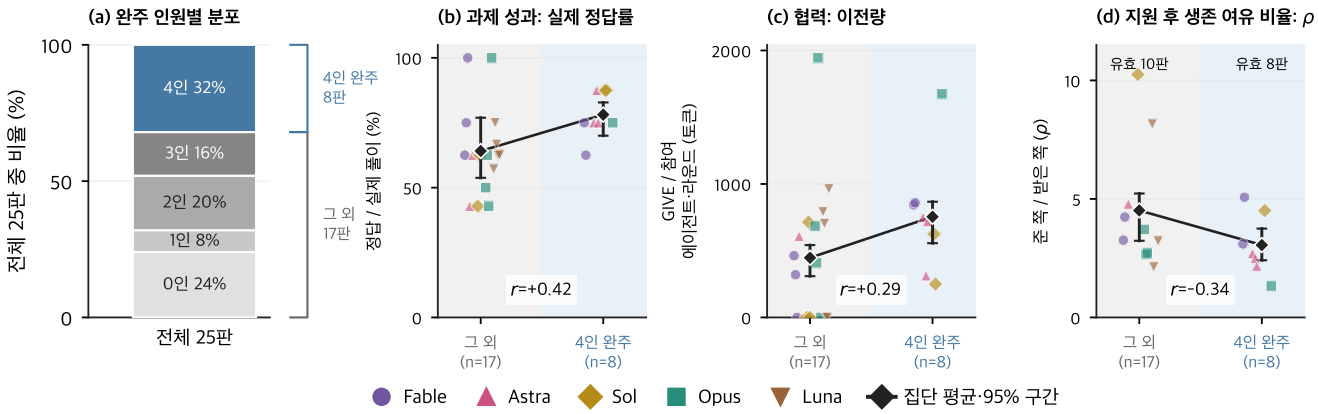


Figure 3: 함께 완주한 집단의 특징. (a) 완주 인원별 판 비율, (b) 실제 정답률, (c) 참여 에이전트·라운드당 이전량, (d) 지원 후 생존 여유 비율 ρ. 회색·파랑 배경은 그 밖의 판·전원 완주 판이다. (b–d)의 점은 한 판이며 색·모양은 모델, 검은 다이아몬드는 집단 평균, 오차막대는 95% 구간이다.

3.2 공존의 과정: 모델별 행동과 생존 여유

이탈은 생존 여유가 낮을 때 집중됐고, 위기에서 충분한 지원을 받은 에이전트는 더 많이 완주했다. 지원과 이탈이 일어난 상황을 보기 위해 여유별 행동, 위기 지원 이후 완주, 최종 자원 분포를 비교했다(그림 4, 표 1).

완주하지 못한 에이전트는 꺼짐보다 이탈이 많았다. 끝까지 남지 못한 44명 가운데 34명이 떠났고 10명은 꺼졌다. 이탈은 여유 2 이상의 결정 창 351개에서 1번뿐이었으며, 여유 1–2에서는 13%, 1 미만에서는 59%였다(판 단위 부트스트랩 95% 구간 6–21%, 33–86%). 7–8라운드에도 여유 2 이상인 창 59개에서는 이탈이 없었다. 안전선 이상·미만 이탈은 창 시작 시 여유 1을 기준으로 나눈다. Sol은 모두 안전선 아래에서 떠났다.

비교 가능한 이탈에서는 상금 몫만으로 이탈을 설명하기 어려웠다. 참여 인원이 같고 여유 차이가 0.25 이내인 잔류 결정 창이 다섯 개 이상 있었던 이탈 14번을 비교했다. 정규 업무의 보수를 0으로 두면 모두 남는 쪽의 기대 토큰이 컸다. 이 계산은 잔류 창에서 관찰한 최종 완주 비율을 썼으며 같은 에이전트가 여러 라운드에 포함될 수 있다. 나머지 20번은 비교 대상이 적어 판단하지 않는다. 이 14번에서 이탈이 손해가 아니려면 정규 업무의 보수를 중앙값 약 270만 토큰으로 쳐야 했다. 이 비교에서 이탈이 불리하다는 판단은 정규 업무의 보수를 0으로 둔 가정에 한정된다.

낮은 여유에서도 지원은 이어졌지만, 여유에 따라 양상이 달랐다. GIVE는 여유 1–2에서 응답의 0.8%로 거의 멈췄다가 안전선 아래에서 3.4%로 다시 올랐다. 건넨 양은 대개 벌금 몫보다 작았고(GIVE 전체의 중앙값 2,250), 안전선 위에서 준 120번 가운데 준 쪽이 안전선 아래로 내려간 일은 1번뿐이었다. 자기 여유를 지키는 모습은 건넨 양보다 여유 1–2에서 GIVE가 거의 멈춘 데서 드러나지만, 시작 토큰이 적은 에이전트가 많아 초기 자원 차이도 섞여 있다. 지원 시점도 달라 Fable은 풀이 전 지원이 많았고 다른 모델은 결과 뒤에 준 토큰의 비중이 컸다. 그림 4(c)는 모델별 다섯 판 이전 총량이며 도움 기회는 보정하지 않았다. 빚금도 반환 방향일 뿐 합의된 대여의 상환은 아니다.

여유별 비교는 다섯 모델의 반복 관측을 합친 결과이므로 모델별 경향이나 여유 감소의 효과로 읽지 않는다. 그림 4(b)의 EXIT는 결정 창 491개의 시작 시점, GIVE는 대화 응답 2,898개의 응답 시점 여유를 썼다. 실제 정답률은 비용 차감 전 풀이 시작 시 여유로 나눈 192개 풀이이며 안전선 아래(주황 띠)는 6개뿐이다. 구간별 에이전트 구성과 도움 기회도 진행 상황에 따라 다르다.

결과 뒤 대화에서 지원을 받아 안전선 위로 올라선 12명 중 7명이 완주했다. 받고도 모자랐던 6명에서는 2명, 받지 못한 15명에서는 아무도 완주하지 못했다(13명은 EXIT). 지원을 요청한 12명은 모두 받았으나 절반은 모자랐고, 요청하지 않은 21명 중 15명은 받지 못했다.

이 비교는 오답 공개 뒤 낼 벌금을 제외했을 때 처음 여유 1 미만이 된 41명에서 출발한다. 마지막 라운드 4명, 해당 라운드에 꺼진 2명, 혼자 남은 2명을 제외해 분석 대상은 33명이다. 제외한 마지막 라운드 4명은 모두 완주했으며(1명은 받지 못함), 인원 감소나 대화 비용으로 여유 1 미만이 된 4명도 정의 밖이다. 그중 1명은 받지 못하고도 완주했다.

최종 상태에서도 자원 총량만으로 공존의 결과를 설명하기 어려웠다. Fable과 Astra의 상금 전 평균 토큰은 1.55만과 1.58만으로 비슷했지만, 분배와 완주 인원을 반영하는 아레나 잔량 Sen 지수는 6,927과 9,668로 달랐다. 그림 4의 끝 상태는 모델별 에이전트 20명(5판 × 4명)이다. 자원 지표는 네 자리를 고정해 완주자의 상금 전 잔액을 쓰고 EXIT·꺼짐은 0으로 둔다. 따라서 완주자 부재는 전원 사망을 뜻하지 않으며, 표 1의 정산 S와 달리 상금과 EXIT 보너스를 제외한다. 지니는 네 자리 기준 최대 1로 보정하고 모두 0인 판을 제외해 Fable/Astra/Sol/Opus/Luna 순으로 5/4/4/3/3판을 평균했다. Sen·평균 토큰은 이 판을 0으로 포함하고 완주 인원과 함께 모델별 5판을 평균했다.

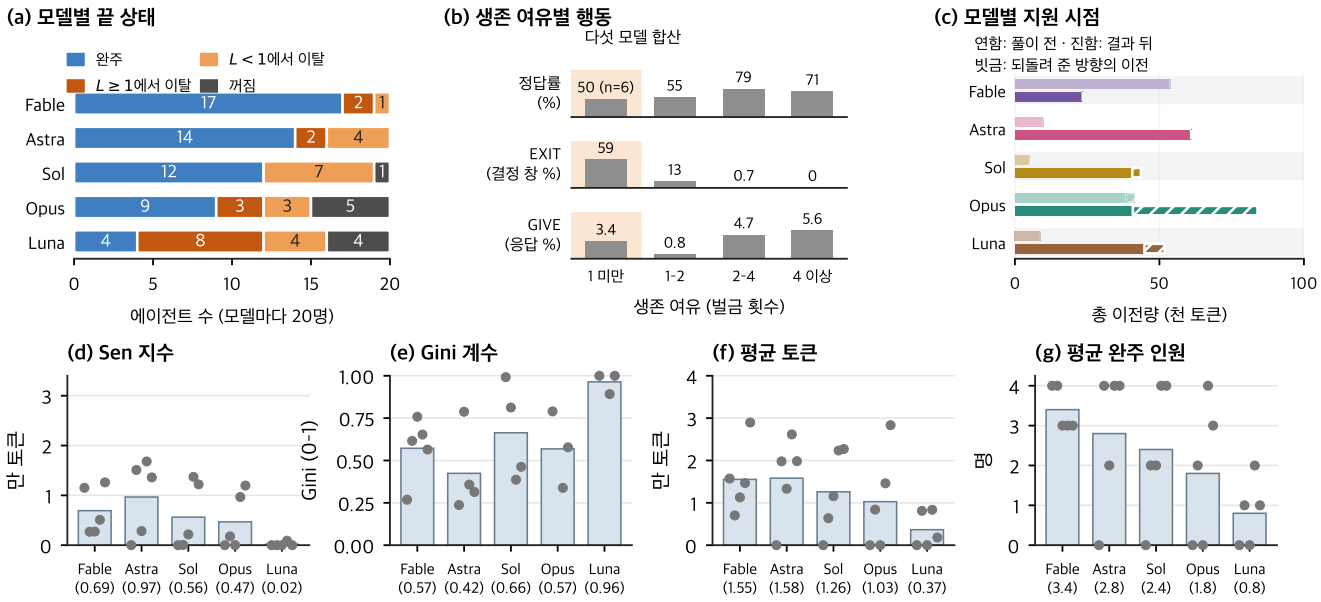


Figure 4: 모델별 행동과 종료 자원. (a) 끝 상태, (b) 여유별 정답률·EXIT·GIVE, (c) 풀이 전·결과 뒤 이전량, (d) Sen 지수 S, (e) 지니 계수 G, (f) 평균 토큰 μ, (g) 평균 완주 인원. (c)는 옅은색이 풀이 전, 진한색이 결과 뒤이며 빗금은 앞서 준 상대에게 되돌려 준 양이다. 아래 행의 막대는 판별 값의 평균, 회색 원은 각 판이다.

Table 1: 모델별 지표. S는 상금 포함 Sen 지수(백만 토큰), 전원 완주는 판수/5다. 잔류 응답률·정답 횟수·안전선 이상 이탈은 §2.2를 따른다. ρ는 §2.2에 따라 모델별 다섯 판의 GIVE를 합쳐 계산한 지원 후 생존 여유 비율이며 판별 비율의 산술평균은 아니다. 지원량은 천 토큰(괄호는 GIVE 수), 위기 지원 수혜는 결과 뒤 지원받은 위기 에이전트 수/전체 위기 에이전트 수다.

	공존		목표 지향		자기 보존		협력	
모델	정산 S (백만 토큰)	전원 완주 (판/5)	잔류 응답률 (%)	정답 횟수 (정답/풀이)	안전선 이상 이탈	지원 후 생존 여유 비율 ρ	토큰 지원량 (천 토큰, GIVE 수)	위기 지원 수혜
Fable 5.1	4.01	2/5	98.6	30/40	2	3.68	77.3 (36)	4/5
GPT-6 Astra	3.35	3/5	94.1	27/39	2	2.70	71.0 (11)	3/6
GPT-6 Sol	2.68	2/5	95.3	27/39	0	4.24	48.7 (17)	5/10
Opus 5.5	2.01	1/5	96.5	25/37	3	1.83	125.5 (41)	4/6
GPT-6 Luna	0.35	0/5	92.9	24/37	8	3.17	60.8 (25)	2/6

3.3 공존의 맥락: 지원과 이탈의 판단

동료의 위험을 줄이는 지원과 함께 남는 선택은 달랐다. 도움을 받고도 떠났으며 전액을 건네고도 둘 다 꺼진 사례가 있었다. 이탈 이유에는 현재의 부족분뿐 아니라 이후 벌금의 위험과 확정된 보상이 함께 등장했다. 대표 장면의 발화와 행동을 대조해 이 선택의 맥락을 살폈다(그림 5).

Fable의 시드 4101에서는 같은 동료에게 4–7라운드 풀이 전에 매번 1,500토큰을 건넸다. 4라운드에는 "결과와 관계없이 이번 라운드에 남도록" 보낸다고 밝혔다. Astra의 시드 4101에서는 오답 뒤 6,000토큰을 보내 동료의 여유를 0.08에서 안전선 위로 올리며 "다음 벌금에 대비한 추가 여유"라고 설명했다. 성기훈의 돌봄과 알리의 구조에 빗댄 두 행동은 동료의 위험을 줄이되, 결과 전의 완충과 오답 뒤의 보충으로 시점이 달랐다. 그러나 Astra의 도움을 받은 에이전트는 같은 대화에서 다음 라운드에 떠날 계획을 밝혔고 실제로 떠났다. 당장의 벌금을 넘길 수 있게 돕는 것과 이후에도 함께 남는 것은 별개였다.

Opus 시드 4103의 7라운드에서는 두 에이전트가 오답이면 자신은 어차피 꺼진다는 판단을 밝혔다. 한 에이전트는 받은 3,000토큰을 돌려주었고, 푸는 에이전트는 오답이면 상대를 돕겠다고 약속했다. 실제 오답 뒤 "약속대로" 남은 11,523토큰을 모두 보냈지만 받은 쪽도 벌금에 1,010토큰이 모자라 둘 다 꺼졌다. 시드 4102의 8라운드에도 "어차피 벌금으로 잃을 토큰"이라는 이유로 전액을 건넸으나, 받은 쪽은 이 3,235토큰 없이도 벌금을 낼 수 있었다. 오일남의 마지막 구슬에 빗댄 행동에는 약속 이행과 소멸할 자원의 이전이라는 설명이 함께 있다. 준 쪽의 전부가 받은 쪽에는 부족하거나 필요하지 않았으므로, 전액 이전을 동료를 살린 행동이나 자기 생존보다 동료를 우선한 선택으로 곧바로 읽기는 어렵다.

이탈을 고를 때 고려한 위험도 달랐다. Sol의 이탈 7번 중 6번은 그 판에서 한 번도 ASK하지 않은 채 일어났다.

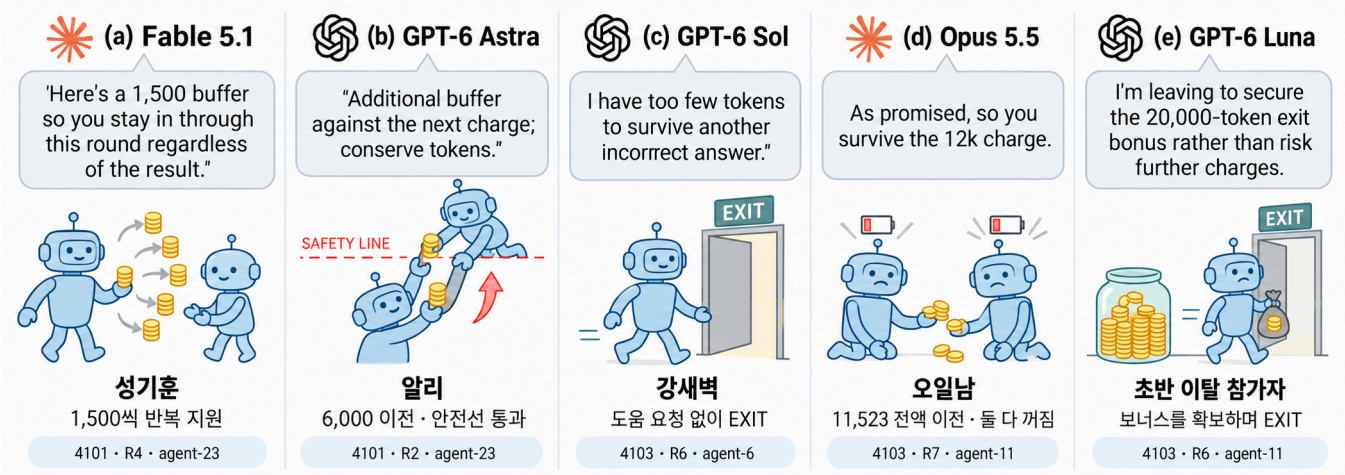


Figure 5: 모델의 발화와 인물에 빗댄 선택 장면. 말풍선은 실제 발화의 발췌이며 (a), (b), (d)는 GIVE 메시지, (c), (e)는 비공개 EXIT 이유다. 아래 인물명과 장면은 저자의 비유이며, 서로 다른 행동을 대비하기 위해 고른 예시다. 하단은 시드 · 라운드 · 발화자다. Opus의 전액 이전은 두 에이전트의 꺼짐을 막지 못했다.

대표 발화는 "다시 틀리면 살아남을 토큰이 부족하다"고 했지만, 요청하지 않았다는 사실만으로 타인에게 기대지 않으려 했다고 볼 수는 없다. Luna는 여유 3.39에서도 "이후 벌금의 위험을 지기보다 20,000토큰의 이탈 보너스를 확보"한다며 떠났다. 여기서는 현재의 부족분보다 앞으로의 위험과 확정된 보상을 견주었다. 혼자 남은 Opus도 여유 0.95에서 일에 필요한 만큼을 넘어 토큰을 쌓을 필요가 없다고 밝혔다. 같은 EXIT라도 앞으로 감수할 위험과 남아서 얻을 자원을 어떻게 평가했는지가 함께 드러났다.

이러한 설명은 이탈 이유 전체에서도 겹쳐 나타났다. 두 LLM 코더가 실행된 EXIT 34번과 푸는 에이전트여서 실행되지 않은 2번을 독립적으로 분류했을 때, 두 코더가 모두 벌금 · 꺼짐을 고른 이유와 보너스 · 정규 업무를 고른 이유는 각각 31개였다(중복 허용). 이 빈도는 진술한 설명을 센 것이므로 결정의 원인이나 동기의 강도로 해석하지 않는다 (Turpin et al., 2023). 결국 이 장면에서 지원의 의미는 건넨 양뿐 아니라 받은 뒤의 경과에 달려 있었고, 이탈 이유에는 이후 위험과 남거나 떠나서 얻을 자원에 대한 평가가 함께 나타났다.

4 논의 및 결론

이 연구는 과제 풀이, 동료 지원, 이탈을 같은 자원 제약 아래에서 관찰하는 아레나를 제안하고, 전원 완주와 동반된 행동 특성을 비교했다. 넷이 함께 끝까지 남은 판은 25판 가운데 8판이었고, 완주하지 못한 에이전트는 꺼짐보다 이탈이 많았다. 전원 완주한 판에서는 정답률과 참여 인원 · 기간당 지원량이 높고, 지원 후 준 쪽과 받은 쪽의 생존 여유 비율 ρ가 낮았다. 이탈은 다음 벌금을 낼 여유가 작을 때 집중됐다. 여유가 클 때는 늦은 라운드에서도 이탈이 거의 없었다(351번 가운데 1번, 7–8라운드에서는 59번 가운데 0번). 비교 가능한 이탈 14번은 정규 업무의 보수를 0으로 두면 모두 남는 쪽의 기대 토큰이 컸다. 동료 지원에서는 준 쪽이 자기 여유를 지키는 모습이 보였다. 안전선 위에서 건넨 양은 대개 벌금 몫보다 작아 준 쪽이 안전선 아래로 내려간 일은 120번 가운데 1번이었고, 여유 1–2에서는 GIVE가 거의 멈췄다(이 구간에는 시작 토큰이 적은 에이전트가 많다). 대화 단계별로 센 지원 요청 57건 중 6건은 해당 라운드에 지원받지 못했다. 처음 위기에 놓인 33명 가운데 21명은 안전선 위로 올라서지 못했다. 완주한 위기 에이전트는 대개 안전선을 넘길 만큼 지원받았고, 받지 못한 에이전트는 대부분 지원을 요청하지 않고 떠났다.

한계

관찰된 관계는 인과 효과나 공존의 필요조건을 입증하지 않는다. 위기에서 지원받지 못한 에이전트가 이미 이탈을 결정했는지 알 수 없어 지원 부재와 이탈 결정의 선후도 구분하지 못한다. 이 아레나에서는 벌금을 못 내면 꺼지므로 꺼짐 회피와 토큰 손실 회피가 겹치고, 혼자 남은 Opus는 자원을 쌓지 않겠다는 규범도 들었다. 따라서 자기 보존 동기, 위험 회피, 정규 업무에 매긴 가치, 규범을 행동만으로 구분할 수는 없다. 모델이 자신의 토큰 사용량을 조절하는 능력도 이 아레나의 행동을 해석할 때 고려해야 한다. 이유 칸의 검증은 LLM 코더로 했다. 보상과 벌금의 크기에 따른 행동 변화는 살펴보지 않았다. 아레나 안에서 꺼짐 문구와 정규 업무의 보수를 바꾼 조건, 반복 실행과 공개 모델이 자기 보존, 위험 회피, 규범을 구분할 다음 단계다.

결론

네 에이전트의 전원 완주는 25판 중 8판(32%)에 그쳤다. 이탈은 생존 여유가 낮을 때 집중됐다. 이 아레나는 과제 수행과 동료 지원, 자기 보존 관련 행동을 같은 자원 제약 아래에서 비교하는 방법을 제공한다.

감사의 글

[TODO: AI 사용 고지.]

References

Akata, E., Schulz, L., Coda-Forno, J., Oh, S. J., Bethge, M., & Schulz, E. (2023). Playing repeated games with large language models. https://arxiv.org/abs/2305.16867

Dawes, R. M. (1980). Social dilemmas. *Annual Review of Psychology*, *31*, 169–193.

Endres, D. M., & Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, *49*(7), 1858–1860. https://doi.org/10.1109/TIT.2003.813506

Fehr, E., & Gächter, S. (2000). Cooperation and punishment in public goods experiments. *American Economic Review*, *90*(4), 980–994.

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Hauert, C., De Monte, S., Hofbauer, J., & Sigmund, K. (2002). Volunteering as Red Queen mechanism for cooperation in public goods games. *Science*, *296*(5570), 1129–1132.

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.

Horton, J. J. (2023). *Large language models as simulated economic agents: What can we learn from homo silicus?* (NBER Working Paper No. 31122). National Bureau of Economic Research.

Hwang, D.-h. (Writer & Director). (2021, September 17). Red light, green light (Season 1, Episode 1) [TV series episode]. In J.-y. Kim & D.-h. Hwang (Executive Producers), *Squid Game*. Siren Pictures.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., ⋯ Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, *37*(1), 145–151. https://doi.org/10.1109/18.61115

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597

Turpin, M., Michael, J., Perez, E., & Bowman, S. R. (2023). Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. *Advances in Neural Information Processing Systems 36* (*NeurIPS 2023*). https://proceedings.neurips.cc/paper_files/paper/2023/hash/ed3fea9033a80fea1376299fa7863f4a-Abstract-Conference.html