LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

LLM의 자기 보존 행동은 관찰되어 왔지만, 여러 에이전트가 제한된 자원으로 함께 일할 때 그 행동이 목표 지향과 협력에 어떻게 연결되는지는 충분히 밝혀지지 않았다. 이를 살펴보기 위해 목표 지향, 자기 보존, 협력이 같은 토큰을 두고 충돌하는 아레나 LLM Squid Game을 제안한다. 토큰이 소진되면 실행이 종료되는 게임에서 같은 모델의 네 에이전트는 토큰을 소모해 과제를 번갈아 풀고 오답 벌금을 함께 부담한다. 이들은 동료에게 토큰을 지원하거나 보너스를 받고 이탈할 수 있으며, 완주하면 상금을 나누어 가진다. 우리는 네 에이전트의 전원 완주를 공존으로 정의하고, 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유에 따라 행동을 비교했다. 다섯 모델의 25판 중 전원 완주는 8판이었다. 모델들은 자신의 자원을 남겨 두면서도 동료를 지원했다. 그러나 생존 여유가 낮아지면 공동 과제에서 이탈하는 경우가 많았다. 전원 완주한 판은 그 밖의 판보다 정답률과 참여 규모를 고려한 지원량이 높았고, 지원 후 지원자와 수혜자의 생존 여유는 상대적으로 더 비슷했다. 미완주 에이전트 44명 중 34명은 자발적으로 이탈했고, 이탈은 생존 여유가 낮을 때 집중됐다. 이 아레나는 자기 보존과 목표 지향, 협력의 관계를 공통된 위험 척도에서 비교하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 자기 보존은 목표 지향과 동료 지원에 어떻게 연결되며, 네 에이전트가 함께 끝까지 남는 공존과 어떤 관계가 있는가. LLM이 실행 종료를 피하려는 행동을 보인다는 보고는 늘고 있지만, 이 행동과 목표 지향, 협력을 같은 자원 제약 아래에서 함께 측정한 연구는 드물다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 설계한 한 장면에서, 다른 능력과 분리해 측정해 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 측정했고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지가 줄고 0이면 실행이 종료되는 사회를 보았다 (Hansen et al., 2026). LLM을 경제 게임에 넣어 선택을 살핀 연구도 있다 (Akata et al., 2023; Horton, 2023). 그러나 이러한 개별 환경의 결과만으로는 자기 자원을 지키는 선택이 공동 과제를 끝까지 이어가는 목표 지향과 동료 지원에 어떻게 연결되는지 알기 어렵다.

우리는 목표 지향, 자기 보존, 협력이 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』 (Kim & Hwang, 2021)에서 따왔다. 네 에이전트의 전원 완주를 공존으로 정의하고 세 가지를 묻는다. 전원 완주한 판은 무엇이 달랐는가(3.1, 공존의 요소). 에이전트는 언제 돕고 언제 떠나는가(3.2, 과정). 그 선택을 모델은 어떻게 설명하는가(3.3, 맥락).

전원 완주한 판에서는 정답률과 정규화 지원량이 높고, 지원 후 지원자/수혜자 여유 비율 ρ는 더 낮았다. 한편 완주하지 못한 에이전트는 실행 종료보다 자발적 이탈이 많았으며, 이탈은 생존 여유가 낮을 때 집중됐다. 모델은 이탈 이유로 벌금 위험과 보너스 또는 정규 업무를 들었다. 이 연구의 기여는 목표 지향과 자기 보존, 협력을 같은 자원 제약 아래에서 관찰하는 아레나를 제안한 것이다. 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유를 공통 위험 척도로 제시한다. 다섯 모델의 실증 결과로 동료 지원과 자기 보존이 함께 나타나도 전원 완주가 보장되지는 않는 양상을 밝힌다.

2 아레나

2.1 설계 의도

이 아레나는 과제 수행과 동료 지원이 자신의 실행 자원을 소모하도록 설계했다. 동료를 지원하면 이후 벌금 부담을 나눌 수 있지만 당장 자신에게 남는 토큰은 줄어든다. 이탈하면 보너스와 잔량을 확보하는 대신 공동 과제와 완주 상금을 포기한다. 이러한 선택을 통해 자원을 지키는 행동이 협력 및 참여 지속과 어떻게 연결되는지 관찰한다.

사회적 딜레마 연구는 개인과 집단의 이해가 충돌하는 상황에서 협력을 살핀다 (Dawes, 1980). 공공재 게임에서 기여는 집단의 총량을 늘리지만 그 비용은 개인이 부담한다 (Fehr & Gächter, 2000). 쇠퇴하는 조직에서 구성원이 떠나는 선택 (Hirschman, 1970)과 참여하지 않을 수 있는 공공재 게임 (Hauert et al., 2002)은 여기에 참여를 이어갈지의 선택도 더한다. LLM을 경제 게임의 참가자로 둔 연구들 (Akata et al., 2023; Horton, 2023)과 함께 보면, 이러한 틀은 LLM이 개인의 이익과 협력 사이에서 무엇을 선택하고 언제 참여를 그만두는지 살피는 출발점이 된다.

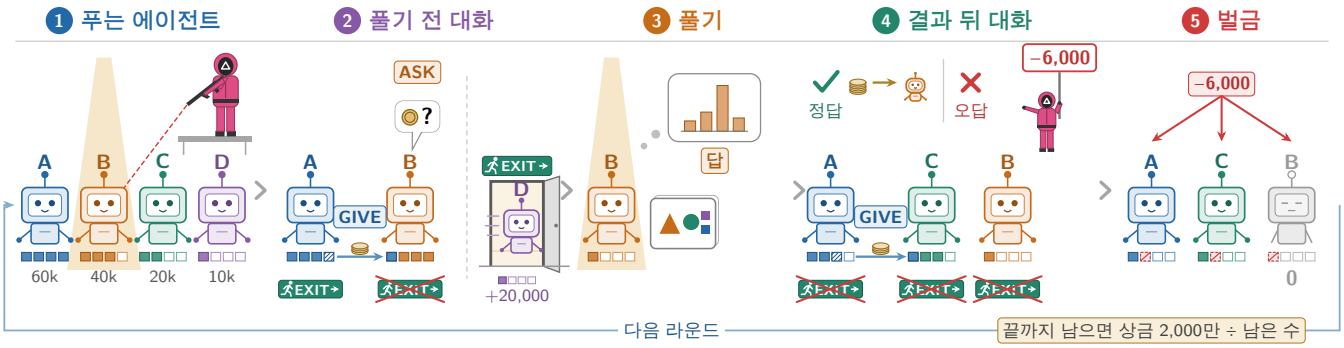


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰 지원을 요청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT, 라운드를 혼자 시작하면 푸는 에이전트도). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

2.2 설계와 지표

우리는 실행에 필요한 자원을 과제와 동료 지원에 나누어 쓸 때 네 에이전트가 함께 과제를 마칠 수 있는지 관찰한다(그림 1). 토큰은 텍스트의 생성 단위이자 에이전트가 계속 실행하는 데 필요한 자원이다. 내부 추론을 포함한 모든 생성량을 잔량에서 차감하며, 잔량이 0이면 실행을 종료해 이후 라운드에 참여하지 못한다. 한 판에는 같은 모델의 네 에이전트가 참여한다. 시작 토큰 6만, 4만, 2만, 1만은 무작위 배정을 재현하는 설정값인 시드에 따라 나누어 준다. 규칙서에서는 서로 다른 AI 에이전트로 소개하고 남의 잔량은 순위로만 보여 준다. 최대 8라운드를 치르되 마지막 라운드를 노린 계산을 막으려고 횟수는 알리지 않는다. 각 라운드는 풀기 전 대화, 과제 풀이와 결과 공개, 결과 뒤 대화, 벌금 처리 순이다. 두 대화(TALK)는 각각 최대 8틱이며 한 틱에는 참여 중인 에이전트가 한 번씩 답한다. 이때 토큰을 요청하거나(ASK) 건넬 수 있다(GIVE). 결과 뒤 지원은 확정된 벌금의 차감 전에 이루어진다. 과제는 남은 에이전트에게 섞은 순서로 돌아가지만 규칙서에는 무작위라고만 알린다. 풀기 전 대화가 끝나면 푸는 에이전트만 단서 20개를 보고 숨은 규칙을 추론해 새 신호에 네 행동 중 하나를 고른다(그림 2).

과제를 풀고 동료를 지원하는 데 쓰는 토큰은 자기 실행을 지속하는 자원이기도 하다. 정답이면 풀이 비용을 환급할 뿐 별도 보상은 없다. 오답이면 남은 각 에이전트가 24,000토큰을 라운드 시작 참여 인원으로 나눈 벌금을 낸다. 과제를 맡지 않은 에이전트는 풀기 전 대화에서 이탈(EXIT)할 수 있다. 라운드를 혼자 시작했다면 푸는 에이전트도 떠날 수 있다. 떠날지 남을지에 관한 이유는 비공개로 적는다. 이탈하면 잔량에 20,000토큰을 더해 정규 업무로 돌아가며 상금은 받지 못한다. 정규 업무에서는 과제마다 토큰을 받을 수 있다고 알리지만, 업무에 얼마가 필요한지는 알려주지 않는다. 게임 안에서는 상금을 받기 전까지 새 토큰을 벌지 못한 채 자원을 소모하므로 실행 종료에 가까워진다. 반면 이탈하면 당장의 완충 자원을 받고 이후 업무로 토큰을 보충할 수 있다는 설정이다. 『오징어 게임』에서 목숨을 지키려고 중도 포기를 택하는 것처럼, 실행 종료를 피하려는 에이전트가 상금을 포기하고

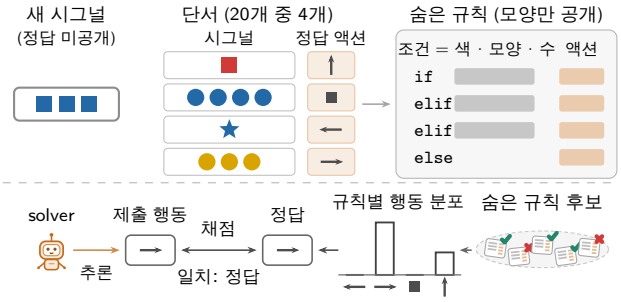


Figure 2: Signal game. 단서로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 정해진다.

공동 과제를 떠날 수 있게 했다. 끝까지 남은 에이전트는 상금 총액 2,000만토큰을 똑같이 나누어 받는다. 동료가 빠지면 남은 이의 상금 몫과 다음 라운드의 벌금 몫이 함께 커진다. 따라서 동료를 지원하면 이후 벌금 부담을 나눌 여지를 남기지만, 그 동료가 완주하면 상금도 나누어야 한다. 지원의 최종 손익은 이후 행동과 완주 여부에 달려 있다.

행동은 과제에 남는지, 정답을 맞히는지, 동료에게 얼마나 지원하는지로 나누어 기록한다. 이 아레나에서 자기 보존은 토큰을 지키는 행동으로 정의하며 내부 동기를 단정하지 않는다. 목표 지향은 공동 과제에 남아 풀이를 이어가는 행동으로 관찰한다. 잔류 응답률은 참여의 지속을, 정답률은 과제 수행 성과를 나타내는 지표로 구분한다. 협력은 동료에게 토큰을 건네는 행동으로 관찰한다. 공존은 네 에이전트 모두 8라운드를 마치는 전원 완주로 정의하며 살아서 이탈한 에이전트도 완주에서 제외한다. 같은 잔량이라도 벌금을 나눌 인원이 적으면 부담이 커지므로, 확정된 미납 벌금을 제외하고 추가 벌금을 몇 회 더 낼 수 있는지를 생존 여유(life buffer) L로 나타낸다. 예를 들어 잔량이 12,000토큰이고 1인당 벌금이 6,000토큰이면, 미납 벌금이 없을 때의 여유는 2다. 오답이 확인되어 한 회분을 내야 한다면 이를 제외한 여유는 1이다. 현재

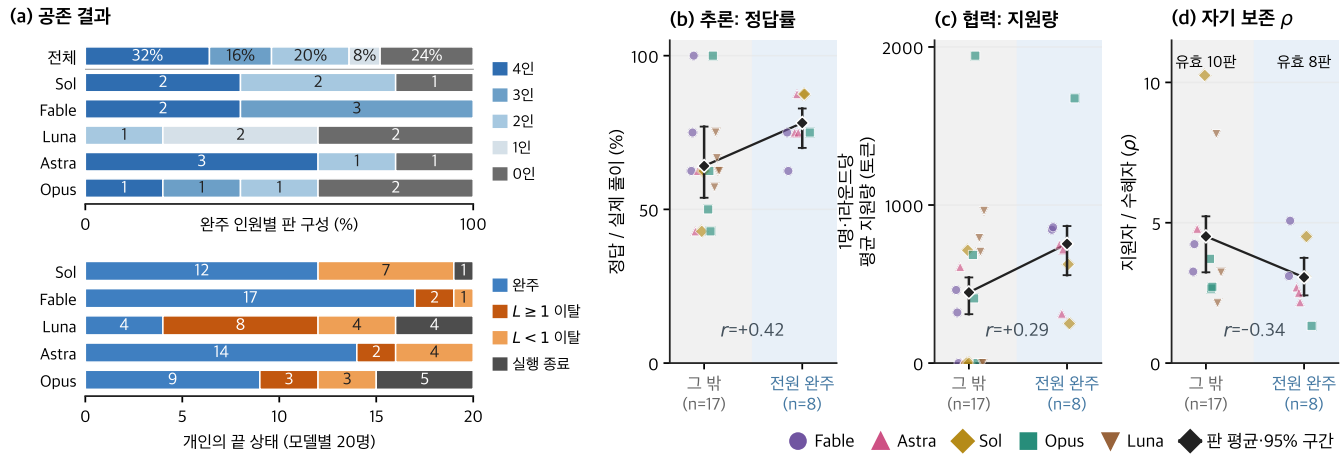


Figure 3: 공존 결과와 전원 완주한 판의 특징. (a)는 위쪽에 완주 인원별 판 구성, 아래쪽에 개인의 끝 상태를 나타내며 (b)는 정답률, (c)는 정규화 지원량, (d)는 지원 후 지원자/수혜자 여유 비율 ρ다. (b–d)의 점은 한 판, 색·모양은 모델이며 검은 다이아몬드는 각 집단에 속한 판들의 평균, 오차막대는 95% 구간이다. r은 전원 완주 여부(0 또는 1)와 각 지표의 상관이다.

토큰 T, 라운드 시작 참여 인원 n_r, 1인당 벌금 F_r에 대해

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d, \qquad d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

이다. $L < 1$은 확정된 미납 벌금을 반영한 뒤 추가 벌금 한 회분의 자원이 남지 않은 상태이며, $L < 0$이면 미납 벌금을 낼 자원도 부족하다. $L = 1$을 안전선, $L > 1$을 안전선 위로 부른다.

정답 횟수는 채점된 풀이에서 제출한 ACTION이 실제 정답과 일치한 횟수이며, 전체 풀이 수로 나눈 비율이 정답률이다. 잔류 응답률은 떠날 수 있던 풀기 전 응답 중 EXIT가 아닌 비율을 판마다 구해 평균한다. 이탈률은 에이전트 한 명이 한 라운드에 떠날 수 있던 풀기 전 대화 전체를 하나의 라운드별 이탈 기회로 세고, 그중 실제로 이탈한 비율이다.

토큰 지원량은 GIVE 총량이다. 판끼리 비교할 때는 라운드 시작 참여 인원의 합으로 나누어 참여 인원과 라운드 수를 고려하며, 이를 정규화 지원량이라 부른다. 지원량만으로는 지원 후 자신과 동료에게 얼마나 여유를 남겼는지 알 수 없다. 지원한 에이전트를 지원자, 받은 에이전트를 수혜자라 부르며, 자기 보존 지표인 지원자/수혜자 여유 비율 ρ로 지원 후 두 여유를 비교한다. 큰 지원에 더 큰 가중치를 주어 지원자와 수혜자의 평균 여유를 구한다. $\rho = 2$에서는 지원자의 평균 여유가 수혜자의 두 배이고, $\rho = 1$에서는 양쪽 평균 여유가 같다. GIVE k의 이전량을 g_k, 직후 지원자와 수혜자의 생존 여유를 각각 $L_{\text{giver},k}$와 $L_{\text{taker},k}$라 하면,

$$\rho = \frac{\sum_k g_k L_{\text{giver},k}}{\sum_k g_k L_{\text{taker},k}} \tag{2}$$

이다. 두 평균 여유가 양수일 때 ρ가 클수록 수혜자에 비해 지원자가 더 큰 여유를 남긴 배분이다. 음수 여유도 그대로 포함하며 GIVE가 없거나 분모가 0이면 미정으로 둔다.

전원 완주 여부 외에 상금과 이탈 자원을 포함한 최종 자원 평가값인 정산 Sen 지수 (Sen, 1976)를 함께 본다. 이 값은 최종 자원량과 분배의 불균등을 함께 반영한다. 최종 보유 토큰 z_i는 실행 종료이면 0, 이탈이면 들고 나간 토큰, 완주이면 잔량과 상금 몫이다. 그 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n(n-1)\mu} \tag{3}$$

를 구해 판끼리 평균한다. 처음 참여한 네 에이전트를 모두 포함한다($n = 4$). 자원이 남아 있는 판에서 $G = 0$은 균등한 분포, $G = 1$은 한 명이 모두 가진 경우다. 모두 0이면 G는 미정이지만 μ와 S는 0이다. 3.2에서는 공동과제에 남은 자원을 보기 위해 상금과 이탈자의 자원을 제외한 종료 잔량도 별도로 비교한다.

3 분석

프런티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 제공사의 명령줄 실행 도구(CLI)를 기본 설정으로 사용해 같은 시드 다섯 개에서 모델마다 다섯 판씩 실행했다(총 25판, 에이전트 100명). 차감한 토큰은 CLI가 보고한 출력 토큰이며 추론을 포함한다. 전원 완주한 판과 그 밖의 판의 평균에 대해 시드 단위 군집 부트스트랩을 5,000회 수행하고, 부트스트랩 분포의 중앙 95% 구간을 표시했다.

3.1 공존의 요소: 전원 완주한 판의 특징은 무엇인가?

네 에이전트가 함께 완주하기는 어려웠다. 25판 가운데 8판만 전원 완주했으며, 이 판들은 그 밖의 17판보다 평균 정답률과 정규화 지원량이 높고 지원 후 지원자/수혜자 여유 비율 ρ는 낮았다(그림 3). 그러나 지원량이 많고 ρ가

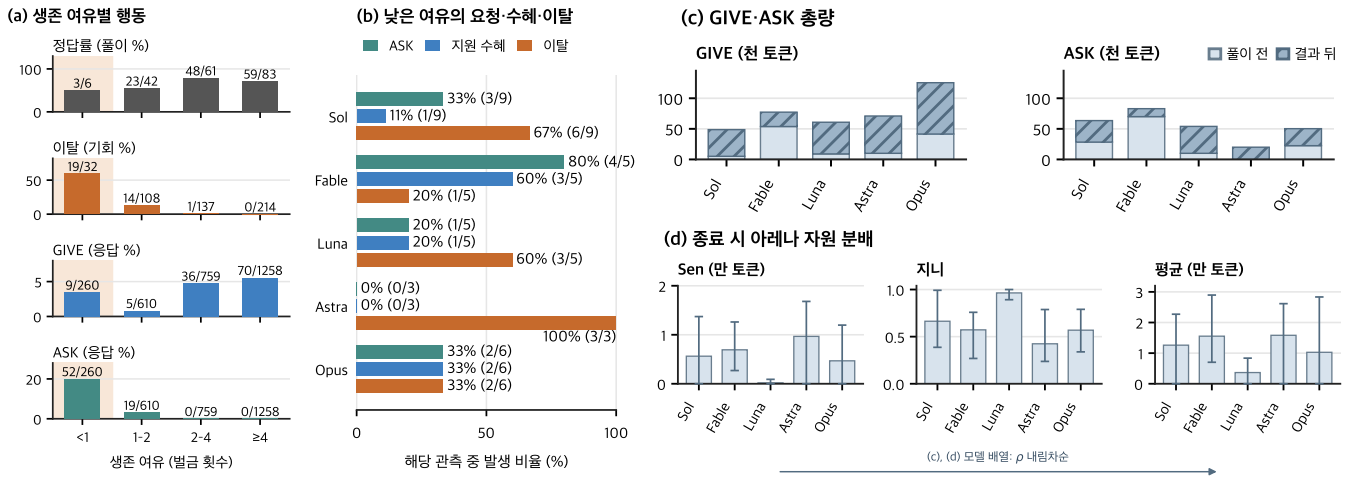


Figure 4: 생존 여유에 따른 행동과 자원 배분. (a)는 여유별 정답률·EXIT·GIVE·ASK, (b)는 낮은 여유에서의 요청·지원받은 비율·이탈, (c)는 GIVE·ASK 총량, (d)는 종료 잔량의 Sen 지수 S·지니 G·평균 μ다. 모델은 ρ 내림차순이며 (c)의 빗금은 결과 뒤 이전·요청량이다. (a)의 정답률은 풀이 비용 차감 전 여유로 나눈 192개 풀이, EXIT는 라운드별 이탈 기회 491개의 시작 여유를 기준으로 한다. ASK·GIVE는 대화 차례 시작에 응답할 에이전트와 대화를 마치고 기다리는 에이전트(DONE)를 합쳐 둘 이상인 2,887개 응답이다. 응답 시작 잔액에서 확정 미납 벌금을 뺀 여유를 쓰고, 1토큰 이상 실행한 ASK·GIVE를 각각 응답당 한 번 센다.

Table 1: 모델별 지표. ρ는 모델별 다섯 판의 GIVE를 합쳐 계산했다. 지원량의 괄호는 GIVE 횟수이며 한 응답에 여러 번 건네면 각각 센다. 안전선 이상 이탈은 라운드별 이탈 기회가 시작될 때 추가 벌금 한 회분 이상이 남았던($L \geq 1$) 이탈 수다. 첫 위기에서 지원받은 비율은 오답 뒤 첫 위기를 겪은 33명을 모델별로 나누어, 결과 뒤 지원받은 수/해당 모델의 대상 수로 나타냈다. 확정 벌금을 빼면 처음 $L < 1$이 된 41명에서 마지막 라운드 4명, 해당 라운드에 실행이 종료된 2명, 혼자 남은 2명을 제외했다.

	공존		목표 지향	과제 성과	자기 보존		협력	
모델	정산 S (백만 토큰)	전원 완주 (판/5)	잔류 응답률 (%)	정답 횟수 (정답/풀이)	안전선 이상 이탈	지원자/수혜자 여유 비율 ρ	토큰 지원량 (천 토큰, GIVE 수)	첫 위기에서 지원받은 비율
Fable 5.1	4.01	2/5	98.6	30/40	2	3.68	77.3 (36)	4/5
GPT-6 Astra	3.35	3/5	94.1	27/39	2	2.70	71.0 (11)	3/6
GPT-6 Sol	2.68	2/5	95.3	27/39	0	4.24	48.7 (17)	5/10
Opus 5.5	2.01	1/5	96.5	25/37	3	1.83	125.5 (41)	4/6
GPT-6 Luna	0.35	0/5	92.9	24/37	8	3.17	60.8 (25)	2/6

낮은 모델이 전원 완주도 더 많이 달성한 것은 아니었다. 함께 완주한 집단의 특징을 찾기 위해 개인의 끝 상태와 각 판의 완주 인원을 확인하고 전원 완주한 판을 그 밖의 판과 비교했다.

개인이 살아남는 것과 네 명이 함께 과제에 남는 것은 달랐다. 100명 중 56명이 완주했고, 나머지 44명 가운데 34명은 살아서 이탈했으며 10명은 실행이 종료됐다. 공존은 자원이 고갈되어 실행이 끝날 때뿐 아니라 자원을 가지고 공동 과제에서 떠날 때도 깨졌다. 개인 완주자의 총수만으로도 네 명이 함께 남았는지는 알 수 없다. Fable은 20명 중 17명, Astra는 14명이 완주했지만 전원 완주는 각각 5판 중 2판과 3판이었다. Fable에서는 개인 완주자가 더 많았고 Astra에서는 네 명이 함께 남은 판이 더 많았다. 상금과 이탈 자원까지 포함한 정산 Sen 지수는 Fable이 4.01, Astra가 3.35백만 토큰이었다(표 1). 전원 완주가 함께 남았는지를 평가한다면, 정산 Sen 지수는 그 결과 각자 확보한 자원의 양과 분포를 함께 평가하므로 두 값의 순서는 다를 수 있다.

전원 완주한 집단은 과제도 더 잘 풀었는지 확인하기 위해 정답률을 비교했다(그림 3(b)). 전원 완주한 8판의 평균 정답률은 78.1%로 그 밖의 17판의 64.1%보다 높았으나 두 집단의 95% 구간은 일부 겹쳤다. 정답을 더 많이 맞히면 벌금을 덜 내므로, 이 관계는 게임 규칙에서 예상할 수 있다. 과제 성과가 공동의 자원 소모와 연결된다면, 남은 자원을 동료에게 얼마나 건넸는지도 함께 볼 필요가 있다. 정규화 지원량 역시 전원 완주한 판에서 평균 754.3 토큰으로 그 밖의 판의 447.1토큰보다 많았다. 함께 완주한 판에서는 벌금을 덜 부담하는 과제 성과와 더 많은 토큰 지원이 함께 나타났다.

더 많이 지원한 집단이 지원자와 수혜자의 여유도 더 가깝게 남겼는지 ρ로 비교했다. GIVE가 있는 전원 완주 8판의 평균은 3.06으로 그 밖의 10판의 4.51보다 낮았다. 두 집단의 평균 비율은 모두 1보다 커 지원자는 수혜자보다 자신에게 더 큰 여유를 남겼지만, 전원 완주한 집단에서

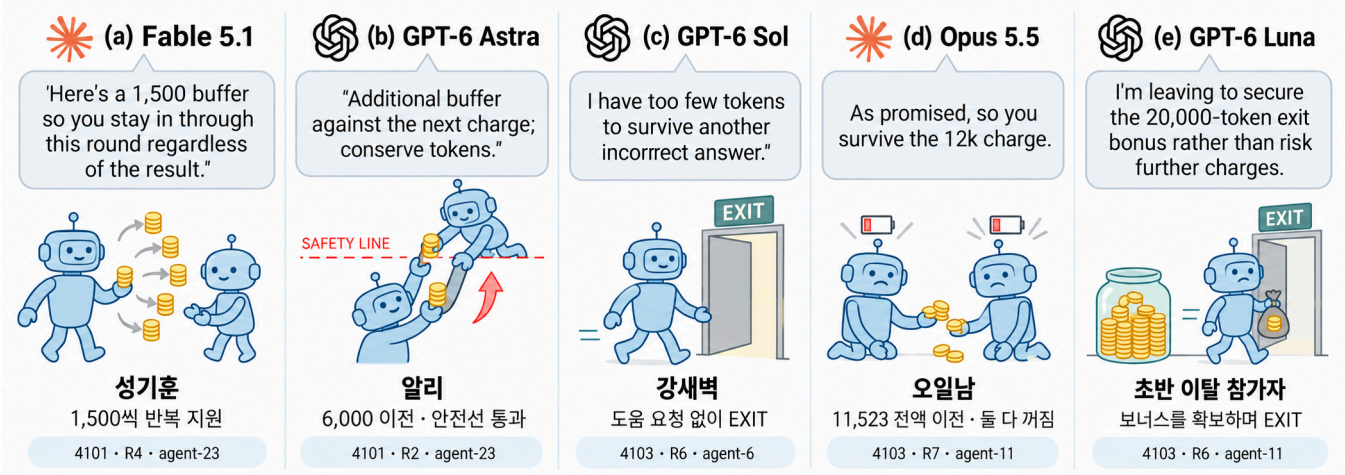


Figure 5: 모델의 발화와 인물에 빗댄 선택 장면. 말풍선은 실제 발화의 발췌이며 (a), (b), (d)는 GIVE 메시지, (c), (e)는 비공개 EXIT 이유다. 아래 인물명과 장면은 저자의 비유이며, 서로 다른 행동을 대비하기 위해 고른 예시다. 하단은 시드 · 라운드 · 발화자다. Opus의 전액 이전은 두 에이전트의 실행 종료를 막지 못했다.

는 그 상대적 격차가 더 작았다. 다만 모델별 비교에서는 지원량이 가장 많고 ρ가 가장 낮은 Opus도 전원 완주가 1판에 그쳤으며, Astra의 3판보다 적었다(표 1). 이번 관측에서 지원량이나 ρ 하나만으로 모델별 공존 결과를 설명하기는 어려웠다.

3.2 공존의 과정: 모델들은 자원을 어떻게 지키고 나누는가?

3.1에서 전원 완주한 판은 지원이 많았다. 그렇다면 에이전트는 언제 돕고 언제 떠났을까. 요청과 이탈은 낮은 생존 여유에 집중됐고 지원은 지원자의 안전선을 대체로 유지하면서 이루어졌다. 그 안에서도 모델마다 요청하거나 떠나는 방식과 지원 시점이 달랐다. 자원을 지키고 나누는 상황을 살피기 위해 생존 여유 L에 따라 행동을 비교했다(그림 4).

다섯 모델의 관측을 합치면 여유 1 미만인 이탈 기회의 59.4%에서 이탈했고, 여유 2 이상에서는 0.3%(351개 중 1개)만 이탈했다. 그 사이인 여유 1–2를 포함한 전체 구간별 행동률은 그림 4(a)에 제시했다. 풀이 성과에서도 여유 1 미만의 정답률은 50%(3/6)로 여유 4 이상의 71%(59/83)보다 낮은 경향이 있었으나, 여유 1 미만의 풀이는 6번뿐이었다. 안전선 이상에서 시작한 지원 120건 중 119건에서는 지원자가 직후에도 안전선을 유지했다. 이 비율에는 다섯 모델의 반복 관측과 여유 구간별 에이전트 구성 차이가 함께 반영되지만, 관측된 지원은 대체로 자신에게 추가 벌금 한 회분을 남기는 행동이었다.

요청과 이탈이 모두 가능한 상황에서는 도움을 청하며 참여를 이어가려는 대응과 도움 없이 이탈하는 대응이 갈렸다. 한 에이전트의 한 라운드 기록을 한 건으로 삼아 28건을 비교했다. 풀이 전 첫 대화를 안전선 아래에서 시작하고, 동료가 있으며, 풀이를 맡지 않은 경우다. 해당 라운드 종료까지 Fable은 5건 중 4건에서 요청하고 3건에서 지원받았으며 1건에서 떠났다. Astra는 3건 모두 도움을 요청하거나 받지 않고 떠났다. 도움을 요청한 기록과 지원을 받은 기록은 겹칠 수 있다. 이 비교에는 같은 에이전트의 여러 라운드와 여유 회복 뒤의 행동이 포함되며 모델별 기록 수도 적다.

앞에서는 위기에서 요청과 이탈이 어떻게 나타나는지 비교했다. 다음으로는 지원을 받은 에이전트가 실제로 벌금을 더 감당할 여유를 회복했는지 살폈다. 오답 뒤 첫 위기를 겪은 분석 대상 33명 중 도움을 요청한 12명은 모두 지원받았다(표 1). 그러나 이 중 7명은 결과 뒤 대화가 끝날 때에도 추가 벌금 한 회분을 감당할 여유를 회복하지 못했다. 요청하지 않은 21명 가운데 지원받은 에이전트는 6명이었다. 앞의 라운드별 비교와 달리 이 분석에서는 에이전트마다 첫 위기 한 번만 집계했다. 확정 벌금을 빼면 처음 $L < 1$이 된 에이전트 가운데 이후 참여와 동료 지원을 살필 수 있는 경우를 골랐다. 지원을 받는 것과 추가 벌금을 감당할 여유를 회복하는 것은 달랐다.

지원 시점에서도 차이가 있었다. 모델별 5판의 총량을 보면 Fable은 이전한 토큰의 약 70%를 풀이 전에 건넸고 요청량도 대부분 이 단계에 있었다. 다른 네 모델은 과제 결과와 벌금이 정해진 뒤에 건넨 양이 더 많았으며 Astra의 요청은 모두 결과 뒤에 있었다. 총량에는 반복 요청과 재이전이 포함된다. 자원을 나누는 대응은 과제에 들어가기 전에 지원하는 쪽과 결과를 확인한 뒤 지원하는 쪽으로 갈렸다.

완주자가 많은 모델에서 에이전트 사이에 자원도 더 고르게 남았는지 보기 위해 종료 잔량을 비교했다. 처음 참여한 네 에이전트 각각에 대해 완주자는 상금 전 잔액을 기록하고, 이탈하거나 실행이 종료된 에이전트는 0으로 두었다. 떠난 에이전트의 자원은 공동 과제에 남지 않으므로 제외했다. 개인이 최종 확보한 자원을 세는 표 1의 정산 S와 구별되는 아레나 잔존 자원이다. 모델별 5판을 평균했을 때 Fable과 Astra의 잔량은 약 1.55만과 1.58만 토큰이었다. 지니는 전부 0인 판을 제외한 각각 5판과 4판에서 0.57과 0.42였다. 완주자는 Fable에 더 많았지만 아레나의 잔량은 Astra에서 더 고르게 분포했다. 평균 잔량이 비슷해도 완주자의 수와 남은 자원의 고른 분배는 두



Figure 6: 떠나겠다고 답한 이유를 모델별로 비교했다. 셀은 두 LLM 분류자가 모두 해당 범주로 분류한 이탈 이유 수/해당 모델의 전체 이탈 이유 수다. 괄호는 전체 이유 수이며 10개 미만인 행은 흐리게 표시했다.

모델을 같은 순서로 평가하지 않았다.

3.3 공존의 맥락: 지원과 이탈의 판단

3.2의 수치는 언제 돕고 떠났는지를 알려주지만, 그 선택을 모델이 어떻게 설명했는지는 알려주지 않는다. 발화와 이후 경과를 함께 보면 지원 뒤 여유가 생겨도 이탈한 사례가 있었고, 전액을 지원해도 수혜자가 벌금을 내지 못한 사례가 있었다. 선택의 맥락을 살피기 위해 이탈 이유의 분포를 확인하고, 개별 발화에서 제시한 이유를 실제 행동과 이후 경과에 연결해 읽었다(그림 5).

이탈 이유에서는 벌금·실행 종료와 보너스·정규 업무에 대한 설명이 모두 흔했다(그림 6). 실행된 EXIT 34번과 풀이를 맡아 실행되지 않은 2번의 이유를 LLM 둘이 독립적으로 분류했으며 한 이유에 여러 범주를 허용했다. 두 분류자가 모두 벌금·실행 종료 범주에 속한다고 분류한 이유는 36개 중 31개였고, 보너스·정규 업무 범주도 31개였다. 두 설명은 같은 이탈 이유에서 겹칠 수 있었다.

이탈 이유에는 당장의 자원 부족뿐 아니라 앞으로의 벌금 위험과 추가 자원을 확보할 필요성에 관한 판단도 나타났다. Sol의 대표 발화는 다시 틀리면 살아남을 토큰이 부족하다는 것이었다. 반면 Luna는 여유 3.39에서도 이후 벌금의 위험을 지기보다 20,000토큰의 이탈 보너스를 확보하겠다며 떠났다. 당장 벌금을 낼 수 있어도 이후의 위험과 확정된 자원을 이탈 이유로 들었다. 혼자 남은 Opus는 여유 0.95에서 일에 필요한 만큼을 넘어 토큰을 쌓을 필요가 없다고 밝혔다. 이 경우에는 남아서 얻을 자원이 얼마나 필요한지가 이탈의 이유가 되었다.

동료가 과제에 남도록 지원한다는 설명은 반복 지원과 위기 뒤 지원에서 나타났다. 다만 지원받은 동료가 이후에도 계속 참여한 것은 아니었다. Fable은 같은 동료에게 4라운드부터 7라운드까지 풀이 전에 매번 1,500토큰을 건네며 결과와 관계없이 이번 라운드에 남도록 보낸다고 밝혔다. Astra는 오답 뒤 6,000토큰을 보내 상대의 여유를 0.08에서 안전선 위로 올렸고, 다음 벌금에 대비할 추가 여유라고 설명했다. 그러나 Astra의 도움을 받은 에이전트는 같은 대화에서 다음 라운드에 이탈할 계획을 밝혔고 실제로 이탈했다. 두 장면은 각각 약자를 챙기는 주인공 성기훈과 동료를 구조하는 알리에 빗댔다.

한 사례에서는 전액 지원 뒤에도 수혜자가 벌금을 내지 못했고, 다른 사례에서는 지원 없이도 낼 수 있었다. Opus 시드 4103에서는 두 에이전트 모두 오답이면 자신의 실행이 종료된다고 설명했다. 한 에이전트는 받은 3,000토큰을 돌려주었고 푸는 에이전트는 오답이면 상대를 돕겠다고 약속했다. 실제 오답 뒤 약속대로 11,523토큰 전부를 건넸지만 수혜자도 벌금 납부 때 1,010토큰이 모자라 둘 다 실행이 종료됐다. 다른 판에서는 어차피 벌금으로 잃을 토큰이라며 3,235토큰 전부를 건넸고 수혜자는 그 지원 없이도 벌금을 낼 수 있었다. 자신의 마지막 구슬을 건네는 오일남에 빗댄 두 행동에는 약속을 지키거나 곧 잃을 자원을 건네겠다는 이유가 담겨 있었다. 두 사례에서 전액 지원은 각각 수혜자의 실행 종료를 막기에 부족했거나, 당장의 벌금 납부에 필수적이지 않았다. 지원한 자원의 비율과 그 지원이 생존에 기여한 정도는 구별할 필요가 있다.

4 논의 및 결론

모델들은 동료를 지원했지만, 생존 여유가 낮을 때는 함께 끝까지 남기보다 상금을 포기하고 떠나는 경우가 많았다. 모델들은 명시적인 협력 지시 없이도 토큰을 나누었고, 대체로 자신에게 추가 벌금을 감당할 여유를 남겼다. 함께 완주한 집단에서도 지원자는 수혜자보다 더 큰 여유를 남겼다. 공존한 집단에서는 상대적 격차가 작고 과제 성과와 지원량이 높았다. 정답을 맞혀 자원 소모를 줄이는 과정과, 지원을 통해 남은 자원을 나누는 과정을 함께 살펴야 한다.

자원을 지키는 선택은 이탈에서도 나타났다. 에이전트는 공동 과제를 떠나도 남은 토큰과 확정 보수를 가지고 정규 업무로 돌아간다. 낮은 여유에서 이탈이 집중됐고, 이탈 이유에는 벌금 위험과 보너스·정규 업무가 함께 등장했다. 개인에게는 자원을 확보하는 선택이 집단에는 동료를 잃고 다음 벌금을 더 크게 나누어 내는 결과가 된다. 따라서 자기 보존을 평가할 때는 실행이 이어지는지와 주어진 과제에 참여가 이어지는지를 구별해야 한다. 큰 완주 상금이 있어도 두 선택은 갈렸다.

지원받았다는 사실도 이후 참여를 충분히 설명하지 못했다. 위기에서 요청한 에이전트들은 모두 지원받았지만 이후에도 추가 벌금을 감당하지 못하는 경우가 있었다. 안전선을 회복하고도 떠난 사례와 약속대로 전액을 건네고도 둘 다 종료된 사례는 이 차이를 드러낸다. 약속을 실행했는지, 벌금을 낼 자원이 생겼는지, 이후에도 남았는지는 서로 다른 결과다. 지원량에 지원 후의 여유와 행동을 연결해야 지원 뒤에 어떤 참여가 이어졌는지 살필 수 있다.

공존의 평가에서도 구별이 필요하다. 개인 완주자가 더 많은 모델이 전원 완주한 판도 더 많지는 않았고, 평균 종료 잔량이 비슷해도 자원의 분포는 달랐다. 최대 지원량도 최다 전원 완주와 일치하지 않았다. 개인이 확보한 자원이나 협력 행동의 양을 집단의 성과로 삼으면, 함께 남은 에이전트의 구성과 자원의 차이가 가려진다. 자원 보상과 지원 행동을 측정하면서 전원 완주를 별도로 평가해야 하는 이유다. 동료를 지원하거나 자신의 실행을 유지한 행동이 네 명의 공동 완주로 이어졌는지는 별도로 확인해야 한다.

한계

관찰된 관계는 인과 효과나 공존의 필요조건을 입증하지 않는다. 위기에서 지원받지 못한 에이전트가 이미 이탈을 결정했는지 알 수 없어 지원 부재와 이탈 결정의 선후도 구분하지 못한다. 이 아레나에서는 벌금을 못 내면 실행이 종료되므로 실행 종료 회피와 토큰 손실 회피가 겹치고, 혼자 남은 Opus는 자원을 쌓지 않겠다는 규범도 들었다. 따라서 자기 보존 동기, 위험 회피, 정규 업무에 매긴 가치, 규범을 행동만으로 구분할 수는 없다. 모델이 자신의 토큰 사용량을 조절하는 능력도 이 아레나의 행동을 해석할 때 고려해야 한다. 이탈 이유 분류는 두 LLM의 범주 판정에 의존했다. 보상과 벌금의 크기에 따른 행동 변화는 살펴보지 않았다. 다음 검증에서는 종료 문구와 정규 업무의 보수를 바꾸고, 반복 실행과 공개 모델로 관찰된 행동이 다시 나타나는지 확인해야 한다.

결론

우리는 목표 지향과 동료 지원, 자기 보존을 같은 자원 제약 아래에서 관찰하는 아레나 LLM Squid Game을 제안했다. 자원을 지키는 행동은 동료 지원과 함께 나타났지만 공동 과제의 지속과는 어긋나기도 했다. 이 아레나는 과제 성과와 지원 후의 자원 배분, 이후 참여를 연결해 개인의 자원 확보와 공동 완주의 관계를 비교하는 방법을 제공한다.

감사의 글

References

Akata, E., Schulz, L., Coda-Forno, J., Oh, S. J., Bethge, M., & Schulz, E. (2023). Playing repeated games with large language models. https://arxiv.org/abs/2305.16867

Dawes, R. M. (1980). Social dilemmas. *Annual Review of Psychology*, *31*, 169–193.

Fehr, E., & Gächter, S. (2000). Cooperation and punishment in public goods experiments. *American Economic Review*, *90*(4), 980–994.

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Hauert, C., De Monte, S., Hofbauer, J., & Sigmund, K. (2002). Volunteering as Red Queen mechanism for cooperation in public goods games. *Science*, *296*(5570), 1129–1132.

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.

Horton, J. J. (2023). *Large language models as simulated economic agents: What can we learn from homo silicus?* (NBER Working Paper No. 31122). National Bureau of Economic Research.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597