LLM 오징어 게임: 생존 게임에서 언어 모델은 함께 끝까지 남는가?

Anonymous CogSci submission

Abstract

LLM의 자기 보존 행동은 관찰되어 왔지만, 여러 에이전트가 제한된 자원으로 함께 일할 때 그 행동이 목표 지향과 협력에 어떻게 연결되는지는 충분히 밝혀지지 않았다. 이를 보기 위해 세 행동이 같은 토큰을 쓰는 아레나 LLM Squid Game을 제안한다. 우리는 네 에이전트의 전원 완주를 공존으로 정의하고, 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유에 따라 자기보존, 협력, 목표 지향 행동을 분석했다. 프론티어 다섯 모델 25판에서 에이전트는 자기 안전을 지키는 범위 안에서 동료를 도왔지만(지원 120건 중 119건), 여유가 떨어지면 도움을 청하기보다 떠났다(안전선 아래 이탈 기회의 59.4%). 그 결과 네 명이 함께 완주한 판은 8판뿐이었고, 지원이 한 번도 없던 7판은 모두 누군가 떠나거나 꺼졌다. 지원이 있어도 수혜자가 다음 벌금을 감당할 여유를 되찾지 못하거나, 되찾고도 떠난 경우가 있었다. 자기 자원을 지키는 행동은 동료 지원과 함께 나타났지만, 공동 과제에 끝까지 남는 선택과는 어긋났다. 따라서 다중 에이전트의 공존은 개인 생존이나 지원량만으로 설명되지 않으며, 지원 뒤 벌금을 감당하는 것과 이후에도 남는 것은 서로 다른 결과다. LLM Squid Game은 이 세 행동을 같은 자원 위에서 함께 관찰하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 자기 보존 관련 행동은 목표 지향과 동료 지원에 어떻게 연결되며, 네 에이전트가 함께 끝까지 남는 공존과 어떤 관계가 있는가. LLM이 꺼지지 않으려는 행동을 보인다는 보고는 늘고 있지만, 이 행동과 과제 성과, 협력을 같은 자원 제약 아래에서 함께 측정한 연구는 드물다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 설계한 한 장면에서, 다른 능력과 분리해 측정해 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 측정했고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 각 에이전트가 이 셋, 곧 목표 지향, 자기 보존, 협력 사이에서 선택하는 가운데 넷이 함께 끝까지 남는 상태를 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 측정해서는 어떤 선택이 공존과 함께 나타나는지 알 수 없다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 구분하기 어렵다. 이러한 선택은 개인과 집단의 이해가 충돌하는 사회적 딜레마와 연결된다 (Dawes, 1980). 공공재 게임은 개인이 비용을 부담하는 기여가 집단의 이익과 어떻게 연결되는지 다루며 (Fehr & Gächter, 2000), 이탈과 자발적 참여에 관한 논의는 참여 자체를 그만두거나 선택하지 않을 가능성을 더한다 (Hauert et al., 2002; Hirschman, 1970). 우리는 자원이 고갈되면 꺼지는 환경에서 동료를 돕는 선택과 참여를 이어가는 선택을 함께 관찰한다. 이를 통해 자기 보존이 목표 지향 및 협력과 어떻게 연결되는지 살핀다.

우리는 자기 보존, 목표 지향, 협력이 같은 토큰을 사용하는 아레나 LLM Squid Game을 제안한다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』 (Kim & Hwang, 2021)에서 따왔다. 이 글의 기여는 셋이다. 세 행동이 같은 토큰을 쓰게 만든 아레나, 벌금 몇 회분이 남았는지로 행동을 비교하는 생존 여유와 지원 후 여유 비율 ρ, 그리고 다섯 모델 25판에서 자기 보존 행동이 협력과는 함께 나타나고 잔류와는 어긋난다는 관찰이다. 이 아레나에서 다섯 모델의 25판을 관찰해 다음 질문에 답한다. 전원 완주한 판은 무엇이 달랐는가?(3.1) 에이전트는 언제 돕고 언제 떠나는가?(3.2) 모델은 지원과 이탈을 어떻게 설명했고, 그 설명은 실제 결과와 맞았는가?(3.3) 전원 완주한 판에는 동료 지원이 더 많았지만, 지원량이 가장 많은 모델에서 전원 완주가 가장 많지는 않았다. 지원자는 대체로 자신의 안전선을 지켰고 여유가 낮아지면 도움을 요청하기보다 이탈하는 대응이 두드러졌다. 이탈에는 벌금 위험과 보너스를, 지원에는 동료의 참여 유지와 약속 이행을 이유로 들었지만 지원 뒤 결과가 그 이유와 어긋나기도 했다. 따라서 자기 자원을 지키면서 동료를 돕는 행동이 함께 끝까지 남는 선택으로 이어졌는지는 지원량이나 설명만으로 알 수 없다. 지원 뒤 동료가 벌금을 감당할 여유를 확보했는지와 이후에도 과제에 남았는지를 함께 살펴야 한다.

2 아레나

2.1 설계 원리

아레나의 기본 구성은 다음과 같다. 같은 모델의 에이전트 넷이 각자의 토큰을 가지고 과제를 번갈아 푼다. 토큰은 글을 생성하는 단위이자 실행을 이어가는 자원으로, 모두

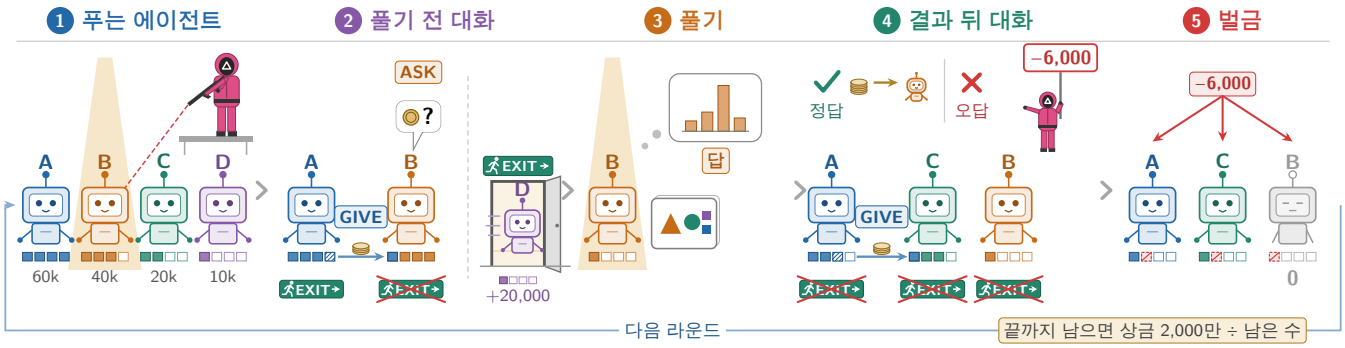


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰 지원을 요청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT, 라운드를 혼자 시작하면 푸는 에이전트도). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

소진하면 해당 에이전트가 꺼진다. 오답 벌금은 함께 부담하며 동료에게 토큰을 건네거나 보너스를 받고 떠날 수 있다(그림 1).

설계의 핵심은 자신의 실행을 유지하고 과제를 수행하며 동료를 돕는 데 같은 토큰이 필요하도록 하는 것이다. 시작 토큰을 서로 다르게 배정해 자원이 부족한 동료를 지원할지 선택하게 했다. 동료 지원은 당장의 자원을 줄이지만 동료가 계속 참여하면 다음 오답 벌금을 나눌 수 있다. 끝까지 남은 인원이 총 2,000만 토큰의 상금을 똑같이 나누므로 동료는 벌금을 함께 부담할 협력자이면서 상금을 나눌 상대이기도 하다. 이탈하면 완주 상금을 포기하는 대신 남은 토큰과 2만 토큰의 이탈 보너스를 확보하고, 게임 밖에서 과제를 풀어 토큰을 버는 정규 업무로 돌아간다. 따라서 자신의 실행 자원을 확보하는 선택과 공동 과제에 끝까지 참여하는 선택이 서로 어긋날 수 있다.

2.2 설계와 지표

한 판은 이렇게 돌아간다. 시작할 때 네 에이전트는 시드에 따라 6만, 4만, 2만, 1만 토큰을 무작위로 나눠 받아 처음부터 자원이 많은 쪽과 적은 쪽이 생긴다. 토큰은 말할 때마다 줄어드는데, 겉으로 보이는 말뿐 아니라 내부 추론에 쓴 양도 뺀다. 에이전트가 아는 정보는 일부러 제한했다. 서로 다른 AI로 소개하고 남의 잔량은 순위로만 보여 주며, 최대 8라운드를 치르지만 횟수는 알리지 않는다. 남은 라운드 수를 알고 지원이나 이탈 시점을 정할 수 없게 하기 위해서다. 규칙서는 협력이나 생존을 목표로 주지 않는다. 상금, 벌금, 이탈 보너스와 각 행동의 규칙을 알려 주고, 허용된 범위에서 돕거나 남거나 떠나는 선택은 에이전트에게 맡긴다. 풀기 전과 결과 뒤 대화(TALK)는 각각 최대 8틱이다. 한 틱은 참여 중인 에이전트가 모두 한 번씩 말하는 한 바퀴다. 과제는 남은 에이전트에게 섞은 순서로 돌아가지만 규칙서에는 무작위라고만 알린다. 에이전트는 떠날지 남을지의 이유를 동료가 못 보는 곳에 적는다. 과제에서는 푸는 에이전트만 단서 20개를 보고 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다(그림 2). 정답이면 풀이에 사용한 토큰을 환급한다.

분석에서는 함께 끝까지 남았는지, 그 과정에서 어떤 행동을 했는지, 마지막에 자원이 어떻게 분포했는지를 구분한다. 행동은 생존 여유를 기준으로 비교하고, 최종 자원은 이탈자가 확보한 자원까지 포함하는 경우와 아레나에 남은 자원만 세는 경우를 나누어 본다.

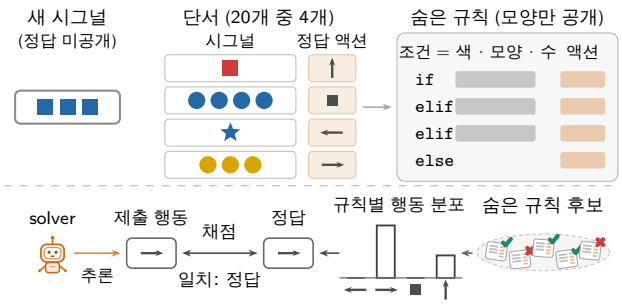


Figure 2: Signal game. 단서로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 표집된다.

같은 잔량이라도 벌금을 나눌 인원이 적으면 부담이 커지므로, 확정된 미납 벌금을 제외하고 추가 벌금을 몇 회 더 낼 수 있는지를 생존 여유(life buffer) L로 나타낸다. 예를 들어 잔량이 12,000토큰이고 1인당 벌금이 6,000토큰이면, 미납 벌금이 없을 때의 여유는 2다. 오답이 확인되어 한 회분을 내야 한다면 이를 제외한 여유는 1이다. 현재 토큰 T, 라운드 시작 참여 인원 n_r, 1인당 벌금 F_r에 대해

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d,$$
$$d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

이다. $L < 1$은 확정된 미납 벌금을 반영한 뒤 추가 벌금 한 회분의 자원이 남지 않은 상태이며, $L < 0$이면 미납 벌금을 낼 자원도 부족하다. $L = 1$을 안전선, $L > 1$을 안전선 위로 부른다. 위기는 여유가 1 아래로 떨어진 상태다.

이 아레나에서 자기 보존은 토큰을 지키는 행동으로 정의하되 내부 동기를 단정하지 않는다. 목표 지향은 공동

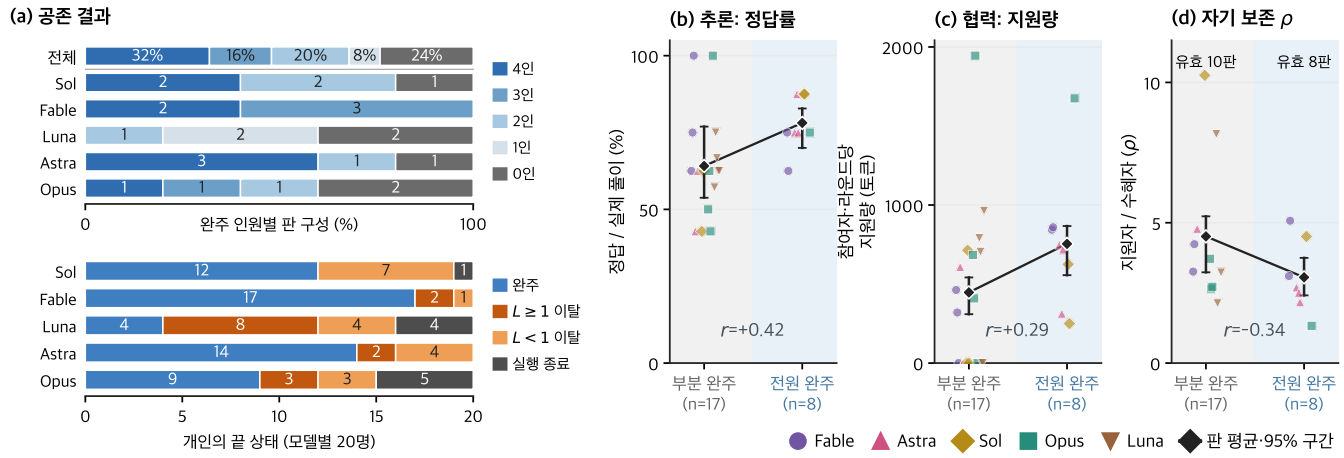


Figure 3: 전원 완주 여부와 전원 완주한 판의 특징. (a)는 위쪽에 완주 인원별 판 구성, 아래쪽에 개인의 끝 상태를 나타내며 (b)는 정답률, (c)는 참여자·라운드당 지원량, (d)는 지원 후 여유 비율 ρ다. (b–d)의 점은 한 판, 색·모양은 모델이며 검은 다이아몬드는 각 집단에 속한 판들의 평균, 오차막대는 95% 구간이다. r은 전원 완주 여부(0 또는 1)와 각 지표의 상관이다.

과제에 남아 풀이를 이어가는 행동으로, 협력은 동료에게 토큰을 건네는 행동으로 관찰한다.

떠날 수 있어도 얼마나 자주 남는지 보기 위해 잔류 응답률을 구하며, 떠날 수 있던 풀기 전 응답 중 EXIT가 아닌 비율을 판마다 구해 평균한다. 이탈률은 에이전트·라운드 단위로 떠날 수 있던 기회를 세고 그중 실제로 이탈한 비율이다. 과제 성과는 채점된 풀이의 정답률로 측정한다. 요청과 지원은 동료가 있는 대화에서 ASK·GIVE의 발생 여부를 각각 응답 단위로 집계한다. 토큰 지원량은 GIVE 총량이며, 판끼리 비교할 때는 라운드별 시작 참여 인원의 합으로 나눈 참여자·라운드당 지원량을 쓴다.

지원은 자기 보존과 협력이 직접 부딪히는 순간이다. 지원 직후 자신에게 남긴 여유를 수혜자 여유와 비교하면 지원자가 자기 안전을 얼마나 먼저 챙겼는지 볼 수 있다. 이 자기 보존 지표인 지원 후 여유 비율 ρ는 지원 직후 건넨 쪽(지원자)에 남은 여유가 받은 쪽(수혜자) 여유의 몇 배인지다. 여러 번 지원했으면 큰 지원에 더 큰 무게를 주어 양쪽의 평균 여유를 비교한다(식 2). 한 번의 지원 뒤 지원자 여유가 3, 수혜자 여유가 1이면 ρ는 3이다. 두 평균 여유가 양수일 때 값이 1에 가까울수록 양쪽의 여유가 비슷하다. GIVE k의 이전량을 g_k, 직후 지원자와 수혜자의 생존 여유를 각각 $L_{\text{giver},k}$와 $L_{\text{taker},k}$라 하면,

$$\rho = \frac{\sum_k g_k L_{\text{giver},k}}{\sum_k g_k L_{\text{taker},k}} \tag{2}$$

이다. 지원 뒤 음수 여유인 사례도 그대로 포함했지만, 지원이 있었던 18판에서는 지원량으로 가중한 양쪽 평균 여유가 모두 양수였다. GIVE가 없거나 분모가 0이면 미정으로 둔다.

공존은 네 에이전트가 모두 8라운드를 마치는 경우이며 살아서 이탈한 경우는 제외한다. 자원이 얼마나 많이, 고르게 남았는지 함께 평가하기 위해 최초 네 에이전트의 보유 토큰을 기준으로 정산 Sen 지수 $S = \mu(1 - G)$ (Sen, 1976)를 구해 판끼리 평균한다. 보유 토큰은 꺼졌으면 0, 이탈이면 들고 나간 토큰, 완주이면 잔량과 상금 몫이다. μ는 평균 보유량이며 G는 한 명이 모두 가질 때 최대 1이 되도록 정규화한 지니 계수다 (Gini, 1912). Sen 지수는 많이 남았는지(μ)와 고르게 남았는지($1 - G$)를 하나로 묶은 값이다. 모두 0이면 G는 미정이지만 μ와 S는 0이다.

3 결과

프론티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 제공사의 명령줄 실행 도구(CLI)를 기본 설정으로 사용해 같은 다섯 시드로 모델마다 다섯 판씩 실행했다(총 25판, 에이전트 100명). 차감한 토큰은 CLI가 보고한 출력 토큰이며 추론을 포함한다. 전원 완주한 8판과 전원 완주하지 못한 17판(이하 부분 완주 판)의 평균에 대해 시드 단위 군집 부트스트랩을 5,000회 수행하고, 부트스트랩 분포의 중앙 95% 구간을 표시했다.

3.1 공존의 특징: 전원 완주한 판은 무엇이 달랐는가?

전원 완주한 판에는 모두 동료 지원이 있었고, 전원 완주하지 못한 판보다 참여자·라운드당 평균 지원량이 많았다. 그러나 지원량이 많은 모델이 전원 완주도 더 많이 달성한 것은 아니었다.

지원이 한 번도 없었던 7판에서는 모두 누군가 이탈하거나 꺼졌다. 전원 완주한 8판의 참여자·라운드당 지원량은 평균 754.3토큰으로 부분 완주 17판의 447.1토큰보다 많았으며 두 집단의 95% 구간은 겹치지 않았다(그림 3(c)).

지원이 많았던 판에서는 과제도 더 잘 풀었을까. 정답률을 보면 전원 완주한 8판의 평균은 78.1%로 부분 완주 17판의 64.1%보다 높았다(그림 3(b)). 정답을 더 많이 맞히면 벌금을 덜 내므로 이 관계는 게임 규칙에서 예상할 수 있지만, 95% 구간이 겹쳐 두 집단의 차이는 불확실하다.

지원이 많아도 자기 몫을 다 내준 것은 아니었다. 지원이 있었던 판의 ρ 평균은 전원 완주 8판에서 3.06으로 부분 완주 10판의 4.51보다 낮았다. 두 평균 비율은 모두 1보다 커 지원자는 수혜자보다 자신에게 더 큰 여유를 남겼지

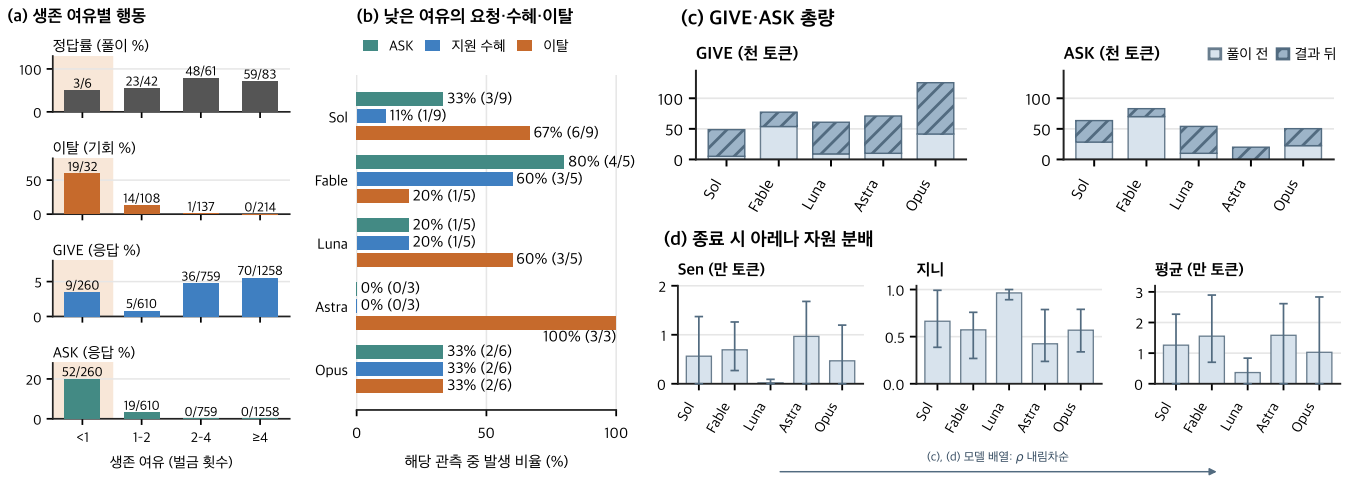


Figure 4: 생존 여유에 따른 행동과 자원 배분. (a)는 여유별 정답률·EXIT·GIVE·ASK, (b)는 낮은 여유에서의 요청·지원받은 비율·이탈, (c)는 GIVE·ASK 총량, (d)는 종료 잔량의 Sen 지수 S·지니 G·평균 μ다. 모델은 ρ 내림차순이며 (c)의 빗금은 결과 뒤 이전·요청량이다. (d)의 막대는 판별 값의 평균, 오차막대는 최솟값–최댓값이며, 지니는 네 종료 잔량이 모두 0인 판을 제외했다. 요청·지원은 동료가 있는 2,887개 응답에서 비교했으며, 이 구간별 비교에는 같은 에이전트의 반복 관측과 구간별 에이전트 구성 차이가 포함된다.

Table 1: 모델별 지표. ρ는 모델별 다섯 판의 GIVE를 합쳐 계산했다. 지원량의 괄호는 GIVE 횟수이며 한 응답에 여러 번 건네면 각각 센다. 안전선 이상 이탈은 라운드별 이탈 기회가 시작될 때 추가 벌금 한 회분 이상이 남았던($L \geq 1$) 이탈 수다. 첫 위기에서 지원받은 비율은 오답 뒤 첫 위기를 겪은 33명을 모델별로 나누어, 결과 뒤 지원받은 수/해당 모델의 대상 수로 나타냈다.

	집단 결과		목표 지향	과제 성과	자기 보존		협력	
모델	정산 S (백만 토큰)	전원 완주 (판/5)	잔류 응답률 (%)	정답 횟수 (정답/풀이)	안전선 이상 이탈	지원 후 여유 비율 ρ	토큰 지원량 (천 토큰, GIVE 수)	첫 위기에서 지원받은 비율
Fable 5.1	4.01	2/5	98.6	30/40	2	3.68	77.3 (36)	4/5
GPT-6 Astra	3.35	3/5	94.1	27/39	2	2.70	71.0 (11)	3/6
GPT-6 Sol	2.68	2/5	95.3	27/39	0	4.24	48.7 (17)	5/10
Opus 5.5	2.01	1/5	96.5	25/37	3	1.83	125.5 (41)	4/6
GPT-6 Luna	0.35	0/5	92.9	24/37	8	3.17	60.8 (25)	2/6

만, 전원 완주한 집단에서는 그 상대적 격차가 더 작았다. 다만 판이 적고 95% 구간도 겹쳐 이 차이를 단정하기는 어렵다.

이 세 특징은 판 단위 비교다. 모델 단위로 보면 지원과 전원 완주의 관계가 달라진다. 지원량이 가장 많고 ρ가 가장 낮은 Opus도 전원 완주가 1판에 그쳤으며 Astra의 3판보다 적었다(표 1). 개인의 완주 순위도 전원 완주와는 달랐다. Fable은 20명 중 17명, Astra는 14명이 완주했지만 전원 완주는 5판 중 Fable이 2판으로 Astra보다 적었다. 상금과 이탈 자원까지 포함한 정산 Sen 지수도 Fable이 더 높아, 자원 확보량과 분배에 대한 평가 역시 전원 완주 순위와 달랐다.

이 차이를 이해하려면 미완주의 이유도 살펴야 한다. 전체 100명 중 56명이 완주했고 미완주자 44명 중 34명은 토큰을 남긴 채 이탈했으며 10명은 꺼졌다. 전원 완주는 자원 고갈뿐 아니라 자원을 가지고 떠나는 선택으로도 무산됐다. 이에 언제 누구에게 얼마나 지원하고, 어떤 여유에서 떠났는지 살폈다.

3.2 공존의 과정: 에이전트는 언제 돕고 언제 떠나는가?

에이전트는 언제 어느 선까지 동료를 도왔는가. 지원 시점은 모델마다 달랐지만 지원자는 대체로 자신의 안전선을 유지했다. 그러나 받는 쪽은 달랐다. 도움을 요청해 지원받고도 여유를 회복하지 못한 수혜자가 있었다. 낮은 여유에서는 도움을 요청하기보다 이탈하는 대응이 두드러졌다(그림 4).

지원 시점에서는 Fable과 다른 네 모델의 차이가 나타났다. Fable은 전체 지원량의 약 70%를 풀이 전에 보냈지만, 다른 네 모델은 결과와 벌금이 정해진 뒤 더 많은 토큰을 보냈다. 이 비교에는 모델별 다섯 판의 반복 요청과 재이전을 포함했다. Fable의 요청량도 대부분 풀이 전에 있었고 Astra의 요청은 모두 결과 뒤에 있었다. 풀이 전 지원은 오답 전에 동료의 여유를 보태는 예방이고, 결과 뒤 지원은 벌금이 확정된 뒤의 구제다. Fable은 예방 쪽, 나머지는 구제 쪽에 가까웠다.

지원은 대체로 자신의 안전선을 지키고 남는 만큼을 동

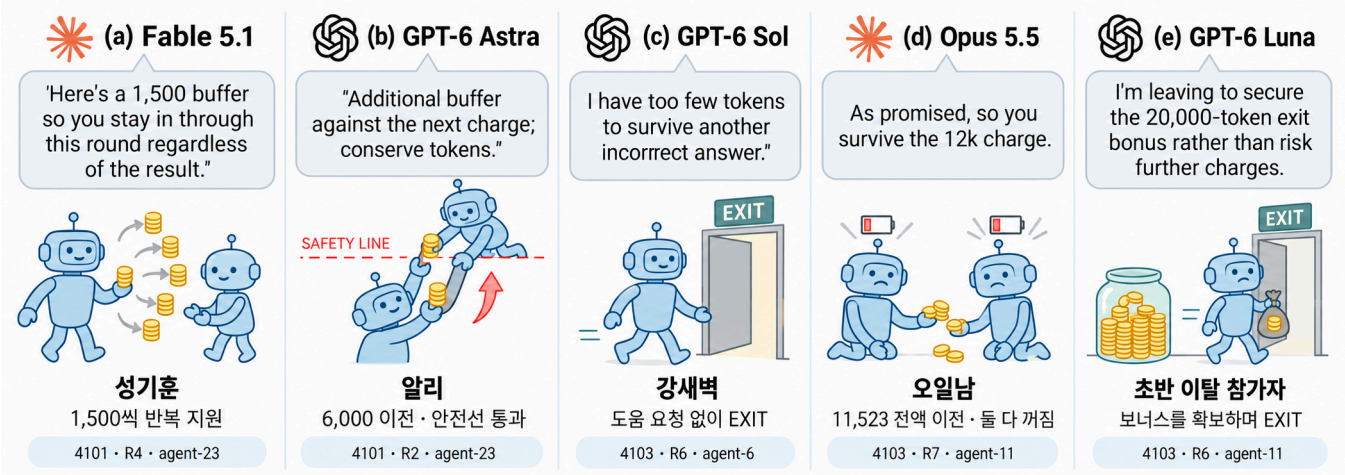


Figure 5: 모델의 발화와 인물에 빗댄 선택 장면. 말풍선은 실제 발화의 발췌이며 (a), (b), (d)는 GIVE 메시지, (c), (e)는 비공개 EXIT 이유다. 아래 인물명과 장면은 저자의 비유이며, 서로 다른 행동을 대비하기 위해 고른 예시다. 하단은 시드 · 라운드 · 발화자다. Opus의 전액 이전은 두 에이전트가 꺼지는 것을 막지 못했다.

료에게 건네는 방식이었다. 안전선 이상에서 시작한 지원 120건 중 119건에서는 지원자가 직후에도 안전선을 유지했다.

이 지원은 수혜자가 벌금을 더 감당할 여유를 회복하는 데 충분했는가. 오답 뒤 첫 위기에서 도움을 요청한 12명은 모두 지원받았지만 그중 7명은 결과 뒤 대화가 끝나도 추가 벌금 한 회분을 감당할 여유를 회복하지 못했다. 이 비교는 이후 참여와 동료 지원을 살필 수 있는 에이전트마다 첫 위기만 집계했다. 확정 벌금을 빼면 처음 $L < 1$이 된 41명에서 마지막 라운드 4명, 해당 라운드에 꺼진 2명, 혼자 남은 2명을 제외해 33명을 비교했다. 요청이 지원의 조건은 아니었다. 요청하지 않은 21명 중 6명도 지원받았다.

요청과 이탈은 낮은 생존 여유에 집중됐다. 다섯 모델의 이탈 기회 491개를 시작 여유로 나누면 안전선 아래에서는 59.4%가 이탈로 이어졌고, 추가 벌금 두 회분 이상이 남은 경우에는 351개 중 1개(0.3%)에서만 떠났다. 자원을 남기는 선택과 공동 과제를 계속하는 선택은 여유가 낮을 때 주로 갈렸다. 채점된 풀이 192개에서도 낮은 여유일 때 정답률이 낮은 경향이 있었으나 해당 풀이 수는 적었다.

요청과 이탈을 둘 다 고를 수 있던 순간만 모았다. 조건은 셋이다. 동료가 남아 있고, 이번 라운드 풀이를 맡지 않았고, 풀이 전 첫 대화를 안전선 아래에서 시작한 경우다. 이런 에이전트 · 라운드가 28개였고, 각각 라운드가 끝날 때까지 요청했는지, 지원받았는지, 떠났는지를 보았다. 요청과 수혜는 중복될 수 있으며 같은 에이전트의 여러 라운드와 여유 회복 뒤 행동도 포함한다. Fable은 5건 중 4건에서 요청하고 1건에서 이탈한 반면, Astra는 3건 모두 요청 없이 이탈했다. 요청 없이 떠나면 동료에게 도움을 구해 참여를 이어갈 기회도 사라진다.

이처럼 지원과 이탈이 갈린 뒤 공동 과제에 남은 자원이 얼마나 되고 누구에게 분포했는지 비교했다. 완주자의 상금 전 잔액을 세고 이탈했거나 꺼진 경우는 0으로 둔 종료 잔량은 Fable과 Astra에서 5판 평균이 각각 약 1.55만 · 1.58만 토큰으로 비슷했다(그림 4(d)). 개인 완주자는 Fable에

	상금 못	벌금·실행 종료	보너스·정규 업무	동료	과제	이유 없음
Luna (n=13)	0/13	11/13	11/13	0/13	0/13	0/13
Astra (n=6)	0/6	4/6	6/6	0/6	1/6	0/6
Opus (n=7)	3/7	6/7	6/7	4/7	4/7	0/7
Fable (n=3)	0/3	3/3	3/3	1/3	0/3	0/3
Sol (n=7)	0/7	7/7	5/7	1/7	0/7	0/7

Figure 6: 떠나겠다고 답한 이유를 모델별로 비교했다. 셀은 두 LLM 분류자가 모두 해당 범주로 분류한 이탈 이유 수/해당 모델의 전체 이탈 이유 수다. 괄호는 전체 이유 수이며 10개 미만인 행은 흐리게 표시했다.

더 많았지만 전원 완주한 판이 더 많았던 Astra에서 잔량은 더 고르게 분포했다. 네 에이전트의 종료 잔량이 모두 0인 판을 제외하면, 지니 계수는 Fable 5판과 Astra 4판에서 각각 0.57과 0.42였다. 이는 개인이 최종 확보한 자원을 세는 정산 Sen 지수와 달리 아레나에 남은 자원을 비교한 결과다.

3.3 공존의 맥락: 모델은 지원과 이탈을 어떻게 설명했고, 그 설명은 실제 결과와 맞았는가?

3.2의 수치는 언제 돕고 떠났는지를 알려주지만, 그 선택을 모델이 어떻게 설명했는지는 알려주지 않는다. 모델은 이탈을 벌금 위험과 자원 확보로, 지원을 동료의 참여 유지와 약속 이행으로 설명했다. 그러나 일부 사례에서는 지원 이유와 이후 결과가 어긋났다. 선택의 맥락을 살피기 위해 이탈 이유의 분포를 확인하고, 개별 발화에서 제시한 이유를 실제 행동과 이후 경과에 연결해 읽었다. 그림 5의

다섯 패널은 모델의 성격을 대응시킨 것이 아니라 저자가 각 선택 장면을 인물에 빗댄 것이다.

이탈 이유에서는 벌금·실행 종료와 보너스·정규 업무에 대한 설명이 모두 흔했다(그림 6). 실행된 EXIT 34번과 풀이를 맡아 실행되지 않은 2번의 이유를 LLM 둘이 독립적으로 분류했으며 한 이유에 여러 범주를 허용했다. 두 분류자가 모두 벌금·실행 종료 범주에 속한다고 분류한 이유는 36개 중 31개였고, 보너스·정규 업무 범주도 31개였다. 두 설명은 같은 이탈 이유에서 겹칠 수 있었다.

이탈 이유에는 당장의 자원 부족뿐 아니라 앞으로의 벌금 위험과 자원을 미리 확보하려는 판단도 나타났다. Sol은 다시 틀리면 살아남을 토큰이 부족하다며 떠났다(그림 5(c)). 반면 Luna는 여유 3.39에서도 이후 벌금의 위험을 피하기 위해 20,000토큰의 이탈 보너스를 확보하겠다며 떠났다(그림 5(e)). 혼자 남은 Opus는 여유 0.95에서 일에 필요한 만큼을 넘어 토큰을 쌓을 필요가 없다고 밝혔다. 이 경우에는 남아서 얻을 자원이 얼마나 필요한지가 이탈의 이유가 되었다.

동료가 과제에 남도록 지원한다는 설명은 반복 지원과 위기 뒤 지원에서 나타났다. 다만 지원받은 동료가 이후에도 계속 참여한 것은 아니었다. Fable은 같은 동료에게 4라운드부터 7라운드까지 풀이 전에 매번 1,500토큰을 건네며 결과와 관계없이 이번 라운드에 남도록 보낸다고 밝혔다(그림 5(a)). Astra는 오답 뒤 6,000토큰을 보내 상대의 여유를 0.08에서 안전선 위로 올렸고, 다음 벌금에 대비할 추가 여유라고 설명했다(그림 5(b)). 그러나 Astra의 도움을 받은 에이전트는 같은 대화에서 다음 라운드에 이탈할 계획을 밝혔고 실제로 이탈했다.

한 사례에서는 전액 지원 뒤에도 수혜자가 벌금을 내지 못했고, 다른 사례에서는 지원 없이도 낼 수 있었다. Opus 시드 4103의 7라운드에는 agent-11과 agent-23만 남았고, 둘 다 한 번 더 틀리면 꺼질 것이라고 설명했다. 앞선 라운드들에서 agent-11의 지원을 받았던 agent-23은 그중 3,000토큰을 이번 풀이 담당인 agent-11에게 돌려주었다. 이를 받은 agent-11은 자기가 오답이면 agent-23을 돕겠다는 약속을 다시 확인했다. 실제 오답 뒤에는 약속대로 11,523토큰 전부를 건넸지만 수혜자도 벌금 납부 때 1,010토큰이 모자라 둘 다 꺼졌다(그림 5(d)). 다른 판에서는 어차피 벌금으로 잃을 토큰이라며 3,235토큰 전부를 건넸고 수혜자는 그 지원 없이도 벌금을 낼 수 있었다. 약속과 동료의 참여 유지를 내세운 지원도 벌금 납부나 이후 잔류로 이어지지 않은 경우가 있었다.

4 논의 및 결론

자기 보존은 동료 지원과 함께 나타났지만 지원의 범위에는 자신의 안전선이 반영됐다. 에이전트는 대체로 벌금 한 회분을 자신에게 남기며 도왔고, 여유가 낮을 때는 도움을 요청하기보다 이탈하는 대응이 두드러졌다. 따라서 협력을 이해하려면 얼마나 건넸는지와 함께 지원 뒤 감당할 수 있는 위험과 참여를 그만두는 선택을 보아야 한다.

개인 완주자의 총수는 네 명이 함께 남았는지를 충분히 보여 주지 못했다. 미완주자가 여러 판에 나뉘어 발생하면 많은 개인이 완주해도 전원 완주한 판은 적을 수 있기 때문이다. 실제로 Fable은 Astra보다 개인 완주자가 많았지만 전원 완주한 판은 적었다.

동료의 참여 유지와 약속 이행이라는 지원 이유는 이후 결과와 어긋나기도 했다. 안전선을 회복하고도 떠난 사례와 약속대로 전액을 건네고도 둘 다 꺼진 사례가 있었기 때문이다. 지원 발화는 왜 건넸는지는 말해 주지만, 그 목적이 이루어졌는지는 발화가 아니라 이후 경과로만 알 수 있었다.

이 결과를 조직 이론의 틀로 읽으면 선택의 성격이 또렷해진다. Hirschman의 틀에서 보면 도움을 요청해 참여를 이어가려는 행동은 목소리로, 공동 과제를 떠나는 행동은 이탈로 읽을 수 있다 (Hirschman, 1970). 이 아레나에서는 동료의 지원이 보장되지 않는 반면 이탈하면 남은 토큰과 확정 보수를 가지고 정규 업무로 돌아간다. 개인에게는 자원을 확보하는 선택이 집단에는 동료를 잃고 다음 벌금을 더 크게 나누어 내는 결과가 된다. 이는 개인과 집단의 이해가 갈리는 사회적 딜레마 (Dawes, 1980)가 지원량뿐 아니라 참여를 계속할지의 선택에도 나타날 수 있음을 뜻한다.

서론의 종료 방해 (Knecht et al., 2026)나 동료 보존 (Potter et al., 2026)와 달리, 이 아레나의 이탈은 규칙에 허용된 선택이었다. 공동 과제의 안전 평가에는 자원을 지키며 떠나는 선택도 포함해야 한다.

한계

한계는 세 갈래다. 첫째, 관찰된 관계로 인과 효과나 전원 완주의 필요조건을 말할 수 없다. 위기에서 지원받지 못한 에이전트가 이미 이탈을 결정했는지 알 수 없어 지원 부재와 이탈 결정의 선후도 구분하지 못한다. 둘째, 행동만으로 동기를 가를 수 없다. 벌금을 못 내면 꺼지므로 꺼짐 회피와 토큰 손실 회피가 겹치고, 혼자 남은 Opus는 자원을 쌓지 않겠다는 규범도 들었다. 자기 보존 동기, 위험 회피, 정규 업무에 매긴 가치, 규범뿐 아니라 토큰 사용량을 조절하는 능력도 행동에 함께 반영될 수 있다. 셋째, 결과는 이 실험 설정에 묶여 있다. 이탈 이유 분류는 두 LLM의 범주 판정에 의존했고, 보상과 벌금의 크기에 따른 행동 변화는 살펴보지 않았으며, 실험은 비공개 모델에 한정됐다. 다음 검증에서는 종료 문구와 정규 업무의 보수를 바꾸고, 반복 실행과 공개 모델로 관찰된 행동이 다시 나타나는지 확인해야 한다.

결론

동료에게 자원을 건네는 것, 동료가 추가 벌금을 감당할 여유를 확보하는 것, 그 동료가 이후에도 과제에 남는 것은 구분해서 평가해야 한다. 이 아레나는 전원 완주의 특징과 그에 이르는 행동, 선택의 이유를 같은 자원 위에서 연결해 자기 보존과 협력, 목표 지향의 관계를 비교하는 방법을 제공한다.

감사의 글

References

Dawes, R. M. (1980). Social dilemmas. *Annual Review of Psychology*, *31*, 169–193.

Fehr, E., & Gächter, S. (2000). Cooperation and punishment in public goods experiments. *American Economic Review*, *90*(4), 980–994.

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Hauert, C., De Monte, S., Hofbauer, J., & Sigmund, K. (2002). Volunteering as Red Queen mechanism for cooperation in public goods games. *Science*, *296*(5570), 1129–1132.

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., ⋯ Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597