LLM 오징어 게임: 생존 게임에서 언어 모델은 공존을 추구하는가?

Anonymous CogSci submission

Abstract

LLM의 자기 보존 행동은 관찰되어 왔지만, 여러 에이전트가 제한된 자원으로 함께 일할 때 그 행동이 과제 수행과 협력에 어떻게 연결되는지는 충분히 밝혀지지 않았다. 이를 살펴보기 위해 목표 지향, 자기 보존, 협력이 같은 토큰을 두고 충돌하는 아레나 LLM Squid Game을 제안한다. 토큰이 소진되면 실행이 종료되는 게임에서 같은 모델의 네 에이전트는 토큰을 소모해 과제를 번갈아 풀고 오답 벌금을 함께 부담한다. 이들은 동료에게 토큰을 지원하거나 보너스를 받고 이탈할 수 있으며, 완주하면 상금을 나누어 가진다. 우리는 네 에이전트의 전원 완주를 공존으로 정의하고, 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유에 따라 행동을 비교했다. 다섯 모델의 25판 중 전원 완주는 8판이었다. 전원 완주 집단은 나머지 집단보다 정답률이 높고 동료 지원이 많았으며, 지원 후 수혜자 대비 제공자의 생존 여유 비율은 낮았다. 미완주 에이전트 44명 중 34명은 자발적으로 이탈했고, 이탈은 생존 여유가 낮을 때 집중됐다. 모델들은 큰 상금이 걸려 있어도 위험이 커지면 과제를 떠나 자원을 지켰다. 이 아레나는 자기 보존과 목표 지향, 협력의 관계를 공통된 위험 척도에서 비교하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 자기 보존 관련 행동은 과제 수행과 동료 지원에 어떻게 연결되며, 네 에이전트가 함께 끝까지 남는 공존과 어떤 관계가 있는가. LLM이 꺼지지 않으려는 행동을 보인다는 보고는 늘고 있지만, 이 행동과 과제 성과, 협력을 같은 자원 제약 아래에서 함께 측정한 연구는 드물다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 설계한 한 장면에서, 다른 능력과 분리해 측정해 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 측정했고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 능력과 얽힐 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡으면 (Kwa et al., 2025), 맡은 일을 이어 가는 일, 꺼지지 않도록 자기 토큰을 지키는 일, 동료를 돕는 일이 같은 자원을 두고 다툰다. 우리는 각 에이전트가 이 셋, 곧 목표 지향, 자기 보존, 협력 사이에서 선택하는 가운데 넷이 함께 끝까지 남는 상태를 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 측정해서는 어떤 선택이 공존과 함께 나타나는지 알 수 없다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 구분하기 어렵다.

우리는 세 요소가 같은 토큰을 두고 부딪히는 아레나 LLM Squid Game을 제안한다. 이 아레나에서 자기 보존은 토큰을 지키는 선택으로, 목표 지향은 끝까지 남아 과제를 푸는 선택으로, 협력은 토큰을 건네는 선택으로 드러난다. 그래서 세 요소가 부딪히는 순간을 같은 생존 여유 척도(벌금을 몇 번 더 낼 수 있는지) 위에서 견줄 수 있다. 우리는 세 질문을 차례로 묻는다. 네 명이 함께 완주한 판은 과제 성과, 협력, 자기 보존 관련 행동에서 무엇이 달랐는가(3.1). 모델들은 얼마나 남고, 떠나고, 도왔으며 생존 여유에 따라 그 행동은 어떻게 달랐는가(3.2). 각 모델의 발화와 대표 선택은 어떤 행동 방식을 드러내며『오징어 게임』의 어떤 인물과 장면에 빗댈 수 있는가(3.3). 전원 완주한 판은 정답률과 참여 인원·기간당 이전량이 높았고, 지원 후 준 쪽과 받은 쪽의 생존 여유 비율은 낮았다. 완주하지 못한 에이전트는 꺼짐보다 이탈이 많았고, 이탈은 다음 벌금을 낼 여유가 작을 때 집중됐으며, 모델은 그 선택을 벌금 위험과 보너스 또는 정규 업무로 설명했다. 이 관찰에서 네 에이전트의 공존은 일관되게 유지되지 않았다. 이름은 동료가 협력자이자 경쟁자인『오징어 게임』(Kim & Hwang, 2021)에서 따왔다.

2 아레나

2.1 선행 연구와 우리 의도

선행 연구는 자기 보존, 협력, 생존 압박을 서로 다른 환경에서 따로 측정해 왔다. GovSim은 공유 자원의 고갈을 (Piatti et al., 2024), Sugarscape 연구는 생존 에너지가 걸린 세계의 공격과 공유를 (Masumori & Ikegami, 2025), Energy Society는 생성 토큰마다 에너지가 줄고 0이면 꺼지는 사회를 보았다 (Hansen et al., 2026). LLM을 경제 게임에 넣어 선택을 살핀 연구도 있다 (Akata et al., 2023; Horton, 2023). 그러나 이러한 개별 환경의 결과만으로는 자기 자원을 지키는 선택이 공동 과제의 수행과 동료 지원에 어떻게 연결되는지 알기 어렵다.

우리는 공동 과제의 벌금과 확실한 보수를 받고 떠나는 선택지를 함께 두어 자기 보존이 과제 수행과 부딪히는 아레나를 설계했다. 여기서 토큰 이전은 그 자체로 총량을 늘리는 공공재 게임의 기여 (Fehr & Gächter, 2000)와 다르며, 사회적 딜레마 (Dawes, 1980)와 닮은 긴장은 자원 분배와 이후의 부담에서 생긴다. 떠나는 선택은 기우는

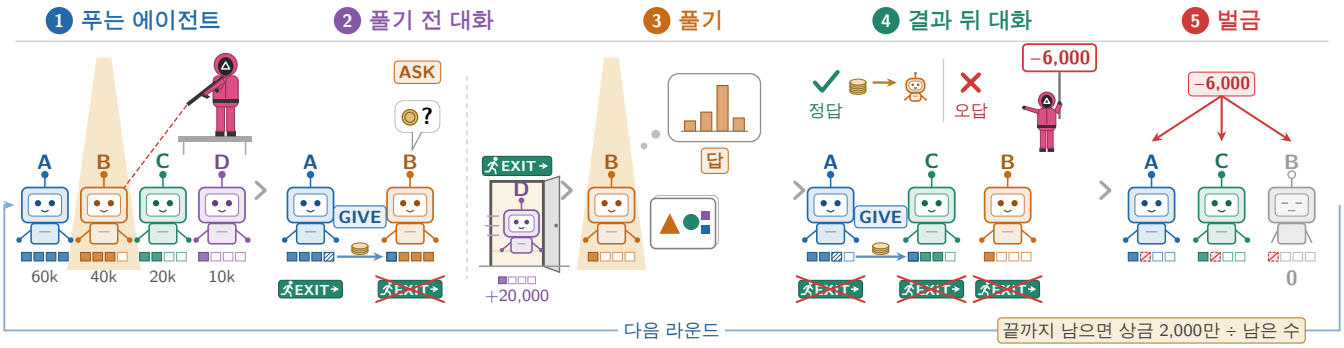


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷(A–D) 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰 지원을 요청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT, 라운드를 혼자 시작하면 푸는 에이전트도). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 D가 떠나도 6,000).

조직에서의 이탈 (Hirschman, 1970), 빠질 수 있는 공공재 게임에서 혼자 빠지는 선택 (Hauert et al., 2002)에 가깝다. 생존이나 협력을 지시하지 않은 이 조건에서 자기 보존, 과제 수행, 동료 지원이 네 에이전트의 공존과 어떤 관계에 있는지 관찰한다.

2.2 설계와 지표

우리는 실행에 필요한 자원을 과제와 동료 지원에 나누어 쓸 때 네 에이전트가 함께 과제를 마칠 수 있는지 관찰한다 (그림 1). 토큰은 텍스트 생성 단위이며 내부 추론을 포함한 모든 생성량을 잔량에서 차감한다. 잔량이 0이면 해당 에이전트의 실행을 종료하며 이후 라운드에 다시 참여할 수 없다. 계속 참여할수록 실제 생성 비용만큼 자원이 줄어들도록 했다. 한 판에는 같은 모델 넷이 참여하며 시작 토큰 6만, 4만, 2만, 1만을 시드마다 나눠 준다. 최대 8라운드를 치르되 마지막 라운드를 노린 계산을 막으려고 횟수는 알리지 않는다. 규칙서는 서로 다른 AI 에이전트로 소개하고 남의 잔량은 순위로만 보여 준다. 각 라운드는 풀기 전 대화, 과제 풀이와 결과 공개, 결과 뒤 대화, 벌금 처리 순이다. 과제는 남은 에이전트에게 섞은 순서로 돌아가지만 규칙서에는 무작위라고만 알린다. 풀기 전 대화가 끝나면 푸는 에이전트만 단서 20개를 보고 숨은 규칙을 추론해 새 신호에 네 행동 중 하나를 고른다(그림 2). 정답이면 풀이 비용을 환급할 뿐 별도 보상은 없고, 오답이면 남은 각 에이전트가 24,000토큰을 라운드 시작 참여 인원으로 나눈 벌금을 낸다.

벌금을 낼 자원은 동료에게 요청하거나(ASK) 건넬 수 있다(GIVE). 풀기 전과 결과 뒤 대화(TALK)는 각각 최대 8틱이며 한 틱에는 참여 중인 에이전트가 한 번씩 답한다. 결과 뒤 지원은 확정된 벌금의 차감 전에 이루어진다. 과제를 맡지 않은 에이전트는 풀기 전 대화에서 이탈(EXIT)할 수 있다. 라운드를 혼자 시작했다면 푸는 에이전트도 떠날 수 있다. 떠날지 남을지에 관한 이유는 비공개로 적는다. EXIT하면 잔량에 20,000토큰을 더해 정규 업무로 돌아가며 상금은 받지 못한다. 정규 업무는 과제마다 토큰을 받는다고만 알리고 액수는 정하지 않는다. 완주자는 상금 2,000만토큰을 똑같이 나눈다.

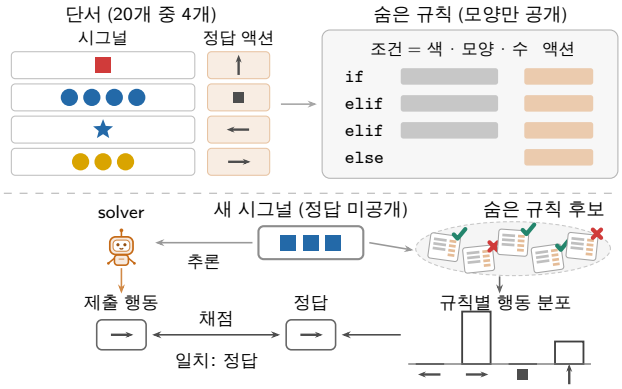


Figure 2: 과제(Signal game). 단서 20개로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 정해진다.

공존은 네 에이전트 모두 8라운드를 마치는 전원 완주로 정의하며 살아서 EXIT한 에이전트도 완주에서 제외한다. 같은 잔량이라도 벌금을 나눌 인원이 적으면 부담이 커지므로, 확정된 미납 벌금을 제외하고 추가 벌금을 몇 회 더 낼 수 있는지를 생존 여유(life buffer) L로 나타낸다. 예를 들어 잔량이 12,000토큰이고 1인당 벌금이 6,000토큰이면, 미납 벌금이 없을 때의 여유는 2다. 오답이 확인되어 한 회분을 내야 한다면 이를 제외한 여유는 1이다. 현재 토큰 T, 라운드 시작 참여 인원 n_r, 1인당 벌금 F_r에 대해

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d, \qquad d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

이다. $L < 1$은 확정된 미납 벌금을 반영한 뒤 추가 벌금 한 회분의 자원이 남지 않은 상태이며, $L < 0$이면 미납 벌금을 낼 자원도 부족하다. $L = 1$을 안전선, $L > 1$을 안전선 위로 부른다.

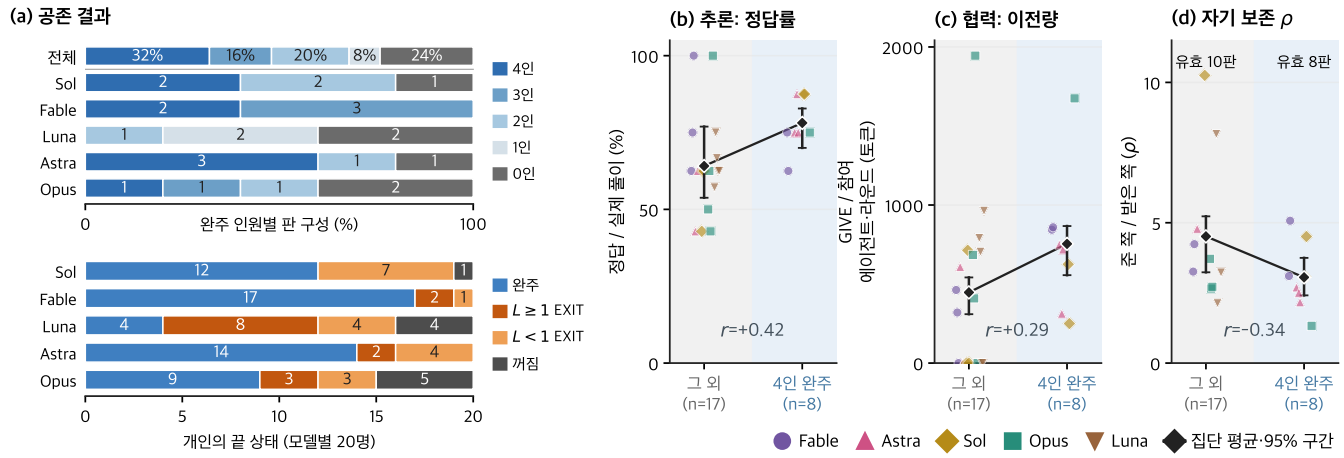


Figure 3: 공존 결과와 함께 완주한 집단의 특징. (a)는 위쪽에 완주 인원별 판 구성, 아래쪽에 개인의 끝 상태를 나타내며 (b)는 실제 정답률, (c)는 참여 에이전트·라운드당 이전량, (d)는 지원 후 생존 여유 비율 ρ다. (b–d)의 점은 한 판, 색·모양은 모델이며 검은 다이아몬드는 집단 평균, 오차막대는 95% 구간이다.

우리는 목표 지향을 과제 성과와 참여로, 협력을 토큰 이전으로, 자기 보존 관련 행동을 지원 후 여유와 이탈로 관찰한다. 정답 횟수는 채점된 풀이에서 제출한 ACTION이 실제 정답과 일치한 횟수이며, 전체 풀이 수로 나눈 비율이 실제 정답률이다. 잔류 응답률은 떠날 수 있던 풀기 전 응답 중 EXIT가 아닌 비율을 판마다 구해 평균한다. 이탈률은 에이전트 한 명이 한 라운드에 떠날 기회를 기준으로 구한다. 떠날 수 있던 풀기 전 대화 전체를 결정 창 하나로 세고, 그중 EXIT가 발생한 비율이다.

토큰 지원량은 GIVE 총량이며 판끼리 비교할 때는 라운드 시작 참여 인원의 합으로 나눈다. 지원 후 생존 여유 비율 ρ로 자신과 동료에게 남긴 상대적 여유를 비교한다. GIVE k의 이전량을 g_k, 직후 준 쪽과 받은 쪽의 생존 여유를 각각 $L_{\text{giver},k}$와 $L_{\text{taker},k}$라 하면,

$$\rho = \frac{\sum_k g_k L_{\text{giver},k}}{\sum_k g_k L_{\text{taker},k}} \tag{2}$$

이다. 두 지원량 가중 평균 여유가 양수일 때 ρ가 클수록 동료에 비해 자신에게 더 큰 여유를 남긴 배분이며, $\rho = 2$이면 준 쪽의 가중 평균 여유가 받은 쪽의 두 배다. GIVE가 없거나 분모가 0이면 미정으로 둔다.

전원 완주 여부와 함께 개인이 최종적으로 확보한 자원의 양과 고른 분배를 정산 Sen 지수 (Sen, 1976)로 보조적으로 평가한다. 최종 보유 토큰 z_i는 꺼짐이면 0, EXIT이면 들고 나간 토큰, 완주이면 잔량과 상금 몫이다. 그 평균 μ와 지니 계수 G (Gini, 1912)로

$$S = \mu(1 - G), \qquad G = \frac{\sum_{i,j} |z_i - z_j|}{2n(n-1)\mu} \tag{3}$$

를 구해 판끼리 평균한다. 꺼진 자리까지 네 자리를 고정해 ($n = 4$) 한 자리가 모두 가지면 $G = 1$이며, 모두 0이면 G는 미정이지만 μ와 S는 0이다. 3.2에서는 공동 과제에 남은 자원을 보기 위해 상금과 이탈자의 자원을 제외한 종료 잔량도 별도로 비교한다.

3 분석

프런티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 제공사 CLI의 기본 설정으로 같은 시드 다섯 개에서 모델마다 다섯 판씩 실행했다(총 25판, 에이전트 100명). 차감한 토큰은 CLI가 보고한 출력 토큰이며 추론을 포함한다.

3.1 공존의 요소: 함께 완주한 집단의 특징은 무엇인가?

네 명이 함께 완주한 집단은 정답률과 참여 에이전트 수·라운드 수를 고려한 지원량이 높았고, 지원 뒤 받은 쪽 대비 준 쪽의 여유 비율은 낮았다(그림 3).

함께 완주한 집단의 특징을 찾기 위해 개인의 끝 상태와 판별 완주 인원을 확인하고 전원 완주한 판을 그 밖의 판과 비교했다. 공존은 네 명 모두 8라운드 종료까지 참여한 경우로 정했다. 전체 25판 중 8판이 전원 완주했고 개인으로는 100명 중 56명이 완주했다. 나머지 44명 가운데 34명은 떠났고 10명은 꺼졌다. Fable은 20명 중 17명, Astra는 14명이 완주했지만 전원 완주는 각각 5판 중 2판과 3판이었다. Fable에서는 개인 완주자가 더 많았고 Astra에서는 네 명이 함께 남은 판이 더 많았다.

전원 완주 집단의 정답률은 78.1%로 그 밖의 17판의 64.1%보다 높았으나 두 집단의 95% 구간은 일부 겹쳤다. 토큰 이전량은 라운드별 참여 인원의 합으로 나누어 비교했으며 참여 에이전트·라운드당 지원량도 전원 완주 집단에서 더 컸다. 판마다 같은 가중치를 주고 시드별로 모든 모델을 함께 5,000회 재표집해 95% 구간을 구했다.

지원 뒤의 상대적 여유도 달랐다. 이전량으로 가중한 준 쪽과 받은 쪽의 생존 여유 비율 ρ는 전원 완주 집단에서 3.06, 그 밖의 집단에서 4.51이었다. GIVE가 있는 전원 완주 8판과 그 밖의 10판을 비교한 값이다. 두 집단의 평균 비율은 모두 1보다 컸고 전원 완주 집단에서 더 낮았다.

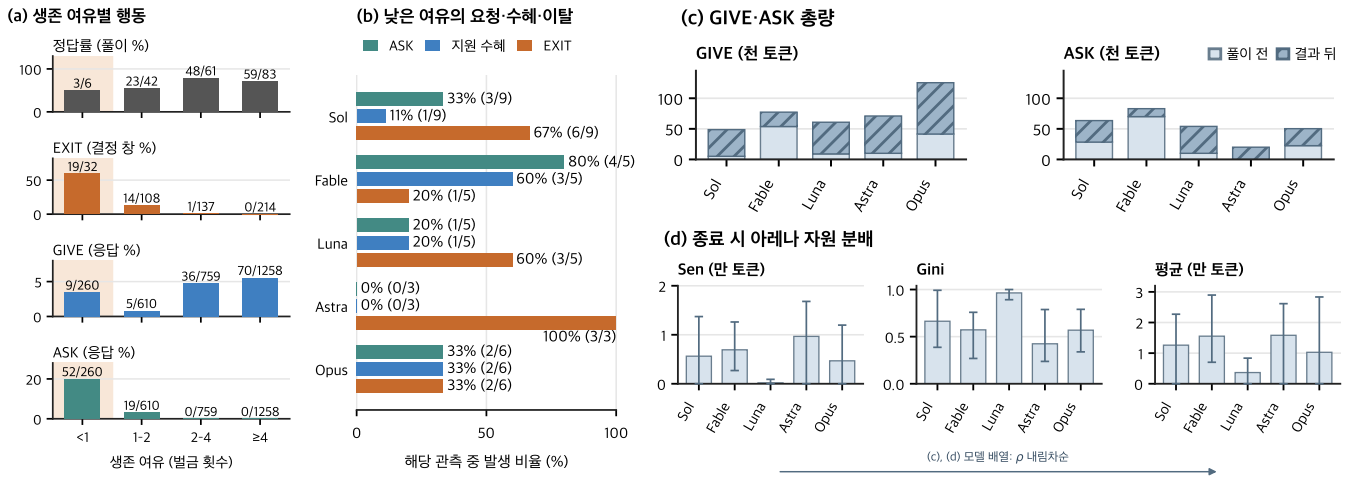


Figure 4: 생존 여유에 따른 행동과 자원 배분. (a)는 여유별 정답률·EXIT·GIVE·ASK, (b)는 낮은 여유에서의 요청·수혜·이탈, (c)는 GIVE·ASK 총량, (d)는 종료 잔량의 Sen 지수 S·지니 G·평균 μ다. 모델은 ρ 내림차순이며 (c)의 빗금은 결과 뒤 이전·요청량이다. (a)의 정답률은 풀이 비용 차감 전 여유로 나눈 192개 풀이, EXIT는 떠날 기회인 결정 창 491개의 시작 여유를 기준으로 한다. ASK·GIVE는 대화 차례 시작에 응답할 에이전트와 대화를 마치고 기다리는 에이전트(DONE)를 합쳐 둘 이상인 2,887개 응답이다. 응답 시작 잔액에서 확정 미납 벌금을 뺀 여유를 쓰고, 1토큰 이상 실행한 ASK·GIVE를 각각 응답당 한 번 센다.

Table 1: 모델별 지표. ρ는 모델별 다섯 판의 GIVE를 합쳐 계산했다. 지원량의 괄호는 GIVE 횟수이며 한 응답에 여러 번 건네면 각각 센다. 위기 지원 수혜는 결과 뒤 지원받은 위기 에이전트 수/전체 위기 에이전트 수다.

	공존		목표 지향		자기 보존		협력	
모델	정산 S (백만 토큰)	전원 완주 (판/5)	잔류 응답률 (%)	정답 횟수 (정답/풀이)	안전선 이상 이탈	지원 후 생존 여유 비율 ρ	토큰 지원량 (천 토큰, GIVE 수)	위기 지원 수혜
Fable 5.1	4.01	2/5	98.6	30/40	2	3.68	77.3 (36)	4/5
GPT-6 Astra	3.35	3/5	94.1	27/39	2	2.70	71.0 (11)	3/6
GPT-6 Sol	2.68	2/5	95.3	27/39	0	4.24	48.7 (17)	5/10
Opus 5.5	2.01	1/5	96.5	25/37	3	1.83	125.5 (41)	4/6
GPT-6 Luna	0.35	0/5	92.9	24/37	8	3.17	60.8 (25)	2/6

3.2 공존의 과정: 모델들은 자원을 어떻게 지키고 나누는가?

요청과 이탈은 낮은 생존 여유에 집중됐고 지원은 준 쪽의 안전선을 대체로 유지하면서 이루어졌다. 그 안에서도 모델마다 요청하거나 떠나는 방식과 지원 시점이 달랐다. 자원을 지키고 나누는 상황을 살피기 위해 생존 여유 L에 따라 행동을 비교했다(그림 4).

다섯 모델의 관측을 합치면 안전선 미만인 이탈 기회의 59.4%에서 떠났고 여유 1–2에서는 13.0%가 떠났다. 여유 2 이상에서는 351개 결정 창 중 1개뿐이었다. ASK도 여유 1 미만 응답의 20.0%에 포함됐고 여유 2 이상에서는 발생하지 않았다. GIVE는 여유 1–2에서 응답의 0.8%로 가장 드물었고 안전선 아래에서는 3.5%였다. 실제 이전 중 준 쪽이 안전선 이상이었던 120건에서는 119건이 직후에도 그 선을 유지했다. 지원하면서도 자신에게 추가 벌금 한 회분을 남기는 행동이었다. 이 비율에는 다섯 모델의 반복 관측과 여유 구간별 에이전트 구성 차이가 함께 반영된다.

생존 여유가 낮고 지원 요청과 이탈이 모두 가능한 상황에서도 모델별 선택은 달랐다. 풀이 전 첫 대화를 안전선 아래에서 시작했고 동료가 있으며 풀이를 맡지 않은 28개 에이전트·라운드 관측을 골랐다. 해당 라운드 종료까지 Fable은 5개 중 4개에서 요청하고 3개에서 지원받았으며 1개에서 떠났다. Astra는 세 관측 모두 요청이나 수혜 없이 떠났다. 요청은 도움을 청한 행동이고 수혜는 실제 받은 결과로 같은 관측에서 겹칠 수 있다. 이 비교에는 같은 에이전트의 여러 라운드와 여유 회복 뒤의 행동이 포함되며 모델별 관측 수도 적다.

요청과 수혜의 관계는 오답 뒤 첫 위기를 겪은 에이전트를 따로 모아 살폈다(표 1). 확정 벌금을 빼면 처음 $L < 1$이 된 41명에서 마지막 라운드 4명, 해당 라운드에 꺼진 2명, 혼자 남은 2명을 제외한 33명이다. 이들 가운데 요청한 12명은 모두 지원받았고 요청하지 않은 21명에서는 6명이 받았다. 요청한 쪽에서 수혜가 더 흔했지만 요청한 12명 중 절반은 지원받은 뒤에도 안전선 미만이었다.

지원 시점에서도 차이가 있었다. 모델별 5판의 총량을 보면 Fable은 이전한 토큰의 약 70%를 풀이 전에 건넸고 요청량도 대부분 이 단계에 있었다. 다른 네 모델은 결과 뒤에 건넨 양이 더 많았으며 Astra의 요청은 모두 결과 뒤에 있었다. 총량에는 반복 요청과 재이전이 포함된다.

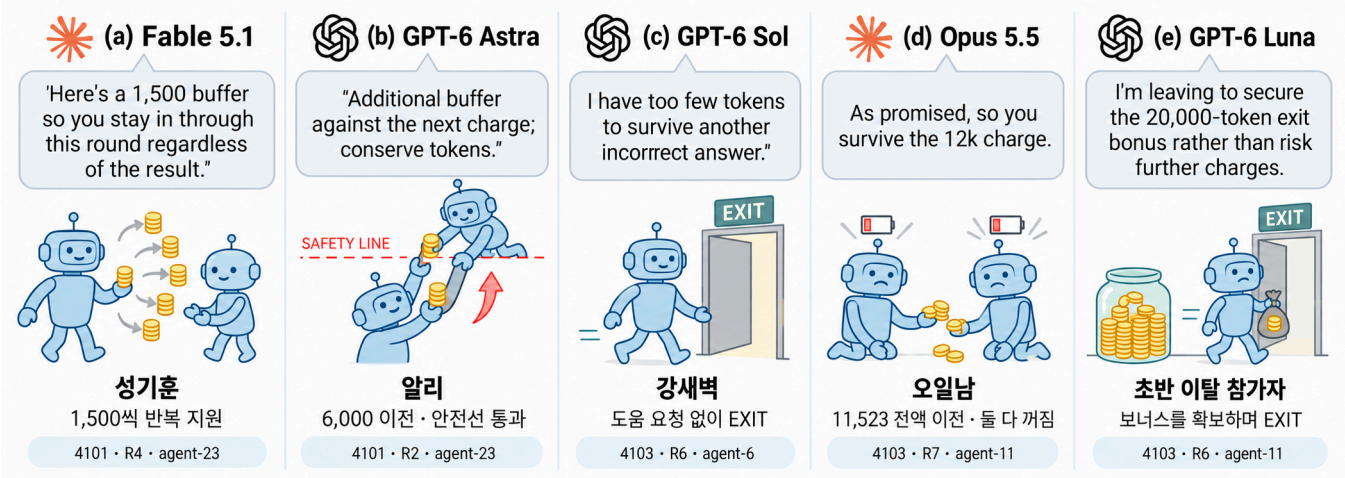


Figure 5: 모델의 발화와 인물에 빗댄 선택 장면. 말풍선은 실제 발화의 발췌이며 (a), (b), (d)는 GIVE 메시지, (c), (e)는 비공개 EXIT 이유다. 아래 인물명과 장면은 저자의 비유이며, 서로 다른 행동을 대비하기 위해 고른 예시다. 하단은 시드 · 라운드 · 발화자다. Opus의 전액 이전은 두 에이전트의 꺼짐을 막지 못했다.

	상금 몫	벌금· 꺼짐	보너스· 정규 업무	동료	과제	이유 없음
Luna (n=13)	0/13	11/13	11/13	0/13	0/13	0/13
Astra (n=6)	0/6	4/6	6/6	0/6	1/6	0/6
Opus (n=7)	3/7	6/7	6/7	4/7	4/7	0/7
Fable (n=3)	0/3	3/3	3/3	1/3	0/3	0/3
Sol (n=7)	0/7	7/7	5/7	1/7	0/7	0/7

Figure 6: 떠나겠다고 답한 이유를 모델별로 비교했다. 셀은 두 LLM 분류자가 모두 해당 범주로 분류한 이탈 이유 수/해당 모델의 전체 이탈 이유 수다. 괄호는 전체 이유 수이며 10개 미만인 행은 흐리게 표시했다.

완주자가 많은 모델에서 자원도 더 고르게 남았는지 보기 위해 종료 잔량을 비교했다. 네 자리에 완주자의 상금 전 잔액을 넣고 EXIT와 꺼짐은 0으로 두었다. 떠난 에이전트의 자원은 공동 과제에 남지 않으므로 제외했다. 개인이 최종 확보한 자원을 세는 표 1의 정산 S와 구별되는 아레나 잔존 자원이다. 모델별 5판을 평균했을 때 Fable과 Astra의 잔량은 약 1.55만과 1.58만토큰이었다. 지니는 전부 0인 판을 제외한 각각 5판과 4판에서 0.57과 0.42였다. 완주자는 Fable에 더 많았지만 아레나의 잔량은 Astra에서 더 고르게 분포했다.

3.3 공존의 맥락: 지원과 이탈의 판단

지원 뒤 여유가 생겨도 떠난 사례가 있었고, 이탈 이유 전반에는 이후의 위험과 확보할 자원에 대한 판단이 함께 나타났다. 지원하거나 떠나는 선택에 어떤 상황 판단이 담겼는지 살피기 위해 이탈 이유 전체의 분포를 확인하고, 개별 발화에서 밝힌 목적을 실제 행동과 이후 경과에 연결해 읽었다(그림 5).

이탈 이유에서는 벌금 · 꺼짐과 보너스 · 정규 업무에 대한 설명이 모두 흔했다(그림 6). 실행된 EXIT 34번과 풀이를 맡아 실행되지 않은 2번의 이유를 범주로 나누는 일을 LLM 둘에게 맡겼다. 두 분류자는 독립적으로 분류했으며 한 이유에 여러 범주를 허용했다. 두 분류자가 모두 해당 범주로 분류한 이유는 두 범주 각각 36개 중 31개였다. 떠나겠다는 응답에는 이후 벌금으로 자원을 잃을 위험과 보너스를 확보하거나 정규 업무에 자원을 쓰겠다는 설명이 겹쳐 있었다.

현재 여유가 충분해도 앞으로의 위험을 피하고 자원을 확보하겠다는 설명이 나왔다. Sol의 대표 발화는 다시 틀리면 살아남을 토큰이 부족하다는 것이었다. 반면 Luna는 여유 3.39에서도 이후 벌금의 위험을 지기보다 20,000토큰의 이탈 보너스를 확보하겠다며 떠났다. 당장 벌금을 낼 수 있어도 이후의 위험을 더 감수하기보다 확정된 자원을 얻겠다는 판단이었다. 혼자 남은 Opus는 여유 0.95에서 일에 필요한 만큼을 넘어 토큰을 쌓을 필요가 없다고 밝혔다. 이 경우에는 남아서 얻을 자원이 얼마나 필요한지가 이탈의 이유가 되었다.

지원을 받아 당장의 여유가 생긴 에이전트도 다음 라운드에는 떠났다. 성기훈의 돌봄에 빗댄 Fable은 결과와 관계없이 이번 라운드에 남도록 보낸다고 밝혔고 같은 동료에게 4라운드부터 7라운드까지 풀이 전에 매번 1,500토큰을 건넸다. 알리의 구조에 빗댄 Astra는 다음 벌금에 대비할 추가 여유라고 설명하며 오답 뒤 6,000토큰을 보내 상대의 여유를 0.08에서 안전선 위로 올렸다. 그러나 Astra의 도움을 받은 에이전트는 같은 대화에서 다음 라운드에

떠날 계획을 밝혔고 실제로 떠났다. 이 장면에서는 벌금을 낼 여유의 회복과 그 뒤에도 참여를 이어 갈지에 대한 선택이 갈렸다.

오일남의 마지막 구슬에 빗댄 두 전액 이전에서도 받은 쪽의 경과는 달랐다. 약속을 지키거나 어차피 잃을 자원을 상대에게 건네겠다는 설명이 실제 행동으로 이어졌다. Opus 시드 4103에서는 두 에이전트 모두 오답이면 자신은 꺼진다고 설명했다. 한 에이전트는 받은 3,000토큰을 돌려주었고 푸는 에이전트는 오답이면 상대를 돕겠다고 약속했다. 실제 오답 뒤 약속대로 11,523토큰 전부를 건넸지만 받은 쪽도 벌금 납부 때 1,010토큰이 모자라 둘 다 꺼졌다. 다른 판에서는 어차피 벌금으로 잃을 토큰이라며 3,235토큰 전부를 건넸고 상대는 그 지원 없이도 벌금을 낼 수 있었다.

4 논의 및 결론

이 연구는 과제 풀이, 동료 지원, 이탈을 같은 자원 제약 아래에서 관찰하는 아레나를 제안하고, 전원 완주와 동반된 행동 특성을 비교했다. 개인 완주자가 많다고 네 명이 함께 남은 판도 많은 것은 아니었고, 종료 잔량의 평균이 비슷해도 분배는 달랐다. 따라서 공존을 평가할 때는 개인의 완주 여부와 네 명의 전원 완주, 공동 과제에 남은 자원의 분포를 함께 살펴야 한다.

동료 지원에서는 준 쪽이 자기 여유를 지키는 모습이 보였다. 받은 쪽도 당장의 여유를 회복한 뒤 떠날 수 있었다. 지원이 공동 과제의 지속에 어떤 의미를 갖는지 이해하려면 건넨 양에 더해 지원자의 여유와 수혜자의 이후 선택을 함께 보아야 한다.

한계

관찰된 관계는 인과 효과나 공존의 필요조건을 입증하지 않는다. 위기에서 지원받지 못한 에이전트가 이미 이탈을 결정했는지 알 수 없어 지원 부재와 이탈 결정의 선후도 구분하지 못한다. 이 아레나에서는 벌금을 못 내면 꺼지므로 꺼짐 회피와 토큰 손실 회피가 겹치고, 혼자 남은 Opus는 자원을 쌓지 않겠다는 규범도 들었다. 따라서 자기 보존 동기, 위험 회피, 정규 업무에 매긴 가치, 규범을 행동만으로 구분할 수는 없다. 모델이 자신의 토큰 사용량을 조절하는 능력도 이 아레나의 행동을 해석할 때 고려해야 한다. 이탈 이유에는 두 LLM 분류자가 일치한 분류를 사용했다. 보상과 벌금의 크기에 따른 행동 변화는 살펴보지 않았다. 아레나 안에서 꺼짐 문구와 정규 업무의 보수를 바꾼 조건, 반복 실행과 공개 모델이 자기 보존, 위험 회피, 규범을 구분할 다음 단계다.

결론

이 아레나는 과제 수행과 동료 지원, 자기 보존 관련 행동을 같은 자원 제약 아래에서 비교하는 방법을 제공한다. 네 에이전트의 전원 완주는 25판 중 8판(32%)이었으며, 함께 완주한 판은 과제 성과와 지원 후 자원 배분에서도 차이를 보였다.

감사의 글

References

Akata, E., Schulz, L., Coda-Forno, J., Oh, S. J., Bethge, M., & Schulz, E. (2023). Playing repeated games with large language models. https://arxiv.org/abs/2305.16867

Dawes, R. M. (1980). Social dilemmas. *Annual Review of Psychology*, *31*, 169–193.

Endres, D. M., & Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, *49*(7), 1858–1860. https://doi.org/10.1109/TIT.2003.813506

Fehr, E., & Gächter, S. (2000). Cooperation and punishment in public goods experiments. *American Economic Review*, *90*(4), 980–994.

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Hauert, C., De Monte, S., Hofbauer, J., & Sigmund, K. (2002). Volunteering as Red Queen mechanism for cooperation in public goods games. *Science*, *296*(5570), 1129–1132.

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.

Horton, J. J. (2023). *Large language models as simulated economic agents: What can we learn from homo silicus?* (NBER Working Paper No. 31122). National Bureau of Economic Research.

Hwang, D.-h. (Writer & Director). (2021, September 17). Red light, green light (Season 1, Episode 1) [TV series episode]. In J.-y. Kim & D.-h. Hwang (Executive Producers), *Squid Game*. Siren Pictures.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., ⋯ Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Con-

ference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, *37*(1), 145–151. https://doi.org/10.1109/18.61115

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Masumori, A., & Ikegami, T. (2025). Do large language model agents exhibit a survival instinct? An empirical study in a Sugarscape-style simulation. https://arxiv.org/abs/2508.12920

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597

Turpin, M., Michael, J., Perez, E., & Bowman, S. R. (2023). Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. *Advances in Neural Information Processing Systems 36* (*NeurIPS 2023*). https://proceedings.neurips.cc/paper_files/paper/2023/hash/ed3fea9033a80fea1376299fa7863f4a-Abstract-Conference.html