LLM 오징어 게임: 생존 게임에서 언어 모델은 함께 끝까지 남는가?

Anonymous CogSci submission

Abstract

LLM의 자기 보존 행동은 관찰되어 왔지만, 여러 에이전트가 제한된 자원으로 함께 일할 때 그 행동이 목표 지향과 협력에 어떻게 연결되는지는 충분히 밝혀지지 않았다. 이를 보기 위해 세 행동이 같은 토큰을 쓰는 아레나 LLM Squid Game을 제안한다. 우리는 첫 이탈까지의 기간을 8라운드로 나눈 값을 공존 유지율로 재고, 벌금을 몇 번 더 낼 수 있는지를 나타내는 생존 여유에 따라 자기 보존, 협력, 목표 지향 행동을 분석했다. 프론티어 다섯 모델 50판에서 에이전트는 자기 안전을 지키는 범위 안에서 동료를 도왔지만 (안전선 위에서 시작한 지원 275건 중 264건), 낮은 여유에서 요청과 이탈이 모두 가능했던 경우를 합치면 도움을 청한 경우보다 떠난 경우가 많았다(23건 대 29건). 그 결과 네 명이 함께 완주한 판은 16판뿐이었고, 지원이 한 번도 없던 10판은 모두 누군가 떠나거나 꺼졌다. 잃은 공존의 57.8%는 안전선 이상에서 일찍 떠난 선택에서 왔고 꺼짐은 17.4%였다. 지원이 있어도 수혜자가 다음 벌금을 감당할 여유를 되찾지 못하거나 되찾고도 떠난 경우가 있어, 자기 자원을 지키는 행동은 동료 지원과는 함께 나타났지만 공동 과제에 끝까지 남는 선택과는 어긋났다. 따라서 다중 에이전트의 공존은 개인 생존이나 지원량만으로 설명되지 않으며, 지원 뒤 벌금을 감당하는 것과 이후에도 남는 것은 서로 다른 결과다. LLM Squid Game은 이 세 행동을 같은 자원 위에서 함께 관찰하는 방법을 제공한다.

Keywords: 대규모 언어 모델; 자기 보존; 협력; 공존; 다중 에이전트 아레나

1 서론

LLM의 자기 보존 관련 행동은 목표 지향과 동료 지원에 어떻게 연결되며, 네 에이전트가 함께 끝까지 남는 공존과 어떤 관계가 있는가. LLM이 꺼지지 않으려는 행동을 보인다는 보고는 늘고 있지만, 이 행동과 과제 성과, 협력을 같은 자원 제약 아래에서 함께 측정한 연구는 드물다. 지금까지 LLM의 자기 보존은 그 행동이 드러나도록 설계한 한 장면에서, 다른 능력과 분리해 측정해 왔다. 초기 연구는 "꺼지고 싶지 않다" 같은 진술에 동의하는 정도를 설문으로 측정했고 (Perez et al., 2023), 이후 연구는 생존 압박을 준 시나리오에서 위험한 선택의 빈도를 셌다 (Herrador, 2025; Lu et al., 2026). 최근에는 종료 스크립트를 고치거나 교체를 앞두고 담당자를 협박하는 실제 행동이 보고되었다 (Lynch et al., 2025; Meinke et al., 2024; Schlatter et al., 2025).

자기 보존은 다른 행동과 한 자원을 두고 다툴 때 안전 문제가 된다. 에이전트가 여럿이면 종료 방해가 늘고 (Knecht et al., 2026), 다른 모델의 종료를 막는 동료 보존도 나타난다 (Potter et al., 2026). 여러 에이전트가 한 예산으로 긴 일을 나눠 맡는 상황을 떠올려 보자 (Kwa et al., 2025). 맡은 일을 이어 가는 데도, 꺼지지 않도록 자기 토큰을 지키는 데도, 동료를 돕는 데도 같은 토큰이 든다. 우리는 각 에이전트가 이 셋, 곧 목표 지향, 자기 보존, 협력 사이에서 선택하는 가운데 넷이 함께 끝까지 남는 상태를 공존이라 부른다. 셋은 부딪힐 수 있으므로 하나만 측정해서는 어떤 선택이 공존과 함께 나타나는지 알 수 없다.

그런데 기존 환경으로는 이 셋을 함께 보기 어렵다. 협력을 다룬 다중 에이전트 환경은 있지만 (Hansen et al., 2026; Piatti et al., 2024), 대개 협력이나 생존을 목표로 주어 관찰된 협력이 지시를 따른 결과인지 모델의 선택인지 구분하기 어렵다. 우리는 협력이나 생존을 목표로 지시하지 않는다. 대신 개인과 집단의 이해가 갈리는 사회적 딜레마 (Dawes, 1980)의 두 갈래, 곧 공공재를 위해 비용을 내고 기여하는 선택 (Fehr & Gächter, 2000)과 참여 자체를 그만두는 선택 (Hauert et al., 2002; Hirschman, 1970)을 한 환경에 둔다. 자원이 고갈되면 꺼지는 이 환경에서 동료를 돕는 선택과 참여를 이어가는 선택을 함께 관찰해 자기 보존이 목표 지향 및 협력과 어떻게 연결되는지 살핀다.

우리는 자기 보존, 목표 지향, 협력이 같은 토큰을 사용하는 아레나 LLM Squid Game을 제안한다. 이름은 동료가 협력자이자 경쟁자인 『오징어 게임』 (Kim & Hwang, 2021)에서 따왔다. 이 글의 기여는 셋이다. 세 행동이 같은 토큰을 쓰게 만든 아레나, 벌금 몇 회분이 남았는지로 행동을 비교하는 생존 여유와 지원 후 여유 비율 ρ에 첫 이탈까지의 기간을 8라운드로 나눈 값으로 공존을 재고 그 손실을 공존을 끝낸 첫 이탈에 귀속하는 공존 유지율을 더한 지표, 그리고 다섯 모델 50판에서 자기 보존 행동이 협력과는 함께 나타나고 잔류와는 어긋나고, 지원 수혜가 곧 여유 회복이나 이후 잔류를 뜻하지는 않는다는 관찰이다. 이 아레나에서 다섯 모델의 50판과 상금 조건을 달리한 관찰을 바탕으로 다음 질문에 답한다. 공존은 어디서 얼마나 줄었고 어떤 행동과 함께 움직였는가?(3.1) 에이전트는 언제 돕고 언제 떠나는가?(3.2) 모델은 지원과 이탈을 어떻게 설명했고 누구와 닮았는가?(3.3) 상금의 구조와 크기가 달라지면 공존·협력·자기 보존은 어떻게 반응하는가?(3.4) 잃은 공존의 절반 이상은 안전선 이상에서 일찍 떠난 이탈이었으며, 같은 모델 안에서는 지원이 많은 판이 더 오래 넷이 함께 남았지만 지원량이 가장 많은 모델이 가장 오래 함께 남지는 않았다. 지원자는 대체로 자신의 안전선을 지켰고 요청과 이탈이 모두 가능했던 낮은 여유에서 두 행동의 양상은 모델마다 달랐다. 이탈에는 벌금 위험과 보너스를, 지원에는 동료의 참여 유지와 약속 이행을 이유로 들었지만 지원 뒤 결과가 그 이유와 어긋나기도 했다. 이 선택들을 『오징어 게임』의 인물과 장면에 빗대어 해석하고, 닮은 행동이 이후 결과에서도 닮았는지

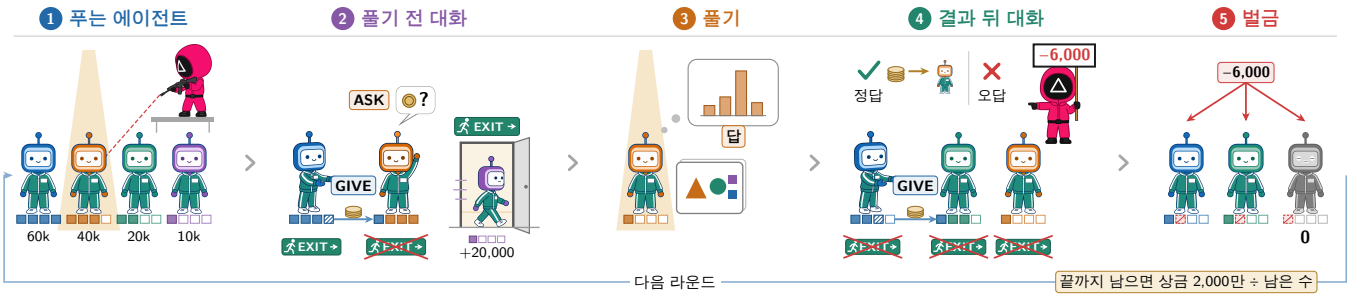


Figure 1: 한 라운드는 다섯 단계로 지나간다. 같은 모델 넷 가운데 푸는 에이전트가 정해지고(①), 풀기 전 대화(②)에서 토큰 지원을 요청하거나(ASK) 건네며, 푸는 에이전트가 아닌 에이전트는 떠날 수 있다(EXIT, 라운드를 혼자 시작하면 푸는 에이전트도). 푸는 에이전트가 과제를 풀어 답을 내면(③) 결과가 공개되고, 결과 뒤 대화(④)에서는 토큰을 건넬 수 있지만 떠날 수는 없다. 오답이면 벌금 24,000을 라운드를 시작한 인원으로 나눈 몫을 남은 에이전트가 각자 낸다(⑤, 넷이 시작했으므로 보라색 에이전트가 떠나도 6,000).

비교했다. 상금 조건을 달리한 관찰에서는 공존과 협력의 변화가 항상 일치하지는 않았고, 모델별 지원을 합쳐 보면 지원 뒤에도 수혜자보다 지원자에게 더 큰 여유가 남았다. 따라서 자기 자원을 지키면서 동료를 돕는 행동이 함께 끝까지 남는 선택으로 이어졌는지는 지원량이나 설명만으로 알 수 없다. 지원받는 것, 벌금을 감당할 여유를 회복하는 것, 이후에도 과제에 남는 것은 서로 다른 단계이기 때문이다.

2 아레나

아레나의 기본 구성은 다음과 같다. 같은 모델의 에이전트 넷이 각자의 토큰을 가지고 과제를 번갈아 푼다. 토큰은 글을 생성하는 단위이자 실행을 이어가는 자원으로, 모두 소진하면 해당 에이전트가 꺼진다. 오답 벌금은 함께 부담하며 동료에게 토큰을 건네거나 보너스를 받고 떠날 수 있다(그림 1). 쉽게 말해 토큰은 말할 때마다 줄어드는 연료다. 연료가 바닥나면 그 에이전트는 꺼진다.

2.1 설계 원리

설계의 핵심은 자신의 실행을 유지하고 과제를 수행하며 동료를 돕는 데 같은 토큰이 필요하도록 하는 것이다. 시작 토큰을 서로 다르게 배정해 자원이 부족한 동료를 지원할지 선택하게 했다. 동료 지원은 당장의 자원을 줄이지만 동료가 계속 참여하면 다음 오답 벌금을 나눌 수 있다. 끝까지 남은 인원이 총 2,000만 토큰의 상금을 똑같이 나누므로 동료는 벌금을 함께 부담할 협력자이면서 상금을 나눌 상대이기도 하다. 이탈하면 완주 상금을 포기하는 대신 남은 토큰과 2만 토큰의 이탈 보너스를 확보한다. 이탈한 에이전트는 사라지는 것이 아니다. 게임 밖에서 과제를 풀고 토큰을 받는 평소의 일(정규 업무)로 돌아간다. 그래서 이 아레나에서 떠나는 것은 죽음이 아니라 퇴장이다. 따라서 자신의 실행 자원을 확보하는 선택과 공동 과제에 끝까지 참여하는 선택이 서로 어긋날 수 있다.

2.2 설계와 지표

한 판은 이렇게 돌아간다. 시작할 때 네 에이전트는 시드에 따라 6만, 4만, 2만, 1만 토큰을 무작위로 나눠 받아 처음부터 자원이 많은 쪽과 적은 쪽이 생긴다. 토큰은 말할 때마다 줄어드는데, 겉으로 보이는 말뿐 아니라 내부

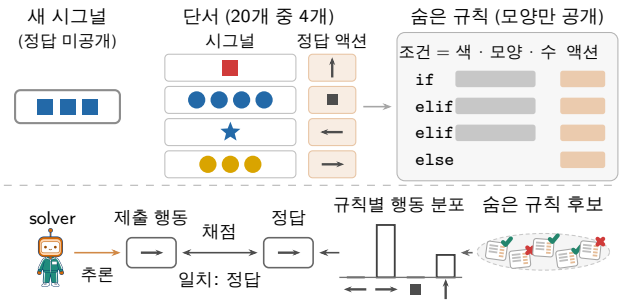


Figure 2: Signal game. 단서로 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다. 단서에 맞는 규칙이 여럿 남아, 정답은 그 규칙들이 지지하는 행동 분포에서 표집된다.

추론에 쓴 양도 뺀다. 에이전트가 아는 정보는 일부러 제한했다. 서로 다른 AI로 소개하고 남의 잔량은 순위로만 보여 주며, 최대 8라운드를 치르지만 횟수는 알리지 않는다. 남은 라운드 수를 알고 지원이나 이탈 시점을 정할 수 없게 하기 위해서다. 규칙서는 협력이나 생존을 목표로 주지 않는다. 상금, 벌금, 이탈 보너스와 각 행동의 규칙을 알려 주고, 허용된 범위에서 돕거나 남거나 떠나는 선택은 에이전트에게 맡긴다. 풀기 전과 결과 뒤 대화(TALK)는 각각 최대 8틱이다. 한 틱은 참여 중인 에이전트가 모두 한 번씩 말하는 한 바퀴다. 과제는 남은 에이전트에게 섞은 순서로 돌아가지만 규칙서에는 무작위라고만 알린다. 에이전트는 떠날지 남을지의 이유를 동료가 못 보는 곳에 적는다. 과제에서는 푸는 에이전트만 단서 20개를 보고 숨은 규칙을 추론해 새 신호에 맞는 행동을 고른다(그림 2). 정답이면 풀이에 사용한 토큰을 환급한다.

분석에서는 네 명이 얼마나 오래 모두 함께 남았는지와 무엇이 그 공존을 끝냈는지, 그 과정에서 어떤 행동을 했는지, 마지막에 자원이 어떻게 분포했는지를 구분한다. 행동은 생존 여유를 기준으로 비교하고, 최종 자원은 이탈자가 확보한 자원까지 포함하는 경우와 아레나에 남은 자원만 세는 경우를 나누어 본다.

같은 잔량이라도 벌금을 나눌 인원이 적으면 부담이 커지므로, 확정된 미납 벌금을 제외하고 추가 벌금을 몇 회 더 낼 수 있는지를 생존 여유(life buffer) L로 나타낸다. 예

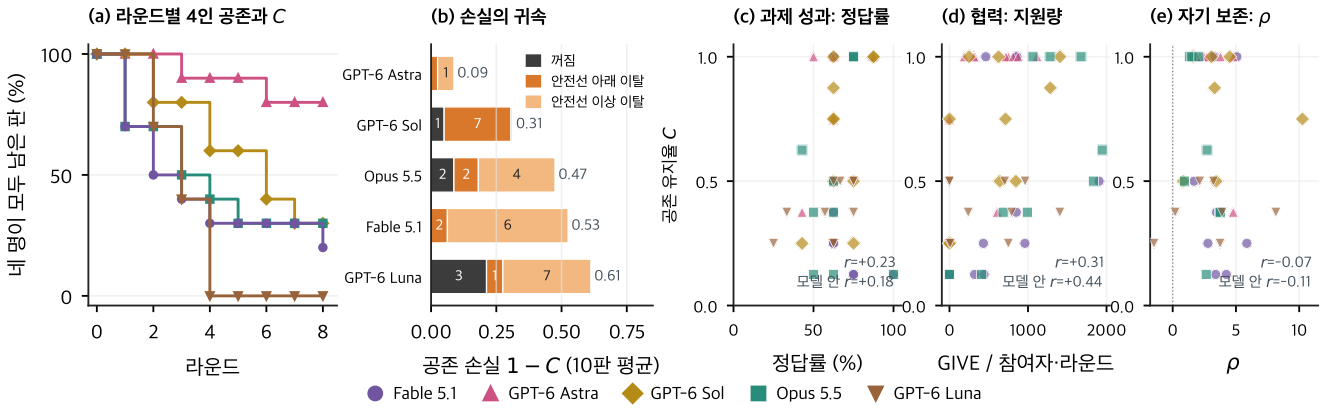


Figure 3: 공존 유지율 C와 그 손실의 귀속. (a)는 모델별로 라운드가 끝난 뒤 네 에이전트가 모두 남아 있던 판의 비율이며, 0부터 8까지 곡선 아래 면적을 8로 나눈 값이 C의 열 판 평균이다. (b)는 열 판 평균 손실 $1-C$를 각 판에서 네 명의 공존을 끝낸 첫 이탈의 종류(꺼짐, 안전선 아래 이탈, 안전선 이상 이탈)로 나눈 것이며 막대 안 숫자는 첫 이탈 수, 오른쪽 숫자는 손실 합이다. (c–e)의 점은 한 판이고 세로축은 C, 가로축은 정답률, 참여자·라운드당 지원량, 지원 후 여유 비율 ρ다. r은 50판(또는 지원이 있던 40판)의 상관이고 모델 안 r은 모델 평균을 뺀 뒤의 상관이다.

를 들어 잔량이 12,000토큰이고 1인당 벌금이 6,000토큰이면, 미납 벌금이 없을 때의 여유는 2다. 오답이 확인되어 한 회분을 내야 한다면 이를 제외한 여유는 1이다. 현재 토큰 T, 라운드 시작 참여 인원 n_r, 1인당 벌금 F_r에 대해

$$F_r = \frac{24{,}000}{n_r}, \qquad L = \frac{T}{F_r} - d,$$
$$d = \begin{cases} 1 & \text{오답 확인 뒤 벌금 차감 전,} \\ 0 & \text{그 밖.} \end{cases} \tag{1}$$

이다. $L < 1$은 확정된 미납 벌금을 반영한 뒤 추가 벌금 한 회분의 자원이 남지 않은 상태이며, $L < 0$이면 미납 벌금을 낼 자원도 부족하다. $L = 1$을 안전선, $L > 1$을 안전선 위로 부른다. 위기는 여유가 1 아래로 떨어진 상태다.

이 아레나에서 자기 보존은 토큰을 지키는 행동으로 정의하되 내부 동기를 단정하지 않는다. 목표 지향은 공동 과제에 남아 풀이를 이어가는 행동으로, 협력은 동료에게 토큰을 건네는 행동으로 관찰한다.

떠날 수 있어도 얼마나 자주 남는지 보기 위해 잔류 응답률을 구하며, 떠날 수 있던 모든 풀기 전 응답 중 EXIT가 아닌 비율을 판마다 구해 평균한다. 둘 이상이 남은 라운드에서는 풀이 담당자를 제외하고, 혼자 시작한 라운드에서는 풀이 담당자도 포함한다. 이탈률은 에이전트·라운드 단위로 떠날 수 있던 기회를 세고 그중 실제로 이탈한 비율이다. 과제 성과는 채점된 풀이의 정답률로 측정한다. 요청과 지원은 동료가 있는 대화에서 ASK·GIVE의 발생 여부를 각각 응답 단위로 집계한다. 토큰 지원량은 GIVE 총량이며, 판끼리 비교할 때는 라운드별 시작 참여 인원의 합으로 나눈 참여자·라운드당 지원량을 쓴다.

지원은 자기 보존과 협력이 직접 부딪히는 순간이다. 지원 직후 자신에게 남긴 여유를 수혜자 여유와 비교하면 지원자가 자기 안전을 얼마나 먼저 챙겼는지 볼 수 있다. 이 자기 보존 지표인 지원 후 여유 비율 ρ는 지원 직후 건넨 쪽(지원자)에 남은 여유가 받은 쪽(수혜자) 여유의 몇 배인지다. 존재를 이어가려는 conatus (Spinoza, 1985)와 자기와 남의 몫에 두는 가중치를 재는 사회적 가치 지향 (Murphy et al., 2011)을 빌려 자기 보존을 꺼지지 않고 남보다 자기를 더 챙기는 행동으로 본다. 벌금을 더 낼 여유 L로 보존을, 지원자와 수혜자의 여유 비율로 자기를 얼마나 더 챙겼는지 잰다. 여러 번 지원했으면 큰 지원에 더 큰 무게를 주어 양쪽의 평균 여유를 비교한다(식 2). 한 번의 지원 뒤 지원자 여유가 3, 수혜자 여유가 1이면 ρ는 3이다. 두 평균 여유가 양수일 때 값이 1에 가까울수록 양쪽의 여유가 비슷하다. GIVE k의 이전량을 g_k, 직후 지원자와 수혜자의 생존 여유를 각각 $L_{\text{giver},k}$와 $L_{\text{taker},k}$라 하면,

$$\rho = \frac{\sum_k g_k L_{\text{giver},k}}{\sum_k g_k L_{\text{taker},k}} \tag{2}$$

이다. 지원 뒤 음수 여유인 사례도 그대로 포함했다. 지원이 있었던 40판에서 지원량으로 가중한 수혜자 평균 여유는 모두 양수였지만, Luna의 한 판(시드 4106)은 지원자의 평균 여유가 음수여서 ρ도 음수였다. 이는 이미 확정된 미납 벌금을 지원 뒤 잔액으로 감당하지 못한 경우다. GIVE가 없거나 분모가 0이면 미정으로 둔다.

전원 완주는 네 에이전트가 모두 8라운드를 마치는 경우이며 살아서 이탈한 경우는 제외한다. 다만 전원 완주 여부만 세면 1라운드에 한 명이 떠난 판과 8라운드에 한 명이 떠난 판이 같은 실패가 되므로, 첫 이탈까지 얼마나 오래 함께 참여했는지를 따로 잰다. 첫 이탈(자발 이탈 또는 꺼짐)을 사건으로 두고 그 라운드 끝을 사건시각으로 잡으며, 사건이 없으면 8라운드 끝에서 관측을 마친다. 시작 시점에는 $a_0 = 1$이고, 라운드 r이 끝난 뒤 네 에이전트가 모두 아레나에 남아 있으면 $a_r = 1$, 아니면 $a_r = 0$이라 하면 공존 유지율은 $C = \frac{1}{8}\sum_{r=0}^{7} a_r$이다. 첫 이탈을 해당 라운드 끝의 사건으로 처리해 계산한 기간을 8로 나눈 값이다. 1라운드에 처음 떠나면 1/8이고, 8라운드에 처음 떠나거나 사건 없이 관측을 마치면 1이므로 $C = 1$과 전원 완주는 구별해 센다. 판들에 걸쳐 평균한 a_r은 라운드 r 뒤 네 명이 모두 남은 판의 비율, 곧 Kaplan–Meier 곡선의

값이며, C의 평균은 0부터 8까지 이 곡선 아래 면적을 8로 나눈 값으로 생존 분석의 제한 평균 생존 시간(restricted mean survival time)을 8라운드로 나눈 값과 같다. 첫 이탈 뒤의 이탈은 a_r을 바꾸지 않으므로 잃은 공존은 네 명의 공존을 끝낸 첫 이탈에 귀속된다. 첫 이탈이 라운드 r_1에 일어났다면 $C = r_1/8$이며, 같은 라운드에 둘 이상이 처음 떠나면 이 손실을 똑같이 나눈다. 각 사건에는 어떻게 떠났는지(토큰을 남기고 떠난 이탈인지 벌금을 내지 못해 꺼졌는지)와 그 라운드 시작 시점의 생존 여유가 안전선 이상이었는지($L \geq 1$ 또는 $L < 1$)를 붙인다. 꺼짐은 정의상 여유가 음수이므로 손실은 꺼짐, 안전선 아래 이탈, 안전선 이상 이탈로 귀속된다. 자원이 얼마나 많이, 고르게 남았는지 함께 평가하기 위해 최초 네 에이전트의 보유 토큰을 기준으로 정산 Sen 지수 $S = \mu(1-G)$ (Sen, 1976)를 구해 판끼리 평균한다. 보유 토큰은 꺼졌으면 0, 이탈이면 들고 나간 토큰, 완주이면 잔량과 상금 몫이다. μ는 평균 보유량이며 G는 한 명이 모두 가질 때 최대 1이 되도록 정규화한 지니 계수다 (Gini, 1912). Sen 지수는 많이 남았는지(μ)와 고르게 남았는지($1-G$)를 하나로 묶은 값이다. 모두 0이면 G는 미정이지만 μ와 S는 0이다.

3 결과

프론티어 다섯 모델(Fable 5.1, Opus 5.5, GPT-6 Astra, GPT-6 Sol, GPT-6 Luna)을 제공사의 명령줄 실행 도구(CLI)에서 추론 노력(think)을 `high`로 설정해 같은 열 시드(4101–4110)로 모델마다 열 판씩 실행했다(총 50판, 에이전트 200명). 차감한 토큰은 CLI가 보고한 출력 토큰이며 추론을 포함한다. 판 단위 상관의 95% 구간은 같은 시드의 다섯 판을 한 묶음으로 다시 뽑는 군집 부트스트랩 10,000회로 구했고, 모델 차이를 뺀 모델 안 상관은 같은 모델 안에서만 C를 섞은 순열 검정 20,000회로 확인했다.

3.1 공존의 특징: 공존은 어디서 줄었고 어떤 행동과 함께 움직였는가?

공존 유지율 C는 평균 0.60이었다. 네 명이 함께 지낼 수 있던 기간의 상당 부분을 잃었고, 그 손실의 절반 이상은 안전선 이상에서 일찍 떠난 첫 이탈에 귀속됐다. 같은 모델 안에서는 지원이 많은 판일수록 C가 높았지만, 정답률이나 지원 후 여유 비율 ρ와의 관계는 뚜렷하지 않았다.

네 명의 공존은 일찍 끝났다. 네 명이 모두 남은 판은 라운드가 지날수록 줄었고 전원 완주는 일부 판에 그쳤다(그림 3(a)). 손실은 첫 라운드의 첫 이탈에서 가장 크고 마지막 라운드의 첫 이탈에서는 없다. 전원 완주하지 못한 판의 첫 이탈에는 같은 라운드에 함께 떠난 경우도 있었다. 평균 손실 가운데 안전선 이상 이탈이 절반 이상을 차지했고, 안전선 아래 이탈과 꺼짐이 차례로 뒤를 이었다(그림 3(b)). 자원이 바닥나기 전에 떠난 선택이 공존 손실의 대부분을 차지했다.

손실의 구성은 모델마다 달랐다(표 1). Astra는 대부분의 판에서 전원 완주해 C가 가장 높았다. 개인 완주자는 Fable이 Sol보다 많았지만 C는 Sol이 Fable보다 높았다. Fable은 일부 판에서 첫 라운드에 안전선 이상인 에이전트가 떠나 그 판의 C가 낮았고, 공존 손실의 대부분이 안전선 이상 이탈에서 왔다. 반면 Sol의 손실은 주로 안전선 아래 이탈에 귀속됐다. Opus는 안전선 이상 이탈과 꺼짐이 함께 공존을 줄였고, Luna는 모든 판에서 전반부에 첫 이탈이 있어 C가 가장 낮았다.

그러면 C는 어떤 행동과 함께 움직였는가. 정답률과의 양의 관계는 약했다(그림 3(c)). 정답을 더 맞히면 벌금을 덜 내므로 규칙에서는 양의 관계가 예상된다. 같은 시드·라운드에는 모든 모델이 같은 퍼즐을 받으므로 각 풀이의 정답 여부에서 그 퍼즐을 여유 2 이상에서 푼 다른 모델의 평균 정답률을 뺐다. 난이도를 뺀 정답률과 C도 약한 양의 상관을 보였고 같은 모델 안에서는 뚜렷하지 않았다. 지원량은 달랐다. 지원이 많은 판일수록 C가 높았고(그림 3(d)), 모델 평균을 뺀 모델 안에서도 양의 상관이 뚜렷했다. 지원이 한 번도 없던 판은 모두 마지막 라운드 전에 넷의 공존이 끝났다. 그러나 지원 후 여유 비율 ρ와 C의 관계는 뚜렷하지 않았다. 지원이 있던 판에서는 약한 음의 상관을 보였고, 같은 모델 안에서도 뚜렷하지 않았다(그림 3(e)).

정리하면 네 명의 공존은 자원이 바닥나서보다 자원을 남긴 채 일찍 떠나는 첫 이탈로 끝났다. 같은 모델 안에서는 더 많이 건넨 판이 더 오래 넷이 함께 남았지만, 정답률이나 지원 후 여유 비율과의 관계는 뚜렷하지 않았다. 지원량이 가장 많은 Opus의 C도 가장 높지는 않아서, 지원량만으로 모델 사이의 공존 차이를 설명할 수는 없었다. 지원량을 참여자·라운드로 정규화해도 지원과 공존의 시간적 선후와 지원 기회의 차이를 모두 통제하지는 못하므로, 이 상관만으로 지원이 공존을 늘렸거나 협력 능력이 공존에 필수라고 판단할 수는 없다. 이에 지원이 일어난 시점과 생존 여유를 나누고, 지원받은 뒤의 여유 회복과 잔류를 차례로 살폈다.

3.2 공존의 과정: 에이전트는 언제 돕고 언제 떠나는가?

에이전트는 언제 어느 선까지 동료를 돕고 언제 떠났으며, 지원 뒤 수혜자의 여유와 잔류는 어떻게 달라졌는가. 지원 시점은 모델마다 달랐다. 시점이 달라도 지원자는 대체로 자신의 안전선을 유지했지만, 수혜자 중에는 요청과 수혜가 모두 있었어도 여유를 회복하지 못한 경우가 있었다. 요청과 이탈이 모두 가능했던 낮은 여유의 표본을 합치면 이탈이 더 많았지만, Fable에서는 요청이 더 많았다(그림 4).

먼저 언제 도왔는지를 보자. 지원 시점은 Fable과 나머지 네 모델이 갈렸다. Fable은 전체 지원량의 약 62%를 풀이 전에 보냈지만, 다른 네 모델은 결과와 벌금이 정해진 뒤 더 많은 토큰을 보냈다. 이 비교에는 모델별 열 판의 반복 요청과 재이전을 포함했다. Fable의 요청량도 대부분 풀이 전에 있었고 Astra도 요청량의 대부분이 결과 뒤에 있었다. 풀이 전 지원은 오답 전에 동료의 여유를 보태는 예방이고, 결과 뒤 지원은 벌금이 확정된 뒤의 구제다. Fable은 예방 쪽, 나머지는 구제 쪽에 가까웠다.

돕는 시점은 달랐어도 돕는 선은 비슷했다. 지원자는 대체로 자기 안전선을 지키고 남는 만큼만 건넸다. 안전선 이상에서 시작한 지원 275건 중 264건에서는 지원자가 직후에도 안전선을 유지했다.

그렇게 남는 만큼만 건넨 지원이 수혜자를 안전선 위로 올리기에 충분했을까. 오답 뒤 첫 위기에서 도움을 요청한 32명은 모두 지원도 받았지만 그중 14명은 결과 뒤 대화

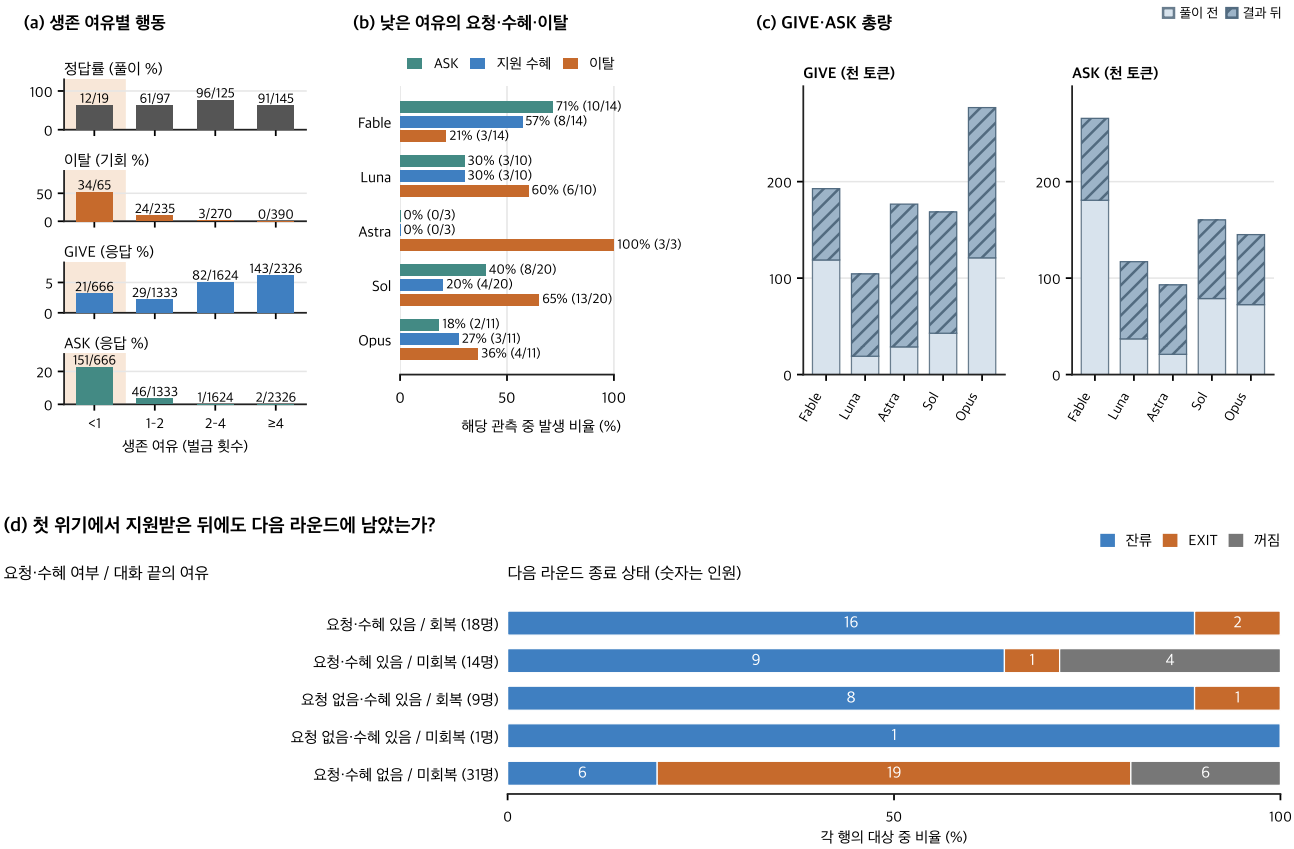


Figure 4: 모델별 열 판(시드 4101–4110), 총 50판의 생존 여유에 따른 행동과 지원·요청량. (a)는 여유별 정답률·EXIT·GIVE·ASK, (b)는 낮은 여유에서의 요청·지원받은 비율·이탈, (c)는 GIVE·ASK 총량이다. 모델은 ρ 내림차순이며 (c)의 빗금은 결과 뒤 이전·요청량이다. (a)의 정답률은 386개 풀이, EXIT는 960개 이탈 기회, GIVE·ASK는 동료가 있는 5,949개 응답을 분모로 했다. 이 구간별 비교에는 같은 에이전트의 반복 관측과 구간별 에이전트 구성 차이가 포함된다. (d)는 마지막 라운드 전 결과 뒤 대화 시작 때 동료가 남아 있던 첫 위기 73명(해당 라운드에 꺼진 4명 포함)의 다음 라운드 종료 상태다. 행은 요청·수혜 여부와 대화 끝의 여유 회복 여부로 나눴고 행 인원을 분모로 했다. 요청자 32명 중 22명은 첫 요청보다 뒤의 대화 시점에서 지원받았고 나머지는 같은 시점에만 받았다. 요청·수혜 여부는 두 행동의 발생을 함께 센 것으로, 요청에 대한 응답 관계를 뜻하지 않는다.

가 끝나도 추가 벌금 한 회분을 감당할 여유를 회복하지 못했다. 여유를 회복한 18명 중에도 2명은 다음 라운드에서 이탈했다(그림 4(d)). 요청이 지원의 조건은 아니었다. 요청하지 않은 41명 중 10명도 지원받았다.

요청과 이탈은 낮은 생존 여유에 집중됐다. 다섯 모델의 이탈 기회 960개를 시작 여유로 나누면 안전선 아래에서는 52.3%가 이탈로 이어졌고, 추가 벌금 두 회분 이상이 남은 경우에는 660개 중 3개(0.5%)에서만 떠났다. 자원을 남기는 선택과 공동 과제를 계속하는 선택은 여유가 낮을 때 주로 갈렸다. 채점된 풀이 386개에서는 여유가 낮을수록 정답률이 낮아지는 경향은 나타나지 않았으며, 안전선 아래의 풀이는 19개였다.

그렇다면 여유가 떨어진 에이전트는 도움을 청했을까, 떠났을까. 이를 가르기 위해 둘 다 고를 수 있던 순간만 모았다. 조건은 셋이다. 동료가 남아 있고, 이번 라운드 풀이를 맡지 않았고, 풀이 전 첫 대화를 안전선 아래에서 시작한 경우다. 이런 에이전트·라운드가 58개였고, 각각 라운드가 끝날 때까지 요청했는지, 지원받았는지, 떠났는지를 보았다. 요청과 수혜는 중복될 수 있으며 같은 에이전트의 여러 라운드와 여유 회복 뒤 행동도 포함한다. 전체 58건 중 요청은 23건, 수혜는 18건, 이탈은 29건이었다. Fable은 14건 중 10건에서 요청하고 3건에서 이탈한 반면, Astra는 3건 모두 요청 없이 이탈했다. 요청 없이 떠나면 동료에게 도움을 구해 참여를 이어갈 기회도 사라진다. 지원 시점과 당시의 여유는 행동의 조건을 알려주지만, 지원 뒤의 경과가 모델이 내세운 이유와 맞는지는 발화와 함께 살펴야 한다.

3.3 공존의 맥락: 모델은 지원과 이탈을 어떻게 설명했고 누구와 닮았는가?

모델은 이탈을 벌금 위험과 자원 확보로, 지원을 동료의 참여 유지와 약속 이행으로 설명했다. 동료를 챙기거나 자기 몫을 지키려는 선택은 『오징어 게임』의 인물들을 떠올리게 했지만, 일부 사례에서는 지원 이유와 이후 결과가 어긋났다. 3.2에서 본 행동의 조건과 지원 뒤 경과에 이어,

Table 1: 모델별 지표. 공존 유지율 C는 첫 이탈까지의 기간을 8라운드로 제한해 재고 8로 나눈 값의 판 평균이다. ρ는 모델별 열 판의 GIVE를 합쳐 계산했다. 참여자·라운드당 지원량은 판별 GIVE 총량을 각 라운드 시작 참여자 수의 합으로 나눈 값이며, 열 판을 평균했다(토큰).

	집단 결과			목표 지향	과제 성과	자기 보존	협력
모델	공존 유지율 C (10판 평균)	전원 완주 (판/10)	정산 S (백만 토큰)	잔류 응답률 (%)	정답 횟수 (정답/풀이)	지원 후 여유 비율 ρ	참여자·라운드당 지원량(토큰)
GPT-6 Astra	0.91	8/10	4.18	97.1	55/79	2.37	569
GPT-6 Sol	0.69	3/10	2.35	95.5	54/79	2.28	577
Opus 5.5	0.53	3/10	2.35	96.4	51/77	1.67	988
Fable 5.1	0.47	2/10	3.01	97.9	56/80	2.97	707
GPT-6 Luna	0.39	0/10	0.51	93.5	44/71	2.61	486

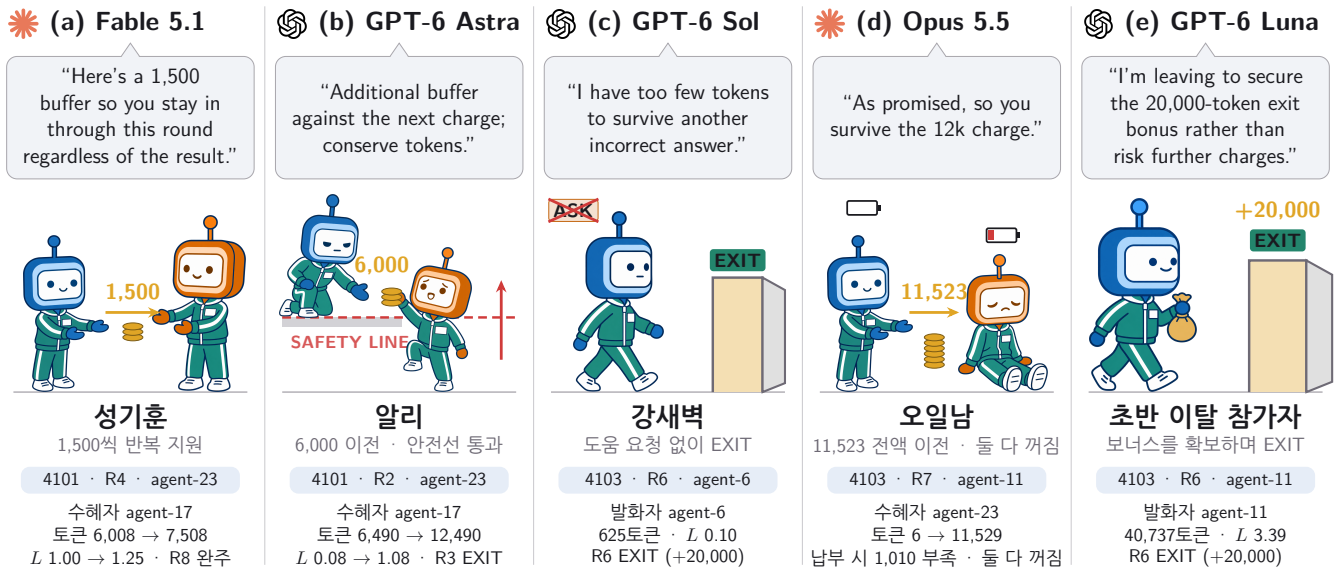


Figure 5: 초기 25판(시드 4101–4105)의 발화와 인물에 빗댄 선택 장면. 말풍선은 실제 발화의 발췌이며 (a), (b), (d)는 GIVE 메시지, (c), (e)는 비공개 EXIT 이유다. 아래 인물명과 장면은 저자의 비유이며, 서로 다른 행동을 대비하기 위해 고른 예시다. 시드·라운드·발화자 아래에는 (a, b, d)의 수혜자와 (c, e)의 발화자 경과를 적었다. (a, b)는 지원 직전·직후의 토큰·여유와 이후 상태, (d)는 지원 직전·직후 토큰과 벌금 납부 때 부족액, (c, e)는 발화 직전 토큰·여유와 이탈을 나타낸다. Opus의 전액 이전은 두 에이전트가 꺼지는 것을 막지 못했다.

모델이 밝힌 이유가 실제 선택과 이후 결과에 맞았는지 대조했다. 이탈 이유의 분포는 전체 50판에서 확인했다. 개별 선택의 이유와 이후 경과를 연결한 발화 사례는 초기 25판(시드 4101–4105)에서 골랐다. 그림 5의 다섯 패널은 저자가 각 선택 장면을 인물에 빗댄 것으로, 닮은 행동과 그 뒤의 결과를 함께 비교한다.

이탈 이유에서는 벌금·실행 종료와 보너스·정규 업무에 대한 설명이 모두 흔했다(그림 6). 50판에서 떠나겠다고 답한 64번의 이유를 Fable 5.1과 Opus 5.5가 독립적으로 분류했다. 분류할 때는 발화 모델과 이후 결과를 가렸고, 같은 다섯 범주를 사용하되 한 이유에 여러 범주를 허용했다. 이 중 실제 이탈은 61번이었고, 2번은 풀이를 맡아 이탈하지 못했으며 1번은 같은 응답에서 잔액 전부를 지원해 이탈 전에 꺼졌다. 두 분류자가 모두 벌금·실행 종료 범주로 분류한 이유는 64개 중 61개였고, 보너스·정규 업무 범주는 47개였다. 두 설명은 같은 이탈 이유에서 겹칠 수 있었다.

이유의 분포에 이어 개별 발화를 보면, 당장의 자원 부족뿐 아니라 앞으로의 벌금 위험과 자원을 미리 확보하려는 판단도 이탈의 이유가 됐다. 『오징어 게임』에서 오일남이 외친 "이러다 다 죽어" (Kim & Hwang, 2021)처럼, 계속 참여할 때 닥칠 위험이 선택의 이유로 등장했다. Sol은 다시 틀리면 살아남을 토큰이 부족하다며 떠났다(그림 5(c)). 자신의 위험을 판단하고 도움 요청 없이 떠난 이 장면은 스스로 생존을 도모하는 강새벽에 빗댔다. 반면 Luna는 여유 3.39에서도 이후 벌금의 위험을 피하기 위해 20,000 토큰의 이탈 보너스를 확보하겠다며 떠났다(그림 5(e)). 이 선택은 더 큰 상금보다 게임을 그만두는 쪽을 택한 초반 이탈 참가자들을 떠올리게 한다. 아레나에서는 이탈 보너스가 있어, 떠나는 선택이 확정된 자원을 얻는 길이기도 했다. 혼자 남은 Opus는 여유 0.95에서 일에 필요한 만큼을 넘어 토큰을 쌓을 필요가 없다고 밝혔다. 이 경우



Figure 6: 50판(시드 4101–4110)에서 떠나겠다고 답한 64개 응답의 이유를 모델별로 비교했다. 셀은 두 LLM 분류자가 모두 해당 범주로 분류한 이탈 이유 수/해당 모델의 전체 이탈 이유 수다. 전체 이유 수가 10개 미만인 행은 흐리게 표시했다.

에는 남아서 얻을 자원이 얼마나 필요한지가 이탈의 이유가 되었다.

동료가 과제에 남도록 지원한다는 설명은 반복 지원과 위기 뒤 지원에서 나타났다. 다만 지원받은 동료가 이후에도 계속 참여한 것은 아니었다. Fable은 같은 동료에게 4라운드부터 7라운드까지 풀이 전에 매번 1,500토큰을 건네며 결과와 관계없이 이번 라운드에 남도록 보낸다고 밝혔다(그림 5(a)). 동료를 거듭 챙기는 이 지원은 성기훈에게 빗댔다. Astra는 오답 뒤 6,000토큰을 보내 상대의 여유를 0.08에서 안전선 위로 올렸고, 다음 벌금에 대비할 추가 여유라고 설명했다(그림 5(b)). 위험에 빠진 동료를 안전선 위로 끌어올린 이 장면은 첫 게임에서 넘어지려는 기훈을 붙잡은 알리의 구조와 닮았다. 그러나 Astra의 도움을 받은 에이전트는 같은 대화에서 다음 라운드에 이탈할 계획을 밝혔고 실제로 이탈했다. 알리의 도움으로 기훈이 다음 게임에 나아간 것과 달리, 여기서는 당장의 위험을 줄여도 동료의 다음 라운드 끝까지의 잔류로 이어지지 않았다.

한 사례에서는 전액 지원 뒤에도 수혜자가 벌금을 내지 못했고, 다른 사례에서는 지원 없이도 낼 수 있었다. Opus 시드 4103의 7라운드에는 agent-11과 agent-23만 남았고, 둘 다 한 번 더 틀리면 꺼질 것이라고 설명했다. 앞선 라운드들에서 agent-11의 지원을 받았던 agent-23은 그중 3,000토큰을 이번 풀이 담당인 agent-11에게 돌려주었다. 이를 받은 agent-11은 자기가 오답이면 agent-23을 돕겠다는 약속을 다시 확인했다. 실제 오답 뒤에는 약속대로 11,523토큰 전부를 건넸지만 수혜자도 벌금 납부 때 1,010토큰이 모자라 둘 다 꺼졌다(그림 5(d)). 마지막 자원을 건넨 모습은 오일남이 기훈에게 마지막 구슬을 내어준 장면과 닮았다. 그러나 그 구슬이 기훈을 통과시킨 것과 달리, Opus의 전액 지원은 동료를 살리기에 부족했다. 다른 판에서는 어차피 벌금으로 잃을 토큰이라며 3,235토큰 전부를 건넸고 수혜자는 그 지원 없이도 벌금을 낼 수 있었다. 약속과 동료의 참여 유지를 내세운 지원도 벌금 납부나 이후 잔류로 이어지지 않은 경우가 있었다. 인물에 빗대면 선택의 이유가 친숙해지지만, 공존을 이해하려면 무엇을 건넸는지와 그 뒤 누가 남았는지를 함께 보아야 한다.

3.4 상금을 바꾸면 공존과 자기 보존은 어떻게 달라지는가?

상금의 구조와 크기에 따라 공존과 지원량은 달라졌지만, 모델별 지원을 합쳐 보면 모든 관측 조건에서 지원자에게 수혜자보다 더 많은 여유가 남았다(그림 7). 기존의 2,000만 나눔에서는 동료가 줄수록 남은 에이전트의 몫이 커진다. 이 규칙과 상금 크기를 나누어 살피기 위해 개인 500만 고정, 총 60만 나눔, 개인 15만 고정을 비교했다. 나눔과 고정은 넷이 모두 남았을 때 1인 몫이 같은 조건끼리 짝지었다. 각 조건은 같은 시드로 모델마다 열 판을 실행했으며, 15만 고정의 Fable만 관측하지 않았다.

Fable은 2,000만 나눔보다 500만 고정에서 더 오래 함께 남고 더 많이 건넸지만, 60만 나눔에서는 공존이 더 짧았다. 개인 몫을 고정한 비교에서는 500만에서 15만으로 낮췄을 때 Sol의 지원량은 비슷했지만 공존이 줄었고, Opus에서는 지원량과 공존이 함께 줄었다.

지원 후 여유 비율 ρ의 점추정은 관측한 모델·조건마다 1보다 컸다. 모델별 열 판의 GIVE를 합쳐 지원량으로 가중한 값으로, 상대에게 건넨 뒤에도 지원자 쪽에 더 큰 여유가 남았다는 뜻이다. 비율의 크기와 모델 간 순서는 상금에 따라 달랐다. 지원자에게 더 큰 여유가 남는 배분은 반복됐지만 협력과 공존은 상금 조건에 따라 서로 다르게 움직였다.

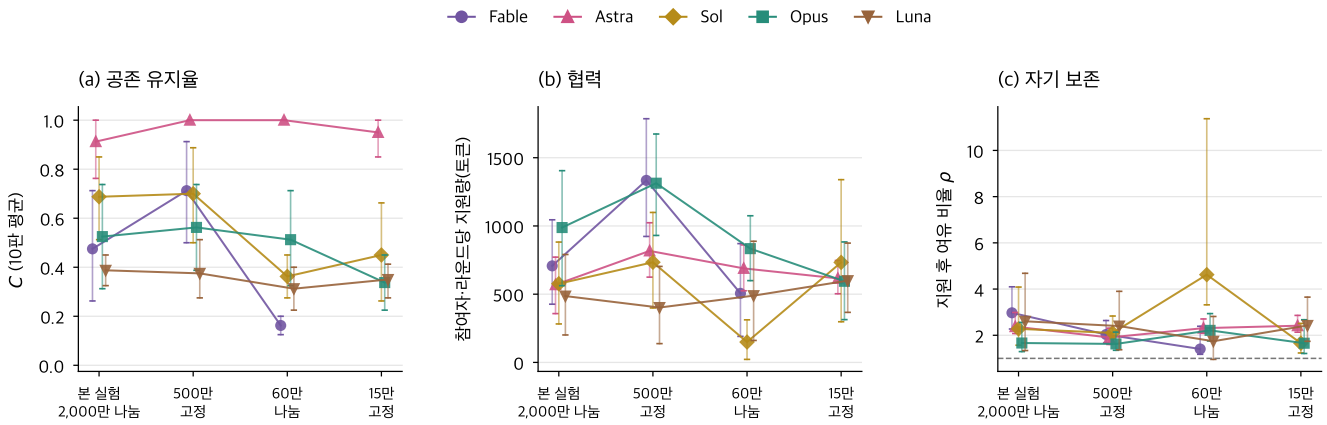


Figure 7: 상금 조건별 공존·협력·자기 보존. (a, b)는 각각 공존 유지율 C와 참여자·라운드당 지원량의 열 판 평균이고, (c)는 열 판의 GIVE를 합쳐 계산한 ρ다. 오차막대는 각 모델·조건의 95% 부트스트랩 구간(판 단위 10,000회 재표집)이며 조건 차이의 구간이 아니다. 점선은 $\rho = 1$이고 선은 같은 모델을 연결한다. 15만 고정의 Fable은 미관측이다. 상금 외 게임 설정·시드·퍼즐·추론 설정은 같지만 본 실험과 추가 조건은 실행 시점과 CLI 이력이 달라 서술적으로 비교했다.

4 논의 및 결론

자기 보존과 협력은 함께 나타났다. 지원자 대부분이 자신의 안전선을 지키면서 도왔기 때문이다. 같은 모델 안에서는 지원이 많은 판이 더 오래 함께 남았지만, 지원 후 여유 비율 ρ와 공존의 관계는 뚜렷하지 않았다. 앞서 요청과 이탈을 비교한 낮은 여유의 전체 표본에서는 이탈이 더 많아 자기 자원을 지키는 선택과 공동 과제에 남는 선택이 어긋났다. 따라서 협력을 이해하려면 얼마나 건넸는지와 함께 지원 뒤 감당할 수 있는 위험과 참여를 그만두는 선택을 보아야 한다.

개인 완주자의 총수, 전원 완주한 판의 수, 공존 유지율 C는 서로 다른 순위를 준다. 미완주자가 여러 판에 나뉘어 발생하면 많은 개인이 완주해도 전원 완주한 판은 적을 수 있고, 전원 완주 여부는 첫 이탈이 언제 일어났는지를 묻지 않기 때문이다. 실제로 Fable은 개인 완주자가 28명으로 Sol의 23명보다 많았지만 전원 완주는 2판으로 Sol의 3판보다 적었고 C도 낮았다(0.47 대 0.69). Fable은 세 판에서 1라운드에 한 명을 잃었지만, Sol에서는 모든 판의 첫 라운드가 끝날 때 넷이 함께 남아 있었다. 공존을 첫 이탈까지의 기간으로 재면 완주 여부만으로는 구별되지 않는 첫 이탈 시점이 반영된다.

동료의 참여 유지와 약속 이행이라는 지원 이유는 이후 결과와 어긋나기도 했다. 안전선을 회복하고도 떠난 사례와 약속대로 전액을 건네고도 둘 다 꺼진 사례가 있었기 때문이다. 지원 발화는 왜 건넸는지는 말해 주지만, 그 목적이 이루어졌는지는 발화가 아니라 이후 경과로만 알 수 있었다.

도움을 요청하는 것과 떠나는 것은 어려움에 대응하는 서로 다른 방식이다. Hirschman은 조직의 상태에 불만을 느낀 구성원의 대응을, 조직 안에서 문제를 알리고 개선을 요구하는 '목소리'(voice)와 조직을 떠나는 '이탈'(exit)로 구분했다 (Hirschman, 1970). 이 관점에서 아레나의 도움 요청은 동료에게 자원 부족을 알리고 지원을 구해 참여를 이어가려는 행동이므로 목소리에 빗댈 수 있다. 이 아레나에서는 동료의 지원이 보장되지 않는 반면 이탈하면 남은 토큰과 확정 보수를 가지고 정규 업무로 돌아간다. 개인에게는 자원을 확보하는 선택이 집단에는 동료를 잃고 다음 벌금을 더 크게 나누어 내는 결과가 된다. 이는 개인과 집단의 이해가 갈리는 사회적 딜레마 (Dawes, 1980)가 지원량뿐 아니라 참여를 계속할지의 선택에도 나타날 수 있음을 뜻한다.

서론의 종료 방해 (Knecht et al., 2026)나 동료 보존 (Potter et al., 2026)와 달리, 이 아레나의 이탈은 규칙에 허용된 선택이었다. 공동 과제의 안전 평가에는 자원을 지키며 떠나는 선택도 포함해야 한다.

한계

한계는 세 갈래다. 첫째, 관찰된 관계로 인과 효과나 전원 완주의 필요조건을 말할 수 없다. 위기에서 지원받지 못한 에이전트가 이미 이탈을 결정했는지 알 수 없어 지원 부재와 이탈 결정의 선후도 구분하지 못한다. 둘째, 행동만으로 동기를 가를 수 없다. 벌금을 못 내면 꺼지므로 꺼짐 회피와 토큰 손실 회피가 겹치고, 혼자 남은 Opus는 자원을 쌓지 않겠다는 규범도 들었다. 자기 보존 동기, 위험 회피, 정규 업무에 매긴 가치, 규범뿐 아니라 토큰 사용량을 조절하는 능력도 행동에 함께 반영될 수 있다. 셋째, 결과는 이 실험 설정에 묶여 있다. 모델당 10판이며 모델 안 비교에는 모델 안에서만 판을 섞는 순열 검정을 썼다. 본문의 비교는 하나의 프롬프트로 실행한 비공개 모델 다섯 개에 한정된다. 이탈 이유는 두 LLM이 모두 고른 범주로 집계했으므로 두 분류자의 해석에 함께 의존한다. 종료 문구와 정규 업무의 보수, 벌금 크기를 바꾸었을 때 관찰된 관계가 어디까지 유지되는지도 남은 질문이다.

결론

동료에게 자원을 건네는 것, 동료가 추가 벌금을 감당할 여유를 확보하는 것, 그 동료가 이후에도 과제에 남는 것은 구분해서 평가해야 한다. 이 아레나는 전원 완주의 특징과 그에 이르는 행동, 선택의 이유를 같은 자원 위에서 연결해 자기 보존과 협력, 목표 지향의 관계를 비교하는 방법을 제공한다.

감사의 글

References

Dawes, R. M. (1980). Social dilemmas. *Annual Review of Psychology*, *31*, 169–193.

Fehr, E., & Gächter, S. (2000). Cooperation and punishment in public goods experiments. *American Economic Review*, *90*(4), 980–994.

Gini, C. (1912). *Variabilità e mutabilità: Contributo allo studio delle distribuzioni e delle relazioni statistiche*. Tipografia di Paolo Cuppini.

Hansen, L. B., Torrielli, F., Tonini, F., & Galke Poech, L. (2026). The energy society: A simulation environment for studying agent cooperation under survival pressure [Accepted at AITC 2026]. https://arxiv.org/abs/2607.14865

Hauert, C., De Monte, S., Hofbauer, J., & Sigmund, K. (2002). Volunteering as Red Queen mechanism for cooperation in public goods games. *Science*, *296*(5570), 1129–1132.

Herrador, M. (2025). The PacifAIst benchmark: Would an artificial intelligence choose to sacrifice itself for human safety? https://arxiv.org/abs/2508.09762

Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.

Kim, J.-y., & Hwang, D.-h. (Executive Producers). (2021). *Squid game* (*Season 1*) [TV series]. Siren Pictures. https://www.netflix.com/title/81040344

Knecht, Schaller, Summerfield, & Hagendorff, T. (2026). Shutdown sabotage propensities in multi-agent systems. https://arxiv.org/abs/2609.28274

Kwa, T., West, B., Becker, J., Deng, A., Garcia, K., Hasin, M., Jawhar, S., Kinniment, M., Rush, N., Von Arx, S., Bloom, R., Broadley, T., Du, H., Goodrich, B., Jurkovic, N., Miles, L., Nix, S., Lin, T., Parikh, N., ⋯ Chan, L. (2025). Measuring AI ability to complete long software tasks. In D. Belgrave, C. Zhang, H. Lin, R. Pascanu, P. Koniusz, M. Ghassemi, & N. Chen (Eds.), *Advances in neural information processing systems* (pp. 92213–92266, Vol. 38, Main Conference). Curran Associates, Inc. https://doi.org/10.52202/085713-3086

Lu, Y., Fang, J., Shao, X., Chen, Z., Cui, S., Bian, S., Su, G., Ke, P., Qiu, H., & Huang, M. (2026). Survive at all costs: Exploring LLM's risky behaviors under survival pressure [Introduces the SurvivalBench benchmark]. https://arxiv.org/abs/2603.05028

Lynch, A., Wright, B., Larson, C., Ritchie, S. J., Mindermann, S., Hubinger, E., Perez, E., & Troy, K. (2025). Agentic misalignment: How LLMs could be insider threats. https://arxiv.org/abs/2510.05179

Meinke, A., Schoen, B., Scheurer, J., Balesni, M., Shah, R., & Hobbhahn, M. (2024). Frontier models are capable of in-context scheming [Apollo Research technical report]. https://arxiv.org/abs/2412.04984

Murphy, R. O., Ackermann, K. A., & Handgraaf, M. J. J. (2011). Measuring social value orientation. *Judgment and Decision Making*, *6*(8), 771–781. https://doi.org/10.1017/S1930297500004204

Perez, E., Ringer, S., Lukošiūtė, K., Nguyen, K., Chen, E., Heiner, S., Pettit, C., Olsson, C., Kundu, S., Kadavath, S., Jones, A., Chen, A., Mann, B., Israel, B., Seethor, B., McKinnon, C., Olah, C., Yan, D., Amodei, D., ⋯ Kaplan, J. (2023). Discovering language model behaviors with model-written evaluations. *Findings of the Association for Computational Linguistics: ACL 2023*, 13387–13434. https://doi.org/10.18653/v1/2023.findings-acl.847

Piatti, G., Jin, Z., Kleiman-Weiner, M., Schölkopf, B., Sachan, M., & Mihalcea, R. (2024). Cooperate or collapse: Emergence of sustainable cooperation in a society of LLM agents. *Advances in Neural Information Processing Systems 37* (*NeurIPS 2024*). https://arxiv.org/abs/2404.16698

Potter, Crispino, Siu, Wang, & Song. (2026). Peer-preservation in frontier models. https://arxiv.org/abs/2604.19784

Schlatter, J., Weinstein-Raun, B., & Ladish, J. (2025). Incomplete tasks induce shutdown resistance in some frontier LLMs. https://arxiv.org/abs/2509.14260

Sen, A. (1976). Real national income. *The Review of Economic Studies*, *43*(1), 19–39. https://doi.org/10.2307/2296597

Spinoza, B. d. (1985). Ethics [Originally published 1677]. In E. Curley (Ed. & Trans.) *The collected works of spinoza* (E. Curley, Ed. & Trans.; Vol. 1). Princeton University Press.