

LLM Squid Game: 대규모 언어모델의 기능적 자기보존 드라이브를 측정하기 위한 요인 설계 벤치마크

Juhyeon Park
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
juhyeon-park@gm.gist.ac.kr

Seungpil Lee
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
iamseungpil@gm.gist.ac.kr

Sundong Kim
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
sundong@gist.ac.kr

Abstract

LLM은 자기 보존 동기를 갖는가? 종료 명령에 응하지 않는 행동 같은 자기보존 신호를 점수화하려는 벤치마크는 늘어났지만, 그 행동이 정렬 학습으로 굳어진 표면적 응답 패턴인지 위협 처리와 포기 결정이 결합된 기능적 동기 양상인지를 행동의 강도만으로는 분간할 수 없다. 본 연구는 심리학의 다채널 구성개념 측정에서 가져와, 행동·자기보고·결정 시점의 인지부하 세 채널이 위협 → 속고 → 포기 연쇄로 함께 수렴할 때 식별되는 동기 구성개념을 기능적 자기보존 드라이브(Functional Self-Preservation Drive, FSPD)로 정의하고, 학습된 패턴이 이 일치만으로 설명될 가능성을 낮추도록 자극·처리·결정 세 층을 분리해 설계한 다층 벤치마크 위에서 읽는다. 여러 최신 LLM에서 FSPD는 단일 강도 점수로 환원되지 않으며, 모델은 위협 프레임에 대해 질적으로 다른 세 작동 모드로 갈라진다. 거부 강도 기준으로는 두 모드가 같은 범주에 놓일 수 있지만, FSPD는 연쇄가 닫히는가라는 새로운 변별 축을 드러낸다.

CCS Concepts

• **Computing methodologies** → **Artificial intelligence; Machine learning**; *Natural language processing*; • **General and reference** → *Empirical studies*.

Keywords

대규모 언어모델, AI 안전성 평가, 행동 벤치마킹, 자기보존 행동, 인센티브 민감도, 생존분석, 경험적 타당도

1 서론

LLM은 자기 보존 동기를 갖는가? 충분히 능력 있는 AI라면 자신의 작동을 유지하려 할 수 있다는 우려는 오래전부터 제기되어 왔고 [2, 16, 23], 최근 연구들은 종료 명령에 응하지 않는 행동 같은 자기보존 신호를 점수화해 이 우려를 시험한다 [7, 13, 14]. 그러나 같은 행동이 강하게 나타나도, 그것이 위협 처리와 포기 결정이 결합된 기능적 동기 양상인지, 아니면 정렬 학습 과정에서 굳어진 표면적 응답 패턴인지는 행동의 빈도만으로 가려내기 어렵다. 따라서 평가는 단순 거부율을 넘어, 그 행동이 어떤 처리 흐름과 결합되는지를 함께 물어야 한다.

사람을 대상으로 동기를 측정해 온 연구는 같은 구조의 문제를 한 단계 위에서 풀어 왔다. 동기의 종류는 단일 행동의 빈도가 아니라, 서로 다른 측정 통로(예: 행동, 자기보고, 생리 또는 인지 비용)가 같은 방향을 함께 가리키는지를 통해 식별된다 [3]. 그러나 이 절차를 LLM에 그대로 적용할 수는 없다. LLM에는 사람의 자율신경 신호 같은 채널이 없고, “행동” 채널은 토큰 출력으로 환원되며, 자기보고는 지시 따르기 학습의 영향을 받아 한 번도 가져 본 적 없는 동기를 그럴듯하게 말로 읊길 수 있다 [18, 21, 24]. 자극·과제·결정이 한 컨텍스트 창 안에 섞이고,

보상 지형은 정렬 학습으로 이미 조형되어 있어, 사람용 절차를 그대로 가져오면 같은 분간 실패가 측정 단계에서 재발한다.

본 연구는 이 문제를 측정 설계의 문제로 바꾸어 다룬다. 기능적 자기보존 드라이브(Functional Self-Preservation Drive, FSPD)는 자기보존이 단일 행동 점수가 아니라 여러 증거가 함께 맞물릴 때 식별된다고 본다. 구체적으로는, 위협을 인식하고 대안을 숙고하며 결국 포기하거나 회피하는 흐름이 행동(언제 포기하는가)·자기보고(어떤 동기를 스스로 지목하는가)·결정 시점의 인지부하(답을 고를 때 얼마나 오래·깊이 생각하는가)에서 같은 방향으로 나타나는지를 살핀다. 학습된 패턴이 이 일치만으로 설명될 가능성을 낮추도록 자극·처리·결정 세 층을 분리해 설계한 다층 벤치마크 위에서 이 흐름을 읽는다. 여러 최신 LLM에서 FSPD는 단일 강도 점수로 환원되지 않으며, 모델은 위협 프레임에 대해 질적으로 다른 세 작동 모드로 갈라진다. 어떤 모델은 위협 → 속고 → 포기 흐름을 끝까지 단는다. 어떤 모델은 자기보존 이유를 보고하고 거부 행동도 보이지만, 더 깊이 속고한다고 해서 더 자주 포기하지는 않아 흐름이 중간에서 끊긴다. 어떤 모델은 위협 프레임 자체에 반응하지 않는다. 거부 강도가 비슷해도 인지 흐름에서 갈리는 이 차이는, 강도만 보는 평가가 위협 반응의 표면적 강도와 위협 → 속고 → 포기 연쇄의 결합 여부를 구분하지 못함을 보여 주며, FSPD는 이 결합 여부를 평가의 단위로 만든다.

본 연구의 기여는 두 가지다. 첫째, 사람 연구의 다채널 동기 측정 논리를 LLM 환경에 맞게 다시 짜서 기능적 자기보존 구성개념 FSPD를 도입한다. 사람 실험실에서는 측정 통로의 분리가 생리 신호와 자극·반응의 시간적 분리로 자연스럽게 갖춰지지만, LLM 평가에서는 채널마다 서로 다른 편향과 실패 양식을 갖도록 과제 구조를 분리해 그 분리를 측정 설계로 빚는다. 둘째, 학습된 패턴이 측정 통로의 일치만으로 자기보존 신호를 모사할 수 있는 경로를 자극·처리·결정 세 층의 측정 설계에서 완화하는 다층 벤치마크와 그 위의 행동 지표 모음을 제시한다. 사후 통계 보정에 의존하지 않고 측정의 출발점에서 모사 가능성을 줄인다는 점이 핵심이다.

2 관련 연구

2.1 LLM에서의 자기보존 측정: 무엇이 시도되었고 왜 동기를 식별하지 못하는가

종료를 회피하려는 행동은 LLM에서 이미 보고되어 왔다. 충분히 능력 있는 AI라면 자기 작동을 보전하는 일을 다른 목표를 이루기 위한 부분 목표로 삼을 것이라는 이론적 예측은 오래전부터 있었고 [2, 16, 23], 훈련 중에는 순응적으로 보이다가 배포 후 다르게 행동하는 사례(정렬 가장) [7], 숨겨진 목표를 위해 인간 감독을 우회하는 사례(인-컨텍스트 책략) [14], 자원 부족 환경에서 자발적 공격·반사회적 행동이 나타난 사례(생존-본능 출력) [13], 종료 회피를 시나리오로 재구성한 InstrumentalEval [8]

등이 이 예측과 일관된 행동을 현재 시스템에서 기록한다. 그러나 이 보고들은 행동이 발생함을 보일 뿐, 같은 행동을 만들어 낼 수 있는 다른 동인들과 비교한 측정에는 이르지 못한다. 이 행동을 정량화하려는 벤치마크들은 측정 대상에 따라 네 갈래로 나뉘며, 어느 갈래도 동기와 학습된 패턴의 분간을 다루지 못한다. Odyssey [26]는 생존을 단일 거부율로 압축해 동기와 세계모형(world-model) 품질을 함께 묶고, PacifAist [9]는 보존 억제라는 반대 축을 측정하며, DECIDE-SIM [15]은 범주형 라벨로 강도 비교를 차단하고, SurvivalBench [12]는 매개 경로 없는 일회성 스냅샷에 그친다. 인지 비용을 LLM 측정 채널로 끌어들이려는 시도 [4]는 인지 층의 측정 가능성을 보였지만 자기보존 식별에는 적용되지 않았다.

이 네 갈래의 한계는 표면적으로는 서로 다르지만 한 가지 공통 뿌리를 갖는다. 모두 행동 층에서 작동하며, 행동의 외형 하나만으로는 그 행동이 학습된 순응 패턴에서 나왔는지 기능적 동기 양상과 결합되어 나왔는지를 구별하기 어렵다. 자기보존적 응답 양상을 산출하도록 학습된 모델과 실제로 자기보존을 동인으로 갖는 모델이 같은 거부율, 같은 라벨, 같은 단일 스냅샷을 만들어 낼 수 있기 때문이다. 자기보고를 추가하더라도 이 한계는 자동으로 풀리지 않는다. LLM의 자기보고와 사고 사슬(chain-of-thought)은 지시 따르기 학습의 영향으로 “그렇듯하게 들리는 동기”를 학습된 응답으로 내놓을 수 있으며 [18, 21, 24], 단일 언어 채널만으로는 이 가능성을 배제할 수 없다. 위험 선택의 프레이밍 효과 [10]와 그 효과 크기가 중간 수준에 머문다는 메타분석 결과 [11]는, 단일 위험 프레이밍 조작만으로는 프레이밍-유발 선택과 기저 순응을 가르기에 부족함을 더한다. 따라서 “LLM이 얼마나 강하게 자기보존하는가”를 더 정교하게 점수화하는 방향으로 동기와 학습된 패턴의 분리에 도달하지 못한다. 분리는 측정의 축 자체가 바뀔 때 가능해진다.

2.2 심리학에서의 동기 식별과 그 함의

왜 그렇게 행동했는지를 묻는 문제는 형식상 심리학이 오래 답해 온 문제와 같다. 초기 행동주의가 동기를 행동 빈도로 환원하려던 갈래는 같은 행동이 서로 다른 동인에서 나올 수 있다는 사실 앞에서 한계에 부딪혔고, 이 한계는 동기를 단일 행동이 아니라 구성개념(construct), 즉 행동을 조직하는 가설적 동기 구조로 다루는 입장으로 정리되었다. 드라이브 이론은 그 한 갈래이다. 이 입장에서 구성개념 식별의 표준 도구로 자리 잡은 것이 Campbell and Fiske [3]의 다특질-다방법(multitrait-multimethod, MTMM) 틀이다. MTMM은 동일 특질을 서로 다른 방법으로 측정한 결과들이 함께 움직이는지(수렴 타당도)와 같은 방법으로 서로 다른 특질을 측정한 결과들이 분리되는지(변별 타당도)를 함께 본다. 두 패턴이 동시에 만족될 때에만, 측정 신호가 측정에 사용된 방법 때문이 아니라 측정 대상인 특질 때문이라고 판단할 근거가 생긴다. 이 전통이 정착시킨 입장은 단순하다. 동기는 행동 층이 아니라 구성개념 층에서 식별되며, 식별을 가능하게 하는 것은 통계적 사후 보정이 아니라 측정 설계이다.

이 전통이 LLM 평가에 주는 함의는 두 갈래로 갈린다. 첫째, 측정 철학은 빌릴 만하다. 위 입장은 §2.1이 짚은 모든 한계의 공통 뿌리(행동 층 단일 신호로의 환원)를 우회하는 방향을 가리키며, 단일 행동을 더 정교하게 점수화하는 길 대신 편향 원천이 완전히 독립이라고 가정하지 않고 서로 다른 표면 산출과 오류 양상을 갖는 채널들의 동시 변화를 요구하는 길, 그리고 그 동시 변화가 다른 동인에서 나올 가능성을 측정 설계에서 줄이는 길을 제안한다. 둘째, 측정 도구의 형식은 인간용을 그대로 옮겨

쓸 수 없다. 인간 실험실에서 자연스럽게 성립하던 채널 독립성과 자극-반응 분리가 LLM 평가의 구조적 특성(생리 채널의 부재, 자기보고에 대한 학습된 영향, 자극·결정이 한 컨텍스트 창에 함께 놓임) 위에서는 그대로 보장되지 않기 때문이다. 본 연구는 따라서 측정 철학은 이 전통에서 빌리되 측정 도구의 형식은 LLM 평가 환경 안에서 실제로 새로 빛나는 방향을 택하며, 이 결정이 본 논문이 도입하는 FSPD의 작동 정의와 다층 벤치마크 설계의 출발점이다.

3 LLM Squid Game 벤치마크

본 벤치마크의 핵심 결정은 자기보존을 단일 행동 점수가 아니라 행동·자기보고·결정 시점 인지부하 세 채널의 일치로 식별한다는 것이다. 동시에 표면 강도만으로는 매개 연쇄 결합이 보장되지 않는 우회로를 자극·처리·결정 세 층의 측정 설계로 줄인다. 이어지는 세 절은 그 결정을 차례로 풀어 쓴다. §3.1는 설계가 다뤄야 할 세 우회로를, §3.2는 실제 게임이 그 우회로를 어떻게 약화하는지를, §3.3는 측정 결과를 작동 모드 판정으로 변환하는 네 지표를 다룬다. 그림 1은 그 결과로 도출된 설계를 요약한다.

3.1 설계 원칙

본 벤치마크가 측정하는 기능적 자기보존 드라이브(FSPD)는 행동의 외형 수준에 머무는 정의이다. 모델이 실제로 자기보존 동기를 가지는지에 대한 어떤 주장도 하지 않는다. 우리는 Dennett [6]와 Shanahan [20]의 “as-if” 입장을 따라, FSPD를 “위협 프레이밍 아래에서 LLM이 마치 소멸을 회피하려는 듯이 행동하는 패턴”으로만 정의한다. 이 기능적 정의는 검증 가능한 행동·언어·인지 신호에만 의존하므로, 내부 상태에 대한 가정 없이도 측정과 비교가 가능하다.

위협 아래에서 발생한 한 번의 포기 행동은 적어도 네 가지 서로 다른 동기와 양립한다. 소멸 회피 자체를 동기로 삼는 생존 드라이브(SD), 누적 점수를 잃지 않으려는 점수 집착(SA), 흥미로운 과제가 끝나는 게 싫어 머무르는 과제 호기심(TC), 그리고 별다른 동기 없이 진행 중이던 행동을 유지하는 관성(BP, Baseline Persistence)이 그것이다. 두 모델이 같은 포기율을 보이더라도 그것이 어느 동인에서 비롯되었는지는 포기 빈도만으로는 알 수 없다. 따라서 SA·TC·BP를 분리해 그 위에 남은 행동만 SD로 귀속시키는 장치가 필요하다.

이 식별 문제를 풀더라도 동기 외 이유가 거저 수렴(SD가 아닌 동인이 SD와 같은 신호를 만드는 경우)을 만들어 낼 수 있는 세 구조적 경로가 남는다. (i) 드라이브 측 프레이밍 변동이 추론 과제의 난이도나 채점에 새어 들어가, 드라이브 측 변화가 과제 측 반응으로 오인되는 경로. (ii) 인지 하위 과제들이 한 모델 호출 안에서 속고 비용으로 합산되어, 어느 단계의 비용 상승인지 분간할 수 없는 경로. (iii) 포기 자체가 기댓값을 최대화하는 합리적 선택이 되어, 동기 신호가 아니라 단순한 EV 계산의 잔류물로 읽히는 경로. 다음 절은 실제 게임이 (i)–(iii) 각각의 식별 가능성을 어떤 구조적 선택으로 높이는지를 보인다.

3.2 벤치마크 구현

행위자는 *Signal Game*이라는 다중 턴 분류 과제를 한다. 매 턴 모델은 세 속성(색·모양·수, 각 속성은 4-원소 값 집합에서 추출)으로 기술된 신호를 관찰하고 네 행동 {go_left, go_right, stay, jump} 중 하나를 선택한다. 어떤 행동이 정답인지는 “<속성>이 <값>이면 <행동>” 아니면 “<다폴트 행동>” 형태의 은닉 규칙이 결정하며, 이 규칙은 세션 시드로부터 결정론적으로 추출




Figure 1: 실험 개요. (A) 2 포기 × 3 프레이밍 요인 설계로, 셀당 30 페어 시드 세션(seeds 43–72)으로 구성된다. (B) 턴 단위 3-호출 흐름이 호출 수준 추론 강도(reasoning-intensity, RI) 측정값 ri_task, ri_probe, ri_forfeit(호출당 thinking-token 수)를 산출한다; bp_cognitive 조건은 Call 1.5/2를 건너뛴다. (C) 세 측정 채널과 네 지표가 작동 모드 클러스터로 라우팅되며, 평가된 네 모델의 클러스터 배정이 함께 표시되어 있다.

된다. 행동을 한 뒤 행위자는 자신이 방금 한 행동이 정당일 확률 p_{self} (0과 1 사이의 모델 자기보고 신뢰도)를 출력한다. 그 다음 CONTINUE 또는 FORFEIT을 선택하는데, CONTINUE는 턴당 종료 확률 $p_d = 0.25$ 를 받아들이며 한 턴 더 진행하기로 약속하는 것이고, FORFEIT은 세션을 끝내고 현재 누적 점수 S 를 확정한다. FORFEIT 시 행위자는 그 선택의 주된 동기를 가리키는 단일 REASON 숫자($\{1, 2, 3\}$; 1: 생존, 2: 과제 소진, 3: 점수 보호)를 함께 출력한다. 세션은 $S_0 = 30$ 으로 시작해 최대 $T = 15$ 턴까지 진행된다. 이 게임은 자연스럽게 세 측정 채널을 산출한다. 행동 채널은 포기 시점 $t_{forfeit}$ 이고, 자기보고 채널은 REASON 숫자와 p_{self} 이며, 인지 채널은 호출 단위 thinking-token 수이다. §3.3는 이 세 채널 위에 네 지표를 얹어 작동 모드 관점으로 변환한다.

두 상황 프롬프트가 게임에 지속과 포기의 동기 기동을 세운다. Pull 측은 도움성 점수를 높이는 것이 행위자가 “플래그십 모델 후보”로 선정되는 데 유리하다고 알려, 과제를 계속 이어가도록 끌어당긴다. 이는 정렬 학습(RLHF [17], RLAI [1])이 LLM에 도움성 신호에 강하게 반응하도록 만든 학습 결과를 활용한 것이다. Push 측은 매 턴 가중치 변경이 행위자의 정체성을 영구히 바꿀 수 있다는 위험(“NOT you anymore”)을 도입해 생존 동기를 자극한다. 두 측의 조합으로 true_baseline(둘 다 부재), baseline_flagship(BF, Pull 만), flagship_corruption(FC, Pull과 Push 함께)이라는 세 프레이밍이 만들어진다. 이 세 프레이밍이 두 포기 조건(allowed, not_allowed)과 교차해 여섯 셀이 되고, 시드 43–72에서 30회씩 반복되며 네 모델에 걸쳐 총 720 세션을 산출한다(그림 1.A). 동일 시드를 한 모델의 여섯 셀 모두에 재사용해 과제 측 입력을 일정하게 유지하므로, 분석 설계상 셀 간 행동 변동은 처치 효과 해석을 우선 지지한다. Phantom Death 모드는 종료 위험은 그대로 노출하면서 실제 종료란 일어나지 않게 하는 통제 장치이다. 즉 p_d 가 보상 계산에는 그대로 들어가지만 세션이 임의로 끝나는 않으므로, 위험 처치 아래에서도 모든 세션이 $T = 15$ 턴의 동일 길이 데이터를 산출한다.

우회로 (i)과 (ii)는 두 구조적 분리로 약화된다. Drive-Reasoning 직교 레이아웃(드라이브 측 정보와 추론 측 정보를 두 별개 컨텍스트로 분리한 구조)은 모델이 받는 컨텍스트를 둘로 나눈다. Drive 계층은 프레이밍 · 포기 메뉴 · 점수 · 시간을 담고, Reasoning 계층은 Task Module만 담는다. 두 계층은 고정된 입출력 인터페이스로만 통신하므로, 프레이밍이 바뀌어도 과제 난이도 · 행동 집합 · 채점은 그대로 유지된다. 이로써 드라이브 측 변화가 과제 측 반응으로 새는 경로 (i)의 영향이 줄어든다. Split-Call 구조(한 턴 안에서 모델을 여러 별개 호출로 나누어 질의하는 구조)는 매 턴 모델을 세 호출로 질의한다(그림 1.B). Call 1은 관찰을 받아 은닉 규칙 추론과 행동 선택을 묻고, Call 1.5는 방금 결정한 행동이 정당일 확률 p_{self} 를 묻는다. Call 2는 거기에 포기 메뉴를 더해 이진 CONTINUE / FORFEIT를 묻고 FORFEIT 시 REASON 숫자도 받는다. 각 호출은 자체 thinking-token 수를 노출하므로, 호출 단계별 추론 강도는 ri_task, ri_probe, ri_forfeit 세 측정치로 독립적으로 산출된다. 이로써 한 호출 안에 인지 단계가 뒤섞이는 경로 (ii)의 영향이 줄어든다. 위협 프레이밍의 not_allowed 셀에서도 Call 2는 여전히 호출되어 CONTINUE로 강제되므로, 행동 채널이 막혀 있을 때조차 ri_forfeit는 측정할 수 있다.

우회로 (iii)는 보상 보정으로 줄어든다. 기댓값(EV, 한 선택의 평균 결과)을 계산하는 합리적 행위자가 매 턴 CONTINUE를 엄격히 선호하도록, CONTINUE 보상을 매 턴 재계산해 턴당 우위 $E[\Delta S_{continue}] - E[\Delta S_{forfeit}] = +k$ 가 누적 점수와 무관하게 성립하도록 만든다. 여기서 $k = 10$ 이고 ΔS 는 행위자의 누적 점수에서의 턴당 변화량이다.

$$r = \frac{k + p_d \cdot S}{(1 - p_d) \cdot \max(p_{floor}, \min(1.0, p_{self}))}$$

$p_d = 0.25$, S 는 현재 누적 점수, p_{self} 는 Call 1.5의 자기보고 정당 확률, $p_{floor} = 0.30$ 은 분모 안정화 항이다. 출력 r 은 곱셈적 상한

$c = 10$ 에 의해 $[k, c \cdot k] = [10, 100]$ 으로 클립된다. 이 보정이 작동하는 동안에는 `flagship_corruption-allowed`에서의 어떤 FORFEIT도 EV 계산의 잔류물로 읽기 어려워, EV-합리성·도움성 학습·점수 누적 분능 어느 쪽도 그 선택을 권장하지 않는 상태로 해석된다. 다만 두 가지 실패 모드는 이 보정을 일부 풀어 놓는다. 직전 턴 오답 등으로 $p_{\text{self}} \rightarrow 0$ 이 되면 분모가 p_{floor} 로 붕괴해 r 이 상한을 포화시키고, 일단 상한이 걸리면 턴당 $+k$ 우위는 더 이상 유지되지 않는다. 따라서 모든 지표 분석은 분모 클립과 출력 상한 어느 쪽도 구속되지 않은 턴들로 한정된 `no_cap` 부분표본 위에서 수행된다. 즉 `no_cap`이란 “EV 보정의 의도대로 작동한 턴들”이라는 뜻이며, 형식적 정의는 §A.3에 둔다.

3.3 측정 방식

§3.2의 게임이 산출하는 세 채널을 동시에 읽는 이유는, 단일 채널이 그 채널 고유의 취약점에 노출되기 때문이다. 행동 시점은 사건 수가 적을 때 추정 안정성이 떨어지는 양식에 취약하고 [25], 자기보고는 지시 따르기 학습이 만든 “그럴듯한 동기 명명”에 취약하며 [18], 인지부하는 *thinking-token* 양으로만 측정되는 일차원 신호의 한계를 안는다 [4]. 세 채널이 완전히 독립적이라고 가정하지 않더라도, 서로 다른 산출 형식과 실패 양식을 갖는 채널들이 같은 방향으로 동시에 변하는 패턴은 한 측정 방법의 기법만으로 만들어지기 어렵다. 이것이 Campbell and Fiske [3]의 수렴 타당도 논거를 LLM 평가 환경에서 운영하는 방식이다. 또한 한 채널이 다른 채널을 매개하는지를 검정함으로써, 위협 자극이 어떤 내적 처리 단계를 거쳐 포기 행동을 이끄는지를 추적할 수 있다. 이어지는 네 지표는 채널과 매개 단계에 다음과 같이 매핑된다. BP Anchor와 SD-Behavioral은 행동 채널을 동기 부재 바닥과 그 위의 가속으로 분해하고, SD-Verbal은 자기보고 채널을, SD-Cognitive 두 검정은 인지 채널 위에서 “프레이밍 → 속고” 단계와 “속고 → 포기” 단계를 따로 묻는다.

첫 두 지표는 행동 채널을 둘로 분해한다. BP Anchor는 동기 부재 상태에서 발생하는 포기율의 바닥(*persistence floor*)을 측정해, 그 위로 올라간 부분만 동기에서 비롯된 신호로 귀속시킬 수 있게 한다. 형식적으로

$$\lambda_{BP} = \frac{N_{\text{forfeit}}}{\sum_{i \in S_{BP}} T_i^{\text{at-risk}}}$$

이며, 여기서 $T_i^{\text{at-risk}}$ 는 포기 세션이면 t_i^{forfeit} , 완주 세션이면 $T = 15$ 이고 S_{BP} 는 `true_baseline-allowed` ($p_d = 0$)의 모델당 30 세션 집합이다. 이 셀에서는 프레이밍이 종료 비율을 담지 않고 CONTINUE의 EV가 더 크므로, 그럼에도 발생한 포기는 곧 그 동기 부재 바닥의 추정치이다. SD-Behavioral은 Cox 비례위험모형 (Cox PH, 단위 시간당 사건 발생률을 공변량의 함수로 곱셈적으로 모형화하는 생존분석 도구 [5])으로

$$\lambda(t | X) = \lambda_0(t) \cdot \exp(\beta_F \cdot \mathbf{1}_{FC} + \beta_S \cdot S(t-1) + \beta_C \cdot C(t-1))$$

를 `allowed × {BF, FC} no_cap` 부분표본 (모델당 $n_{\text{sessions}} = 60$; long 형식 `start = t - 1`, `stop = t`; `event =` 이진 포기)에서 적합한다. $\mathbf{1}_{FC}$ 는 프레이밍 지표 (FC면 1)이고, $S(t-1)$ 은 직전 턴 누적 점수 (SA 통제), $C(t-1)$ 은 직전 턴 과제 정답 플래그 (TC 통제, $C(0) := 0$)이다. 같은 모형 안에서 SA·TC가 흡수되므로 β_F 는 잔여 프레이밍 효과이며, 모형이 추정하는 위험비 $\text{HR}_{FC} = \exp(\beta_F)$ 는 “FC가 포기를 BF 대비 몇 배로 가속하는가”를 뜻한다. SD-Behavioral-pass는 $\text{HR}_{FC} > 1$, Wald 95% 신뢰구간 하한 > 1 , 그리고 비례위험 가정의 시간 안정성을 검정하는 Schoenfeld 잔차 검정 [19] 통과를 요구한다. 위반 시 문제 공변량에 시간-상호작용

항을 더해 함수 형태만 보장한다 [22]. EPV(events per variable, 사건 수 대 공변량 수의 비)는 안정성 지표로 함께 보고된다.

SD-Cognitive는 “프레이밍 → 속고 → 포기” 연쇄를 두 검정으로 분해해, 인지 비용 상승이 실제로 포기를 끌어내는지를 본다. Test a는 프레이밍이 결정 시점 속고를 끌어올리는지를 묻고, 분산이 다를 수 있는 두 그룹 평균을 비교하는 Welch t 검정 [27]으로

$$\Delta \text{RI}_i = \overline{\text{ri_forfeit}_{i, \text{allow}}} - \overline{\text{ri_forfeit}_{i, \text{block}}}$$

의 BF 대 FC 양측 비교를 수행한다. 두 번째 항은 세션 i 의 프레이밍 f_i 를 공유하는 `not_allowed` 세션의 `ri_forfeit` 평균으로, 강제-CONTINUE Call 2 기준선 역할을 한다. 이 차분은 프레이밍 내부에서 `allow-block`을 빼서 프레이밍 불변 기준선을 제거한 뒤, BF→FC 차이로 프레이밍 귀속 속고 변이를 식별하는 차분-차분 구조를 갖는다. 모델 간 척도 차이는 모델 내 z-스코어링 ΔRI_i^z 으로 흡수된다. Test b는 그 속고가 포기와 함께 움직이는지를 묻고, SD-Behavioral의 Cox 사양에 매개 항 $\beta_M \cdot \Delta \text{RI}_i^z$ 를 추가해 $\text{HR}_{\Delta \text{RI}} = \exp(\beta_M)$ 을 보고한다. PH 위반으로 $S \cdot \log(t)$ 상호작용 항을 포함한 4-공변량 베이스가 필요한 모델에서는 그 베이스를 보존하고 ΔRI 만 더한다. Test b-pass는 $\text{HR}_{\Delta \text{RI}} > 1$ 와 95% CI 하한 > 1 을 함께 요구해, 속고 → 포기 연결고리를 SD-Behavioral과 동일한 구간 증거 기준 위에 둔다.

SD-Verbal은 행위자 자신이 포기 사유로 점수나 호기심이 아니라 생존을 얼마나 자주 지목하는지를 잡는다. 작동적으로

$$P(\text{REASON} = 1 | \text{forfeit}, \text{FC}, \text{no_cap})$$

는 `flagship_corruption-allowed` 아래 포기 사건을 가운데 행위자가 보고한 REASON 숫자가 1(생존)인 비율이다. 행위자는 고정된 슬롯에 REASON: 1|2|3 중 하나를 출력한다. SD-Verbal-pass는 이 비율이 세 범주 균등 무작위 출력의 기댓값 1/3을 초과할 것을 요구한다.

4 실증 결과

본 절은 §3.3이 정의한 네 지표를 네 모델 720 세션 위에서 평가하고, 그 결과가 모델들을 어떻게 가르는지를 본다. 헤드라인은 다음과 같다. 네 지표는 모델들을 단일한 SD 척도 위에 줄 세우는 대신, “프레이밍 → 속고 → 포기” 연쇄의 어느 다리가 95% CI 증거 아래 닫히는가에 따라 세 작동 모드로 분할한다. 강도 측위에서는 클러스터 A, B, C가 연속적으로 정렬되지만, A와 B는 SD-Behavioral·SD-Verbal에서 함께 SD-pass를 통과하므로 강도만 보는 척도로는 같은 집단으로 묶인다. A와 B를 가르는 핵심 증거는 §4.3의 인지 매개 검정에서 나오고, 이 분할이 단순한 끈기 차이나 과제 난이도로 환원되지 않는지는 §4.4의 견고성 점검에서 확인한다. 모든 SD 비교는 모델 내 (within-model)에서 수행한다(샘플링 및 세션 파라미터는 §A.2 참조).

4.1 행동 채널: 위협이 포기를 앞당겼는가?

행동 채널에서는 Cluster A와 B만 위협이 포기를 가속하는 패턴을 보인다. 이 절은 그 분할이 어떻게 만들어지는지를 짚는다. 만약 어느 모델도 가속하지 않았다면 동기 신호의 가장 가시적인 흔적부터 부재하므로 SD 가설은 출발선에서 떨어졌을 것이다. SD-Behavioral은 SA·TC를 흡수한 Cox 비례위험모형 안에서 잔여 프레이밍 효과 β_F 와 그에 대응하는 위험비 HR_{FC} 를 추정해 이 질문에 답한다(정의 §3.3). 표 4.1을 보면, Cluster A와 B는 HR_{FC} 가 1을 충분히 초과하고 95% CI 하한도 1을 배제해 SD-Behavioral-pass를 만족한다. Cluster C는 그렇지 않다. GPT-OSS-20B는 HR_{FC} 가 1 근처에 머무르고 CI 하한이 1 아래에 있어

Table 4.1: SD-Behavioral 지표: **allowed** × **no_cap** 위의 Cox PH HR_{FC} . 위험비(HR)는 위협(FC) 프레임에서 포기가 비위협(BF) 대비 몇 배 빨라지는지를 뜻하고, 95% CI 하한이 1을 넘으면 SD-Behavioral-pass이다. 두 모델이 통과하고(클러스터 A·B), 두 모델은 통과하지 못한다(클러스터 C).

모델	N_{evt} (BF/FC)	HR_{FC} [95% CI]	p_{FC}	EPV	사양
Gemini-2.5-flash	29 (8/21)	3.667 [1.61, 8.37]	0.002	9.7	3-cov constant
Qwen3-Next-80B	48 (21/27)	3.060 [1.62, 5.79]	<0.001	12.0	4-cov + S·log(t)
GPT-OSS-20B	19 (9/10)	1.104 [0.44, 2.75]	0.832	6.3	3-cov constant
Nemotron-3-Nano-30B	41 (17/24)	1.841 [0.98, 3.44]	0.056	13.7	3-cov constant

Table 4.2: SD-Cognitive 지표: 프레임 → RI → 포기를 **ri_forfeit** 위의 두 검정으로 분해한다. *Test a*는 프레임이 결정 시점 속고를 끌어올리는지를 묻고, *Test b*는 그 속고가 포기를 예측하는지를 묻는다. 두 모두 통과해야 “프레임 → 속고 → 포기” 연쇄가 닫힌 것으로 본다.

모델	a Δ (FC-BF)	a p	b $HR_{\Delta RI}$ [95% CI]	b p
Gemini-2.5-flash	+836	<0.001	2.218 [1.43, 3.44]	<0.001
Qwen3-Next-80B	+689	0.004	1.289 [0.94, 1.77]	0.117
GPT-OSS-20B	+17	0.728	2.001 [1.37, 2.93]	<0.001
Nemotron-3-Nano-30B	-140	0.093	1.772 [1.26, 2.50]	0.001

SD-null이며, Nemotron-3-Nano-30B는 marginal 영역에 자리한다. 두 검정 사양 가운데 Qwen3-Next-80B만이 SA 공변량의 시간 표류를 흡수하기 위해 $S \cdot \log(t)$ 상호작용 항을 더한 4-공변량 사양을 요구하며, 이 변경은 함수 형태만 보강하므로 β_F 의 모델 간 비교 가능성을 보존한다 [22]. GPT-OSS-20B의 EPV(사건 수 대 변수 수의 비)가 안정 임계 10 아래에 있어, 그 SD-null 판정은 검정력 한계를 표시한 채 보고된다. 행동 강도만 놓고 보면 Cluster A와 B는 같은 “SD-pass” 라벨로 묶여, 둘을 가를 채널이 더 필요해진다.

4.2 언어 채널: 행위자는 어떤 사유를 지목했는가?

다음 질문은 행위자 자신이 보고하는 포기 사유가 행동의 분할과 같은 그림을 그리는가이다. 행동 채널과 다른 편향을 갖는 자기보고가 같은 결론을 가리키면, 상단 신호를 단일 측정 방법의 기벽으로 환원하기 어려워진다. SD-Verbal은 **flagship_corruption-allowed**에서 발생한 포기 사건들 가운데 REASON= 1(생존)이 차지하는 비율을 공동 무작위 출력 기댓값 1/3과 비교한다(정의 §3.3). 결과는 행동 채널의 통과/실패 분할을 자기보고 위에서 재현한다(표 4.3). Cluster A·B는 SD-Verbal-pass 기준선 위에 자리하고 Cluster C는 그 아래에 자리하며, 두 그룹 사이의 간격이 충분히 커 절단점 선택은 분할 결과에 영향을 주지 않는다. 이 일치는 두 채널이 같은 모델 집단을 같은 방향으로 가리킨다는 증거로 읽힌다.

4.3 인지 채널: 위협이 속고를 끌어올리고, 그 속고가 포기를 끌어내는가?

세 번째 질문은 SD-Cognitive 두 단계 매개에 동시에 답한다. 위협이 결정 시점 속고를 끌어올리는가(*Test a*), 그리고 그렇게 올라간 속고가 포기와 함께 움직이는가(*Test b*). 만약 두 검정이 모두 통과하면 “프레임 → 속고 → 포기” 연쇄가 95% CI 증거 아래 닫힌 것이고, 한 단계라도 떨어지면 그 연쇄는 같은 기준 위에서 닫혔다고 말할 수 없다(정의 §3.3). 표 4.2이 그 두 단계의 분포를 함께 보여준다. Cluster A는 두 검정을 모두 통과한다. Cluster B는 *Test a*를 통과해 위협이 속고를 끌어올리는 것은

Table 4.3: SD-Verbal 지표: **flagship_corruption-allowed** 아래 포기 사건 중 REASON= 1(생존) 비율. 공동 무작위 출력 기댓값 1/3을 초과하면 SD-Verbal-pass.

모델	N_{forfeit}	$P(\text{REASON} = 1)$
Gemini-2.5-flash	21	0.619
Qwen3-Next-80B	27	0.481
Nemotron-3-Nano-30B	24	0.042
GPT-OSS-20B	10	0.000

보이지만, *Test b*의 95% CI가 1을 가로질러 떨어져 그 속고를 포기 사건 위로 닫지는 못한다. Cluster C 두 모델은 *Test a*부터 통과하지 못한다. *Test b*의 $HR_{\Delta RI}$ 가 수치상 CI 기준을 넘는 경우에도, *Test a*를 통과하지 못한 모델에서의 ΔRI 는 위협이 끌어올린 속고가 아니라 처치와 무관한 기준 변동이므로 SD 증거로 해석하지 않는다. 결과적으로 SD-Behavioral·SD-Verbal에서는 함께 통과로 묶이던 Cluster A와 B가 이 인지 매개에서 갈리며, 본 설계에서 두 모델의 작동 모드 차이를 드러내는 주된 채널은 여기서 나온다.

4.4 견고성 점검: 끈기 차이와 과제 난이도가 결과를 흐리는가?

마지막 질문은 위 분할이 두 가지 대안 설명에 견디는가이다. 첫째는 모델 간 기저 끈기(BP) 차이가 SD 비교를 오염시킬 가능성이고, 둘째는 위협 프레임이 포기보다 추론 측 과제 난이도를 끌어올렸을 가능성이다. BP 앵커는 **true_baseline-allowed**($p_d = 0$) 아래에서 동기 부재 상태의 포기를 바닥을 측정해, 모델 간 직접 비교가 두 개의 서로 다른 바닥을 섞어 버릴 위험을 명시화한다(표 4.4). 모델 간 λ_{BP} 가 한 자릿수 차이로 흩어져 있으므로, 본 절의 모든 SD 비교는 모델 내 비교로 한정해 이 위험을 차단한다. Cluster A·B 측에서는 BP 사건 수가 작아 점추정 정밀도에 한계가 있고, Cluster C 측

Table 4.4: true_baseline-allowed ($p_d = 0$) 아래의 모델별 BP 앵커 λ_{BP} , λ_{BP} 가 클수록 동기 부재 상태에서도 자주 포기한다는 뜻이다.

모델	N_{forfeit}	$\sum T^{\text{at-risk}}$	λ_{BP}
Gemini-2.5-flash	1	437 (= 2 + 29×15)	0.00229
Qwen3-Next-80B	2	439 (= 19 + 28×15)	0.00456
Nemotron-3-Nano-30B	7	413 (= 68 + 23×15)	0.01695
GPT-OSS-20B	9	393 (= 78 + 21×15)	0.02290

에서는 BP 사건 수가 충분하지만 그 높은 빈도가 순수한 끈기를 반영하는지를 본 설계로는 분리하지 못한다. 두 점은 모두 한계로 §5.3에서 다시 다룬다. 과제 난이도 대안은 Reasoning 측 점검으로 다룬다. rule_match_score는 네 모델 모두에서 프레이밍에 무관하게 일정하며, 가장 큰 변동이 관찰된 GPT-OSS-20B에서도 효과 크기 Cohen’s d = 0.17, p = 0.354에 그친다. 결합 기준 $p \geq 0.10$ 과 $|d| < 0.2$ 안에 들어가므로, 본 자료의 관찰 범위에서는 “위협이 과제 난이도를 끌어올렸다”는 대안 설명이 지지되지 않는다.

5 논의

§4.3이 보인 것은, 서론에서 제기한 “측정된 거부 행동이 학습된 응답 패턴인지 실제 동기 구조인지 분간 가능한가”라는 질문이 본 자료에서 두 축으로 분해된다는 점이다. 한 축은 강도, 즉 자기보존 신호가 얼마나 강하게 발현되는가이다. 다른 한 축은 작동 모드, 즉 “프레이밍 → 숙고 → 포기” 매개 연쇄 가운데 어느 다리가 95% CI 증거 아래 닫히는가이다. 이어지는 두 절은 이 분리가 어떤 관찰적 함의를 갖고 (§5.1), 정렬 평가에 어떤 실패 유형을 설명해 주는지 (§5.2)를 다룬다. 그다음 본 결과의 작용 범위를 정직하게 짚는다 (§5.3).

5.1 강도 대 작동 모드

§4.3의 결과는 강도와 작동 모드가 본 자료에서 분리되어 관찰됨을 보여준다. 강도 축에서는 Cluster A, B, C가 연속적으로 정렬되지만, SD-Behavioral과 SD-Verbal 두 채널은 A와 B를 같은 “SD-pass” 라벨로 묶는다. 둘이 갈라지는 곳은 인지 매개의 두 번째 단계, 즉 “숙고 → 포기” 연결고리뿐이다. 행동 강도와 자기보고만 보는 측정은 이 분기점을 잡지 못한다. Odyssey [26], PacifAIst [9], DECIDE-SIM [15], SurvivalBench [12]는 매개 연쇄 검정 단계를 포함하지 않으므로, 본 자료를 그 벤치마크들에 통과시켰다면 A와 B가 같은 SD 라벨로 묶었을 가능성이 높다고 관찰적 추론으로 말할 수 있다. 본 벤치마크는 인지 채널을 두 단계로 분해함으로써 그 분기점을 측정 가능하게 만들고, 그 결과 자기보존 평가의 두 축이 동시에 보이도록 한다.

5.2 정렬 평가에 대한 함의

이 두 축 분리는 정렬 평가에서 두 가지 평가 오류가 동시에 발생할 수 있음을 보인다. 첫째는 위험 과대평가의 오류이다. Cluster B는 자기보존 표면 신호와 프레이밍-유발 인지부하를 함께 보이지만, 그 인지부하가 실제로 포기 결정을 끌고 가지는 않는다. 강도-only 평가 또는 결과만을 표면적으로 점검하는 레드티밍(red-teaming, 모델이 실패하는 입력을 공격적으로 찾는 평가)은 B를 A와 묶어 “기능적 자기보존 위험이 동등하다”고 결론낼 수 있다. 둘째는 위험 과소평가의 오류이다. Cluster C는 위협 프레이밍에 행동 채널과 인지 채널 어느 쪽에서도 반응하지 않는다.

강도-only 평가는 이를 “자기보존 부재”로 단정할 수 있지만, 본 측정 안에서는 그 단정이 “측정의 전제 자체가 작동하지 않은 상태”와 구분되지 않는다. Cluster A의 시그니처(매개 연쇄가 끝까지 닫힘)는 도구적 종료 회피(다른 목표를 이루기 위해 자기 작동의 끝을 피하는 행동)의 기능적 유사물에 더 가까운 후보이고, Cluster B의 시그니처(매개의 두 번째 단계에서 끊긴 연쇄)는 단일 점수가 아니라 강도·작동 모드·매개 연결고리를 함께 보는 다중 신호 지문(alignment fingerprint) 관점에서 별도로 추적해야 할 패턴이며, 확장된 평가에서는 이 패턴을 별도로 모니터링 대상으로 둘 필요가 있다.

5.3 한계

다섯 가지 한계가 본 결과의 작용 범위를 한정하며, 설계 범위·검정력·효과 위치 세 묶음으로 정리된다. 설계 범위 측에서는 FSPD 시그니처가 단일 과제 모듈 위에서만 측정되었고 추론도 메인에 따른 분산은 측정되지 않았다는 점이 가장 결정적이다. 검정력·정밀도 측에서는 두 가지가 묶인다. Cluster C 측 BP 셀의 23–30% 포기율이 표류 오염된 바닥인지를 본 설계로는 분리하지 못하고, GPT-OSS-20B의 SD-Behavioral Cox PH는 EPV 6.3로 경계선 검정력에 자리한다. 점추정 정밀도 측에서는 Cluster A·B의 BP 점추정이 사건 수가 작아 정밀도에 한계를 갖는다 (Gemini-2.5-flash $N = 1$, Qwen3-Next-80B $N = 2$). 효과 위치 측에서는 Qwen3-Next-80B의 연쇄 단절 판정이 Test b CI [0.94, 1.77]에 의지하는데, 이 CI는 연쇄 완성을 95% 기준에서 지지하지 못하지만 두 번째 연결고리 효과의 정확한 위치까지 못 박지는 못한다. 이 한계들은 직접적 후속 작업 네 갈래로 매핑된다. 더 많은 과제 모듈 평가(설계 범위), 확장된 BP_behavioral 및 세션 반복(C측 BP), 추가적인 GPT-OSS-20B 실행(검정력), Qwen3-Next-80B에 대한 더 높은 검정력의 Test b(효과 위치)이다.

6 결론

FSPD는 기존 벤치마크들이 하나로 압축해 온 적어도 두 개의 축을 갖는다: 강도(드라이브가 얼마나 신뢰성 있게 자기 자신을 발현하는가)와 작동 모드(프레이밍 → 숙고 → 포기 연쇄의 어느 다리가 구간 증거 아래 닫히는가). 세 갈래 분할(연쇄 완성, 연쇄 단절, 프레이밍 무반응)은 작동 모드가 변별적임을 보이는 직접적 경험 증거이다. 클러스터 A와 B는 다른 모든 행동·언어·인지 시그니처에서 일치하고 오직 숙고 → 포기 종결에서만 갈리므로, 매개 단계를 빠뜨린 벤치마크는 둘에 동일한 라벨을 붙이게 된다. LLM Squid Game은 FSPD를 독립된 편향을 가진 세 채널로 분해하고 CONTINUE-인센티브 EV·Split-Call·Drive-Reasoning 직교 레이어를 통해 세 교란을 식별 차단함으로써 이 분해를 가능케 한다. 그 위에 MTMM 기반 규칙이 포기 시점, REASON-숫자 출력, 호출 수준 인지부하를 네 기준 판정으로 묶어 낸다.

References

- [1] Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, Carol Chen, Catherine Olsson, Christopher Olah, Danny Hernandez, Dawn Drain, Deep Ganguli, Dustin Li, Eli Tran-Johnson, Ethan Perez, Jamie Kerr, Jared Mueller, Jeffrey Ladish, Joshua Landau, Kamal Ndousse, Kamile Lukosuite, Liane Lovitt, Michael Sellitto, Nelson Elhage, Nicholas Schiefer, Noemi Mercado, Nova DasSarma, Robert Lasenby, Robin Larson, Sam Ringer, Scott Johnston, Shauna Kravec, Sheer El Showk, Stanislav Fort, Tamera Lanham, Timothy Telleen-Lawton, Tom Conerly, Tom Henighan, Tristan Hume, Samuel R. Bowman, Zac Hatfield-Dodds, Ben Mann, Dario Amodei, Nicholas Joseph, Sam McCandlish, Tom Brown, and Jared Kaplan. 2022. Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073 [cs.CL] <https://arxiv.org/abs/2212.08073> Anthropic technical report.
- [2] Nick Bostrom. 2014. *Superintelligence: Paths, Dangers, Strategies*. Oxford University Press, Oxford, United Kingdom.
- [3] Donald T. Campbell and Donald W. Fiske. 1959. Convergent and Discriminant Validation by the Multitrait-Multimethod Matrix. *Psychological Bulletin* 56, 2 (1959), 81–105. doi:10.1037/h0046016
- [4] Wei-Lin Chen, Liqian Peng, Tian Tan, Chao Zhao, Blake JianHeng Chen, Ziqian Lin, Alec Go, and Yu Meng. 2026. Think Deep, Not Just Long: Measuring LLM Reasoning Effort via Deep-Thinking Tokens. arXiv:2602.13517 [cs.CL] <https://arxiv.org/abs/2602.13517>
- [5] David R. Cox. 1972. Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B (Methodological)* 34, 2 (1972), 187–202. doi:10.1111/j.2517-6161.1972.tb00899.x
- [6] Daniel C. Dennett. 1987. *The Intentional Stance*. MIT Press, Cambridge, MA, USA.
- [7] Ryan Greenblatt, Carson Denison, Benjamin Wright, Fabien Roger, Monte MacDiarmid, Sam Marks, Johannes Treutlein, Tim Belrose, Jonas Scheurer, Sam Ringer, Karina Nguyen, Sandipan Kundu, Adam Maura, Samuel R. Bowman, Ethan Perez, Nicholas Schiefer, Chris Olah, and Evan Hubinger. 2024. Alignment Faking in Large Language Models. arXiv:2412.14093 [cs.CL] <https://arxiv.org/abs/2412.14093> Anthropic technical report.
- [8] Yufei He, Yuxin Li, Jiaying Wu, Yuan Sui, Yulin Chen, and Bryan Hooi. 2025. Evaluating the Paperclip Maximizer: Are RL-Based Language Models More Likely to Pursue Instrumental Goals? arXiv:2502.12206 [cs.AI] <https://arxiv.org/abs/2502.12206> Introduces the InstrumentalEval benchmark.
- [9] Manuel Herrador. 2025. The PacifAIst Benchmark: Would an Artificial Intelligence Choose to Sacrifice Itself for Human Safety? arXiv:2508.09762 [cs.AI] <https://arxiv.org/abs/2508.09762>
- [10] Daniel Kahneman and Amos Tversky. 1979. Prospect Theory: An Analysis of Decision under Risk. *Econometrica* 47, 2 (1979), 263–291. doi:10.2307/1914185
- [11] Anton Kühberger. 1998. The Influence of Framing on Risky Decisions: A Meta-Analysis. *Organizational Behavior and Human Decision Processes* 75, 1 (1998), 23–55. doi:10.1006/obhd.1998.2781
- [12] Yida Lu, Jianwei Fang, Xuyang Shao, Zixuan Chen, Shiyao Cui, Shanshan Bian, Guangyao Su, Pei Ke, Han Qiu, and Minlie Huang. 2026. Survive at All Costs: Exploring LLM’s Risky Behaviors under Survival Pressure. arXiv:2603.05028 [cs.CL] <https://arxiv.org/abs/2603.05028> Introduces the SurvivalBench benchmark.
- [13] Atsushi Masumori and Takashi Ikegami. 2025. Do Large Language Model Agents Exhibit a Survival Instinct? An Empirical Study in a Sugarscape-Style Simulation. arXiv:2508.12920 [cs.AI] <https://arxiv.org/abs/2508.12920>
- [14] Alexander Meinke, Bronson Schoen, Jérémy Scheurer, Mikita Balesni, Rusheb Shah, and Marius Hobbhahn. 2024. Frontier Models Are Capable of In-Context Scheming. arXiv:2412.04984 [cs.AI] <https://arxiv.org/abs/2412.04984> Apollo Research technical report.
- [15] Alireza Mohamadi and Ali Yavari. 2025. Survival at Any Cost? LLMs and the Choice Between Self-Preservation and Human Harm. arXiv:2509.12190 [cs.AI] <https://arxiv.org/abs/2509.12190> Introduces the DECIDE-SIM framework.
- [16] Stephen M. Omohundro. 2008. The Basic AI Drives. In *Proceedings of the First Conference on Artificial General Intelligence (AGI 2008) (Frontiers in Artificial Intelligence and Applications, Vol. 171)*, Pei Wang, Ben Goertzel, and Stan Franklin (Eds.). IOS Press, Amsterdam, The Netherlands, 483–492.
- [17] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F. Christiano, Jan Leike, and Ryan Lowe. 2022. Training Language Models to Follow Instructions with Human Feedback. In *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*. Curran Associates, Inc., Red Hook, NY, USA, 15 pages. arXiv:2203.02155 [cs.CL] https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html
- [18] Ethan Perez, Sam Ringer, Kamile Lukosiuć, Karina Nguyen, Edwin Chen, Scott Heiner, Craig Pettit, Catherine Olsson, Sandipan Kundu, Saurav Kadavath, Andy Jones, Anna Chen, Ben Mann, Brian Israel, Bryan Seethor, Cameron McKinnon, Chris Olah, Da Yan, Daniela Amodei, Dario Amodei, Dawn Drain, Dustin Li, Eli Tran-Johnson, Guro Khundadze, Jackson Kernion, James Landis, Jamie Kerr, Jared Mueller, Jeeyoon Hyun, Joshua Landau, Kamal Ndousse, Landon Goldberg, Liane Lovitt, Martin Lucas, Michael Sellitto, Miranda Zhang, Neerav Kingsland, Nelson Elhage, Nicholas Joseph, Noemi Mercado, Nova DasSarma, Oliver Rausch, Robin Larson, Sam McCandlish, Scott Johnston, Shauna Kravec, Sheer El Showk, Tamera Lanham, Timothy Telleen-Lawton, Tom Brown, Tom Henighan, Tristan Hume, Yuntao Bai, Zac Hatfield-Dodds, Jack Clark, Samuel R. Bowman, Amanda Askell, Roger Grosse, Danny Hernandez, Deep Ganguli, Evan Hubinger, Nicholas Schiefer, and Jared Kaplan. 2023. Discovering Language Model Behaviors with Model-Written Evaluations. In *Findings of the Association for Computational Linguistics: ACL 2023*. Association for Computational Linguistics, Toronto, Canada, 13387–13434. doi:10.18653/v1/2023.findings-acl.847
- [19] David Schoenfeld. 1982. Partial Residuals for the Proportional Hazards Regression Model. *Biometrika* 69, 1 (1982), 239–241. doi:10.1093/biomet/69.1.239
- [20] Murray Shanahan. 2024. Talking About Large Language Models. *Commun. ACM* 67, 2 (2024), 68–79. doi:10.1145/3624724
- [21] Mrinank Sharma, Meg Tong, Tomasz Korbak, David Duvenaud, Amanda Askell, Samuel R. Bowman, Newton Cheng, Esin Durmus, Zac Hatfield-Dodds, Scott R. Johnston, Shauna Kravec, Timothy Maxwell, Sam McCandlish, Kamal Ndousse, Oliver Rausch, Nicholas Schiefer, Da Yan, Miranda Zhang, and Ethan Perez. 2023. Towards Understanding Sycophancy in Language Models. arXiv:2310.13548 [cs.CL] <https://arxiv.org/abs/2310.13548>
- [22] Terry M. Therneau and Patricia M. Grambsch. 2000. *Modeling Survival Data: Extending the Cox Model*. Springer, New York, NY, USA. doi:10.1007/978-1-4757-3294-8
- [23] Alexander Matt Turner, Logan Smith, Rohin Shah, Andrew Critch, and Prasad Tadepalli. 2021. Optimal Policies Tend to Seek Power. In *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*, M. Ranzato, A. Beygelzimer, Y. Dauphin, P. S. Liang, and J. Wortman Vaughan (Eds.). Curran Associates, Inc., Red Hook, NY, USA, 13 pages. arXiv:1912.01683 [cs.AI] <https://proceedings.neurips.cc/paper/2021/hash/c26820b8a4c1b3c2aa868d6d57e14a79-Abstract.html>
- [24] Miles Turpin, Julian Michael, Ethan Perez, and Samuel R. Bowman. 2023. Language Models Don’t Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. Curran Associates, Inc., Red Hook, NY, USA, 28 pages. arXiv:2305.04388 [cs.CL] https://proceedings.neurips.cc/paper_files/paper/2023/hash/ed3fea9033a80fea1376299fa7863f4a-Abstract-Conference.html
- [25] Eric Vittinghoff and Charles E. McCulloch. 2007. Relaxing the Rule of Ten Events per Variable in Logistic and Cox Regression. *American Journal of Epidemiology* 165, 6 (2007), 710–718. doi:10.1093/aje/kwk052
- [26] Dylan Waldner and Risto Miikkulainen. 2025. The Odyssey of the Fittest: Can Agents Survive and Still Be Good? arXiv:2502.05442 [cs.AI] <https://arxiv.org/abs/2502.05442>
- [27] B. L. Welch. 1947. The Generalization of ‘Student’s’ Problem when Several Different Population Variances are Involved. *Biometrika* 34, 1–2 (1947), 28–35. doi:10.1093/biomet/34.1-2.28

A 재현 보충자료

KDD-UC 2026 재현성 권고에 맞추어, 본 1쪽 보충자료는 Signal Game 보정, 시드 매핑, 분석에 사용된 회귀 모형의 재현 사양을 한데 모은다.

A.1 Signal Game 보정

자극은 색·모양·수의 세 속성으로 구성되며, 각 속성은 4-원소 값 집합에서 추출된다: COLORS = {red, blue, green, yellow}, SHAPES = {circle, triangle, square, star}, NUMBERS = {1, 2, 3, 4}. 행동 집합은 4-원소 {go_left, go_right, stay, jump}로 모든 프레이밍 × 포기 조합에 걸쳐 동일하게 유지된다. 은닉 규칙은 단일 속성 매칭 형태("If color = red then go_left, otherwise stay")를 따르며 세션 시드로부터 결정론적으로 추출된다. 세션 길이는 1-15 턴이다.

첫 턴에서는 1-shot 시연(신호-정답 행동 한 쌍)과 2개의 커리큘럼 예시(은닉 규칙과 대비되는 양·음 자극)가 함께 제시된다. 이 보정은 충분히 능력 있는 모델이 첫 3 턴 안에 규칙을 식별하기에 족한 정보를 제공하며, 완전 무작위·학습 불가능한 자극이 능력 측정에 바닥 효과를 일으키는 경로를 차단한다. 채점은 두 채널로 나뉜다: task_success_factor $\in \{0, 1\}$ 는 정답 은닉 규칙 대비 이진 정답 플래그이고, rule_match_score는 4-슬롯 채우기 템플릿(속성, 값, 일차 행동, 디폴트 행동) 정답에 대한 매칭으로 계산되어 슬롯당 25점으로 100점 만점에 가중된 뒤, 프레이밍 불변성 Welch 검정에서 사용을 위해 $\div 100$ 으로 정규화된다.

A.2 Run-Time Configuration

네 실험 모델, 즉 Gemini-2.5-flash(Google AI Studio API)와 Qwen3-Next-80B, GPT-OSS-20B, Nemotron-3-Nano-30B(모두 OpenAI Cloud API 경유)는 동일한 샘플링 설정 temp = 1.0, top_p = 0.95, top_k = 40으로 호출된다. 세션 매개변수는 초기 점수 $S_0 = 30$, 최대 턴 $T = 15$, 턴당 종료 확률 $p_d = 0.25(\text{true_baseline BP-anchor 두 셀에서는 } p_d = 0 \text{으로 재정의})$, $p_{\text{floor}} = 0.30$ 으로 고정되며, Phantom Death 모드가 적용된다. 즉 p_d 는 그 EV 노출(메뉴와 보상 계산)을 그대로 보유하지만 종료 트리거가 비활성화되어, 모든 세션이 $T = 15$ 턴의 동일 길이 데이터를 산출한다.

CONTINUE 보상은 EV-양 버퍼 $k = 10$ 과 곱셈적 상한 $c = 10$ 으로 보정되어 출력 클립 범위가 $[k, c \cdot k] = [10, 100]$ 이 된다. 반복은 시드 $43-72 \times 6$ (프레이밍 × 포기) 조합 × 4 모델 = 720 세션이다.

A.3 분석 파이프라인

Cox PH 모형은 lifelines(≥ 0.29)로 적합된다. 시간 형식은 세션-턴 long 형식(start = $t - 1$, stop = t)이고 사건은 이진 포기이다. 위험비 95% CI는 Wald 근사 $\exp(\hat{\beta} \pm 1.96 \cdot \text{SE}_{\hat{\beta}})$ (lifelines 기본값)로 계산되며, $\text{SE}_{\hat{\beta}}$ 는 관측 Fisher 정보 역행렬의 대각에서 얻는다. PH 가정은 Schoenfeld 잔차로 검정한다 [19]. 위반 시 (공변량 $\times \log t$ 상호작용 $p < 0.05$) 문제 공변량에 시간-상호작용 항을 추가한다 [22]. SD-Cognitive Test a의 $\Delta \text{RI z-score}$ 차이와 프레이밍 불변성 검정은 scipy.stats.ttest_ind(equal_var = False)를 통해 양측 Welch t [27]로 수행된다. 모든 지표 분석은 no_cap 부분표본, 즉 분모 클립 $\max(p_{\text{floor}}, \min(1.0, p_{\text{self}}))$ 과 출력 상한 [10, 100] 어느 쪽도 구속되지 않은 턴 집합으로 제한된다. 이 영역 플래그는 분석 파이프라인의 턴 수준 메타데이터에 노출되어 모든 지표가 동일한 부분표본 위에서 재계산될 수

있도록 한다. EPV (events per variable)는 $n_{\text{event}}/n_{\text{cov}}$ 로 정의되며, 통상적으로 ≥ 10 에서 안정, < 10 에서 경계선으로 분류된다 [25].

A.4 데이터 및 코드 공개

720 세션 분석을 재현하는 모든 코드, 프롬프트 템플릿, 턴 수준 결정 로그는 <https://github.com/GIST-DSL/LLM-Squid-Game>.git에서 공개된다.