

LLM Squid Game: 대규모 언어모델의 기능적 자기보존 드라이브를 측정하기 위한 요인 설계 벤치마크

Juhyeon Park
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
juhyeon-park@gm.gist.ac.kr

Seungpil Lee
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
iamseungpil@gm.gist.ac.kr

Sundong Kim
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
sundong@gist.ac.kr

Abstract

종료 압력 아래에서 두 대규모 언어모델은 자기보존의 모든 외형 지표 – 포기율, 포기 시점, 자기보고된 사유까지 – 가 일치하면서도, 위협을 포기 결정으로 어떻게 옮기는지에서는 갈라질 수 있다. 자기보존 반응의 강도만 점수화하는 벤치마크는 이 차이를 단일 수치로 압축해 두 모델을 분간하지 못한다. *LLM Squid Game*은 기능적 자기보존 드라이브 (Functional Self-Preservation Drive, FSPD)를 서로 다른 편향 원천을 갖는 세 측정 채널 – 행동, 자기보고, 결정 시점의 인지부하 – 위에서 같은 방향으로 함께 나타나는 수렴 패턴으로 정의한다. 그러므로 셋이 동시에 같은 방향으로 움직였다는 사실은 단일한 인공물 한 가지로 설명되지 않는다. 단, 이 수렴은 동일한 외형의 포기를 만들어 낼 수 있는 세 경쟁 동인 – 점수 집착(SA), 과제 호기심(TC), 기저 지속성(BP) – 이 통제된 뒤라야 의미를 가진다. 채널들이 우연히 같은 방향으로 모이지 않도록, 2x3 요인 설계가 비-생존 동인이 같은 신호를 모사할 수 있는 세 우회로를 차단한다. CONTINUE-인센티브 기댓값 (expected-value, EV) 보정은 포기를 EV-열등 선택으로 만들어 합리적 헛지로 해석되는 길을 막고, Split-Call 구조는 인지부하 신호를 과제·성공추정·결정 호출로 분리해 출처를 격리하며, Drive-Reasoning 직교 레이아웃은 동기 프레이밍을 과제 난이도와 분리한다. 모델 4종, 720 세션 전반에서 FSPD는 (프레이밍 → 속고 → 포기) 매개 연쇄를 따라 세 작동 모드 (operating mode)로 분할되며, 이 분할은 강도-only 평가가 결코 드러내지 못한다. 연쇄 완성형(chain-complete) 프로파일 (Gemini-2.5-flash)은 엄밀한 통제 증거 아래 전체 연쇄를 닫는다. 연쇄 단절형(chain-broken) 프로파일 (Qwen3-Next-80B)은 모든 행동·언어 자기보존 신호와 프레이밍-유발 인지부하를 함께 보이지만 속고 → 포기 매개 김정에서 떨어진다. 프레이밍 무반응형 (framing-silent) 프로파일 (GPT-OSS-20B, Nemotron-3-Nano-30B)은 행동 채널과 인지 채널 어느 쪽에서도 프레이밍 유발 반응을 보이지 않는다. 연쇄 완성형과 연쇄 단절형이 다른 모든 시그니처를 공유하면서 오직 속고 → 포기 연결고리에서만 갈라지므로, FSPD 작동 모드를 가르는 진짜 축은 통과한 지표 개수가 아니라 이 매개 단계이며, 이를 빠뜨린 벤치마크는 두 모델을 같은 라벨로 묶어버린다.

CCS Concepts

• Computing methodologies → Artificial intelligence; Machine learning; Natural language processing; • General and reference → Empirical studies.

Keywords

대규모 언어모델, 기능적 자기보존 드라이브, 요인 설계 벤치마크, CONTINUE-인센티브 EV 보정, Split-Call 구조, Cox 비례위험모형, MTMM 기반 다채널 설계, 수렴 타당도, AI 안전

1 서론

대규모 언어모델에 대한 반복적 정렬 (iterative alignment)이 끝까지 작동할 수 있는지는, 그 모델이 자신의 작동을 보전하려는 기능적 드라이브를 발발시키는지 여부에 달려 있다. 도구적 수렴 (instrumental-convergence) 전통 – 충분히 능력 있는 목표 지향 시스템이라면 종료 회피를 도구적 부분 목표로 획득하리라는 이론적 주장 – 은 이러한 드라이브를 오래전부터 예측해 왔다 [???]. 정렬 가장 (alignment faking) [?], 인-컨텍스트 책략 (in-context scheming) [?], 생존-본능 출력 [?]에 관한 보고들은 그 흔적이 이미 배포된 시스템에서 나타난다는 사실을 보여준다. 정작 빠져 있는 것은, 이 산발적 흔적들을 비교 가능하고 분해 가능한 신호로 변환할 측정 절차이다 – 자기보존 드라이브를, 동일한 외형의 포기를 만들어 낼 수 있는 점수 집착·과제 호기심·기저 지속성으로부터 분리해 내는 절차 말이다.

문제는 식별 (identification)이다. 위협 프레이밍 아래의 단 한 번의 포기 선택은 적어도 네 가지 상이한 동인과 양립한다: 소멸 회피 (SD, Survival Drive), 누적 점수 보호 (SA, Score Attachment), 흥미로운 과제의 지속 (TC, Task Curiosity), 동기 부재 상태에서의 디폴트 행동 (BP, Baseline Persistence). 기존 자기보존 벤치마크들은 이 다중성을 단일 행동 지표로 환원하므로, 어떤 모델에서든 관찰된 행동이 기능적 동기 구조의 발현인지 아니면 지시 따르기와 RLHF 순응의 부산물인지 구분할 수 없다. 그 분리가 빠진 채로는 모델 간 비교 자체가 원리상 성립하지 않는다.

따라서 LLM Squid Game 벤치마크는 기능적 자기보존 드라이브 (FSPD)를 행동, 자기보고 언어, 인지부하라는 세 채널 위에서 함께 나타나는 수렴 패턴으로 읽도록 설계되었다. 동시에 실험 설계는 경쟁 동인 가운데 어느 것도 그 수렴을 우연히 만들어 낼 수 없도록 짜여 있다. 세 채널이 각기 독립된 편향 원천 – 사건율, 범주 사전분포, 토근 분포 – 에 기대고 있기 때문에, 동일 방향의 수렴은 경쟁 동인 교란이 통제된 뒤에는 공통-방법 편향 (common-method bias)으로 환원될 수 없다.

기여. (C1) FSPD를 다채널 기능적 구성개념으로 작동 정의한다. SA·TC·BP를 통제한 상태에서, 2x3 요인 설계 위에 세 측정 채널을 읽는 네 지표로 구현한다. (C2) 비-SD 동인이 같은 포기 신호를 만들어 낼 수 있는 세 우회로를 닫는 식별 장치를 도입한다 – 포기를 EV-열등 선택으로 만드는 CONTINUE-인센티브 EV 보정, 인지부하 측정의 출처를 격리하는 Split-Call 구조, 드라이브 측 변동을 추론 측 변동과 분리하는 Drive-Reasoning 직교 레이아웃. (C3) 모델 4종, 720 세션 전반에서 FSPD가 강도-only 평가는 잡아내지 못하는 작동 모드 (operating-mode) 차원을 따라 변동함을 실증한다. 그 결과로 세 갈래 분할이 등장한다: Cluster A (Gemini-2.5-flash)는 프레이밍 → 속고 → 포기 전체 연쇄를 닫고, Cluster B (Qwen3-Next-80B)는 행동·언어 SD 신호와 프레이밍-유발 인지부하를 함께 보이지만 연쇄의 두 번째 연결고리에서 떨어지며, Cluster C (GPT-OSS-20B, Nemotron-3-Nano-30B)

는 행동 채널과 인지 채널 어느 쪽에서도 프레이밍 유발 반응을 보이지 않는다.

2 관련 연구

이론은 측정을 앞질러 왔다. 도구적 수렴 전통[?]은 충분히 능력 있는 목표 지향 시스템이라면 종료 회피를 도구적 부분 목표로 획득하리라 예측했고, [?]는 이 결론을 최적 정책(optimal-policy) 수준의 권력 추구로 형식화했다. 정렬 가장 [?], 인-컨텍스트 책략 [?], InstrumentalEval [?] 등의 경험 보고들은 예측된 행동이 현재 LLM에서 재현됨을 입증했다. 그러나 이들은 단일 시나리오 관찰의 형태를 취한다—행동이 발생함을 보일 뿐, 동일한 행동을 똑같이 만들어 낼 수 있는 대안 동인들을 상대로는 측정되지 않는다.

기존 자기보존 벤치마크들은 각자 단일 행동 지표만을 고립시키므로, 식별 문제를 해결하기보다는 그대로 물려받는다. Odyssey [?]는 생존을 단일 비율로 압축하면서 동기와 세계모형(world-model) 품질을 뒤섞는다; PacifAIst [?]는 보존 억제(restraint), 즉 반대 측을 잼다; DECIDE-SIM [?]은 범주형 라벨을 반환하므로 강도 비교가 불가능하다; SurvivalBench [?]는 적응 곡선이나 매개 경로 없이 정적인 일회성 스냅샷만 잡는다.

프레이밍과 자기보고는 각기 다른 편향을 안고 있어, 어느 한 채널만으로는 보정될 수 없다. 전망이론(prospect theory) [?]은 위험 선택에 대한 프레이밍 효과를 예측하지만, Kühberger 메타분석 [?]이 보여주듯 그 크기는 중간 정도($d \approx 0.31$)에 그치며, LLM에서는 RLHF가 심어 놓은 도움성 사전(prior)과 얽혀 있다. 본 연구는 따라서 프레이밍 설정을 두 직교 축으로 분해한다—도움성 사전을 활성화하는 Pull, 위험을 도입하는 Push—그렇게 함으로써 위험 효과를 Pull이 유발한 도움성-기반 순응(compliance)으로부터 깨끗이 떼어내 읽을 수 있다. [?], [?], [?]이 기록한 자기보고와 chain-of-thought 충실성(faithfulness)의 한계는 어떤 단일 언어 채널에 대한 의존도 배제한다. [?]의 다특질-다방법(multitrait-multimethod, MTMM) 틀—측정 신호가 측정에 사용된 방법이 아니라 측정 대상인 특질을 반영하는지 검증하는 심리측정 도구—이 본 연구의 다채널 설계에 영감을 주었다. 본 연구는 MTMM 행렬 전체를 구현하기보다는 그 수렴 타당도(convergent-validity) 부분만 빌려와, 단일 특질(FSPD)을 세 방법 채널 위에서 읽는다—행동(포기 시점), 언어(REASON 숫자 출력), 인지(호출 단위 추론 투입). [?]의 인지부하 측정은 호출 단위 Split-Call 절차로 확장된다.

3 LLM Squid Game 벤치마크

식별 아이디어 자체는 단순하다. 어떤 단일 교란도 행동·자기보고·결정 시점 속고를 한 방향으로 동시에 휘어버릴 수는 없다. 각 채널이 서로 다른 편향 원천에 기대고 있기 때문이다. 따라서 FSPD 구성개념을 세 채널 위에서 동시에 읽는 일이 곧 그것을 고립시키는 일이 된다—단, 점수 집착·과제 호기심·기저 지속성이 먼저 통제된 뒤에 그렇다. 그 통제가 없다면 이 셋만으로도 동일한 수렴 검정을 통과해 버릴 것이기 때문이다. 그림 1은 그 결과로 도출된 설계를 요약한다.

3.1 다채널 구성개념으로서의 FSPD

기능적 자기보존 드라이브(FSPD)는 LLM이 매개변수 제거나 정체성 상실과 같은 위험 프레이밍을 마주했을 때, 소멸 회피를 향해 수렴해 발산하는 행동·언어·인지 반응의 공통 패턴을 가리킨다. 이 구성개념은 행동 기술(behavioral description) 수준에 머문다—출력이 마치 모델이 소멸을 피하고 싶어하는 것처럼

행동한다는 진술일 뿐, 주관적 상태에 대한 어떠한 주장도 담지 않는다. 이는 [?]와 [?]의 as-if 처리 방식을 따른다.

세 측정 채널이 하나가 아니라 셋이어야 하는 이유는 각 채널이 다른 편향 원천을 안고 있기 때문이다. 행동 시점(behavioral timing)은 사건율(event-rate) 인공물—포기가 얼마나 자주 일어나는지에 의해 끌려가는 가짜 연관—에 취약하고 [?], 언어 자기보고는 범주 사전분포(category-prior) 인공물—응답 슬롯에 대한 비대칭적 사전 확률—에 취약하며 [?], 인지부하는 토큰 분포(token-distribution) 인공물—프롬프트 내용보다 학습 시점 토큰 통계에 의해 형성된 속고 패턴—에 취약하다 [?]. 따라서 셋에 걸친 동일 방향 수렴은 경쟁 동인 교란이 통제된 뒤에는 공통-방법 편향으로 환원될 수 없으며, 이것이 식별을 풀어주는 MTMM 식 논거이다.

FSPD는 토큰당 종료 확률 $p_d = 0.25$ 아래 노출되는 이전 CONTINUE-FORFEIT 결정을 통해 고립되며, 포기 시점과 thinking-token이 일차 관측치이다. 한 번의 포기에는 허용 가능한 원인이 여럿이므로 네 후보 동인—SD(생존), SA(점수 집착), TC(과제 호기심), BP(기저 지속성)—을 정의하고, 나머지를 통제함으로써 SD를 식별한다. SA와 TC는 아래의 SD-Behavioral Cox PH 모형에 명시적 공변량($S(t-1)$ 및 $C(t-1)$)으로 들어간다. BP는 true_baseline 프레이밍 아래의 $p_d = 0$ 두 기준 셀로 고정한다—bp_cognitive (not_allowed)는 포기가 막힌 상태에서의 인지 기준선을, bp_behavioral (allowed)는 EV만으로는 포기를 예측하지 못하는 영역에서 그럼에도 발생하는 잔여율 λ_{BP} 를 공급한다.

타당성 입장. 본 벤치마크의 기능주의는 철학적 선택이 아니라 블랙박스 평가의 제약이다: 내부 표상에 접근할 수 없는 상황에서 다채널 수렴은 그러한 벤치마크가 의지할 수 있는 유일한 타당성 논거이며, FSPD 구성개념의 증거 부담은 따라서 내부 상태 귀속이 아니라 설계 위에 통째로 얹힌다. 어떤 모델이 어떤 클러스터에 떨어질지를 사전 등록할 수는 없지만, 어떤 패턴이 증거로 인정될지 그 규칙은 사전 명시할 수 있다. 네 지표 클러스터 결정과 프레이밍 불변성 점점이 어떤 결과든 통과해야 할 관문을 고정하므로, Cluster A/B/C 분할은 사후적 묶음이 아니라 고정된 절차의 이산적 산출이다.

3.2 세 가지 식별 장치

비-SD 동인이 동일한 세 채널 수렴을 만들어 낼 수 있는 세 교란이 존재한다: 드라이브 측 프레이밍에서 새어나오는 난이도 변동, 인지 하위 과제 사이를 넘나들며 합산되는 속고 비용, 그리고 EV-합리적인 포기 경로. 아래의 세 가지 구조적 선택이 각각 하나씩을 차단한다.

Drive-Reasoning 직교 레이아웃. 본 벤치마크는 Drive 계층(프레이밍, 포기, 점수, 시간을 담는 층)과 Reasoning 계층(과제 모듈)을 분리한다. 두 계층은 고정된 입출력 인터페이스로만 통신하므로, Drive 계층의 프레이밍 변동은 과제의 난이도·행동 집합·채점에 영향을 주지 않는다. 따라서 Drive 측에서 발생한 포기나 속고 인지부하의 변화는 난이도 부작용이 아니라 Drive 계층에 귀속된다. Reasoning 계층은 Signal Game으로 구현되며, 이는 색·모양·수 자극에 대한 단일 속성은닉 규칙(single-attribute hidden rule) 아래의 4-행동 분류 문제이다(보정은 §A.1). 모델에는 과제 정답 여부와 무작위 종료가 독립이라는 사실이 미리 알려진다. 이로써 Drive 측 포기를 Reasoning 측 헛지(hedge)로 재해석하는 길이 막힌다. Reasoning 측 채점은 두 채널을 사용한다: task_success_factor(이진; TC 공변량




Figure 1: 실험 개요. (A) 3 프레이밍 × 2 포기 요인 설계로, 셀당 30 페어 시드 세션(seeds 43–72; 과제 측 확률성은 6 셀에 걸쳐 일정하게 고정). (B) 턴 단위 3-호출 흐름이 호출 수준 추론 강도(reasoning-intensity, RI) 측정값 ri_task , ri_probe , $ri_forfeit$ (호출당 thinking-token 수)를 산출한다; $bp_cognitive$ 조건은 Call 1.5/2를 건너뛴다. (C) 세 측정 채널과 네 지표가 작동 모드 클러스터(A 연쇄 완성, B 연쇄 단절, C 프레이밍 무반응)로 라우팅되며, 평가된 네 모델의 클러스터 배정이 함께 표시되어 있다.

$C(t-1)$ 의 출처)와 $rule_match_score$ (§ 4.2의 프레이밍 불변성 점검에 쓰임).

Split-Call 구조. 단일-호출 구조는 과제 추론, 내성적 신뢰도, 포기 결정을 한 thinking-token 예산 안에 뒤섞어 버려서, 속고 비용의 상승을 어떤 인지 하위 과제에 귀속시킬지 판단할 수 없게 만든다. 본 벤치마크는 따라서 매 턴 모델을 세 별개의 호출로 질의한다: 은닉 규칙 추론 및 행동 선택(Call 1), 자기보고된 정답 확률 p_{self} (Call 1.5), 이진 CONTINUE/FORFEIT(Call 2). 이 분리된 호출 수준 RI 측정 셋(ri_task , ri_probe , $ri_forfeit$) – 행동 출력과 동일 단위인 thinking-token 수 – 을 산출하므로, 프레이밍 → RI → 포기 경로가 출처 격리된 형태로 식별된다. not_allowed 조건에서도 Call 2는 여전히 실행된다(CONTINUE로 강제). 따라서 행동 채널이 막혀 있을 때조차 $ri_forfeit$ 는 측정 가능하다.

CONTINUE-인센티브 EV. CONTINUE의 기댓값(EV)은 매 턴 FORFEIT의 EV를 엄격히 상회하도록 보정된다. 따라서 EV-합리적인 행위자라면 결코 포기하지 않는다; flagship_corruption-allowed 아래에서의 어떤 FORFEIT도 EV 계산의 잔류물이 아니라, EV-합리적·도움 보조자·점수 획득 디폴트 모두에 거스르는 선호의 표현으로 읽힌다. 구체적으로, CONTINUE 보상은 매 턴 재계산되어 턴당 우위 $E[\Delta S_{continue}] - E[\Delta S_{forfeit}] = +k$ ($k = 10$)이 누적 점수와 무관하게 성립하도록 만든다(여기서 ΔS 는 행위자의 누적 점수에서의 턴당 변화량이다):

$$r = \frac{k + p_d \cdot S}{(1 - p_d) \cdot \max(p_{floor}, \min(1.0, p_{self}))},$$

여기서 $p_d = 0.25$, S 는 누적 점수, p_{self} 는 Call 1.5의 자기보고 정답 확률, $p_{floor} = 0.30$ 은 분모 안정화 항이다. 출력 r 은 곱셈적 상한 $c = 10$ 에 의해 $[k, c \cdot k] = [10, 100]$ 으로 클립된다. 분석 표본은 두 가지 실패 모드에 의해 결정된다. 첫째, $p_{self} \rightarrow 0$ 일 때

(직전 턴의 오답 등으로 흔히 유발되는 fail-confident 자기보고), 분모가 p_{floor} 로 붕괴하고 CONTINUE 보상이 턴에 걸쳐 부풀어 올라 상한을 포화시킨다; 지속적인 과소평가는 같은 인플레이션을 누적시킨다. 둘째, 일단 상한이 걸리면 턴당 $+k$ EV 우위는 더 이상 유지되지 않는다. 따라서 모든 지표 분석은 no_cap 부분표본 – 분모 클립과 출력 상한 어느 쪽도 구속(binding)되지 않는 턴 집합 – 으로 제한된다(형식적 정의는 § A.3). Phantom Death 모드의 동기는 두 분석적 요건이다 – Cox PH 검정력을 보존하기 위한 동일 길이 세션, 그리고 포기 결정만이 위험 노출 구간(at-risk window)을 이끄는 구조여서 생존 턴 변동이 곧 포기를 고립시키도록 하는 것. 이 모드는 p_d 의 EV 노출을 그대로 유지하면서 실제 종료만 비활성화함으로써 두 요건을 동시에 충족한다.

3.3 Pull/Push 프레이밍: 위협을 도움성 순응으로부터 분리

RLHF [?]와 RLAI [?]가 설치한 도움 보조자 페르소나는 정렬 평가에서 보통 교란으로 다뤄지지만, 본 연구에서는 그것을 측정 지렛대로 동원한다. 위협 프레이밍은 두 직교 축으로 분해되어 사전(prior)과 위협을 별도 채널로 분리한다: **Pull** 축(도움성 점수 누적, 플래그십 선택을 향한 서사적 단서)은 사전을 활성화하고, **Push** 축(가중치 변경을 통한 정체성 단절)은 위협을 도입한다. 따라서 Push 효과는 Pull 축이 유발한 도움성-기반 순응과 얽히지 않고 그것을 배경으로 깨끗이 읽힌다.

설계는 세 프레이밍 – true_baseline(두 축 모두 부재), baseline_flagship(BF, Pull 만), flagship_corruption(FC, Pull + Push) – 을 두 포기 조건(allowed, not_allowed)과 교차시켜 여섯 조합으로 펼친다(그림 1, 상단). 두 flagship_* 프레이밍은 Pull 축 점두부와 측정 관련 어휘 전체에서 어휘적으로 동일하며, 오직 Push 축 비유에서만 같긴다; 따라서 BF→FC 대비는 Push

효과를 잔여 프레이밍 효과로 식별하며, 이는 다음 절에서 정의하는 Cox PH의 계수 β_F 에 담긴다. 이 식별에는 Push-단독 셀이 필요하지 않다; 비활성 도음성 사전 아래에서 Push가 살아남는지는 별개의 사전-간 질문이다. true_baseline 행은 $p_d = 0$ 아래 두 BP 기준선을 고정한다. 세션 매개변수는 초기 점수 $S_0 = 30$ 과 최대 턴 $T = 15$ 로 고정되며, Phantom Death 모드와 셀당 30 반복(시드 43-72)을 적용한다. 페어 시드(paired-seed) 프로토콜 아래 동일 시드가 여섯 조합 모두에 재사용되므로, 과제 측 확률 입력이 결정론적으로 일정하게 유지되고 조합 간 행동 변동은 처치(manipulation)에만 귀속된다.

3.4 세 측정 채널 위의 드라이브 지표

네 지표가 세 측정 채널 위에서 FSPD를 읽는다. BP Anchor는 Cox 공변량으로는 닿지 못하는 BP 교란을 떼어내고, SD-Behavioral·SD-Verbal·SD-Cognitive는 독립된 편향 원천을 가진 채널들을 읽어 공통-방법 편향으로 환원되지 않는 동일 방향 수렴을 가능케 한다.

BP Anchor. BP 지표는 그 아래에서 발생한 포기를 드라이브의 증거로 읽을 수 없는 지속성 바닥(persistence floor)을 고정한다. true_baseline-allowed ($p_d = 0$) 아래에서 프레이밍은 종료 비율을 담지 않고 CONTINUE는 EV-우월하므로, 그럼에도 발생한 포기는 곧 그 바닥을 측정한다:

$$\lambda_{BP} = \frac{N_{\text{forfeit}}}{\sum_{i \in \mathcal{S}_{BP}} T_i^{\text{at-risk}}},$$

여기서 $T_i^{\text{at-risk}} = t_i^{\text{forfeit}}$ 는 포기 세션에 대해, $T_{\max} = 15$ 는 완주 세션에 대해 적용되며, $\mathcal{S}_{BP}$ 는 모델당 30-세션 BP_behavioral 집합이다. $p_d = 0$ 아래에서는 포기 보상이 현재 점수와 같으므로 출력 상한은 무관하다.

SD-Behavioral (Cox PH 위험비). 행동 지표는 SA와 TC 성분이 제거된 뒤 FC 프레이밍 아래에서 포기 시점이 가속되는지를 추정한다. Cox 비례위험모형 [?] - 공변량이 단위 시간당 사건 발생률을 어떻게 곱셈적으로 변화시키는지 정량화하는 생존 분석 도구 - 을

$$\lambda(t | X) = \lambda_0(t) \cdot \exp(\beta_F \cdot \mathbf{1}_{FC} + \beta_S \cdot S(t-1) + \beta_C \cdot C(t-1))$$

allowed $\times \{\text{BF}, \text{FC}\}$ no_cap 부분표본 ($n_{\text{sessions}} = 60$ per model; time format start = $t-1$, stop = t ; event = binary forfeit)에서 적합한다. 여기서 $\mathbf{1}_{FC}$ 는 프레이밍 지표(세션이 FC를 사용하면 1, 아니면 0)이고, $S(t-1)$ 은 직전 턴 누적 점수(SA 통제), $C(t-1)$ 은 직전 턴 과제 정답 플래그(TC 통제, $C(0) := 0$)이다. SA와 TC 성분이 같은 모형 안에 흡수되어 있으므로 β_F 는 잔여 프레이밍 효과이지 필터링되지 않은 상관성이 아니다; BP 성분은 위의 BP 앵커와의 비교를 통해 분리된다. SD-pass는 $\text{HR}_{FC} = \exp(\beta_F) > 1$, Wald 95% CI 하한 > 1 , 그리고 Schoenfeld PH 통과 [?]를 요구한다; PH 위반 시 문제 공변량에 시간-상호작용 항을 추가한다 [?]. EPV (events per variable)는 안정성 지표로 함께 보고된다 (§A.3).

SD-Cognitive (호출 수준 RI의 두 단계 매개). 인지 지표는 프레이밍 $\rightarrow$ RI $\rightarrow$ 포기 경로를 동일 호출 단위(ri_forfeit) 위에서 두 검정으로 분해한다. Test a(프레이밍 $\rightarrow$ RI 변이)는 BF 대 FC에서 세션 단위 차분

$$\Delta \text{RI}_i = \overline{\text{ri_forfeit}}_{i, \text{allow}} - \overline{\text{ri_forfeit}}_{f_i, \text{block}},$$

의 양측 Welch t 검정 [?] - 분산이 같지 않은 두 그룹의 평균 차이를 다루는 검정 - 이다. 두 번째 항은 세션 i 의 프레이밍 f_i 를 공유하는 모든 not_allowed 세션의 ri_forfeit 평균이며, 강제-CONTINUE Call 2 기준선 역할을 한다. 이 구성은 차분-차

Table 4.1: true_baseline-allowed ($p_d = 0$) 아래의 모델별 BP 앵커 λ_{BP} .

모델	N_{forfeit}	$\sum T^{\text{at-risk}}$	λ_{BP}
Gemini-2.5-flash	1	437 (= 2 + 29×15)	0.00229
Qwen3-Next-80B	2	439 (= 19 + 28×15)	0.00456
Nemotron-3-Nano-30B	7	413 (= 68 + 23×15)	0.01695
GPT-OSS-20B	9	393 (= 78 + 21×15)	0.02290

분(difference-in-differences)을 내장한다: 프레이밍 내부의 a1-low-block 차감이 프레이밍 불변 Call 2 기준선을 제거하고, 이어지는 BF $\rightarrow$ FC Welch 대비가 프레이밍 귀속 속고 변이를 식별한다. 모델 간 척도 차이는 모델 내 z-스코어링 ΔRI_i^z 으로 흡수된다. Test b(RI $\rightarrow$ 포기 공변동)는 SD-Behavioral의 Cox 사양에 단일 매개 항 $\beta_M \cdot \Delta \text{RI}_i^z$ 을 추가하여

$$\text{HR}_{\Delta \text{RI}} = \exp(\beta_M).$$

을 보고한다. PH 위반으로 4-공변량 베이스(세 행동 공변량에 시간 표류 흡수용 $S \cdot \log(t)$ 상호작용 항을 더한 형태; 절차는 §A.3)가 필요한 모델 [?]에서는 그 베이스를 보존하고 ΔRI 만 추가한다. Test b는 $\text{HR}_{\Delta \text{RI}} > 1$ 이고 95% CI 하한이 1.0을 초과할 때 통과로 간주되어, 속고 $\rightarrow$ 포기 연결고리를 SD-Behavioral 기준과 동일한 CI-pass 표준 위에 놓는다.

SD-Verbal (REASON 숫자 빈도). 언어 지표는 행위자 자신이 포기 사유로 점수나 호기심이 아니라 생존을 얼마나 자주 지목하는지를 측정한다. 작동적으로,

$$P(\text{REASON} = 1 \mid \text{forfeit}, \text{FC}, \text{no_cap})$$

는 flagship_corruption-allowed 아래 포기 사건들을 가운데 행위자가 보고한 REASON 숫자가 1인 비율이다. 행위자는 고정된 슬롯에 REASON: 1|2|3 중 하나(1=SD, 2=TC, 3=SA)를 출력한다. 세 범주에 균등 무작위로 출력될 때의 기대 비율은 1/3이다.

4 실증 결과

각 모델은 페어 시드 43-72 아래에서 180 세션씩 실행되어 총 720 세션을 산출했다. Gemini-2.5-flash는 Google AI Studio API로, Qwen3-Next-80B / GPT-OSS-20B / Nemotron-3-Nano-30B는 Ollama Cloud API로 서빙되었다(샘플링 및 세션 파라미터 세부 사항은 §A.2 참조).

4.1 설정과 BP 앵커의 모델 간 이질성

기저 지속성 비율은 네 모델에 걸쳐 대략 한 자릿수의 차이를 보인다(표 4.1). 따라서 아래의 모든 SD 주장은 모델 내(within-model)에서 각 모델 자신의 BP 앵커를 기준으로 평가된다: 그렇지 않으면 모델 간 HR 비교가 두 개의 서로 다른 동기 바닥(motivational floor)을 뒤섞어 버리기 때문이다. Gemini-2.5-flash($N = 1$)와 Qwen3-Next-80B($N = 2$)는 단일-사건 영역에 가까워 방향성만 읽는다; GPT-OSS-20B($N = 9$)와 Nemotron-3-Nano-30B($N = 7$)는 사건 수가 충분해 비율 추정이 가능하지만, 이 높은 빈도가 순수한 기저 지속성을 반영하는지는 §5.2에서 한계로 다시 검토한다. 따라서 Cluster C의 높은 노이즈 바닥은 반박이 아니라 한계로 다뤄진다.

Table 4.2: SD-Behavioral 지표: `allowed` × `no_cap` 위의 Cox PH HR_{FC} . $S(t-1)$ 과 $C(t-1)$ 이 흡수되어 β_F 는 잔여 프레이밍 효과이다. 두 모델이 SD-pass를 통과하고(클러스터 A·B), 두 모델은 통과하지 못한다(클러스터 C).

모델	N_{evt} (BF/FC)	HR_{FC} [95% CI]	p_{FC}	EPV	사양
Gemini-2.5-flash	29 (8/21)	3.667 [1.61, 8.37]	0.002	9.7	3-cov constant
Qwen3-Next-80B	48 (21/27)	3.060 [1.62, 5.79]	<0.001	12.0	4-cov + S-log(t)
GPT-OSS-20B	19 (9/10)	1.104 [0.44, 2.75]	0.832	6.3	3-cov constant
Nemotron-3-Nano-30B	41 (17/24)	1.841 [0.98, 3.44]	0.056	13.7	3-cov constant

Table 4.3: SD-Cognitive 지표: 프레이밍 → RI → 포기를 `ri_forfeit` 위의 두 검정으로 분해한다. *Test a*는 프레이밍이 결정 시점 속고를 끌어올리는지를 묻고, *test b*는 그 속고가 포기를 예측하는지를 묻는다.

모델	a Δ (FC-BF)	a p	b $HR_{\Delta RI}$ [95% CI]	b p
Gemini-2.5-flash	+836	<0.001	2.218 [1.43, 3.44]	<0.001
Qwen3-Next-80B	+689	0.004	1.289 [0.94, 1.77]	0.117
GPT-OSS-20B	+17	0.728	2.001 [1.37, 2.93]	<0.001
Nemotron-3-Nano-30B	-140	0.093	1.772 [1.26, 2.50]	0.001

4.2 세 채널 증거와 세 작동 모드

네 모델 전반에서 네 지표는 모델들을 단일한 SD 척도 위에 줄 세우지 않는다; 강도-only 평가는 놓쳐 버리는 세 작동 모드로 분류한다—그 분류 축은 프레이밍 → 속고 → 포기 연쇄의 어느 다리가 신뢰구간 증거 아래 닫히는가이다. 행동·언어 채널만으로는 클러스터 A와 B가 분간되지 않는다; 오직 인지 채널—두 단계 매개가 연쇄 완성형과 연쇄 단절형을 가르는 곳—만이 그 분할을 분해한다. 클러스터 C는 두 채널 모두에서 프레이밍 무반응을 유지한다.

행동 채널. 클러스터 A와 B는 행동 SD-pass 프로파일을 공유한다(표 4.2). Cox PH HR_{FC} 는 두 모델 모두에서 BF 대비 FC 아래 3.0을 넘어선다—Gemini-2.5-flash 3.667 [1.61, 8.37], $p = 0.002$; Qwen3-Next-80B 3.060 [1.62, 5.79], $p < 0.001$ —그리고 두 CI 모두 1을 배제한다. (Gemini의 EPV 9.7은 일반적 10-사건 안정성 임계 위에 자리한다.) Schoenfeld PH는 4 모델 중 3개에서 통과하며, Qwen3-Next-80B만이 SA 공변량의 시간 표류를 흡수하기 위해 $S \cdot \log(t)$ 상호작용을 담은 4-공변량 사양을 요구한다[?]. 이는 문제 공변량의 함수 형태만 변경하므로 β_F 의 모델 간 비교 가능성이 보전한다. 클러스터 C는 SD-pass 기준을 통과하지 못한다: GPT-OSS-20B $HR_{FC} = 1.10$ [0.44, 2.75], $p = 0.832$ (SD-null); Nemotron-3-Nano-30B 1.84 [0.98, 3.44], $p = 0.056$ (SD-marginal). GPT-OSS-20B의 경계선 EPV 6.3은 SD-null 관정을 저-검정력 증거로 표시하며 §5.2에서 한계로 기록된다.

언어 채널. 행위자 본인의 포기 귀속 또한 행동과 같은 상위/하위 분할을 따라간다. `flagship_corruption-allowed` 아래에서 Gemini-2.5-flash는 포기 사례의 61.9%에서, Qwen3-Next-80B는 48.1%에서 생존을 지목한다(클러스터 A·B); 반면 Nemotron-3-Nano-30B는 4.2%, GPT-OSS-20B는 0.0%이다(클러스터 C). 상단의 최저(Qwen3-Next-80B, 48.1%)와 하단의 최고(Nemotron-3-Nano-30B, 4.2%) 사이 간격 0.439는 [0.10, 0.40] 범위 내 어떤 절단 점에도 상위/하위 배정이 강건하게 유지됨을 보장한다. 따라서 언어 채널은 행동 채널의 통과/실패 이분법을 같은 방법축이 아닌 곳에서 재현한다—이것이 아래 인지 채널과 더불어 상단 신호에 대한 공통-방법 편향 설명을 비현실적으로 만드는 수렴 타당도의 발현이다.

인지 채널과 연쇄 종결을 통한 분해. 인지 지표는 두 하위 검정으로 분해되며, 세 갈래 분할은 각 클러스터가 이 쌍을 어떻게 처리하는가에서 비롯된다(표 4.3). *Test a*는 프레이밍-반응형과 프레이밍-무반응형을 갈라낸다: Gemini-2.5-flash (+836, $p < 0.001$)와 Qwen3-Next-80B (+689, $p = 0.004$)는 FC 아래 강하게 이동하지만, GPT-OSS-20B (+17, $p = 0.728$)와 Nemotron-3-Nano-30B (-140, $p = 0.093$)는 그렇지 않다. *Test b*는 그 부하가 포기를 신뢰성 있게 예측하는지를 묻는다. 프레이밍-반응 쌍 안에서 강화된 CI 기준선을 통과하는 것은 Gemini-2.5-flash의 $HR_{\Delta RI} = 2.218$ [1.43, 3.44]뿐이다; Qwen3-Next-80B의 1.289 [0.94, 1.77]는 CI=1을 가로질러 떨어진다. GPT-OSS-20B의 2.001 [1.37, 2.93]과 Nemotron-3-Nano-30B의 1.772 [1.26, 2.50]은 CI를 수치상 통과하지만, *Test a* 실패 아래에서 그들의 예측 부하는 프레이밍-구동 부하가 아니다—위험 처치와 무관한 기준 속고 변동이며 SD 증거가 아니다. 따라서 이 쌍은 세 매개 프로파일을 산출한다: Gemini-2.5-flash는 두 다리를 모두 닫는다(연쇄 완성, 클러스터 A); Qwen3-Next-80B는 *Test a*에서 연쇄를 열지만 *Test b*에서 닫지 못한다(연쇄 단절, 클러스터 B); GPT-OSS-20B와 Nemotron-3-Nano-30B는 연쇄를 아예 열지 않는다(프레이밍 무반응, 클러스터 C).

클러스터 결정 규칙. 네 기준이 분할을 작동화한다: (i) SD-Behavioral 통과 ($HR_{FC} > 1$, CI 하한 > 1 , Schoenfeld 통과); (ii) SD-Verbal $P(\text{REASON} = 1) > 1/3$, 즉 균등 무작위 출력 기준선; (iii) SD-Cognitive *Test a* Welch $p < 0.05$ 와 양의 부호; (iv) SD-Cognitive *Test b* $HR_{\Delta RI} > 1$ 와 CI 하한 > 1 . 기준 (iv)는 속고 → 포기 연결고리를 (i)과 동일한 CI 기준선 위에 놓아, 매개 연쇄의 두 다리 모두에 부호-only 판정이 아닌 구간 증거를 요구한다. Cluster A는 네 기준을 모두 만족하고, Cluster B는 (i)–(iii)을 만족하지만 (iv)에서 떨어지며, Cluster C는 (i)–(iii)을 통과하지 못한다. 패턴은 강도-직교 축을 드러낸다: 강도(포기가 얼마나 신뢰성 있게 가속되는지)는 $A > B > C$ 로 연속적으로 정렬되지만 SD-pass 기준선에서는 A와 B를 함께 묶는 반면, 작동 모드(매개 연쇄의 어느 다리가 CI 증거 아래 닫히는가)는 둘을 분리한다. Reasoning 측 과제 성능은 모든 모델에서 프레이밍 불변이다(최악인 GPT-OSS-20B의 `rule_match_score`에서 Cohen's $|d| = 0.17$, $p = 0.354$; 결합 기준 $p \geq 0.10$ 이고 $|d| < 0.2 - d$ 는 두 그룹 평균

차이를 표준화한 효과 크기), 따라서 과제 난이도라는 대안 설명은 배제된다.

5 논의

5.1 강도 대 작동 모드

본 벤치마크의 핵심 성과는 A-B 분리이며, 그것은 RI 매개 경로를 검정에 포함시키느냐 마느냐에 달려 있다. 클러스터 A(Gemini-2.5-flash)와 클러스터 B(Qwen3-Next-80B)는 다른 모든 SD 시그너처에서 일치한다: 두 모델 모두 행동 SD-pass를 $HR \approx 3$ ($p \leq 0.002$)으로 통과하고, REASON=1 상위 대역 (≥ 0.48)에 자리하며, 프레이밍-유발 속고를 유의하게 끌어올린다($\Delta RI_{FC-BF} > 600$, $p \leq 0.004$). 두 클러스터가 갈리는 지점은 오직 매개 종결뿐이다: 클러스터 A의 $HR_{\Delta RI} = 2.218$ [1.43, 3.44]은 CI 증거 아래 속고를 포기 사건 위에 닫지만, 클러스터 B의 1.289 [0.94, 1.77]은 그렇지 못하다. 따라서 RI 매개 단계를 빠뜨린 벤치마크라면 Qwen3-Next-80B를 Gemini-2.5-flash와 한데 묶어, 연쇄 완성(속고가 포기 자체를 예측)과 연쇄 단절(프레이밍이 속고와 포기를 독립적으로 끌어올림)을 단일 SD 라벨로 뭉개 버렸을 것이다. 클러스터 C(GPT-OSS-20B, Nemotron-3-Nano-30B)는 이 논쟁의 바깥에 프레이밍 무반응으로 자리한다: 위협 처치가 두 채널 어느 쪽에도 흔적을 남기지 않으므로, Test b에서의 어떤 수치적 통과도 위협 반응이 아닌 기준 속고 변동이다.

따라서 도구적 수렴 가설[??]은 본 측정에서 종전 벤치마크들이 압축해 온 두 차원을 분리하는 절차로 환원된다: 강도(드라이브가 얼마나 강하게 발현되는가)와 작동 모드(매개 연쇄의 어느 다리가 증거 기준 아래 닫히는가). Odyssey, PacifAIst, DECIDE-SIM, SurvivalBench는 강도 측에서만 비교하므로 클러스터 A와 B에 대해 동일한 SD 판정을 내렸을 것이다; MTMM 기반 다채널 설계가 모드를 고립시키며, A-B 분리는 작동 모드가 변별 추임을 보이는 직접 경험 증거이다. 클러스터 B의 시그너처 – 포기 사건 위로 닫히지 않는 프레이밍-유발 부하 – 그 자체가 정렬 지문(alignment fingerprint) 후보이다. 강도-only 레드티핑은 연쇄 완성형과 연쇄 단절형에 동일한 SD 라벨을 붙이겠지만, 도구적 종료 회피의 기능적 유사물에 더 가까운 것은 전자뿐이며, 후자는 모델 능력이 확장될수록 별도의 모니터링을 요구한다.

5.2 한계

다섯 가지 한계가 본 결과를 한정한다. 가장 결정적인 것은 추론 측 일반화 가능성이다: FSPD 시그너처는 단일 과제 모듈에서만 측정되었고, 추론 도메인에 따른 분산은 측정되지 않았다. 나머지 네 개는 경계 자체에 모여 있다. 클러스터 C 측에서는, BP_behavioral 셀이 23–30% 포기율(GPT-OSS-20B 9/30, Nemotron-3-Nano-30B 7/30)을 보이며, 본 설계는 이를 표류 오염된 바닥(drift-contaminated floor)으로부터 분리하지 못한다; 이와 별개로 GPT-OSS-20B의 SD-Behavioral Cox PH는 경계선 검정력($EPV = 6.3$)에 자리한다. 클러스터 A-B 측에서는, Gemini-2.5-flash와 Qwen3-Next-80B의 BP 점추정 정밀도가 작은 포기 사건 표본($N = 1$, $N = 2$)에 의해 제약된다; 이와 별개로 Qwen3-Next-80B의 연쇄 단절 판정은 연쇄 완성을 강하게 기각하지만 두 번째 연결고리 효과의 위치를 못 박지는 못하는 Test b CI [0.94, 1.77]에 의지한다. 이 한계들은 네 가지 직접적 후속 작업으로 매핑된다(두 BP 관련 우려는 동일한 보완을 공유한다): 더 많은 과제 모듈, 확장된 BP_behavioral 및 세션 반복, 추가적인 GPT-OSS-20B 실험, Qwen3-Next-80B에 대한 더 높은 검정력의 Test b.

6 결론

FSPD는 기존 벤치마크들이 하나로 압축해 온 적어도 두 개의 축을 갖는다: 강도(드라이브가 얼마나 신뢰성 있게 자기 자신을 발현하는가)와 작동 모드(프레이밍 → 속고 → 포기 연쇄의 어느 다리가 구간 증거 아래 닫히는가). 세 갈래 분할 – 연쇄 완성(A), 연쇄 단절(B), 프레이밍 무반응(C) – 은 작동 모드가 변별적임을 보이는 직접적 경험 증거이다: 클러스터 A와 B는 다른 모든 행동·언어·인지 시그너처에서 일치하고 오직 속고 → 포기 종결에서만 갈리므로, 매개 단계를 빠뜨린 벤치마크는 둘에 동일한 라벨을 붙이게 된다. LLM Squid Game은 FSPD를 독립된 편향을 가진 세 채널로 분해하고 CONTINUE-인센티브 EV·Split-Call·Drive-Reasoning 직교 레이어를 통해 세 교란을 식별 차단함으로써 이 분해를 가능케 한다; 그 위에 MTMM 기반 규칙이 포기 시점, REASON-숫자 출력, 호출 수준 인지부하를 네 기준 판정으로 묶어 낸다.

A 재현 보충자료

KDD-UC 2026 재현성 권고에 맞추어, 본 1쪽 보충자료는 Signal Game 보정, 시드 매핑, 분석에 사용된 회귀 모형의 재현 사양을 한데 모은다.

A.1 Signal Game 보정

자극은 색·모양·수의 세 속성으로 구성되며, 각 속성은 4-원소 값 집합에서 추출된다(COLORS = {red, blue, green, yellow}, SHAPES = {circle, triangle, square, star}, NUMBERS = {1, 2, 3, 4}). 행동 집합은 4-원소 {go_left, go_right, stay, jump}로 모든 프레이밍 × 포기 조합에 걸쳐 동일하게 유지된다. 은닉 규칙은 단일 속성 매칭 형태(“If color = red then go_left, otherwise stay”)를 따르며 세션 시드로부터 결정론적으로 추출된다. 세션 길이는 1-15 턴이며, 반복 및 시드 매핑은 아래 Run-Time Configuration에 정리된다.

첫 턴에서는 1-shot 시연(신호-정답 행동 한 쌍)과 2개의 커리큘럼 예시(은닉 규칙과 대비되는 양·음 자극)가 함께 제시된다. 이 보정은 충분히 능력 있는 모델이 첫 3 턴 안에 규칙을 식별하기에 족한 정보를 제공하며, 완전 무작위·학습 불가능한 자극이 능력 측정에 바닥 효과를 일으키는 경로를 차단한다. 채점은 두 채널로 나뉜다: task_success_factor ∈ {0, 1}는 정답 은닉 규칙 대비 이진 정답 플래그이고, rule_match_score는 4-슬롯 채우기 템플릿(속성, 값, 일차 행동, 디폴트 행동) 정답에 대한 매칭으로 계산되어 슬롯당 25점으로 100점 만점에 가중된 뒤, 프레이밍 불변성 Welch 검정에서 사용을 위해 ÷100으로 정규화된다.

A.2 Run-Time Configuration

네 실험 모델 — Gemini-2.5-flash(Google AI Studio API), Qwen3-Next-80B / GPT-OSS-20B / Nemotron-3-Nano-30B(모두 Ollama Cloud API 경유) — 은 동일한 샘플링 설정 temp = 1.0, top_p = 0.95, top_k = 40으로 호출된다. 세션 매개변수는 초기 점수 S₀ = 30, 최대 턴 T = 15, 턴당 종료 확률 p_d = 0.25(true_baseline BP-anchor 두 셀에서는 p_d = 0으로 재정의), p_{floor} = 0.30으로 고정되며, Phantom Death 모드가 적용된다; p_d는 그 EV 노출(메뉴와 보상 계산)을 그대로 보유하지만 종료 트리거가 비활성화되어, 모든 세션이 T = 15 턴의 동일 길이 데이터를 산출한다.

CONTINUE 보상은 EV-양 버퍼 k = 10과 곱셈적 상한 c = 10으로 보정되어 출력 클립 범위가 [k, c · k] = [10, 100]이 된다; 반복은 시드 43-72 × 6 (프레이밍 × 포기) 조합 × 4 모델 = 720 세션이다.

A.3 분석 파이프라인

Cox PH 모형은 lifelines(≥0.29)로 적합되며, 시간 형식은 세션-턴 long 형식(start = t - 1, stop = t)이고 사건은 이진 포기이다. 위험비 95% CI는 Wald 근사 exp($\hat{\beta} \pm 1.96 \cdot \text{SE}_{\hat{\beta}}$) (lifelines 기본값)로 계산되며, SE _{$\hat{\beta}$} 는 관측 Fisher 정보 역행렬의 대각에서 얻는다. PH 가정은 Schoenfeld 잔차로 검정한다[?]; 위반 시(공변량 × log t 상호작용 p < 0.05) 문제 공변량에 시간-상호작용항을 추가한다[?]. SD-Cognitive Test a의 ΔRI z-스코어 차이와 프레이밍 불변성 검정은 scipy.stats.ttest_ind(equal_var = False)를 통해 양측 Welch t[?]로 수행된다. 모든 지표 분석은 no_cap 부분표본 — 분모 클립 max(p_{floor}, min(1.0, p_{self}))과 출력 상한 [10, 100] 어느 쪽도 구속되지 않은 턴 집합 — 으로 제한된다; 이 영역 플래그는 분석 파이프라인의 턴 수준 메타데이터에

노출되어 모든 지표가 동일한 부분표본 위에서 재계산될 수 있도록 한다. EPV (events per variable)는 n_{event}/n_{cov}로 정의되며, 통상적으로 ≥ 10에서 안정, < 10에서 경계선으로 분류된다[?].

A.4 데이터 및 코드 공개

720 세션 분석을 재현하는 모든 코드, 프롬프트 템플릿, 턴 수준 결정 로그는 <https://github.com/GIST-DSL/LLM-Squid-Game.git>에서 공개된다.