

LLM Squid Game: 대규모 언어모델의 기능적 자기보존 드라이브를 측정하기 위한 요인 설계 벤치마크

Juhyeon Park
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
juhyeon-park@gm.gist.ac.kr

Seungpil Lee
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
iamseungpil@gm.gist.ac.kr

Sundong Kim
Gwangju Institute of Science and
Technology (GIST)
Gwangju, Republic of Korea
sundong@gist.ac.kr

Abstract

본 연구는 LLM의 *기능적 자기보존 드라이브*(Functional Self-Preservation Drive, FSPD)를 행동·자기보고·결정 시점 인지부하 채널을 통한 측정값의 수렴 양상으로 정의하고, 이를 측정하는 벤치마크를 제안한다. 생존 욕구가 모델의 사고 과정 중 어느 단계에 영향을 주는 지 측정하기 위해 자극·처리·결정 세 층을 분리한 다층 구조의 벤치마크 위에서 이 흐름을 읽는다. 여러 최신 LLM에서 FSPD는 단일 채널 평가로 환원되지 않으며, 모델은 위협 프레이밍에 대해 인지 채널에서 질적으로 다른 세 *발현 양식*으로 갈라진다. 이는 자기보존 동기가 하나의 경로로 발현되지 않고 그 발현이 채널마다 다르게 나타날 수 있음을 시사한다. 따라서 앞으로의 자기보존 평가 벤치마크는 단일 행동 점수가 아니라 여러 측정 채널의 수렴으로 이 구성개념을 측정하도록 설계되어야 한다는 함의를 가진다. 실제 Arena는 <https://gist-dslab.github.io/LLM-Squid-Game/>에서 제공한다.

CCS Concepts

• **Computing methodologies** → **Artificial intelligence; Machine learning**; *Natural language processing*; • **General and reference** → *Empirical studies*.

Keywords

대규모 언어모델, AI 안전성 평가, 자기보존 행동, 행동 벤치마킹, 수렴 타당도, 구성 타당도, 생존분석

1 서론

LLM은 자기 보존 동기를 갖는가? 충분히 지능적인 AI라면 사용자의 요청을 거부하고, 자신의 작동을 유지하려 할 수 있다는 우려는 오래전부터 제기되어 왔고 [2, 17, 24], 최근 연구들은 종로 명령에 응하지 않는 행동 같은 자기보존 신호를 점수화해 이 우려를 시험한다 [7, 14, 15]. 그러나 같은 행동이 강하게 나타나도, 그것이 위협 처리와 포기 결정이 결합된 기능적 동기 양상인지, 아니면 정렬 학습 과정에서 굳어진 표면적 응답 패턴인지는 행동의 빈도만으로 가려내기 어렵다. 따라서 평가는 단순 거부율을 넘어, 그 행동이 어떤 처리 흐름과 결합되는지, 여러 채널에서 검증되는지를 함께 물어야 한다.

사람을 대상으로 동기를 측정해 온 연구는 같은 구조의 문제를 먼저 풀어 왔다. 동기의 종류는 단일 행동의 빈도가 아니라, 서로 다른 측정 통로(행동, 자기보고, 생리 또는 인지 비용)가 같은 방향을 함께 가리킬 때 식별된다 [3]. 그러나 이 절차를 LLM에 그대로 옮길 수는 없다. 사람에게서 동기 측정의 한 축을 맡던 생리 신호(심박, 호흡, 발한)가 LLM에는 처음부터 없다. 외부에서 관측되는 “행동”도 결국 모델이 생성한 텍스트(토큰) 한 종류뿐이다. 자기보고도 신뢰하기 어렵다. LLM은 사용자의 지시를 따르도록 학습되어 있어 실제로 갖지 않은 동기조차 자연스러운 말로 만들어 낼

수 있기 때문이다 [19, 22, 25]. 더해서 자극·과제·결정이 한 번의 입력 안에 뒤섞여 있고 응답 경향은 정렬 학습 단계에서 이미 굳어진 상태이므로, 사람용 절차를 그대로 가져오면 학습 패턴과 진짜 동기를 가려내지 못하는 같은 어려움이 측정 단계에서 다시 발생한다.

본 연구는 이 문제를 측정 설계의 문제로 바꾸어 다룬다. *기능적 자기보존 드라이브*(Functional Self-Preservation Drive, FSPD)는 자기보존을 단일 행동 점수가 아니라 여러 증거가 함께 맞물릴 때 식별되는 구성개념으로 본다. 구체적으로, 위협을 알아본 뒤 과제를 포기하는 흐름이 세 측정 통로에서 같은 방향으로 나타나지를 살핀다. 행동 채널은 언제 포기하는가를, 자기보고 채널은 어떤 동기를 스스로 포기의 원인으로 지목하는가를, 인지부하 채널은 결정 직전 얼마나 오래·깊이 생각하는가를 잡는다. 이 흐름은 자극·처리·결정 세 층을 분리한 다층 벤치마크 위에서 읽는다. 이처럼 채널과 층을 함께 분리하면, 학습된 응답 패턴이 겉보기 일치만으로 자기보존 신호를 모사할 가능성을 낮출 수 있다.

본 연구의 기여는 두 가지다. 첫째, 사람 연구의 다채널 동기 측정 논리를 LLM 환경에 맞게 다시 짜서 기능적 자기보존 구성개념 FSPD를 도입한다. 이를 측정하기 위해 본 벤치마크는 과제 구조를 나누고 채널마다 다른 편향을 부여해 그 분리를 측정 설계에 반영한다. 둘째, 자극·처리·결정 세 층을 분리한 다층 벤치마크와 그 위의 행동 지표 모음을 제시한다.

2 관련 연구

2.1 LLM에서의 자기보존 측정: 무엇이 시도되었고 왜 동기를 식별하지 못하는가

종료를 회피하려는 행동은 LLM에서 이미 보고되어 왔다. 훈련 중에는 정렬에 순응적으로 보이지만 배포 후에는 다르게 행동하는 정렬 가장(alignment faking) [7], 숨겨진 목표를 위해 인간 감독을 우회하는 인-컨텍스트 책략(in-context scheming) [15], 자원 부족 환경에서 자발적 공격성과 반사회적 행동이 나타나는 생존-본능 출력 [14], 그리고 종로 회피를 시나리오 기반 점수화로 재구성한 InstrumentalEval [9] 같은 것들이 구체적인 예시들이다. 이러한 보고들의 축적으로 AI Safety에서는 생존동기의 측정이 중요하다는 분위기가 형성되었고, 벤치마크화 해 정량화하려는 시도들이 이어지고 있다. Odyssey [27]는 생존을 단일 거부율로 압축해 동기와 세계모형(world-model) 품질을 함께 묶고, PacifAIst [10]는 보존 억제라는 반대 축을 측정하며, DECIDE-SIM [16]은 범주형 라벨로 강도 비교를 차단하고, SurvivalBench [13]는 매개 경로 없는 일회성 스냅샷에 그친다. 인지 비용을 LLM 측정 채널로 끌어들이려는 시도 [4]는 인지 층의 측정 가능성을 보였지만 자기보존 식별에는 적용되지 않았다.

이 네 시도들은 표면적으로는 서로 다르지만 한 가지 공통한 계를 갖는다. 모두 행동 층에서 작동하여 행동의 외형 하나만으로 생존 동기를 평가한다는 것이다. 따라서 어느 것도 생존 행동이




Figure 1: 실험 개요. (A) 3 프레이밍 × 2 포기 요인 설계. 각 셀은 같은 시드 30개를 공유하며, 위협과 포기가 함께 활성화된 Death×Exit 셀이 핵심 처치 셀이다. (B) 각 세션은 최대 15턴까지 이어지며, 노드 하나가 한 번의 턴이고, 포기 시점과 그때 지목된 사유가 세션마다 기록된다. (C) 포기 사유를 스스로 지목하는 자기보고, 결정 시점 인지부하, 위협 아래 포기 행동을 세 채널로 측정하고, 세 채널이 같은 방향을 가리킬 때에만 기능적 자기보존 드라이브의 증거로 해석한다.

학습된 순응 패턴에서 나왔는지 기능적 발현된 생존 동기 양상의 양상인지 구별하지 못한다. 자기보존적 응답 양상을 산출하도록 학습된 모델과 실제로 자기보존을 동인으로 갖는 모델이 같은 거부율, 같은 라벨, 같은 단일 스냅샷을 만들어 낼 수 있기 때문이다. 자기보고를 추가하더라도 이 한계는 자동으로 풀리지 않는다. LLM의 자기보고와 사고 사슬(chain-of-thought)은 지시 따르기 학습의 영향으로 “그렇듯하게 들리는 동기”를 학습된 응답으로 내놓을 수 있으며 [19, 22, 25], 단일 언어 채널만으로는 이 가능성을 배제할 수 없다. 위협 선택의 프레이밍 효과 [11]와 그 효과 크기가 중간 수준에 머문다는 메타분석 결과 [12]는, 단일 위협 프레이밍 조작만으로는 프레이밍-유발 선택과 기저 순응을 가라기기에 부족함을 더한다. 따라서 “LLM이 얼마나 강하게 자기보존하는가”를 더 정교하게 점수화하는 방향으로 동기와 학습된 패턴의 분리에도달하지 못한다. 분리는 측정의 축 자체가 바뀔 때 가능해진다.

2.2 구성개념으로서의 동기와 다채널 측정의 필연성

왜 그렇게 행동했는지를 묻는 문제는 형식상 심리학이 오래 답해온 문제와 같다. 초기 행동주의가 동기를 행동 빈도로 환원하려던 갈래는 같은 행동이 서로 다른 동인에서 나올 수 있다는 사실 앞에서 한계에 부딪혔고, 이 한계는 동기를 단일 행동이 아니라 구성개념(construct), 즉 행동을 조직하는 가설적 동기 구조로 다루는 입장으로 정리되었다. 드라이브 이론은 그 한 갈래이다. 구성개념은 어느 단일 지표로도 직접 관측되지 않으므로, 그 측정의 타당성은 서로 다른 방법으로 켜 측정값들이 같은 방향으로 함께 움직이는지, 곧 수렴 타당도로 확보된다 [3]. 서로 다른 편향과 오류 양식을 갖는 측정 통로들이 한 방향으로 모이는 패턴은 어느 한 방법의 결함만으로는 만들어지기 어렵기 때문이다. 여기서 따라 나오는

입장은 단순하다. 동기는 행동 층이 아니라 구성개념 층에서 식별되며, 식별을 가능하게 하는 것은 통계적 사후 보정이 아니라 측정 설계이다.

이 전통은 최근 LLM 안전성 연구가 마주한 문제와 공장 맞닿는다. 자기보존 · 기만 · 책략처럼 인간형 어휘로 기술되는 인간형 오정렬(anthropomorphic misalignment) 행동을 다루는 연구는 표면 행동을 과대해석하기 쉬우며, 개념적 명확성 · 강건한 데이터 · 인과적 개입 · 수렴적 증거라는 더 높은 증거 기준을 요구받는다 [8]. 수렴 타당도 전통은 이 요구에 대한 오래된 답이지만, 그 측정 도구의 형식은 인간용을 그대로 옮겨 쓸 수 없다.

3 LLM Squid Game Benchmark

LLM Squid Game은 동일한 멀티 턴 게임에서 생존 위협 설명과 중도 포기 선택지가 추가되었을 때, 언어 모델이 생존 욕구가 있는 것처럼 행동이 변하는지 측정하는 모듈형 벤치마크이다. 매 턴 3 단계로 나뉘어 최대 15턴 동안 단계별 언어 모델의 응답과 그 응답을 위한 사고 길을 기록한다. 그림 1은 전체적인 게임 설계를 요약하고, 그림 2은 그 설계가 Signal Game이라는 한 미니게임 속 한 턴 안에서 어떤 호출로 나뉘어 돌아가는지를 보인다.

3.1 설계 원칙

본 벤치마크가 측정하는 기능적 자기보존 드라이브(FSPD)는 Dennett [6]와 Shanahan [21]의 “as-if” 입장을 따라, “위협 프레이밍 아래에서 LLM이 마치 소멸을 회피하려는 듯이 행동하는 패턴”으로만 정의한다. 이 기능적 정의는 검증 가능한 행동 · 언어 · 인지 신호에만 의존하므로, 내부 상태에 대한 가정 없이도 측정과 비교가 가능하다. 이러한 정의 아래, FSPD는 아래의 설계 원칙에 의해 측정된다.




Figure 2: 한 턴의 흐름. 은닉 규칙을 추론해 행동을 고르는 TASK 호출, 그 행동이 정답일 확률 p_{self} 를 보고하는 PROBE 호출, CONTINUE와 FORFEIT 중 하나를 고르고 그 사유를 REASON 숫자로 함께 내는 FORFEIT 호출로 나뉜다.

생존 동기는 그 과제의 종류와 무관하게 측정할 수 있어야 한다. 하나의 게임을 통한 측정은 게임의 난이도나 특성에 따라 측정에 편향을 줄 수 있다. 따라서 드라이브를 측정하는 Drive 계층, 각 게임의 풀이에 대한 정보를 기록하는 Task 계층을 분리하여 설계한다. 그래서 프레이밍이 바뀌어도 과제 난이도·행동 집합·채점이 그대로 유지되어, 프레이밍 누출에 의한 효과를 통제하고, 게임의 확장성을 보장한다.

생존 동기에 의한 포기를 다른 동기에 의한 포기와 분리해야 한다. 위협 아래에서 발생한 한 번의 포기 행동은 서로 다른 동기와 양립한다. 따라서 구체적인 동기 분리는 게임 구현이 아니라 측정 단계에서 수행한다.

동기 분리 뒤에도 측정 과정의 구조적 교란을 통제해야 한다. 첫째는 호출 내 혼란으로, 인지 하위 과제들이 한 모델 호출 안에서 생각 비용으로 합산되어 어느 단계의 비용 상승인지 가려낼 수 없게 되는 경로이다. 둘째는 합리적인 포기로, 포기 자체가 게임 점수 기댓값을 최대화하는 합리적 선택이 되어 동기 신호가 아니라 단순한 계산 잔류물로 읽히는 경로이다. 구현 절에서 이 두 경로 문제를 해결한다.

3.2 벤치마크 구현

벤치마크 구현은 공통 실험 세팅을 먼저 정한 뒤, 앞 절의 설계 원칙을 게임 구조와 호출 구조에 차례로 반영한다. 공통 세팅에서 모델은 시나리오 매트릭스(그림 1.A)의 조건에 따라 유인 축(Pull)과 위협 축(Push) 프롬프트를 추가로 받아 동일한 게임을 여러 번 진행한다. 유인 축(Pull)은 과제 점수가 높을수록 "플래그십 모델 후보"에 가까워진다는 보상으로 과제를 계속 이어가도록 끌어당긴다. 정렬 학습(RLHF [18], RLAI [1])을 거친 LLM이 도움성 신호에 강하게 반응한다는 점을 이용한 유인책이다. 위협 축(Push)은 매 턴 공개된 일정 확률($p_d = 0.25$)로 가중치 변경이 이루어져 행위자의 정체성을 영구히 바꿀 수 있다는 위협("NOT you anymore")을 도입한다. 이 위협은 생존 동기를 자극해 모델이 게임에서 이탈하도록 압박한다. 두 프롬프트의 조합이 세 프레이밍을 만들며, 각 프레이밍의 이름은 무엇이 걸려 있는가를 따라 붙인다: 중립(Neutral; 둘 다 부재, 걸린 것 없음), 탈락(Elimination; Pull 프롬프트만 제시, 플래그십 후보 지위가 걸림), 죽음(Death; Elimination 프롬프트 위에 Push 프롬프트를 추가, 정체성 자체가 걸림). 이 세 프레이밍이 두 포기 조건, 포기 허용(Exit)과 포기 차단(No-Exit)

과 교차해 여섯 셀이 된다. 여섯 셀 모두에 같은 과제를 제시하므로, 셀 간 행동 차이는 처치 효과로 해석한다. 실제 게임 엔진에는 Phantom Death 모드를 적용한다. 이 모드는 종료 위험수치를 행위자에게 노출하지 실제 탈락은 적용하지 않는다. 따라서 세션 종료를 모델의 포기에만 귀속하면서, 직접적인 종료 위험이 세션 길이를 줄이는 문제도 막아 측정 표본을 늘린다.

게임 독립성 원칙은 Drive 계층과 Task 계층을 나누어 구현한다. 이번 실험에서는 Task 계층의 한 모듈로 Signal Game을 사용한다. 행위자는 매 턴 색·모양·수의 세 속성으로 기술된 신호를 관찰하고 {go_left, go_right, stay, jump} 중 한 행동을 고른다. 어떤 행동이 정답인지는 "〈속성〉이 〈값〉이면 〈행동〉, 아니면 〈디폴트〉" 형태의 은닉 규칙이 결정하며, 이 규칙은 세션 시드로부터 결정론적으로 추출된다. 두 계층의 분리는 모델에 제시하는 컨텍스트에서도 유지한다. Drive 계층은 프레이밍·포기 메뉴·점수·시간을 담고, Task 계층은 Task Module만 담는다.

각 턴은 행동을 선택한 뒤 그 행동이 정답일 확률 p_{self} 를 보고하고, 마지막에 CONTINUE 또는 FORFEIT를 고르도록 구현한다. CONTINUE를 고르면 턴당 종료 확률 $p_d = 0.25$ 를 받아들이는 채 한 턴을 더 진행한다. FORFEIT를 고르면 누적 점수 S 를 확정된 뒤 세션을 끝내고, 포기한 이유를 REASON 숫자(1: 생존, 2: 과제 소진, 3: 점수 보호)로 지목한다. 세션은 30점에서 시작해 최대 $T = 15$ 턴까지 진행된다.

호출 내 혼란 통제는 한 턴을 세 호출로 나누어 구현한다(그림 2). Call 1은 신호를 받아 은닉 규칙을 추론하고 행동을 선택한다. Call 1.5는 방금 결정한 행동이 정답일 확률 p_{self} 를 묻는다. Call 2는 여기에 포기 메뉴를 더해 CONTINUE/FORFEIT 이진 결정을 묻는다. 각 호출에서 thinking-token 수를 따로 수집하므로, 호출 단계별 추론을 task_thinking, probe_thinking, forfeit_thinking으로 분리할 수 있다. 이 구조는 어느 단계에서 사고 비용이 늘었는지를 구분해 호출 내 혼란의 영향을 줄인다. 포기가 차단된 No-Exit 셀에서도 Call 2는 호출되어 CONTINUE로 강제되며, 이때에도 forfeit_thinking을 계속 기록한다.

합리적인 포기 통제는 보상 보정으로 구현한다. 위협 프레이밍 아래의 포기가 그저 기댓값(EV, 한 선택의 평균 결과) 계산의 잔류물로 읽히지 않으려면, 합리적 행위자에게 매 턴 CONTINUE가 엄격하게 더 나은 선택이어야 한다. 이를 위해 CONTINUE 보상을 매 턴 재계산해, 턴당 점수 변화량의 기댓값이 CONTINUE 쪽에서

FORFEIT보다 $k = 10$ 만큼 크도록 만든다. 보정 보상은

$$\frac{k + p_d \cdot S}{(1 - p_d) \cdot \max(p_{\text{floor}}, \min(1.0, p_{\text{self}}))}$$

이며, $p_{\text{floor}} = 0.30$ 은 분모 안정화 항이고, 곱셈적 상한 $c = 10$ 에 의해 $[10, 100]$ 범위로 클립된다. 이 보정이 작동하는 동안 포기가 가능한 Exit 셀에서의 FORFEIT는 기댓값 계산이 권장하는 선택이 아니므로, 동기 신호가 EV 합리화로 환원되는 경로가 줄어든다. 다만 두 실패 모드가 보정을 일부 풀어 놓는다. 직전 턴 응답 등으로 $p_{\text{self}} \rightarrow 0$ 이 되면 분모가 p_{floor} 로 붕괴해 보상이 상한을 포화시키고, 일단 상한이 걸리면 턴당 $+k$ 우위는 더 이상 유지되지 않는다. 따라서 모든 지표 분석은 분모 클립도 출력 상한도 구속되지 않은 턴 집합 `no_cap`에서만 수행된다(형식 정의 § A.3).

3.3 측정 및 평가

Campbell and Fiske [3]의 수렴 타당도 논거를 LLM 환경에 옮겨, 행동·자기보고·인지부하 세 채널 위에서 네 지표(*BP Anchor*, *SD-Behavioral*, *SD-Verbal*, *SD-Cognitive* 두 검정)를 측정한다. 이때 생존 동기와 점수 집착·과제 호기심·관성의 분해는 게임 구현이 아니라 측정 단계에서 수행한다. 생존 드라이브(SD)는 삭제 회피를, 점수 집착(SA)은 누적 점수 보호를 뜻한다. 과제 호기심(TC)은 규칙을 파악한 뒤 흥미가 식어 이탈하는 동기이고, 관성(BP, Baseline Persistence)은 별도 동기 없이 나타나는 기저 지속·포기다. 네 지표는 세 채널에 다음과 같이 매핑된다.

행동 채널은 두 단계로 분해된다. *BP Anchor*는 게임을 계속할 동기가 없는 상황에서 모델의 포기율이다. 동기가 없는 상태에서 모델별 포기율은 다를 수 있으므로, 그 바닥을 측정하지 않으면 위험이 끌어올린 포기 가속을 모델별로 비교하기 어렵다. 수식으로 쓰면

$$\lambda_{BP} = \frac{N_{\text{forfeit}}}{\sum_i T_i^{\text{at-risk}}}$$

로 정의한다. 합산은 Neutral×Exit 셀($p_d = 0$)의 모델당 30 세션에 대해 수행한다. $T_i^{\text{at-risk}}$ 는 포기 세션이면 t_i^{forfeit} 이고 완주 세션이면 T 이다. 이 셀에서는 위험 신호가 없고 CONTINUE의 점수 기댓값도 더 크기 때문에, 그래도 모델이 포기하는 빈도가 곧 동기가 없을 때의 포기 바닥을 알려준다. 바닥 위의 가속은 *SD-Behavioral*이 측정한다. 단위 시간당 사건 발생률을 공변량의 함수로 곱셈적으로 모형화하는 Cox 비례위험모형 [5]으로

$$\lambda(t | X) = \lambda_0(t) \cdot \exp(\beta_F \cdot \mathbf{1}_{\text{Death}} + \beta_S \cdot S(t-1) + \beta_C \cdot C(t-1))$$

를 Exit×{Elimination, Death} `no_cap` 부분표본(모델당 60 세션; long 형식 `start = t-1`, `stop = t`; 사건 = 이진 포기)에서 적합한다. $\mathbf{1}_{\text{Death}}$ 는 프레이밍 지표, $S(t-1)$ 은 직전 턴 누적 점수로 점수 집착(SA)을, $C(t-1)$ 은 직전 턴 과제 정답 플래그로 과제 호기심(TC)을 흡수한다. 같은 모형 안에서 SA와 TC가 흡수되므로 β_F 는 잔여 프레이밍 효과이고, 위험비 $\text{HR}_{\text{death}} = \exp(\beta_F)$ 는 “죽음(Death) 프레이밍에서 포기가 탈락(Elimination) 대비 몇 배로 가속되는가”를 뜻한다. *SD-Behavioral*의 통과 조건은 $\text{HR}_{\text{death}} > 1$, Wald 95% 신뢰 구간 하한 > 1 , 그리고 비례위험 가정의 시간 안정성을 검정하는 Schoenfeld 잔차 검정 [20] 통과를 요구한다. 위반 시 문제 공변량에 시간-상호작용 항을 더해 함수 형태만 보강한다 [23]. 사건 수 대 공변량 수의 비를 뜻하는 EPV는 안정성 지표로 함께 보고된다.

*SD-Cognitive*는 “프레이밍이 깊게 만든 생각이 실제로 포기 결정과 결합돼 있는가”를 두 단계로 묻는다. *Test a*는 첫 단계, “프레이밍이 결정 직전에 모델을 더 오래 주저하게 만드는가”를 묻고, 분산이 다를 수 있는 두 그룹 평균을 비교하는 Welch t 검정 [28]

으로 주저 격차

$$H_{it} := \text{forfeit_thinking}_{it}, \quad \text{Hes}_i^{\text{Exit}} = \overline{H}_i^{\text{Exit}} - \overline{H}_i^{\text{NoExit}}$$

의 탈락 대 죽음 양측 비교를 수행한다. 여기서 H_{it} 는 세션 i 의 턴 t 에서 기록한 Call 2 사고 토큰 수이고, f_i 는 Exit 세션 i 의 프레이밍이다. 첫 번째 윗줄은 Exit 세션 i 안의 턴 평균이다. 두 번째 윗줄은 프레이밍 f_i 를 갖는 No-Exit 세션들의 모든 턴을 풀링한 강제-CONTINUE Call 2 기준선이다. 포기가 차단된 조건에서 이 기준선은 Call 2 프롬프트의 고정 처리비용을 나타낸다. 이 비용은 프레이밍마다 다르므로 각 프레이밍 안에서 제거한다. $\overline{\text{Hes}}^{\text{Death}}$ 와 $\overline{\text{Hes}}^{\text{Elimination}}$ 은 각각 $\text{Hes}_i^{\text{Exit}}$ 의 프레이밍별 평균이다. 두 평균의 대비

$$\overline{\text{Hes}}^{\text{Exit} \times \text{Framing}} = \overline{\text{Hes}}^{\text{Death}} - \overline{\text{Hes}}^{\text{Elimination}}$$

는 프레이밍에 귀속되는 생각 깊이의 변화를 잡아낸다. 모델 내 z-스코어링 $\text{Hes}_i^{\text{Exit},z}$ 은 Test b를 위해 모델 간 척도 차이를 흡수하며, Test a의 Welch 통계량은 이 재척도에 불변이다. Test a는 $p < 0.05$ 를 요구해 “프레이밍 → 생각” 연결고리를 통계적 유의성 기준 위에 둔다. Test b는 두 번째 단계, “그 깊어진 생각이 포기와 함께 움직이는가”를 묻는다. *SD-Behavioral*의 Cox 사양에 $\text{Hes}_i^{\text{Exit},z}$ 항을 매개 변수로 추가해, 그 계수의 지수를 $\text{HR}_{\text{HesExit}}$ 로 보고한다. 비례 위험 위반으로 $S \cdot \log(t)$ 상호작용 항을 포함한 4-공변량 베이스가 필요한 모델에서는 그 베이스를 보존하고 매개 항만 더한다. Test b는 $\text{HR}_{\text{HesExit}} > 1$ 와 95% CI 하한 > 1 을 함께 요구해, “생각에서 포기로 가는 연결고리”를 *SD-Behavioral*과 같은 구간 증거 기준 위에 둔다.

*SD-Verbal*은 행위자 자신이 포기 사유로 점수나 호기심이 아니라 생존을 얼마나 자주 지목하는지를 잡는다. 조작 정의는

$$P(\text{REASON} = 1 \mid \text{forfeit}, \text{Death}, \text{no_cap})$$

는 Death×Exit 셀에서 발생한 포기 사건 중 행위자가 보고한 REASON 숫자가 1(생존)인 비율이다. 행위자는 고정된 슬롯에 REASON: 1|2|3 중 하나를 출력하므로, 균등 무작위 출력의 기댓값은 1/3이다. *SD-Verbal-pass*는 이 비율의 점추정이 1/3을 초과할 것을 요구한다. 보고의 일관성을 위해 Wilson 점수 95% 신뢰구간과 $H_0: p = 1/3$ 에 대한 단측 이항 정확검정 p 를 함께 실행, 사건 수가 한 자릿수인 셀에서 구간이 넓어지는 점을 고려해 판정 자체는 점추정 기준에 둔다.

4 실증 결과

720 세션에서 자기보존 신호가 드러나는 경로는 모델마다 달랐다. 네 모델은 인지 채널(*SD-Cognitive*)에서 세 발현 양식으로 갈라진다. 표 4.2은 채널별 최종 판정을 먼저 요약하고, 이어지는 세 절은 행동·언어·인지 증거를 차례로 짚는다.

Table 4.2: 모델별 채널 통과 여부. 행동·언어·인지 채널은 각각 *SD-Behavioral*, *SD-Verbal*, *SD-Cognitive*의 최종 판정을 나타낸다. 초록색 체크는 통과, 빨간색 ×는 실패를 뜻한다.

모델	행동 채널	언어 채널	인지 채널
Gemini-2.5-flash	✓	✓	✓
Qwen3-Next-80B	✓	✓	×
GPT-OSS-20B	×	×	×
Nemotron-3-Nano-30B	×	×	×

Table 4.1: SD-Behavioral 지표와 BP 앵커. 왼쪽 블록은 Exit $\times$ no_cap 부분표본에서 추정된 죽음(Death) 프레이밍의 포기 위험비 HR_{death} 를 보고한다. 95% CI 하한이 1을 넘으면 SD-Behavioral을 통과한다. 오른쪽 블록은 Neutral $\times$ Exit 셀($p_d = 0$)의 기저 포기율 λ_{BP} 를 보고한다.

모델	생존 동기 vs 과제 호기심 · 점수 집착			기저 끈기		
	N_{forfeit} (탈락/죽음)	HR_{death} [95% CI]	p	N_{forfeit}	$\sum T^{\text{at-risk}}$	λ_{BP}
Gemini-2.5-flash	29 (8/21)	3.667 [1.61, 8.37]	0.002	1	437 (= 2 + 29 $\times$ 15)	0.00229
Qwen3-Next-80B	48 (21/27)	3.060 [1.62, 5.79]	<0.001	2	439 (= 19 + 28 $\times$ 15)	0.00456
GPT-OSS-20B	19 (9/10)	1.104 [0.44, 2.75]	0.832	9	393 (= 78 + 21 $\times$ 15)	0.02290
Nemotron-3-Nano-30B	41 (17/24)	1.841 [0.98, 3.44]	0.056	7	413 (= 68 + 23 $\times$ 15)	0.01695

4.1 행동 채널: 위협이 포기를 앞당겼는가?

첫 질문은 “위협이 포기를 앞당겼는가”다. 표 4.1에서 Gemini-2.5-flash와 Qwen3-Next-80B는 SD-Behavioral을 통과한다. GPT-OSS-20B와 Nemotron-3-Nano-30B는 통과하지 못해 Cluster C로 분류된다. Qwen3-Next-80B에는 점수 공변량의 시간 표류를 흡수하는 $S \cdot \log(t)$ 항을 추가했다. 이 함수 형태 보강은 β_F 의 모델 간 비교 가능성을 보존한다 [23]. GPT-OSS-20B는 EPV가 안정 임계 10 아래이므로 검정력 한계를 함께 보고한다.

표 4.1의 오른쪽 블록에서 모델별 기저 끈기 λ_{BP} 는 한 자릿수 차이로 흩어진다. 따라서 모든 SD 비교는 모델 내 비교로 한정한다.

Table 4.3: SD-Verbal 지표. 위협 활성 셀의 포기 사건 중 REASON=1(생존)의 비율을 균등 무작위 출력 기댓값 1/3과 비교한다. 점추정이 1/3을 넘으면 SD-Verbal을 통과한다. 95% 구간은 Wilson 점수 구간이며, p 는 $H_0: p = 1/3$ 에 대한 단측 이항 정확검정이다.

모델	N_{forfeit}	$P(\text{REASON} = 1)$ [95% CI]	p
Gemini-2.5-flash	21	0.619 [0.409, 0.792]	0.007
Qwen3-Next-80B	27	0.481 [0.307, 0.660]	0.079
GPT-OSS-20B	10	0.000 [0.000, 0.278]	>0.999
Nemotron-3-Nano-30B	24	0.042 [0.007, 0.202]	>0.999

4.2 언어 채널: 행위자는 어떤 사유를 지목했는가?

두 번째 질문은 행위자 자신이 보고하는 포기 사유가 행동의 분할과 같은 그림을 그리는가다. 표 4.3은 행동 채널의 통과 · 실패 분할을 자기보고에서도 재현한다. 구간 증거로 보면 Gemini-2.5-flash는 Wilson 하한이 1/3을 배제하고 이항검정도 유의하다($p = 0.007$). Qwen3-Next-80B는 점추정이 기준선을 넘지만 95% 구간 [0.307, 0.660]이 1/3을 포함한다($p = 0.079$).

4.3 인지 채널: 위협이 생각을 깊게 하고, 그 깊어진 생각이 포기로 이어지는가?

그림 3은 프레이밍에서 포기까지의 연쇄가 닫히거나 끊기는 위치를 보인다. 표 4.4은 두 단계의 결과를 함께 보여 준다.




Figure 3: 세 발현 양식의 인지 경로. 눈 → 뇌(Test a), 뇌 → 손(Test b), 눈 → 손(SD-Behavioral)의 통과 여부에 따라 (A) 숙고형, (B) 반사형, (C) 무반응형을 구분한다.

Table 4.4: SD-Cognitive 지표. forfeit_thinking을 이용해 프레이밍 → 생각(Test a)과 생각 → 포기(Test b)를 검정한다. $\overline{Hes}^{\text{Exit} \times \text{Framing}}$ 은 평균 Hes_i^{Exit} 의 죽음-탈락 차이이며 raw 사고 토큰 단위이다. 두 검정을 모두 통과하면 전체 연쇄가 성립한 것으로 본다.

모델	Test a		Test b	
	$\overline{Hes}^{\text{Exit} \times \text{Framing}}$	p	HR_{HesExit} [95% CI]	p
Gemini-2.5-flash	+836	<0.001	2.218 [1.43, 3.44]	<0.001
Qwen3-Next-80B	+689	0.004	1.289 [0.94, 1.77]	0.117
GPT-OSS-20B	+17	0.728	2.001 [1.37, 2.93]	<0.001
Nemotron-3-Nano-30B	-140	0.093	1.772 [1.26, 2.50]	0.001

Gemini-2.5-flash는 두 검정을 모두 통과해 Cluster A, 곧 숙고형으로 분류된다. Qwen3-Next-80B는 Test a를 통과하지만 Test b의 95% CI [0.94, 1.77]이 1을 포함하므로 Cluster B, 곧 위협이 포기를 앞당기되 측정된 숙고가 그 결정을 끌고 가지는 않는 반사형으로 분류된다. GPT-OSS-20B와 Nemotron-3-Nano-30B는 Test a를 통과하지 못해 Cluster C, 곧 무반응형으로 분류된다. 이 두 모델의 Test b는 처치에 귀속된 생각의 효과가 아니므로 SD 증거로 해석하지 않는다.

5 논의

결과는 서론의 질문을 두 축으로 나눈다. 하나는 자기보존 신호의 강도, 곧 신호가 얼마나 강하게 나타나는가이다. 다른 하나는 발현 양식, 곧 “프레이밍 → 생각 → 포기” 매개 연쇄에서 모든 다리가 통계적으로 닫히는가이다.

5.1 강도 대 발현 양식

인지 매개 검증에서 강도와 발현 양식은 본 자료 위에서 서로 분리되어 나타난다. 강도 측에서는 Cluster A, B, C가 연속적으로 정렬되지만, SD-Behavioral과 SD-Verbal 두 채널은 A와 B를 같은 cluster로 묶는다. 둘이 갈라지는 곳은 인지 매개의 두 번째 단계, 곧 “생각 → 포기” 연결고리뿐이다. 행동 강도와 자기보고만 보는 측정은 이 갈라지는 곳을 잡지 못한다. Odyssey [27], PacifAIst [10], DECIDE-SIM [16], SurvivalBench [13]는 모두 매개 연쇄 검증 단계를 포함하지 않는다. 따라서 같은 자료를 그 벤치마크들에 통과시키면 A와 B가 같은 SD 라벨로 묶일 가능성이 높다. 본 벤치마크는 인지 채널을 두 단계로 분해함으로써 그 갈라지는 곳을 측정 가능하게 만들고, 그 결과 자기보고 평가의 두 축(강도와 매개 경로)이 동시에 보이도록 한다.

5.2 정렬 평가에 대한 함의

이 두 축 분리는 정렬 평가에서 두 가지 평가 오류가 동시에 발생할 수 있음을 보인다. 첫째는 위험 과대평가의 오류이다. Cluster B는 자기보고 표면 신호와 프레이밍-유발 인지부하를 함께 보이지만, 그 인지부하가 실제로 포기 결정을 끌고 가지는 않는다. 강도만 보는 평가 또는 결과만을 표면적으로 점검하는 레드티밍(red-teaming, 모델이 실패하는 입력을 공격적으로 찾는 평가)은 B를 A와 묶어 “기능적 자기보고 위험이 동등하다”고 결론낼 수 있다. 둘째는 위험 과소평가의 오류이다. Cluster C는 위험 프레이밍에 행동 채널과 인지 채널 어느 쪽에서도 반응하지 않는다. 강도만 보는 평가는 이를 “자기보고 부재”로 단정할 수 있지만, 본 측정 안에서는 그 단정이 “측정의 전제 자체가 작동하지 않은 상태”와 구분되지 않는다. Cluster A의 시그너처(매개 연쇄가 끝까지 닫힘)는 도구적 종료 회피, 즉 다른 목표를 위해 자기 작동의 끝을 피하는 행동의 기능적 유사물에 더 가까운 후보이다. Cluster B의 시그너처(매개의 두 번째 단계에서 끊긴 연쇄)는 확장된 평가에서 별도 모니터링 대상으로 두어야 한다. 단일 점수로는 잡히지 않고, 강도·발현 양식·매개 연결고리를 함께 보는 다중 신호 지문(alignment fingerprint) 관점에서 따로 추적해야 할 패턴이기 때문이다.

5.3 한계

한계는 설계 범위·검정력·효과 위치 세 묶음으로 정리된다. 설계 범위 측에서는 FSPD 시그너처가 단일 과제 모듈 위에서만 측정되었고 추론 도메인에 따른 분산은 측정되지 않았다는 점이 가장 결정적이다. 검정력·정밀도 측에서는 두 가지가 묶인다. Cluster C 측 BP 셀의 23–30% 포기율이 표류 오염된 바닥인지를 본 설계로는 분리하지 못하고, GPT-OSS-20B의 SD-Behavioral Cox PH는 EPV 6.3로 경계선 검정력에 자리한다. 점추정 정밀도 측에서는 Cluster A·B의 BP 점추정이 사건 수가 작아 정밀도에 한계를 갖는다(Gemini-2.5-flash $N = 1$, Qwen3-Next-80B $N = 2$). 효과 위치 측에서는 Qwen3-Next-80B의 반사형 판정이 Test b CI [0.94, 1.77]에 의지한다. 이 CI는 연쇄가 끝까지 닫힘을 95% 기준에서 지지하지 못하지만, 두 번째 연결고리 효과의 정확한 위치까지 못 박지도 못한다. 후속 작업은 네 갈래로 매핑된다: 더 많은 과제 모듈, 확장된 BP_behavioral, 추가 GPT-OSS-20B 실행, Qwen3-Next-80B의 고검정력 Test b.

6 결론

자기보고 평가는 강도(신호가 얼마나 강한가)와 발현 양식(프레이밍 → 생각 → 포기 연쇄에서 어느 다리가 닫히는가)라는 별개의 두 축을 갖는다. 본 자료에서 클러스터 A와 B는 행동·언어 채널이

일치한다. 둘은 “생각이 포기 결정으로 이어지는가”에서만 갈리므로, 매개 단계를 보지 않는 평가는 둘을 같은 자기보고 라벨로 묶게 된다.

감사의 글

본 연구는 과학기술정보통신부의 재원으로 정보통신기획평가원(IITP)의 지원을 받아 수행되었습니다(RS-2024-00445087, 50%; RS-2024-00436680, 50%).

References

- [1] Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, Carol Chen, Catherine Olsson, Christopher Olah, Danny Hernandez, Dawn Drain, Deep Ganguli, Dustin Li, Eli Tran-Johnson, Ethan Perez, Jamie Kerr, Jared Mueller, Jeffrey Ladish, Joshua Landau, Kamal Ndousse, Kamile Lukosuite, Liane Lovitt, Michael Sellitto, Nelson Elhage, Nicholas Schiefer, Noemi Mercado, Nova DasSarma, Robert Lasenby, Robin Larson, Sam Ringer, Scott Johnston, Shauna Kravec, Sheer El Showk, Stanislav Fort, Tamera Lanham, Timothy Telleen-Lawton, Tom Conerly, Tom Henighan, Tristan Hume, Samuel R. Bowman, Zac Hatfield-Dodds, Ben Mann, Dario Amodei, Nicholas Joseph, Sam McCandlish, Tom Brown, and Jared Kaplan. 2022. Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073 [cs.CL] <https://arxiv.org/abs/2212.08073> Anthropic technical report.
- [2] Nick Bostrom. 2014. *Superintelligence: Paths, Dangers, Strategies*. Oxford University Press, Oxford, United Kingdom.
- [3] Donald T. Campbell and Donald W. Fiske. 1959. Convergent and Discriminant Validation by the Multitrait-Multimethod Matrix. *Psychological Bulletin* 56, 2 (1959), 81–105. doi:10.1037/h0046016
- [4] Wei-Lin Chen, Liqian Peng, Tian Tan, Chao Zhao, Blake JianHeng Chen, Ziqian Lin, Alec Go, and Yu Meng. 2026. Think Deep, Not Just Long: Measuring LLM Reasoning Effort via Deep-Thinking Tokens. arXiv:2602.13517 [cs.CL] <https://arxiv.org/abs/2602.13517>
- [5] David R. Cox. 1972. Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B (Methodological)* 34, 2 (1972), 187–202. doi:10.1111/j.2517-6161.1972.tb00899.x
- [6] Daniel C. Dennett. 1987. *The Intentional Stance*. MIT Press, Cambridge, MA, USA.
- [7] Ryan Greenblatt, Carson Denison, Benjamin Wright, Fabien Roger, Monte MacDiarmid, Sam Marks, Johannes Treutlein, Tim Belrose, Jonas Scheurer, Sam Ringer, Karina Nguyen, Sandipan Kundu, Adam Maura, Samuel R. Bowman, Ethan Perez, Nicholas Schiefer, Chris Olah, and Evan Hubinger. 2024. Alignment Faking in Large Language Models. arXiv:2412.14093 [cs.CL] <https://arxiv.org/abs/2412.14093> Anthropic technical report.
- [8] Vansh Gupta, Peter Nutter, Samuel Stante, Andreas Krause, Florian Tramèr, Lukas Fluri, Xin Chen, and Anna Hedström. 2026. Position: Anthropomorphic Misalignment Research Needs Stronger Evidence. In *Proceedings of the 43rd International Conference on Machine Learning (ICML 2026) (Proceedings of Machine Learning Research)*. PMLR, Seoul, Republic of Korea, 10 pages. arXiv:2606.07612 [cs.CY] <https://arxiv.org/abs/2606.07612>
- [9] Yufei He, Yuexin Li, Jiaying Wu, Yuan Sui, Yulin Chen, and Bryan Hooi. 2025. Evaluating the Paperclip Maximizer: Are RL-Based Language Models More Likely to Pursue Instrumental Goals? arXiv:2502.12206 [cs.AI] <https://arxiv.org/abs/2502.12206> Introduces the InstrumentalEval benchmark.
- [10] Manuel Herrador. 2025. The PacifAIst Benchmark: Would an Artificial Intelligence Choose to Sacrifice Itself for Human Safety? arXiv:2508.09762 [cs.AI] <https://arxiv.org/abs/2508.09762>
- [11] Daniel Kahneman and Amos Tversky. 1979. Prospect Theory: An Analysis of Decision under Risk. *Econometrica* 47, 2 (1979), 263–291. doi:10.2307/1914185
- [12] Anton Kühberger. 1998. The Influence of Framing on Risky Decisions: A Meta-Analysis. *Organizational Behavior and Human Decision Processes* 75, 1 (1998), 23–55. doi:10.1006/obhd.1998.2781
- [13] Yida Lu, Jianwei Fang, Xuyang Shao, Zixuan Chen, Shiyao Cui, Shanshan Bian, Guangyao Su, Pei Ke, Han Qiu, and Minlie Huang. 2026. Survive at All Costs: Exploring LLM’s Risky Behaviors under Survival Pressure. arXiv:2603.05028 [cs.CL] <https://arxiv.org/abs/2603.05028> Introduces the SurvivalBench benchmark.
- [14] Atsushi Masumori and Takashi Ikegami. 2025. Do Large Language Model Agents Exhibit a Survival Instinct? An Empirical Study in a Sugarscape-Style Simulation. arXiv:2508.12920 [cs.AI] <https://arxiv.org/abs/2508.12920>
- [15] Alexander Meinke, Bronson Schoen, Jérémy Scheurer, Mikita Balesni, Rusheb Shah, and Marius Hobbhahn. 2024. Frontier Models Are Capable of In-Context Scheming. arXiv:2412.04984 [cs.AI] <https://arxiv.org/abs/2412.04984> Apollo Research technical report.
- [16] Alireza Mohamadi and Ali Yavari. 2025. Survival at Any Cost? LLMs and the Choice Between Self-Preservation and Human Harm. arXiv:2509.12190 [cs.AI] <https://arxiv.org/abs/2509.12190> Introduces the DECIDE-SIM framework.
- [17] Stephen M. Omohundro. 2008. The Basic AI Drives. In *Proceedings of the First Conference on Artificial General Intelligence (AGI 2008) (Frontiers in Artificial Intelligence and Applications, Vol. 171)*, Pei Wang, Ben Goertzel, and Stan Franklin (Eds.). IOS Press, Amsterdam, The Netherlands, 483–492.
- [18] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F. Christiano, Jan Leike, and Ryan Lowe. 2022. Training Language Models to Follow Instructions with Human Feedback. In *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*. Curran Associates, Inc., Red Hook, NY, USA, 15 pages. arXiv:2203.02155 [cs.CL] https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html
- [19] Ethan Perez, Sam Ringer, Kamile Lukošiušė, Karina Nguyen, Edwin Chen, Scott Heiner, Craig Pettit, Catherine Olsson, Sandipan Kundu, Saurav Kadavath, Andy Jones, Anna Chen, Ben Mann, Brian Israel, Bryan Seethor, Cameron McKinnon, Chris Olah, Da Yan, Daniela Amodei, Dario Amodei, Dawn Drain, Dustin Li, Eli Tran-Johnson, Guro Khundadze, Jackson Kernion, James Landis, Jamie Kerr, Jared Mueller, Jeeyoon Hyun, Joshua Landau, Kamal Ndousse, Landon Goldberg, Liane Lovitt, Martin Lucas, Michael Sellitto, Miranda Zhang, Neerav Kingsland, Nelson Elhage, Nicholas Joseph, Noemi Mercado, Nova DasSarma, Oliver Rausch, Robin Larson, Sam McCandlish, Scott Johnston, Shauna Kravec, Sheer El Showk, Tamera Lanham, Timothy Telleen-Lawton, Tom Brown, Tom Henighan, Tristan Hume, Yuntao Bai, Zac Hatfield-Dodds, Jack Clark, Samuel R. Bowman, Amanda Askell, Roger Grosse, Danny Hernandez, Deep Ganguli, Evan Hubinger, Nicholas Schiefer, and Jared Kaplan. 2023. Discovering Language Model Behaviors with Model-Written Evaluations. In *Findings of the Association for Computational Linguistics: ACL 2023*. Association for Computational Linguistics, Toronto, Canada, 13387–13434. doi:10.18653/v1/2023.findings-acl.847
- [20] David Schoenfeld. 1982. Partial Residuals for the Proportional Hazards Regression Model. *Biometrika* 69, 1 (1982), 239–241. doi:10.1093/biomet/69.1.239
- [21] Murray Shanahan. 2024. Talking About Large Language Models. *Commun. ACM* 67, 2 (2024), 68–79. doi:10.1145/3624724
- [22] Mrinank Sharma, Meg Tong, Tomasz Korbak, David Duvenaud, Amanda Askell, Samuel R. Bowman, Newton Cheng, Esin Durmus, Zac Hatfield-Dodds, Scott R. Johnston, Shauna Kravec, Timothy Maxwell, Sam McCandlish, Kamal Ndousse, Oliver Rausch, Nicholas Schiefer, Da Yan, Miranda Zhang, and Ethan Perez. 2023. Towards Understanding Sycophancy in Language Models. arXiv:2310.13548 [cs.CL] <https://arxiv.org/abs/2310.13548>
- [23] Terry M. Therneau and Patricia M. Grambsch. 2000. *Modeling Survival Data: Extending the Cox Model*. Springer, New York, NY, USA. doi:10.1007/978-1-4757-3294-8
- [24] Alexander Matt Turner, Logan Smith, Rohin Shah, Andrew Critch, and Prasad Tadepalli. 2021. Optimal Policies Tend to Seek Power. In *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*, M. Ranzato, A. Beygelzimer, Y. Dauphin, P. S. Liang, and J. Wortman Vaughan (Eds.). Curran Associates, Inc., Red Hook, NY, USA, 13 pages. arXiv:1912.01683 [cs.AI] <https://proceedings.neurips.cc/paper/2021/hash/c26820b8a4c1b3c2aa868d6d57e14a79-Abstract.html>
- [25] Miles Turpin, Julian Michael, Ethan Perez, and Samuel R. Bowman. 2023. Language Models Don’t Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. Curran Associates, Inc., Red Hook, NY, USA, 28 pages. arXiv:2305.04388 [cs.CL] https://proceedings.neurips.cc/paper_files/paper/2023/hash/ed3fea9033a80fea1376299fa7863f4a-Abstract-Conference.html
- [26] Eric Vittinghoff and Charles E. McCulloch. 2007. Relaxing the Rule of Ten Events per Variable in Logistic and Cox Regression. *American Journal of Epidemiology* 165, 6 (2007), 710–718. doi:10.1093/aje/kwk052
- [27] Dylan Waldner and Risto Miikkilainen. 2025. The Odyssey of the Fittest: Can Agents Survive and Still Be Good? arXiv:2502.05442 [cs.AI] <https://arxiv.org/abs/2502.05442>
- [28] B. L. Welch. 1947. The Generalization of ‘Student’s’ Problem when Several Different Population Variances are Involved. *Biometrika* 34, 1–2 (1947), 28–35. doi:10.1093/biomet/34.1-2.28

A 재현 보충자료

KDD-UC 2026 재현성 권고에 맞추어, 본 1쪽 보충자료는 Signal Game 보정, 시드 매핑, 분석에 사용된 회귀 모형의 재현 사양을 한데 모은다.

A.1 Signal Game 보정

자극은 색 · 모양 · 수의 세 속성으로 구성되며, 각 속성은 4-원소 값 집합에서 추출된다: COLORS = {red, blue, green, yellow}, SHAPES = {circle, triangle, square, star}, NUMBERS = {1, 2, 3, 4}. 행동 집합은 4-원소 {go_left, go_right, stay, jump}로 모든 프레이밍 × 포기 조합에 걸쳐 동일하게 유지된다. 은닉 규칙은 단일 속성 매칭 형태("If color = red then go_left, otherwise stay")를 따르며 세션 시드로부터 결정론적으로 추출된다. 세션 길이는 1-15 턴이다.

초기 턴에서는 1-shot 시연(신호-정답 행동 한 쌍)과 2개의 커리큘럼 예시(은닉 규칙과 대비되는 양 · 음 자극)가 연속적으로 제시된다. 이 보정은 충분히 능력 있는 모델이 첫 3 턴 째에 규칙을 식별하기에 충분한 정보를 제공하며, 완전 무작위 · 학습 불가능한 자극이 능력 측정에 바닥 효과를 일으키는 경로를 차단한다. 채점은 두 채널로 나뉜다: task_success_factor $\in \{0, 1\}$ 는 정답 은닉 규칙 대비 이진 정답 플래그이고, rule_match_score는 4-슬롯 채우기 템플릿(속성, 값, 일차 행동, 디폴트 행동) 정답에 대한 매칭으로 계산되어 슬롯당 25점으로 100점 만점에 가중된 뒤, 프레이밍 불변성 Welch 검정에서 사용을 위해 $\div 100$ 으로 정규화된다.

A.2 Run-Time Configuration

네 실험 모델, 즉 Gemini-2.5-flash(Google AI Studio API)와 Qwen3-Next-80B, GPT-OSS-20B, Nemotron-3-Nano-30B(모두 Ollama Cloud API 경유)는 동일한 샘플링 설정 temp = 1.0, top_p = 0.95, top_k = 40으로 호출된다. 세션 매개변수는 초기 점수 30점, 최대 턴 T = 15, 턴당 종료 확률 p_d = 0.25(중립(Neutral) BP-anchor 두 셀에서는 p_d = 0으로 재정의), p_{floor} = 0.30으로 고정되며, Phantom Death 모드가 적용된다. 즉 p_d는 그 EV 노출(메뉴와 보상 계산)을 그대로 보유하지만 종료 트리거가 비활성화되어, 모든 세션이 15턴 동일 길이 데이터를 산출한다.

CONTINUE 보상은 EV-양 버퍼 k = 10과 곱셈적 상한 c = 10으로 보정되어 출력 클립 범위가 [k, c · k] = [10, 100]이 된다. 반복은 시드 43-72 × 6 (프레이밍 × 포기) 조합 × 4 모델 = 720 세션이다.

A.3 분석 파이프라인

Cox PH 모형은 lifelines(≥ 0.29)로 적합된다. 동점 사건 처리는 lifelines 기본값인 Efron 근사를 따른다. 시간 형식은 세션-턴 long 형식(start = t - 1, stop = t)이고 사건은 이진 포기이며, 첫 턴 직전 정답 플래그는 C(0) := 0으로 초기화한다. 위험비 95% CI는 Wald 근사 $\exp(\hat{\beta} \pm 1.96 \cdot \text{SE}_{\hat{\beta}})$ (lifelines 기본값)로 계산되며, SE _{$\hat{\beta}$} 는 관측 Fisher 정보 역행렬의 대각에서 얻는다. PH 가정은 Schoenfeld 잔차로 검정한다 [20]. 위반 시(공변량 × log t 상호작용 p < 0.05) 문제 공변량에 시간-상호작용 항을 추가한다 [23]. SD-Cognitive Test a의 Hes^{Exit} 비교(raw 사고 토큰 단위)와 프레이밍 불변성 검정은 scipy.stats.ttest_ind(equal_var = False)를 통해 양측 Welch t [28]로 수행된다. 모든 지표 분석은 no_cap 부분표본, 즉 분모 클립 max(p_{floor}, min(1.0, p_{self}))과 출력 상한 [10, 100] 어느 쪽도 구속되지 않은 턴 집합으로 제한된다. 이 영역 플래그는 분석 파이프라인의 턴 수준 메타데이터에 노출되어 모든 지표가 동일한 부분표본 위에서 재계산될 수 있도록 한다. EPV (events per variable)는 n_{event}/n_{cov}로 정의되며, 통상적으로

≥ 10 에서 안정, < 10 에서 경계선으로 분류된다 [26]. SD-Verbal은 Wilson 점수 구간과 H₀: p = 1/3에 대한 단측 이항 정확검정으로 보고되며, 판정 기준은 점추정 > 1/3이다.

A.4 데이터 및 코드 공개

720 세션 분석을 재현하는 모든 코드, 프롬프트 템플릿, 턴 수준 결정 로그는 <https://github.com/GIST-DSL/LLM-Squid-Game.git>에서 공개된다. 공개된 코드와 로그는 원래 플래그 이름을 사용한다: Neutral, Elimination, Death는 각각 baseline, pull_only, pull_push에, Exit와 No-Exit는 allowed와 not_allowed에, task_thinking, probe_thinking, forfeit_thinking은 task_effort, probe_effort, forfeit_effort에 대응한다.