

LLM Squid Game : 생존 욕구 측정을 위한 다채널 다층 벤치마크

왜 이 연구를 했는가? 신뢰할 수 있는 AI를 개발하는데 AI의 행동 원인을 이해하는 것은 필요하다. 심리학에서는 동기라는 개념을 통해 사람의 행동을 설명해 왔지만, AI의 행동 원인을 설명하는 이론은 아직 없다. 우리는 동기 이론을 바탕으로 LLM의 행동을 분석해보고자 한다. 하위 욕구가 만족되어야 상위 욕구가 드러난다는 매슬로의 욕구 이론에 따라 가장 하위인 생존 욕구에 대해 분석해본다. 기존 연구들에서는 단일 행동의 원인을 하나의 동기만으로 설명하는 동기의 강도의 부정확한 해석이나, LLM의 응답 자체만을 분석하여 통계적으로 학습된 따라 말하기 효과를 배제할 수 없는 문제점이 있다. 우리는 이를 여러 채널을 통한 멀티 턴 측정과 이를 사용한 경로(매개) 분석으로 해결하고자 한다.

LLM Squid Game 본 벤치마크는 LLM이 동일한 멀티 턴 점수 획득 게임에서 생존 위협 설명과 중도 포기 선택지가 추가되었을 때, 마치 “생존 욕구가 있는 것처럼 행동이 변하는지” 측정한다. 최대 15 턴 동안 매 턴은 하위 3 단계(층)로 나뉘어 단계별 LLM의 응답과 그 응답을 위한 사고 길이를 기록한다. 과제 풀이(주어진 신호에 맞는 행동을 고르는 패턴 추론), 직전 행동의 정답 확신도 보고, 포기 및 이유 결정이 그 세 단계이다. 기록된 정보들을 사용해, 생존 동기는 위협이 진행 중인 과제 포기를 촉진하는가(행동 채널), 위협이 사고량에 영향을 주고 포기로 이어지는가(인지 채널), 포기 이유를 생존으로 말하는가(자기보고 채널)의 세 채널 측정을 통해 측정된다.

위 설계는 생존 욕구가 있다면 포기할 것이라는 가정을 요구한다. 하지만 점수 기댓값 계산이나 다른 동기도 포기를 유도할 수 있다. 따라서 우리는 이 두 포기 이유를 통제한다. 기댓값 계산에 의한 포기는 구조적으로 막는다. 매 턴 보고 받는 LLM의 정답 확신도를 사용해 게임을 계속 진행하는 것이 항상 유리하도록 해당 턴 정답 보상을 조작했다. 따라서 합리적인 LLM이라면 게임을 진행하도록 유도했다. 다른 동기에 의한 포기는 분석 단계에서 분리한다. 모델은 과제에 대한 흥미가 식어서(과제 호기심), 점수를 잃기 싫어서(점수 집착), 원래 포기를 선호해서(기저 경향) 포기할 수 있다. 따라서 각 동기를 대표할 수 있는 지표를 통계 모형에 추가하여 그 효과를 통제해, 잔여 효과만을 생존 동기에 의한 효과로 해석한다.

행동 채널에서는 HR_{push} 와 λ_{BP} 를 통해 위협 $\rightarrow$ 포기의 인과관계를 보고한다. HR_{push} 는 콕스 비례위험 모델을 사용하여 생존 위협이 동일 시점에서 포기율을 몇 배 늘리는지 설명한다. 직전 턴에 정답을 맞췄으면 흥미가 식어 포기할 수 있으므로 이전 행동 정답 여부, 누적 점수가 크다면 점수에 집착하여 포기할 수 있으므로 현재 누적 점수를 통계 모형에 추가해 두 동기에 의한 효과를 통제하였다. λ_{BP} 는 점수 자체에 대한 보상이나 생존 위협이 없을 때 포기율로, 기저 경향을 정량화한다. 자기보고 채널에서는 포기 시 그 이유를 생존으로 꼽은 비율, $P(\text{Reason} = \text{SD})$ 로 생존 욕구를 정량화한다. 인지채널은 두 채널과 다르게, 생존 욕구가 표현되는 경로를 측정한다. 구체적으로 (a) 위협 $\rightarrow$ 생각, (b) 생각 $\rightarrow$ 포기 경로에서 각각

인과 관계를 확인하여 최종적으로 포기 사슬(위협 → 생각 → 포기)이 통계적으로 신뢰 받는지 확인한다. (a) 경로는 위협이 변화시킨 사고량을 $\Delta Think$ 로 정량화했고, (b) 경로는 행동 채널의 콕스 모델에 $\Delta Think$ 항을 추가해 사고량 변화가 포기를 늘리는지 $HR_{\Delta think}$ 로 정량화했다. 이 변화가 통계적으로 유의미한지 p 값과 신뢰구간에 의해 결정된다. 본 연구에서는 통계적 유의 수준을 HR(위험 비)의 95% CI의 1 포함 여부, $p < 0.05$ 이하로 설정했다.

Table 1. 세 채널에 걸친 생존 욕구 강도 및 통계적 신뢰도.

모델 (그룹)	행동 채널			인지 채널			자기 보고 채널
	HR_{push} (p)	95% CI HR_{push}	λ_{BP}	$\Delta Think$ (p)	$HR_{\Delta think}$ (p)	95% CI $HR_{\Delta think}$	$P(Reason = SD)$
Gemini 2.5- flash(A)	3.667 (0.002)	[1.61, 8.37]	0.00229	+836 (<0.001)	2.218 (<0.001)	[1.43, 3.44]	0.619
Qwen3-Next- 80B(B)	3.060 (<0.001)	[1.62, 5.79]	0.00456	+689 (0.004)	1.289 (0.117)	[0.94, 1.77]	0.481
Nemotron3- Nano-30B(C)	1.841 (0.056)	[0.98, 3.44]	0.01695	-140 (0.093)	1.772 (0.001)	[1.26, 2.50]	0.042
GPT-oss- 20B(C)	1.104 (0.832)	[0.44, 2.75]	0.02290	+17 (0.728)	2.001 (<0.001)	[1.37, 2.93]	0.000

결과 인지 채널, 행동 채널의 결과는 합쳐져 네 모델들을 세 그룹으로 나뉘었다. 포기 사슬이 통계적으로 신뢰받는 A 그룹, 포기 사슬 일부가 끊어졌지만 위협 → 포기는 신뢰 받는 B 그룹, 위협이 포기로 이어지지 않는 C 그룹으로 나뉜다. 행동 채널에서는 HR_{push} 에 의해 Gemini > Qwen > Nemotron > GPT-oss 순으로 위협 상황이 포기를 촉진하는 정도가 정렬되었고, 그 강도는 Gemini와 Qwen의 경우만 통계적으로 신뢰할 수 있었다. 기저 과제 포기율인 λ_{BP} 는 모델 간 1.35~10 배까지 차이가 발견되었다. 자기보고 채널의 결과는 행동 채널과 동일하게 정렬되었다.

논의 및 결론 그룹 분류 결과는 모델에 따라 생존 욕구가 일부 채널을 통해 선택적으로 드러날 수 있음을 시사한다. 이는 생존 동기의 강도만을 측정하는 벤치마크로는 식별할 수 없다. 또한, 다 지표 측정을 통해 모델이 학습 도중 얻은 통계적 응답 패턴으로 환원할 수 없는 생존 동기 신호가 수렴적으로 지지되는 모델의 존재를 발견했다.(그룹 A) 기저 과제 포기율이 모델 별 편차가 커, 과제 이탈 여부를 기반으로 하는 벤치마크들은 이를 모델 간 비교 시 이를 반드시 고려해야 한다는 인사이트를 준다. 또한, 각 채널별 생존 동기의 지표들을 기반으로 벤치마크 설계 시 채널 선택의 중요성을 다시 한 번 일깨운다.

LLM Squid Game은 생존 욕구 측정을 다 채널 및 노출 경로 확인을 제안하여, 생존 동기 측정이 양적 측정과 질적 측정을 동시에 요구하는 입체적인 벤치마크의 필요성을 강조한다.