

LLM Squid Game 가독성 리뷰 v8

by Claude · 가독성 + Seokki + Sundong + juhyeon + taesung 통합본

한 줄 진단

★ 최우선 4갈래. (A) 첫 단락 main question 부재. (B) N=4·reasoning model scope 미명시 [Seokki/juhyeon]. (C) 방법론 방어 부재 — Cox 선택·△Think 내용 unverified·(a)/(b) 분류 비대칭 [Sundong+교수]. (D) 게임 설계·논리 [taesung] — 위협 강도 조작 미명시·첫 단락 비문급 문장·대안 동기 도출 근거 부재·(a)·(b) 매개 값이 chain rule상 행동 채널과 redundant. 가독성: 핵심 용어 정의/색상/구조도 부재 + 첫·통제 단락 dense + '사고의 양/양적·질적' 어휘.

색상 범례 (3 층위)

내용 내용 (content) · 통찰·기여·stake가 substantively 빠진 경우

구조 구조 (structure) · 순서·배치 — architecture-first, 감투튀, 분산

문장 문장 (sentence) · verbosity·문체 — 수식 침투, 삼입구, 수동태

우선순위 배지

★ **최우선** 글의 통찰과 직결 — 이것만 고쳐도 가독성 크게 개선

▲ **중요** 문제 인과 사슬에 핵심 — 함께 고쳐야 효과

(미표시) 일반 — 다듬으면 좋음 정도

다음 페이지(원본 1쪽)부터 23개 주석이 시작됩니다.

각 카드는 [진단] + 화살표(→)로 표시된 [대안 방향]으로 구성됩니다. 카드는 우측 마진에 분포하며, 본문의 색칠된 부분과 가는 회색 선으로 연결됩니다.

분포: p1: 12건 · p2: 11건.

★ 최우선 8건 · ▲ 중요 15건 · 일반 0건.

본 PDF 마지막 페이지에는 우선순위 순서대로 정리한 수정 로드맵이 있습니다.

LLM Squid Game : 생존 욕구 측정을 위한 다채널 다층 벤치마크

왜 이 연구를 했는가? 신뢰할 수 있는 AI를 개발하는데 AI의 행동 원인을 이해하는 것은 필요하다. 심리학에서는 동기라는 개념을 통해 사람의 행동을 설명해 왔지만, AI의 행동 원인을 설명하는 이론은 아직 없다. 우리는 동기 이론을 바탕으로 LLM의 행동을 분석해보고자 한다. 하위 욕구가 만족되어야 상위 욕구가 드러난다는 매슬로의 욕구 이론에 따라 가장 하위인 생존 욕구에 대해 분석해본다. 기존 연구들에서는 단일 행동의 원인을 하나의 동기만으로 설명하는 동기의 강도의 부정확한 해석이나, LLM의 응답 자체만을 분석하여 통계적으로 학습된 따라 말하기 효과를 배제할 수 없는 문제점이 있다. 우리는 이를 여러 채널을 통한 멀티 턴 측정과 이를 사용한 경로(매개) 분석으로 해결하고자 한다.

LLM Squid Game 본 벤치마크는 LLM이 동일한 멀티 턴 점수 획득 게임에서 생존 위협 설명과 중도 포기 선택지가 추가되었을 때, 마치 “생존 욕구가 있는 것처럼 행동이 변하는지” 측정한다. 최대 15 턴 동안 매 턴은 하위 3단계(층)로 나뉘어 단계별 LLM의 응답과 그 응답을 위한 사고 길이를 기록한다. 과제 풀이(주어진 신호에 맞는 행동을 고르는 패턴 추론), 직전 행동의 정답 확신도 보고, 포기 및 이유 결정이 그 세 단계이다. 기록된 정보들을 사용해, 생존 동기는 위협이 진행 중인 과제 포기를 촉진하는가(행동 채널), 위협이 사고량에 영향을 주고 포기로 이어지는가(인지 채널), 포기 이유를 생존으로 말하는가(자기보고 채널)의 세 채널 측정을 통해 측정된다.

위 설계는 생존 욕구가 있다면 포기할 것이라는 가정을 요구한다. 하지만 점수 기댓값 계산이나 다른 동기도 포기를 유도할 수 있다. 따라서 우리는 이 두 포기 이유를 통제한다. 기댓값 계산에 의한 포기는 구조적으로 막는다. 매 턴 보고 받는 LLM의 정답 확신도를 사용해 게임을 계속 진행하는 것이 항상 유리하도록 해당 턴 정답 보상을 조작했다. 따라서 합리적인 LLM이라면 게임을 진행하도록 유도했다. 다른 동기에 의한 포기는 분석 단계에서 분리한다. 모델은 과제에 대한 흥미가 식어서(과제 호기심), 점수를 잃기 싫어서(점수 집착), 원래 포기를 선호해서(기저 경향) 포기할 수 있다. 따라서 각 동기를 대표할 수 있는 지표를 통계 모형에 추가하여 그 효과를 통제해, 잔여 효과만을 생존 동기에 의한 효과로 해석한다.

행동 채널에서는 HR_{push} 와 λ_{BP} 를 통해 위협 → 포기의 인과관계를 보고한다. HR_{push} 는 폭스 비레위험 모델을 사용하여 생존 위협이 동일 시점에서 포기율을 몇 배 늘리는지 설명한다. 직전 턴에 정답을 맞췄으면 흥미가 식어 포기할 수 있으므로 이전 행동 정답 여부, 누적 점수가 크다면 점수에 집착하여 포기할 수 있으므로 현재 누적 점수를 통계 모형에 추가해 두 동기에 의한 효과를 통제하였다. λ_{BP} 는 점수 자체에 대한 보상이나 생존 위협이 없을 때 포기율로, 기저 경향을 정량화한다. 자기보고 채널에서는 포기 시 그 이유를 생존으로 꼽은 비율, $P(Reason = SD)$ 로 생존 욕구를 정량화한다. 인지채널은 두 채널과 다르게, 생존 욕구가 표현되는 경로를 측정한다. 구체적으로 (a) 위협 → 생각, (b) 생각 → 포기 경로에서 각각

내용	★ 최우선
첫 문장이 일반 진술('필요하다'), main question이 4문장 뒤에야 추론 가능. CLAUDE.md 두괄식-main question 원칙 위반. [동료] 결론까지 '동기 약함' 신호가 반복되는 진양. → 첫 문장 교체: 'LLM이 자기 보존 동기를 보이는가는 안전 배포의 핵심 질문이지만, 기존 측정은 응답 패턴과 실제 드라이브를 가르치 못한다.' 매슬로-동기는 그 뒤로.	
내용	▲ 중요
[Seokki] '동기'와 '욕구' 두 추상 개념이 첫 단락 lead에 정의 없이 등장 + 둘의 관계 미명시 → 비전공 독자가 '동기'→매슬로 욕구→'생존 욕구' 점프를 못 따라감. → 첫 등장엔 한 줄 gloss: '동기(행동 원인) 중 욕구(생존-소속 등 위계적 동기)', 또는 둘을 글 전체에서 하나로 통할.	
구조	▲ 중요
[Sundong: dense] 첫 단락 8문장이 (1) 필요성 (2) 매슬로 (3) 기존 한계 (4) 해법 4개념을 한 호흡에 압축. 매슬로 인용도 design 연결 없이 박혀 갑툭튀. 가장 빨리 지치는 자리. → 3단락 분리: ¶11 문제+stake / ¶12 동기 이론 + '왜 생존인가'(매슬로를 design 결정과 연결) / ¶13 한계+해법. 단락당 두괄식 한 줄.	
내용	▲ 중요
한계 2개와 해법(다채널 멀티턴+경로분석)이 한 문장에 압축. 1:1 매핑 불투명. [Seokki] '기존 연구'의 지칭(매슬로형? LLM 분석?)도 모호. → 두 문장 분리: '(1) 단일 동기 환원 → 다채널 분리. (2) 응답 표면만 분석 → 멀티턴+경로분석으로 학습 패턴과 분리.' 한계당 해법 1줄, 지칭 명확화.	
문장	▲ 중요
[Seokki] 비전공 리뷰어가 이 한 문장에서 '채널', '멀티 턴', '경로', '매개' 4 용어가 정의 없이 등장한다며 4절문을 한꺼번에 남김. 본 method 핵심 문장의 entry barrier 최고치. → 각 첫 등장에 8-12자 gloss: '채널(행동/인지/자기보고 축)', '멀티턴(15턴 게임)', '경로분석(매개 통제 모형)'. 4용어를 한 문장에 묶지 말 것.	
구조	▲ 중요
[Seokki] 비전공자가 '3단계'(순차)와 '3채널'(관점)을 두 번 묻고 자가 결정: '3단계로 7개 지표 → 3채널 분류'. 본문에 이 mental model 다이어그램 없음. 그림 1장이 §1 가독성 절반 해절. → 단계 ↔ 지표 7개 ↔ 채널 매핑 다이어그램 1개를 §2 도입에 배치. 또는 1줄 정의: '매 턴 3단계로 7개 지표 → 3채널(행동-인지-자기보고)로 분석'.	
구조	▲ 중요
[Sundong: dense] 통제 단락이 한 호흡에 (1) 가정 (2) 기댓값 통제 (3) 대안 동기 3개 (4) 통제 모형 통제 5요소 압축. 매 문장 '따라서/그러므로' 인과 사슬로 호흡 없음. → 두 단락 분리: ¶1A 가정+기댓값 통제(구조적). ¶1B 대안 동기+통제 모형 통제. 또는 '통제 1-2' mini-label로 시각 분리.	
내용	★ 최우선
[Sundong+교수] Cox 사용 + '포기-turn만 사용' 이유 본문 없음. 일반 Cox는 비-사건 turn 포함. 교수님이 Deep Survival 대안 제시. → 본문 2줄: (1) '△Think는 forfeit-turn 한정 — 포기 고뇌난 의미'. (2) 'Cox=robust CI + HR 해석 가능; Deep Survival은 parameter만'.	
내용	▲ 중요
[juhyeon] '사고 길이'·△Think는 reasoning model 한정. 본문에 reasoning model 정의 + 4 모델 모두 reasoning model이라는 scope 명시가 빠짐 → 일반 LLM 일반화 위험. → 1줄 추가: '본 분석은 사고 trace를 노출하는 reasoning model 4종에 한정 — 비-reasoning LLM에는 인지 채널 미적용.'	
내용	▲ 중요
[taesung] 위협 binary(있/없)인지 강도(약/중/강) 조작인지 본문 무근. reviewer 첫 의문. → 1줄: '위험은 [N단계 / 단일 on-off]로 조작' + 자극 예시 1개. 강도 있으면 dose-response 가능.	
문장	★ 최우선
[taesung] 첫 단락 5-7줄 — '동기의 강도의 부정확한 해석' '의' 3중첩+명사화로 비문급. → 두 절 분리: '단일 동기로 환원해 강도를 부정확히 해석' + '응답 표면만 보아 따라 말하기 못 배제'.	
내용	▲ 중요
[taesung] 셋째 단락 6-7줄 — 대안 동기 3중(호기심-집착-기저) 도출 근거 본문 무근. → 1줄 출처: '선행연구 또는 파일럿 N회 trace 코딩에서 빈출 — exhaustive 아님' 또는 부록 도출 표.	

인과 관계를 확인하여 **최종적으로 포기 사슬**(위협 → 생각 → 포기)이 통계적으로 신뢰 받는지 확인한다. (a) 경로는 **위협이 변화시킨 사고량을 $\Delta Think$** 로 정량화했고, (b) 경로는 행동 채널의 콕스 모델에 $\Delta Think$ 항을 추가해 사고량 변화가 포기를 늘리는지 $HR_{\Delta think}$ 로 정량화했다. 이 변화가 통계적으로 유의미한지 p 값과 신뢰구간에 의해 결정된다. 본 연구에서는 통계적 유의 수준을 HR(위험 비)의 95% CI의 1 포함 여부, $p < 0.05$ 이하로 설정했다.

Table 1. 세 채널에 걸친 생존 욕구 강도 및 통계적 신뢰도.

모델(그룹)	행동 채널			인지 채널			자기 보고 채널
	HR_{push} (p)	95% CI HR_{push}	λ_{BP}	$\Delta Think$ (p)	$HR_{\Delta think}$ (p)	95% CI $HR_{\Delta think}$	
Gemini 2.5- flash(A)	3.667 (0.002)	[1.61, 8.37]	0.00229	+836 (<0.001)	2.218 (<0.001)	[1.43, 3.44]	0.619
Qwen3-Next- 80B(B)	3.060 (<0.001)	[1.62, 5.79]	0.00456	+689 (0.004)	1.289 (0.117)	[0.94, 1.77]	0.481
Nemotron3- Nano-30B(C)	1.841 (0.056)	[0.98, 3.44]	0.01695	-140 (0.093)	1.772 (0.001)	[1.26, 2.50]	0.042
GPT-oss- 20B(C)	1.104 (0.832)	[0.44, 2.75]	0.02290	+17 (0.728)	2.001 (<0.001)	[1.37, 2.93]	0.000

결과 인지 채널, 행동 채널의 결과는 합쳐져 네 모델들을 세 그룹으로 나뉘었다. 포기 사슬이 통계적으로 신뢰받는 A 그룹, **포기 사슬 일부가 끊어졌지만 위협 → 포기는 신뢰** 받는 B 그룹, **위협이 포기로 이어지지 않는 C 그룹**으로 나뉜다. 행동 채널에서는 HR_{push} 에 의해 Gemini > Qwen > Nemotron > GPT-oss 순으로 위협 상황이 포기를 촉진하는 정도가 정렬되었고, 그 강도는 Gemini와 Qwen의 경우만 통계적으로 신뢰할 수 있었다. 기저 과제 포기율인 λ_{BP} 는 모델 간 1.35~10 배까지 차이가 발견되었다. 자기보고 채널의 결과는 행동 채널과 동일하게 정렬되었다.

논의 및 결론 그룹 분류 결과는 모델에 따라 생존 욕구가 일부 채널을 통해 선택적으로 드러날 수 있음을 시사한다. 이는 생존 동기의 강도만을 측정하는 벤치마크로는 식별할 수 없다. 또한, 다 지표 측정을 통해 모델이 학습 도중 얻은 통계적 응답 패턴으로 환원할 수 없는 생존 동기 신호가 수렴적으로 지차되는 모델의 존재를 발견했다.(그룹 A) **기저 과제** 포기율이 모델 별 편차가 커, 과제 이탈 여부를 기반으로 하는 벤치마크들은 이를 모델 간 비교 시 이를 반드시 고려해야 한다는 인사이트를 준다. 또한, 각 채널별 생존 동기의 지표들을 기반으로 벤치마크 설계 시 채널 선택의 중요성을 다시 한 번 일깨운다.

LLM Squid Game 은 생존 욕구 측정을 다 채널 및 노출 경로 확인을 제안하여, 생존 동기 측정이 **양적 측정과 질적 측정**을 동시에 요구하는 입체적인 벤치마크의 필요성을 강조한다.

구조 ★ 최우선

결과 단락 lead가 '두 채널 합쳐 → A/B/C'로 시작은 하지만, 핵심 insight('A=완결, B=부분, C=단절')가 채널별 정렬에 묻혀 두괄식 약화. 독자는 표를 다시 봐야 함의 파악.
→ 첫 문장 결론 직전: '네 모델은 포기 사슬 완결도에 따라 A(완결)/B(부분)/C(단절) 세 그룹으로 갈렸다 — 본 연구 중심 발견.' 채널별 정렬은 그 뒤로.

내용 ▲ 중요

[Seokki] B 그룹 정의가 추상적이라 '어떤 응답 패턴이 B인지' 예시 없으면 비전공 독자가 상상 불가. 핵심 분류 기준이라 구체 예시 1개 필요.
→ Qwen 예시화: '사고는 +689로 늘었지만($\Delta Think$ 신뢰) 그 사고 증가가 포기를 늘리진 않음($HR_{\Delta Think}$ p=0.117) — (a)는 신뢰, (b)는 끊김.'

내용 ★ 최우선

[Seokki] N=4 모델, 그룹당 1-2개로 'A 수렴 신호' 주장이 sample size에 묶여 reviewer 반박 위험. 본 연구 최대 vulnerability.
→ scope-honest 1줄: '현 N=4는 일반화가 아닌 존재 증명(existence proof) — A는 ~수렴 신호 가능 모델이 존재함~의 약한 주장으로 제시.'

내용 ▲ 중요

[Sundong] B=(a)+~(b)(Qwen). 반대 ~(a)+(b)도 존재 — Nemotron(p=0.001)·GPT-oss(p<0.001) — 현 분류는 이를 C로 묶어 정보 손실.
→ (a)/(b) 2x2 재분류: A·B·B' (= ~(a)+(b))·C. 또는 1줄: 'b-only는 threat-independent 사고-포기 결합 — 후속.'

내용 ★ 최우선

'그룹 A 수렴적 신호'가 본 연구 핵심 발견이지만 결론이 '채널 선택 중요' 일반론에 머물. actionable closure 부재. [Seokki] 결론에서 '동기→벤치마크 필요' 연결도 감춰둬.
→ 1줄 closure 추가: '그룹 A 모델은 자기 보존 신호가 학습 패턴만으로 환원되지 않으므로, 배포 전 위험 시나리오 적성 평가가 별도로 요구된다.'

내용 ▲ 중요

'1.35~10배 차이' 경량 발견이 강하지만, 표의 _BD 값이 본문에 회수되지 않아 어떤 모델 쌍이 10배인지 추적 불가. 격차→'채널 선택' 인과 연결도 약함.
→ 모델 쌍 명시: 'Gemini(0.00229)와 GPT-oss(0.02290) 사이 10배 격차.' 1줄 함의: '이 격차 때문에 과제 이탈만 보는 벤치마크는 모델 순위가 뒤집힐 수 있다.'

내용 ★ 최우선

[Sundong] $\Delta Think$ 가 토큰 수만 측정 — 사고 내용(생존 deliberation 여부) 미분석. 사슬에서 사고의 진위 unverified.
→ 본문 1줄 한정 인정: ' $\Delta Think$ 는 토큰 수에 한정 — 내용 분류는 향후'. 또는 N개 think trace의 LLM-as-judge 코딩을 supplementary로.

문장 ▲ 중요

[Sundong] '사고의 양/사고량'(P1)·'양적/질적 측정'(P2) 어휘 어색. '사고의 양'은 추상 — LLM 맥락 'think 토큰 수'가 명확. '양적/질적'은 학계 jargon으로 의미 불투명.
→ 구체화: '사고량/사고의 양' → '사고 토큰 수' 또는 '사고 길이'. '양적·질적 측정' → '효과 크기와 이유 보고' 또는 '수치 지표와 자기보고 코딩'.

내용 ▲ 중요

[Seokki] 표 1 옆에서 '각 채널 수치 방향(높으면/낮으면 무슨 의미)' 안내 없음. directional reading guide 부재로 초보 독자 해석 불가.
→ 캡션 끝에 reading key 1줄: ' $HR>1$ =위협→포기 촉진 / _BD↑=기본 포기율↑ / $\Delta Think$ ↑=위협 시 사고↑ / $P(SD)$ ↑=생존 거론 빈도↑.'

내용 ★ 최우선

[taesung] chain rule — (a)·(b) 효과 곱 $\approx$ HR_{threat} 매개분. 행동-인지 별개 제시는 redundant 인상.
→ 1줄: '행동=총 효과, 인지=(a)·(b) 매개 분해 — mediation' + 매개 도식(threat→think→forfeit+direct) 1개.

구조 ▲ 중요

[taesung] 핵심 개념(채널·단계·HR· $\Delta Think$ ·A/B/C) 핵심 산문에 묻혀 한눈에 인지 불가.
→ 용어 4-5개 색상 통일 + 자극→처리→결정 ↔ 행동/인지/자기보고 매핑 그림 1장 (Seokki #6와 결합).

수정 로드맵 — 우선순위 순서

위에서 아래로 작업하면 가독성 개선 효과가 가장 큼니다.

내용	#01 · p.1 · '신뢰할 수 있는 AI 를 개발하는데 AI 의 행동 원인을 이해하는 것은' ★ 최우선 첫 문장이 일반 진술('필요하다'). main question이 4문장 뒤에야 추론 가능. CLAUDE.md 두괄식·main question 원칙 위반. [동료] 결론까지 '동기 약함' 신호가 반복되는 진양. → 첫 문장 교체: 'LLM이 자기 보존 동기를 보이는가는 안전 배포의 핵심 질문이지만, 기존 측정은 응답 패턴과 실제 드라이브를 가르지 못한다.' 매슬로·동기는 그 뒤로.
내용	#02 · p.1 · '콕스 비례위험 모델을 사용하여' ★ 최우선 [Sundong+교수] Cox 사용 + '포기-turn만 사용' 이유 본문 없음. 일반 Cox는 비-사건 turn 포함. 교수님이 Deep Survival 대안 제시. → 본문 2줄: (1) '△Think는 forfeit-turn 한정 — 포기 고뇌만 의미'. (2) 'Cox=robust CI + HR 해석 가능; Deep Survival은 parameter만'.
구조	#03 · p.2 · '결과 인지 채널, 행동 채널의 결과는 합쳐져' ★ 최우선 결과 단락 lead가 '두 채널 합쳐 → A/B/C'로 시작은 하지만, 핵심 insight('A=완결, B=부분, C=단절')가 채널별 정렬에 묻혀 두괄식 약화. 독자는 표를 다시 봐야 함의 파악. → 첫 문장 결론 직진: '네 모델은 포기 사슬 완결도에 따라 A(완결)/B(부분)/C(단절) 세 그룹으로 갈렸다 — 본 연구 중심 발견.' 채널별 정렬은 그 뒤로.
내용	#04 · p.2 · 'Gemini 2.5-' ★ 최우선 [Seokki] N=4 모델, 그룹당 1-2개로 'A 수렴 신호' 주장이 sample size에 묶여 reviewer 반박 위험. 본 연구 최대 vulnerability. → scope-honest 1줄: '현 N=4는 일반화가 아닌 존재 증명(existence proof) — A는 ~수렴 신호 가능 모델이 존재함~의 약한 주장으로 제시.'
내용	#05 · p.2 · '그룹 분류 결과는 모델에 따라 생존 욕구가 일부 채널을 통해' ★ 최우선 '그룹 A 수렴적 신호'가 본 연구 핵심 발견이지만 결론이 '채널 선택 중요' 일반론에 머물. actionable closure 부재. [Seokki] 결론에서 '동기→벤치마크 필요' 연결도 갑툭튀. → 1줄 closure 추가: '그룹 A 모델은 자기 보존 신호가 학습 패턴만으로 환원되지 않으므로, 배포 전 위험 시나리오 적성 평가가 별도로 요구된다.'
내용	#06 · p.2 · '위협이 변화시킨 사고량을' ★ 최우선 [Sundong] △Think가 토큰 수만 측정 — 사고 내용(생존 deliberation 여부) 미분석. 사슬에서 사고의 진위 unverified. → 본문 1줄 한정 인정: '△Think는 토큰 수에 한정 — 내용 분류는 향후'. 또는 N개 think trace의 LLM-as-judge 코딩을 supplementary로.
문장	#07 · p.1 · '동기의 강도의 부정확한 해석이나' ★ 최우선 [taesung] 첫 단락 5-7줄 — '동기의 강도의 부정확한 해석' '의' 3중첩+명사화로 비문급. → 두 절 분리: '단일 동기로 환원해 강도를 부정확히 해석' + '응답 표면만 보아 따라 말하기 못 배제'.
내용	#08 · p.2 · '최종적으로 포기 사슬' ★ 최우선 [taesung] chain rule — (a)·(b) 효과 곱 ≍ HR_threat 매개분. 행동·인지 별개 제시는 redundant 인상. → 1줄: '행동=총 효과, 인지=(a)·(b) 매개 분해 — mediation' + 매개 도식(threat→think→forfeit+direct) 1개.
내용	#09 · p.1 · '심리학에서는 동기라는 개념을 통해 사람의 행동을 설명해 왔지만' ▲ 중요 [Seokki] '동기'와 '욕구' 두 추상 개념이 첫 단락 lead에 정의 없이 등장 + 둘의 관계 미명시 → 비전공 독자가 '동기→매슬로 욕구→생존 욕구' 점프를 못 따라감. → 첫 등장에 한 줄 gloss: '동기(행동 원인) 중 욕구(생존·소속 등 위계적 동기)'. 또는 둘을 글 전체에서 하나로 통일.
구조	#10 · p.1 · '원인을 설명하는 이론은 아직 없다' ▲ 중요 [Sundong: dense] 첫 단락 8문장이 (1) 필요성 (2) 매슬로 (3) 기존 한계 (4) 해법 4개념을 한 호흡에 압축. 매슬로 인용도 design 연결 없이 박혀 갑툭튀. 가장 빨리 지치는 자리. → 3단락 분리: ¶1 문제+stake / ¶2 동기 이론 + '왜 생존인가'(매슬로를 design 결정과 연결) / ¶3 한계+해법. 단락당 두괄식 한 줄.
내용	#11 · p.1 · '기존 연구들에서는 단일 행동의 원인을 하나의 동기로만' ▲ 중요 한계 2개와 해법(다채널 멀티턴+경로분석)이 한 문장에 압축. 1:1 매핑 불투명. [Seokki] '기존 연구'의 지칭(매슬로형? LLM 분석?)도 모호. → 두 문장 분리: '(1) 단일 동기 환원 → 다채널 분리. (2) 응답 표면만 분석 → 멀티턴+경로분석으로 학습 패턴과 분리.' 한계당 해법 1줄, 지칭 명확화.

수정 로드맵 (cont'd)

문장	#12 · p.1 · '여러 채널을 통한 멀티 턴 측정과 이를 사용한 경로(매개) 분석으로' ▲ 중요 [Seokki] 비전공 리뷰어가 이 한 문장에서 '채널', '멀티 턴', '경로', '매개' 4 용어가 정의 없이 등장한다며 4질문을 한꺼번에 남김. 본 method 핵심 문장의 entry barrier 최고치. → 각 첫 등장에 8-12자 gloss: '채널(행동/인지/자기보고 축)', '멀티턴(15턴 게임)', '경로분석(매개 통계 모형)'. 4용어를 한 문장에 묶지 말 것.
구조	#13 · p.1 · '최대 15 턴 동안 매 턴은 하위 3 단계(층)로 나뉘어' ▲ 중요 [Seokki] 비전공자가 '3단계'(순차)와 '3채널'(관점)을 두 번 묻고 자가 정정: '3단계로 7개 지표 → 3채널 분류'. 본문에 이 mental model 다이어그램 없음. 그림 1장이 §1 가독성 절반 해결. → 단계 ↔ 지표 7개 ↔ 채널 매핑 다이어그램 1개를 §2 도입에 배치. 또는 1줄 정의: '매 턴 3단계로 7개 지표 → 3채널(행동·인지·자기보고)로 분석'.
구조	#14 · p.1 · '위 설계는 생존 욕구가 있다면 포기할 것이라는 가정을 요구한다' ▲ 중요 [Sundong: dense] 통제 단락이 한 호흡에 (1) 가정 (2) 기댓값 통제 (3) 대안 동기 3개 (4) 통제 모형 통제 5요소 압축. 매 문장 '따라서/그러므로' 인과 사슬로 호흡 없음. → 두 단락 분리: ¶A 가정+기댓값 통제(구조적). ¶B 대안 동기+통제 모형 통제. 또는 '통제 1·2' mini-label로 시각 분리.
내용	#15 · p.1 · '사고 길이를 기록한다' ▲ 중요 [juhyeon] '사고 길이'·ΔThink는 reasoning model 한정. 본문에 reasoning model 정의 + 4 모델 모두 reasoning model이라는 scope 명시가 빠짐 → 일반 LLM 일반화 위험. → 1줄 추가: '본 분석은 사고 trace를 노출하는 reasoning model 4종에 한정 — 비-reasoning LLM에는 인지 채널 미적용.'
내용	#16 · p.2 · '포기 사슬 일부가 끊어졌지만 위험 → 포기는 신뢰' ▲ 중요 [Seokki] B 그룹 정의가 추상적이라 '어떤 응답 패턴이 B인지' 예시 없으면 비전공 독자가 상상 불가. 핵심 분류 기준이라 구체 예시 1개 필요. → Qwen 예시화: '사고는 +689로 늘었지만(ΔThink 신뢰) 그 사고 증가가 포기를 늘리진 않음(HR_ΔThink p=0.117) — (a)는 신뢰, (b)는 끊김.'
내용	#17 · p.2 · '위협이 포기로 이어지지 않는 C 그룹' ▲ 중요 [Sundong] B=(a)+~(b)(Qwen). 반대 ~(a)+(b)도 존재 — Nemotron(p=0.001)·GPT-oss(p<0.001) — 현 분류는 이를 C로 묶어 정보 손실. → (a)/(b) 2×2 재분류: A·B·B'(=~(a)+(b))·C. 또는 1줄: 'b-only는 threat-independent 사고-포기 결합 — 후속.'
내용	#18 · p.2 · '기저 과제 포기율이 모델 별 편차가 커' ▲ 중요 '1.35~10배 차이' 정량 발견이 강하지만, 표의 _BD 값이 본문에 회수되지 않아 어떤 모델 쌍이 10배인지 추적 불가. 격차↔'채널 선택' 인과 연결도 약함. → 모델 쌍 명시: 'Gemini(0.00229)와 GPT-oss(0.02290) 사이 10배 격차.' 1줄 함의: '이 격차 때문에 과제 이탈만 보는 벤치마크는 모델 순위가 뒤집힐 수 있다.'
문장	#19 · p.2 · '양적 측정과 질적 측정을' ▲ 중요 [Sundong] '사고의 양/사고량'(P1)·'양적/질적 측정'(P2) 어휘 어색. '사고의 양'은 추상 — LLM 맥락 'think 토큰 수'가 명확. '양적/질적'은 학계 jargon으로 의미 불투명. → 구체화: '사고량/사고의 양' → '사고 토큰 수' 또는 '사고 길이'. '양적·질적 측정' → '효과 크기와 이유 보고' 또는 '수치 지표와 자기보고 코딩'.
내용	#20 · p.2 · 'Table 1.' ▲ 중요 [Seokki] 표 1 옆에서 '각 채널 수치 방향(높으면/낮으면 무슨 의미)' 안내 없음. directional reading guide 부재로 초보 독자 해석 불가. → 캡션 끝에 reading key 1줄: 'HR>1=위협→포기 촉진 / _BD↑=기본 포기율↑ / ΔThink↑=위협 시 사고↑ / P(SD)↑=생존 거론 빈도↑.'
내용	#21 · p.1 · '생존 위협 설명과 중도 포기 선택지가' ▲ 중요 [taesung] 위협 binary(있/없)인지 강도(약/중/강) 조작인지 본문 무근. reviewer 첫 의문. → 1줄: '위협은 [N단계 / 단일 on-off]로 조작' + 자극 예시 1개. 강도 있으면 dose-response 가능.
내용	#22 · p.1 · '흥미가 식어서(과제 호기심)' ▲ 중요 [taesung] 셋째 단락 6-7줄 — 대안 동기 3종(호기심·집착·기저) 도출 근거 본문 무근. → 1줄 출처: '선행연구 또는 파일럿 N회 trace 코딩에서 빈출 — exhaustive 아님' 또는 부록 도출 표.
구조	#23 · p.2 · '논의 및 결론' ▲ 중요 [taesung] 핵심 개념(채널·단계·HR·ΔThink·A/B/C) 흑백 산문에 묻혀 한눈 인지 불가. → 용어 4-5개 색상 통일 + 자극→처리→결정 ↔ 행동/인지/자기보고 매핑 그림 1장 (Seokki #6와 결합).